КЛАССИЧЕСКОЕ УНИВЕРСИТЕТСКОЕ ИЗДАНИЕ

Серия основана в 2010 году

КЛАССИЧЕСКОЕ УНИВЕРСИТЕТСКОЕ ИЗДАНИЕ

Редакционный совет серии:

Председатель совета
ректор Белорусского
государственного университета
С. В. Абламейко

Члены совета:

А. В. Данильченко (зам. пред.), Н. Н. Герасимович (отв. секретарь),
М. А. Журавков, С. Н. Ходин, И. С. Ровдо, И. И. Пирожник,
В. В. Лысак, О. М. Самусевич, О. А. Ивашкевич (зам. пред.),
В. М. Анищик, П. А. Мандрик

БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ

В. В. Краснопрошин
Н. А. Лепешинский

ИССЛЕДОВАНИЕ ОПЕРАЦИЙ

Допущено
Министерством образования Республики Беларусь
в качестве учебного пособия для студентов
учреждений высшего образования по специальностям
«Прикладная математика», «Информатика»,
«Экономическая кибернетика»

МИНСК
БГУ
2013

УДК 519.8(075.8)
ББК 22.18я73-1
К78

Р е ц е н з е н т ы:
кафедра прикладной математики и экономической кибернетики
Белорусского государственного экономического университета
(заведующий кафедрой доктор экономических наук, доцент *Г. О. Читая*);
доктор физико-математических наук, профессор *Ю. Н. Сотсков*

Краснопрошин, В. В.

К78 Исследование операций : учеб. пособие / В. В. Краснопрошин, Н. А. Лепешинский. − Минск : БГУ, 2013. − 191 с. – (Классическое университетское издание).
ISBN 978-985-518-830-9.

Рассмотрены проблемы количественного обоснования решений по управлению целенаправленными процессами (операциями) в сложных системах. Детально проанализированы: методология исследования операций и возможности устранения различных типов информационной неопределенности; основные модели и методы линейного программирования, оптимизации на сетях, сетевого планирования, теории расписаний, теории массового обслуживания, решения задач управления запасами, теории игр.

Для студентов учреждений высшего образования, обучающихся по специальностям «Прикладная математика», «Информатика», «Экономическая кибернетика».

УДК 519.8(075.8)
ББК 22.18я73-1

© Краснопрошин В. В.,
Лепешинский Н. А., 2013
© БГУ, 2013

ISBN 978-985-518-830-9

Уважаемые читатели!

Серия «Классическое университетское издание» была основана в 2010 году к 90-летию Белорусского государственного университета. Путь, который прошло наше учебное заведение в своем развитии, свидетельствует о становлении в нем собственной академической и научной традиции. Несомненно, опыт и знания, аккумулированные в стенах БГУ, являются не только предметом нашей гордости, но и достоянием всего белорусского общества. Одна из целей предлагаемой серии — сделать это достояние как можно более открытым и доступным.

Белорусский государственный университет всегда славился академичностью и фундаментальностью в подготовке специалистов. Однако сегодня этого уже недостаточно. От выпускника требуется умение быстро включаться в непосредственную практическую работу, которой свойствен синтез нескольких форм деятельности: собственно производственной, исследовательской, проектно-разработческой. В выигрыше в конечном итоге окажется тот, кто сегодня научится более эффективно создавать и применять знания, оперативно изменять технологии, совершенствовать и радикально трансформировать накопленный опыт. Вот почему совмещение преимуществ фундаментального и прагматического образования стало основой инновационно ориентированной подготовки будущих специалистов в нашем университете.

Серия отражает многолетний опыт научно-педагогической, методической и издательской работы БГУ. Ее цель — представить модель учебного текста, которая в своей структуре содержит набор программ образовательно-научно-производственной деятельности будущих специалистов. Реализация этой модели позволит обеспечить

универсализм выпускника, его способность к эффективному решению важных задач, стоящих перед Республикой Беларусь на национальном и международном уровне.

Классическое университетское издание, являя собой сплав научной и педагогической мысли, призвано формировать особую культуру знания — передового и доступного, теоретического и практического, общекультурного и специализированного. Словом, такого знания, которое будет работать.

Книги этой серии должны стать образцом научно-методического обеспечения современного образовательного процесса в высшей школе, утвердить ведущую роль нашего университета в качестве национального научно-методического центра Республики Беларусь.

Надеемся, что серия «Классическое университетское издание» состоится и как одно из слагаемых особой культурно-образовательной среды БГУ, которая будет способствовать интеллектуальному росту и творческой созидательной деятельности наших студентов.

Ректор Белорусского
государственного университета
академик НАН Беларуси, профессор *С. В. Абламейко*

ПРЕДИСЛОВИЕ

Исследование операций – прикладная математическая дисциплина, рассматривающая количественное обоснование решений по управлению целенаправленными процессами (операциями) в сложных системах. Ее составляющими являются: построение математических моделей принятия наилучших (оптимальных) решений, разработка математических методов получения таких решений для различных типов исходной числовой информации, использование полученных результатов в реальных ситуациях.

Происхождение термина «исследование операций» (operations research) обусловлено исторически. Первые работы в этой области были выполнены в период Второй мировой войны для планирования боевых вылетов (операций) авиации США, дислоцированной в Англии. Достигнутые успехи и соответствующие публикации стали импульсом для интенсивного использования приемов и методов исследования операций при управлении самыми разнообразными сложными техническими и экономическими системами (технологическими процессами, предприятиями, отраслями экономики и т. д.). Развитию этой науки и использованию теоретических результатов на практике в значительной степени способствовало появление и быстрое развитие компьютерных технологий.

Математические модели и методы оптимизации, которые в настоящее время относят к исследованию операций, изучались многими математиками, инженерами и экономистами еще в XIX в. Однако роль таких моделей, разнообразие и возможности использования на практике в полной мере проявились только в рамках дисциплины «Исследование операций».

В Беларуси исследование операций начало развиваться в 1960-е гг. Активность белорусских ученых в этом направлении демонстрирует тот факт, что в 1972 г. в Минске прошла Первая Всесоюзная конференция по исследованию операций под председательством академика АН БССР Д. А. Супруненко.

Учебное пособие обобщает циклы лекций по исследованию операций в Белорусском государственном университете (проф. Н. А. Лепешинский, проф. В. В. Краснопрошин, доц. А. Н. Исаченко), а также в Варминско-Мазурском университете г. Ольштына, Республика Польша (проф. Н. А. Лепешинский).

Излагая с единой научно-методологической позиции известные в исследовании операций результаты, авторы стремились подчеркнуть взаимосвязи моделей, методов и решений, предлагаемых в разных разделах этой науки. Именно поэтому в учебное пособие не были включены строгие математические, но, как правило, неконструктивные доказательства многих приведенных теорем. Основываясь на своем педагогическом опыте, авторы предлагают только те модели (из громадного их разнообразия), которые легко модифицируются и обобщаются. При специализации в области приня-

тия решений и для углубления знаний студенты могут найти в работах из приведенного списка литературы новые типы моделей, не включенные в текст доказательства утверждений, а также анализ конкретных практических ситуаций. В список включены основные зарубежные (переводные) и отечественные издания по исследованию операций. К сожалению, последние два десятилетия книг, содержащих новые результаты, практически не издавалось.

Важным фактором, существенно повлиявшим на выбор материала для настоящего пособия, явилось то, что в соответствии с типовой программой «Исследование операций» в учебном плане изучению этой дисциплины предшествует освоение предмета «Методы оптимизации», поэтому в текст не включены, например, методы решения задач линейного программирования и некоторые другие темы, традиционно присутствующие в книгах по исследованию операций. По аналогичной причине в настоящее пособие не включен раздел по имитационному моделированию, который в учебном плане Белорусского государственного университета также выделен в отдельный предмет.

Учебное пособие в требуемом объеме содержит определения и необходимые математические факты. Однако предполагается, что студенты изучали хотя бы в течение одного семестра математический анализ, линейную алгебру и аналитическую геометрию, теорию вероятностей, введение в информатику.

Вопросы для самопроверки, приведенные в конце каждой темы, помогут студентам закрепить изученный материал.

Авторы признательны рецензентам: доктору физико-математических наук, профессору Ю. Н. Сотскову, доктору экономических наук Г. О. Читае, кандидату экономических наук, доценту Е. В. Крюк за замечания и рекомендации по улучшению содержания учебного пособия. Слова благодарности авторы адресуют О. Г. Кадуриной за техническую помощь в оформлении рукописи.

Авторы будут благодарны читателям, приславшим свои замечания и пожелания по адресу: krasnoproshin@bsu.by.

1. ВВЕДЕНИЕ В ИССЛЕДОВАНИЕ ОПЕРАЦИЙ

1.1. ПРЕДМЕТ ИССЛЕДОВАНИЯ ОПЕРАЦИЙ

Каждый дееспособный человек в любой момент может принимать решение – выбирать определенное целенаправленное действие из множества вариантов. Сознательно или интуитивно это решение основывается на информации об окружающей среде, на памяти о подобных ситуациях и на результатах действий, совершенных в таких случаях (т. е. на опыте).

В настоящее время из-за расширения мира ценностей людей, ускорения изменений в реальной действительности, роста числа возможных вариантов процесс принятия решения значительно усложняется. Это касается как решений отдельных индивидуумов, так и решений, связанных с управлением организациями и обусловливающих успех или неудачу множества людей, целых организаций и даже стран.

Современное предприятие или любая другая организация представляют собой сложную систему «человек – машина». Это может быть: промышленное предприятие или научно-производственное объединение, научно-исследовательский или опытно-конструкторский центр, комбинат бытовых услуг или транспортно-эксплуатационное агентство, т. е. самая различная по характеру деятельности организация производственной или непроизводственной сферы. Эффективность функционирования таких систем существенным образом зависит от качества организации управления.

Чтобы добиться высокого качества управления, современному руководителю уже не достаточно опыта, интуиции и организаторских способностей в традиционном их понимании. При формировании стратегических и тактических решений он вынужден учитывать многочисленные, нередко противоречивые соображения и опираться на сложные критерии оценки путей достижения цели. В связи с этим возникла необходимость в разработке различных компьютерных средств оказания помощи руководителю в понимании сути возникших проблем и нахождении путей для их решения. Такие средства получили название систем поддержки принятия решений (Decision Support Systems – DSS). Они включают базу данных, базу знаний, а также интерфейс пользователя. Естественно, что целью таких систем не является автоматическое принятие решений. Оказание руководителю помощи осуществляется благодаря информационной и вычислительной поддержке на всех этапах процесса принятия решений. Такие системы являются разновидностью информационных систем управления (Management Information Systems – MIS), но отличаются сферой компьютеризации управления и наличием базы знаний, т. е. базы моделей и вычислительных методов.

Создание систем поддержки принятия решений не возможно без организации исследований нетрадиционного междисциплинарного характера. Потребовалось объединить усилия специалистов различных научных профилей, унифицировать и согласовать информацию. Таким образом, возникла объективная необходимость в научной дисциплине, которая занималась бы проблемами создания базы моделей и методов как основы систем поддержки принятия решений. Именно такой дисциплиной и является исследование операций (ИСО).

В широком смысле ИСО можно определить как научный подход к решению задач организационного управления.

Сложность задач управления обусловлена многими причинами, главные из которых следующие:

- в отличие от чисто технических систем в них достаточно трудно предвидеть какие-либо случайные отклонения;
- практически невозможно провести предварительный эксперимент;
- при управлении, как правило, имеется много взаимосвязанных между собой факторов, влияющих на возможные варианты решений.

Например, при подготовке плана выпуска продукции конкретного предприятия необходимо учитывать многие факторы производственного и организационного характера. Это спрос на рынке, потребность в сырье, наличие оборотных средств, мощность оборудования, вероятность возникновения технических неполадок и т. д. Кроме того, различные подразделения предприятия могут преследовать противоречивые цели. Ответственность за принимаемые решения и административные полномочия, как правило, рассредоточены по различным структурам, а внешние экономические факторы содержат элементы неопределенности. Таким образом, проблема составления плана, который одновременно был бы и реальным, и экономически выгодным, является далеко не тривиальной задачей. Помимо этого, в любой организационной задаче всегда фигурирует человеческий фактор, который с трудом поддается изучению и количественному анализу.

Все эти обстоятельства привели в конечном счете к тому, что сфера организационного управления стала предметом изучения широкого спектра наук, и в том числе исследования операций.

В узком смысле ИСО представляет собой прикладную математическую дисциплину, которая занимается вопросами количественного обоснования решений по управлению целенаправленными процессами (операциями) в сложных системах.

В данном определении принципиально важными являются три ключевых момента.

1. Устанавливается объект исследования.

Предметом изучения является *решение в сложных системах*. Такими решениями могут быть выбор плана производства, расстановка сил, осуществляемые действия и т. д. Несмотря на содержательное разнообразие примеров, в них есть нечто общее: последствия принимаемых решений не могут быть достоверно предсказаны (из-за множества неуправляемых факторов), и действовать приходится в условиях существенной неопределенности.

2. Подчеркивается целенаправленность действий.

Система рассматривается с точки зрения целенаправленного управления. В анализируемой операции всегда выделяется субъект, который преследует вполне определенную цель (или цели) и стремится достичь ее с помощью своих решений.

При исследовании сложных систем понятие цели является центральным, определяющим. Само понятие *сложная система* неотделимо от цели. Система сама по себе не является простой или сложной, она представляется таковой с точки зрения поставленной цели.

3. Определяется метод исследования.

Обоснование должно носить количественный характер, т. е. исследование проводится с помощью математических моделей и методов. В принципе любая наука, изучая в каждый временной период реальные явления или процессы, исключает несущественные с ее точки зрения факторы – упрощает действительность, фактически исследуя модели этих явлений или процессов. Каждая наука развивается в первую очередь именно за счет включения в свои модели факторов, которые ранее считались несущественными. Специфика моделей ИСО, о которой будет идти речь далее, состоит прежде всего во включении в модель цели (или целей) управления. Это дает возможность находить не просто хорошие, а даже в определенном смысле оптимальные решения.

Теоретической основой ИСО, как и других наук, имеющих дело с организационным управлением, является кибернетика − наука об управлении в сложных динамических системах.

Под системой понимается упорядоченная совокупность материальных объектов, объединенных какими-либо связями (материальными, финансовыми, информационными и др.) и предназначенных для достижения определенных целей по возможности наилучшим образом. Тем самым подчеркивается единство трех основных составляющих понятий системы: элементов, связей, операций.

Таким образом, исследование операций – целостная научная дисциплина, которая изучает определенный класс моделей человеческой деятельности. Она представляет собой синтез неформальных (на этапе определения и постановки задач) и формализованных (математического аппарата на этапе анализа этих задач) методов.

Исследование операций предоставляет лицу, принимающему решение, научно обоснованный инструмент, помогающий выбрать лучшие стратегии. Однако, как и в повседневной жизни (для слесаря, хирурга или музыканта), результат применения инструмента зависит в конечном итоге от опыта и мастерства пользователя.

1.2. ВИДЫ МОДЕЛЕЙ, ПРИЕМЫ И ПРИНЦИПЫ МОДЕЛИРОВАНИЯ В ИСО

Моделирование в широком смысле означает замену исследуемой системы другой, в некотором роде аналогичной, системой, которая называется моделью, и проведение экспериментов с ней.

Выделяют четыре типа моделей: аналоговые, аналитические, имитационные, ситуационные.

Аналоговые модели строятся путем замены носителей свойств, выбранных исследователем, другими физическими носителями.

Примером может служить моделирование транспортных потоков с помощью гидравлических сетей или биологических систем с помощью электрических схем. Процессы разной физической природы часто проявляют сходство на уровне функциональных преобразований входных переменных в выходные.

Аналитические модели создаются путем замены материальных носителей основных свойств системы абстрактными, математическими символами и различными соотношениями между ними.

Например, аналитической моделью колебания маятника является определенное дифференциальное уравнение. График величины себестоимости продукта в зависимости от общей продукции или математическая функция, достаточно точно соответствующая этому графику, также являются аналитическими моделями.

Для построения аналитических моделей в организационном управлении необходимо прежде всего ответить на следующие три вопроса: чем управлять, при каких ограничениях управлять, для чего управлять?

Ответ на первый вопрос определяет, какой математический объект будет считаться решением задачи. Учет взаимосвязей этих объектов и ресурсов системы, т. е. условий управления, определяет множество допустимых решений. Наконец, ответом на третий вопрос будет определение критерия (или критериев) сравнения решений и выбор наилучшего в смысле этого критерия решения.

Например, при определении плана продукции предприятия на очередной период решение представляет собой вектор, элементами которого будут величины выпуска продуктов по их видам. Ограниченные производственные, финансовые, энергетические и другие ресурсы предприятия, а также состояние спроса определяют множество таких возможных векторов – допустимых решений. Из этого множества требуется выбрать вектор (решение), который, например, максимизирует прибыль предприятия в плановый период.

Другим примером аналитических моделей в организационном управлении могут быть транспортные сети. В данном случае допустимым решением будет множество путей в такой сети и величины транспортируемых товаров, обеспечивающих спрос в узлах потребления. Оптимальным будет решение, которое, например, минимизирует суммарные транспортные издержки.

Многие системы, особенно социально-экономические, нельзя описать аналитическими моделями. В этих случаях может быть полезным имитационное моделирование (ИМ), основой которого является имитационная модель.

Имитационная модель – это алгоритм (или компьютерная программа), реализующая поведение системы в зависимости от конкретного управляющего решения.

ИМ состоит из следующих этапов:

1. *Подготовительный*: постановка задачи, выбор критерия, анализ ограничений, подготовка данных, разработка компьютерной программы.

2. *Рабочий*: собственно моделирование путем генерирования случайных управляющих решений, т. е. многократное применение имитационной модели, оценка характеристик модели (проверка на чувствительность).

3. *Заключительный*: анализ и интеграция полученных результатов, подготовка рекомендаций для руководства и предложений по внедрению модели.

Важная составная часть ИМ – диалоговый режим (обмен информацией, использование опыта и интуиции, контроль). Необходимо при этом разработать сценарий и соответствующие программные и технические средства.

Недостатки имитационных моделей:

- ограниченная точность моделирования и трудность ее априорной оценки;
- отсутствие общности результатов, предоставляемых в распоряжение исследователя;

• высокая стоимость и продолжительность разработок моделей (из-за потребности в высококвалифицированных специалистах и уникальности задачи), а также многократное обращение к модели с соответствующими затратами машинного времени.

ИМ – важное и эффективное средство, но оно не заменяет теоретических исследований.

Ситуационное моделирование основано на предсказании процессов функционирования системы в виде последовательности отдельных ситуаций в определенные дискретные моменты времени. Совокупность ситуаций называется ситуационной моделью. К недостаткам такого моделирования относится некоторая статичность и невозможность учета альтернативных вариантов поведения ее элементов.

Объединение имитационной и ситуационной моделей называется деловой игрой и чаще всего используется для обучения.

При выборе (построении) моделей ИСО предлагает некоторые принципы:

• целенаправленность моделей: выбирать модель необходимо в строгом соответствии с целями исследования, так как модель, хорошая для одних целей, может оказаться плохой для других;

• нейтральность модели: процессы, происходящие в модели, не должны воздействовать на функционирование изучаемой системы;

• необходимость согласования точности моделирования различных элементов системы и устойчивости решения при изменениях параметров модели. Бессмысленно описывать одни элементы точно и громоздко, другие грубо, с большими погрешностями.

К настоящему времени в ИСО сложились определенные приемы моделирования в зависимости от сложности исследуемой системы:

1. При моделировании системы простой структуры необходимо попытаться выразить и исследовать явную зависимость между целью и параметрами управления (*формализация связи*).

2. Для систем сложной структуры целесообразно заменить ее на аналогичную (по части свойств), но более простую систему (*упрощение*).

3. Определение неизвестных параметров или вариантов структуры осуществляется при помощи дополнительных экспериментов (*идентификация модели*).

4. В случае систем неизвестной структуры можно построить гипотетическую структуру, анализируя данные, описывающие ее функционирование (*восстановление структуры по наблюдениям*).

5. Если нельзя применить вышеописанные приемы, возможно построение имитационных и ситуационных моделей с их последующей эволюцией, постоянным усложнением моделей, имитирующих систему (*имитация с эволюцией*).

1.3. ТИПОВЫЕ ЭТАПЫ ОПЕРАЦИОННЫХ ИССЛЕДОВАНИЙ

Каждый научный метод представляет собой циклический процесс, посредством которого человечество приобретает знания на основе опыта. Основной цикл научного метода можно разделить на три шага: индукция, дедукция и верификация (опыт). Индукция – это шаг, который приводит ученого от наблюдений к созданию теории. Ког-

да теория точно сформулирована, становится возможным применение аппарата логики и математики для получения следствий (дедукция). Наконец, как только в теории выведено некоторое количество нетривиальных выводов, их нужно верифицировать (испытать), сопоставляя с известными фактами, либо спланировать очередные наблюдения и эксперименты для предсказания новых явлений. Все это относится и к исследованию операций.

Главной особенностью операционной методологии является то, что поиск оптимального управляющего решения, как правило, предлагает построение математической модели и использование для ее анализа математического аппарата. Каждое операционное исследование содержит несколько типовых этапов: постановка задачи и разработка концептуальной модели; разработка математической модели; сбор необходимой входной информации; выбор (разработка) метода и алгоритма решения математической задачи, полученной по модели; проверка адекватности и корректировка модели; поиск решения на модели; реализация найденного решения на практике.

Отметим, что негативный результат после выполнения каждого из этапов приводит к необходимости возврата к предыдущему или даже к первому этапу.

Рассмотрим каждый из этапов подробнее.

Постановка задачи и разработка концептуальной модели. Это важный и ответственный этап операционного исследования. Недаром говорят, что правильно поставить задачу – наполовину ее решить. Первоначально задачу операционного исследования формулирует субъект, в чьих интересах проводится операционное исследование. На практике таковым является заказчик (руководство фирмы, организации и т. п.). Как правило, постановка задачи имеет общий характер, например: исследовать организацию системы снабжения или основного производства, сделать заключение о ее состоянии и разработать конкретные рекомендации относительно улучшения концепции.

Для проведения исследований создается операционная группа из системных аналитиков, специалистов предметной области, к которой относится система, социологов, психологов и т. п. Операционная группа детально обследует соответствующую систему, изучает информационные и материальные потоки в ней, ее связи с внешней средой. Одновременно изучается организация подсистемы управления, а также показатели качества или критерии эффективности функционирования системы и внешние факторы, которые влияют на эти характеристики.

После сбора данных проводится их подробный анализ, по итогам которого описывается цель (цели) системы и ее структура, выявляются факторы, существенно влияющие на результаты ее функционирования, а также несущественные факторы, которыми можно пренебречь в данном исследовании.

Проводятся неоднократные консультации, в ходе которых уточняется постановка задачи. В случае неоходимости, проводится дополнительное обследование организационной системы в целях выявления неучтенных факторов и их взаимосвязей. По возможности определяются структурные категории системы (детерминированность, стохастичность, статичность, динамичность, линейность, нелинейность).

Результатом этого этапа является концептуальная модель исследуемой системы (задачи). В ней подробно описывается состав системы, ее компоненты и их взаимосвязи, контролируемые и неконтролируемые внешние факторы, перечень основных показателей функционирования системы, перечень стратегий управления, которые надо определить в результате решения поставленной задачи.

Построение модели. После получения концептуальной модели системы (содержательной постановки задачи) переходят к построению математической модели. Этот процесс называется формализацией задачи.

Наиболее общей моделью управляемой системы является так называемый черный ящик, т. е. устройство, в котором можно влиять на входы и наблюдать выходы (рис. 1.1).

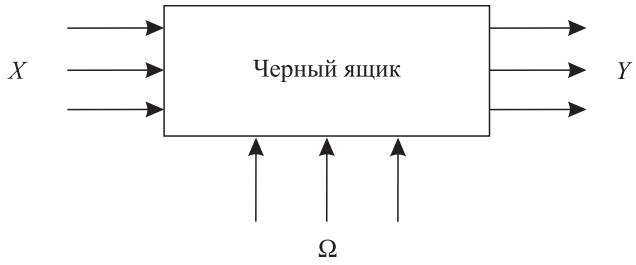

Рис. 1.1. Модель «черный ящик»

Входы (X, Ω) описывают возможные управляющие воздействия на систему, выходы Y – результаты этих воздействий. Описание функционирования черного ящика (моделирование) сводится к установлению соответствия между входами X и выходами Y в зависимости от внешних факторов Ω, также воздействующих на систему.

В сравнительно простых управляющих системах множество Ω определяется только числовыми параметрами. В других случаях на состояние системы влияют внешние возмущения, для которых требуется установить множество значений и/или их вероятностные характеристики.

В сложных системах множество Ω – это неконтролируемые, ненаблюдаемые переменные, и подчас исследователь даже не знает об их существовании. Именно их наличие приводит к неоднозначности: на одни и те же входные воздействия система дает различные значения выходов.

Принцип черного ящика позволяет определить реакцию системы на управление X по наблюдению выходов Y. Тогда зависимость $Y(X, \Omega)$ представляет собой модель системы на макроуровне. Возникает вопрос: как определить эту зависимость?

Существуют два пути решения проблемы.

1. «Внутренний» путь. Некоторым образом пытаются «проникнуть» в механизм работы системы и проанализировать ее внутренние взаимодействия.

Несмотря на уникальность отдельной системы, можно исследовать некоторые часто встречающиеся типовые классы систем и, как следствие, построить соответствующие им типовые модели. В настоящее время наиболее изученными являются модели для задач распределения ресурсов, массового обслуживания, управления запасами, замены оборудования и др.

2. «Внешний» путь. Искомая зависимость восстанавливается (идентифицируется) без знакомства с внутренним устройством, а исключительно по наблюдениям за входом и выходом в процессе функционирования. Методы построения таких моделей дает теория идентификации.

После того как модель системы построена, необходимо перейти к построению модели операции.

На практике одни управляющие решения предпочтительнее других. В модели это отражается заданием так называемых функций полезности $f(Y)$ как отображения зна-

чений выходных переменных на естественно упорядоченное множество действительных чисел. Функция f – числовая характеристика качества принимаемого решения.

Рассмотрим некоторые типовые модели исследования операций.

Исторически первой моделью является модель условной оптимизации, в которой требуется определить числовые значения компонент вектора X, доставляющие максимум (или минимум) функции

$$f(X) \tag{1.1}$$

при условиях

$$g_i(X) \geq 0, \quad i = 1, 2, ..., m. \tag{1.2}$$

Если все функции $g_i(X)$ и целевая функция $f(X)$ линейны относительно каждой компоненты вектора X, получаются линейные модели. Если хотя бы одна из этих функций нелинейна относительно хотя бы одной компоненты вектора X, то говорят о нелинейной модели. Если к условиям (1.2) добавлены требования целочисленности компонент вектора X, то говорят о целочисленных моделях.

Особую группу моделей составляют модели комбинаторного типа. В этом случае в моделях условной оптимизации неизвестными объектами X являются комбинаторные объекты, например, перестановки элементов множества $N = \{1, 2, ..., n\}$. Именно на таких объектах определяется целевая функция и встает задача нахождения объекта, доставляющего минимум (максимум) этой функции.

Большая группа оптимизационных задач – модели на графах и сетях. Графы и сети – относительно новые математические объекты по сравнению, например, с функциями. Составляющим элементам графов (называемым вершинами и ребрами) могут быть приписаны определенные числовые значения, и естественным образом возникают задачи поиска определенных подграфов, например, с минимальной (или максимальной) суммой этих «весов».

Важными в исследовании операций являются разнообразные модели конфликтных ситуаций. Конфликт – это любая ситуация, когда решения принимают две (или более) стороны, заинтересованные в оптимальных для себя исходах. Математические модели таких ситуаций – игры. Для каждой игры уточняется понятие оптимальности, доказывается существование оптимальных исходов и разрабатываются методы их нахождения.

При постановке задачи ИСО, а также при построении модели важную роль играют экспертные оценки. Некоторые методы обработки этих оценок будут освещены в п. 1.4.

Сбор необходимой входной информации. Все решения, в том числе оптимальные, всегда принимаются на основе информации, которой располагает лицо, принимающее решение. Уже на этапе разработки концептуальной модели исследователи устанавливают, какие входные параметры состояния Ω системы влияют на допустимые решения, границы изменений этих параметров, их необходимую точность. Все входные числовые значения должны быть научно обоснованы. Часто это представляет собой достаточно трудоемкий процесс, требующий сложных расчетов. Например, установление так называемого коэффициента полных затрат продукции одной отрасли (допустим, электроэнергии) на производство единицы продукции другой отрасли (пусть тонны алюминия) требует, кроме экономического обоснования, сложных расчетов с использованием алгебры матриц. Необходимо также иметь в виду проблему актуализации данных при многократном и долгосрочном использовании разработанной модели.

Выбор метода и алгоритма решения. В зависимости от типа построенной математической модели и степени неопределенности входной информации сформировались различные разделы ИСО, в которых математики исследуют соответствующие задачи и предлагают методы их решения. Весьма обобщенно эти разделы можно представить как клетки приведенной таблицы.

Основные разделы исследования операций

Степень неопределенности информации	Вид модели								
	Модели условной оптимизации			Комбинаторная модель	Графовая модель	Модель массового обслуживания	Модель управления запасами	Модель конфликтной ситуации	...
	Линейная	Нелинейная	Целочисленная						
Полная определенность									...
Вероятностная информация									...
Нечеткая информация									...
Отсутствие информации	Экспертные оценки Имитационное моделирование								

– задачи изучены наиболее полно

– задачи малоизучены

– задачи изучены частично

– задачи не имеют смысла

Модели условной оптимизации для каждого вида информации в исследовании операций называются задачами математического программирования. Термин «программирование» в этом словосочетании имеет смысл «планирование» и непосредственно не имеет отношения к компьютерному программированию. Он означает выработку программы действий в определенной практической ситуации. В зависимости от свойств моделей условной оптимизации говорят о линейном, нелинейном, целочисленном программировании. Наиболее полно эти направления изучены для точных числовых параметров. Если такие параметры являются вероятностными, т. е. случайными числами с установленными законами распределения, или заданы приближенно, нечетко, например в виде числового отрезка, то изучение соответствующих задач еще не достигло стадии эффективных методов решения.

Комбинаторные модели в исследовании операций содержат конечное, но, как правило, настолько большое множество допустимых решений, что их перебор практически невозможен. Важным классом таких моделей являются задачи оптимального упорядочения, которые изучает теория расписаний. Для моделей массового обслуживания оптимизационные задачи до настоящего времени не изучены. Вычисляются только параметры возникающих очередей на обслуживание при различных законах распределения случайных величин, характеризующих входные данные. Модели конфликтных ситуаций для разных видов входных данных и варианты поведения участников конфликтов изучает теория игр.

Постановка каждой задачи исследования операций должна отражать знания лица, принимающего решения, о множестве допустимых решений и о критерии оптимальности. Если принятие решения происходит в наперед известном и неизменяющемся информационном состоянии, то говорят о статических задачах. Когда информационные состояния в ходе принятия решения изменяются, то задачи называются динамическими и решения целесообразно принимать поэтапно.

Если все числовые параметры математической модели однозначно определены и тем самым позволяют в принципе найти точное решение, то модель относится к классу детерминированных. Во многих смыслах менее точным описанием реальных условий являются вероятностные модели. Как правило, они позволяют сделать достаточно точный прогноз относительно ожидаемых средних значений искомых параметров на основе вероятностных законов распределения исходных данных. Еще больше неопределенности в модель вносится при задании входных данных в виде нечетких чисел. Дело в том, что каждое такое число определяется с помощью специальных функций принадлежности к определенным множествам и такие функции во многом субъективны, т. е. зависят от установок исследователя.

Приведенная выше таблица может иметь также третье измерение, например, в случае, если вместо одной целевой функции (1.1) вводится несколько. Вообще, целевыми функциями (критериями) называют такие показатели, которые, во-первых, характеризуют общую ценность решений таким образом, что у лица, принимающего решение, есть стремление получить по ним наиболее предпочтительные оценки, а не представлять их в виде ограничений, и, во-вторых, являются общими и измеримыми для всех допустимых решений. В этом случае говорят о многокритериальных задачах, или о задачах векторной (в пространстве критериев) оптимизации. Многокритериальность часто вносит дополнительную неопределенность (так называемая неопределенность целей), так как различные критерии, как правило, несовместимы друг с другом: решение, доставляющее максимум (или минимум) одной целевой функции, не является таковым для остальных. Некоторые методы преодоления такой неопределенности, имеющие в ИСО важное методологическое значение, будут изложены в п. 1.5.

Иногда представляет интерес одновременное рассмотрение семейства задач, в которых исходные данные зависят от числовых или векторных параметров. Тогда говорят о параметрическом программировании.

Проверка адекватности и корректировка модели. В сложных системах модель лишь упрощенно описывает реальный объект (или процесс), поэтому необходимо проводить проверку степени соответствия (или адекватности) модели реальному процессу. Сделать это можно путем сравнения выходных характеристик модели $Y_{\text{М}}$ или предвиденного поведения модели с фактическими характеристиками объекта $Y_{\text{О}}$ при изменении значений управляющих X и внешних факторов Ω, а также (по возможности) параметров системы в достаточно широком диапазоне.

В качестве меры адекватности модели выбирают некоторую меру близости между $Y_{\text{М}}$ и $Y_{\text{О}}$, например одну из следующих величин:

а) абсолютное отклонение $\varepsilon = |Y_{\text{М}} - Y_{\text{О}}| \le \varepsilon_{\text{доп}}$;

б) относительное отклонение $\delta = \left| \dfrac{Y_{\text{М}} - Y_{\text{О}}}{Y_{\text{О}}} \right| \cdot 100\ \% \le \delta_{\text{доп}}$;

в) вероятностная оценка $P\{\delta \le \delta_{\text{доп}}\} \ge P_0$,

где $\varepsilon_{\text{доп}}$ и $\delta_{\text{доп}}$ – допустимое отклонение, которое определяет заданную степень адекватности модели; P_0 – заданная величина вероятности выполнения неравенства $\delta \le \delta_{\text{доп}}$. Если величина ε превышает $\varepsilon_{\text{доп}}$, или δ превышает $\delta_{\text{доп}}$, или $P < P_0$, то это свидетельствует о том, что упущены некоторые важные факторы и модель требует корректировки.

Возможны корректировки концептуальной и математической моделей и, соответственно, метода решения.

Корректировка может потребовать проведения дополнительных исследований на объекте или набора необходимых данных, уточнения ряда переменных и структуры модели.

Можно выделить следующие варианты корректировок математической модели: расширение набора внешних факторов, управляющих переменных и выходных характеристик модели; переход от линейных зависимостей к нелинейным зависимостям или повышению степени нелинейности; расширение набора ограничений или их комбинаций.

Корректировка может повторяться многократно до тех пор, пока не будет достигнуто необходимое соответствие между выходными характеристиками объекта и модели.

Вместо корректировки концептуальной или математической модели возможна ее кардинальная замена, необходимость в которой обусловливается в конечном итоге прогрессом науки и техники. Ярким примером (правда не в ИСО) такой замены является переход от геоцентрической модели мира, разработанной во II в. до н. э. в Древней Греции и достаточно точно предсказывающей многие видимые астрономические явления, к гелиоцентрической модели, открытой Н. Коперником в середине XVI в.

Поиск решения на модели. После достижения удовлетворительного уровня адекватности модели применяют соответствующий метод или алгоритм для нахождения оптимального (или субоптимального) решения на математической модели. Это решение может принимать разные формы: аналитическую, численную или алгоритмическую (в виде набора процедур, правил и т. п.).

Важной составляющей при этом является проверка стабильности решения, или так называемый постоптимальный анализ. Он заключается в оценке влияния на решение небольших изменений входных параметров при многократном применении задачи и метода решения.

Реализация найденного решения на практике. Это один из важнейших этапов, завершающий операционное исследование. Внедрение в практику найденного на модели решения можно рассмотреть как самостоятельную задачу. Полученную на модели оптимальную стратегию управления необходимо представить в виде соответствующих инструкций и правил (что и как делать), которые были бы понятны административному персоналу данной организации и реализовались в производственных условиях.

1.4. ЭКСПЕРТНЫЕ ОЦЕНКИ ПРИ ПРИНЯТИИ РЕШЕНИЙ

Одним из главных методологических принципов ИСО как науки в широком смысле является принцип объединения формальных и неформальных методов анализа систем. Поэтому построение математических моделей (неформализованными методами) неотделимо от средств ее исследования (формализованными методами). Соответственно, необходимо организовать процесс принятия решений.

Важную роль в этом процессе отводят интуиции, опыту и знаниям исследователей системы, называемых экспертами. Эксперт в данном случае выступает в роли некоторого «прибора», который либо совершает предпочтительный выбор, либо устанавливает значение параметров и коэффициентов, либо логически связывает причину и

следствие. При этом основной целью является получение объективно обоснованной информации из совокупности индивидуальных мнений.

Работу с экспертом можно описать в виде следующей общей схемы:

• эксперту предъявляется некоторая гипотеза H, и он участвует в выборе множества признаков E, характеризующих эту гипотезу;

• на основании признаков E вычисляется некоторая оценка $P(H/E)$ (возможно, как вероятность, но не обязательно);

• эксперт определяет интервал, в котором может находиться оценка $P(H/E)$.

Экспертные оценки должны удовлетворять следующим требованиям:

• относительная стабильность во времени при неизменности множества E;

• возможность обобщения серии индивидуальных оценок при работе с группой экспертов;

• независимость оценок, полученных разными экспертами.

Рассмотрим пример способа получения экспертных оценок.

Одним из методов научного и технического прогнозирования для получения и обработки экспертных оценок является метод Дельфи.

В рамках этого метода разработана общая методология организации работы группы экспертов.

Процесс получения оценок состоит из следующих этапов:

1) формируется руководящая группа, ответственная за сбор и обработку выводов;

2) определяется количество и состав группы экспертов;

3) определяется общий показатель мнения группы (например, среднего от оценок отдельных экспертов) и показатель согласованности (обычно участок числовой оси, куда должны попадать значения отдельных оценок с вероятностью [0,25; 0,75]);

4) формулируется основной вопрос; он должен интерпретироваться однозначно и позволять экспертам давать ответ в количественной форме; одновременно составляется анкета с условиями проведения эксперимента;

5) проводится первый тур опроса;

6) анализируются ответы на предмет согласованности мнений, выявляются дополнительные факторы, которые необходимо учесть экспертам, чьи мнения не совпадают с большинством;

7) составляется и выдается экспертам дополнительная информация, и в связи с этим ставятся новые вопросы; «оригинальных» экспертов просят обосновать свои заключения;

8) проводится анализ ответов, и определяется необходимое количество повторений этапов 6) – 7);

9) корректируются полученные ответы;

10) обобщаются окончательные экспертные заключения и выдаются рекомендации по исследуемым вопросам.

При построении математической модели возможна ситуация, когда множество переменных $X = \{x_i\}$, $Y = \{y_j\}$ или множество числовых параметров $A = \{a_k\}$ слишком велико («проклятие размерности»). Тогда необходимо выбрать из имеющихся множеств только те переменные или параметры, которые существенно влияют на состояние системы и цель ее функционирования. Также при попытке сведения многокритериальной задачи к задаче с одним критерием необходимо определить значимость и вес каждого критерия. Очень часто возникает задача расположения элементов определенного

конечного множества в порядке их значимости и важности. Точнее, каждому элементу e множества E с n элементами нужно поставить в соответствие некоторое целое число $r(e)$, характеризующее значимость элемента. Число $r(e)$ называется рангом элемента e. Чем больше ранг, тем значимее элемент. Расположение элементов множества в порядке невозрастания их рангов называется ранжированным рядом.

Рассмотрим метод экспертных оценок на примере задачи построения ранжированного ряда.

На первом этапе проводится отбор экспертов из m кандидатов путем опроса мнения каждого эксперта о компетентности всех кандидатов, включая самого опрашиваемого. Компетентность оценивается коэффициентом компетентности $0 \le k \le 1$. В результате получаем матрицу $K = [k_{ij}]_{m\times m}$, элемент k_{ij} которой указывает коэффициент компетентности, присвоенный i-м кандидатом j-му кандидату. Затем для каждого j-го кандидата вычисляется средний коэффициент компетентности $k_j = \frac{1}{m}\sum_{i=1}^{m} k_{ij}$. Для формирования группы экспертов устанавливается порог компетентности $0 < \delta < 1$. Тогда j-й кандидат отбирается, если $k_j \ge \delta$.

Для оценки единодушия мнения экспертов коэффициенты компетентности k_{ij} рассматриваются как случайные числа из интервала [0,1]. Сумма оценок отклонений

$$D(k) = \frac{1}{m^2}\sum_{i=1}^{m}\sum_{j=1}^{m}(k_j - k_{ij})^2$$

принимается за величину, характеризующую совпадение мнения экспертов. Чем ближе $D(k)$ к нулю, тем более точно совпадают мнения экспертов.

При построении ранжированного ряда применяется метод непосредственного ранжирования или метод парных сравнений. Пусть имеется m отобранных экспертов и множество, состоящее из n элементов. Метод непосредственного ранжирования заключается в присваивании каждым экспертом различных рангов элементам множества: i-й эксперт присваивает j-му элементу ранг $r_{ij} \in \{1, 2, ..., n\}$. В случае если эксперт считает некоторые элементы равнозначными, то каждому из них присваивается ранг, равный среднему значению рангов, которые эксперт присвоил бы элементам при неравнозначности. Например, если имеется пять элементов и первый эксперт считает наиболее значимым первый элемент, второй, третий и четвертый – равнозначными и наименее значимым – пятый элемент, то $r_{11} = 5$, $r_{12} = r_{13} = r_{14} = 3$, $r_{15} = 1$. В любом случае при присвоении рангов должно соблюдаться условие

$$\sum_{j=1}^{n} r_{ij} = \frac{(n+1)n}{2}, \quad i = 1, 2, ..., m.$$

Далее вычисляется средний ранг каждого элемента $r_j = \frac{1}{m}\sum_{i=1}^{m} r_{ij}$, j = 1, 2, ..., n. Ранжированный ряд строится по невозрастанию средних рангов.

Для определения совпадения мнений экспертов вычисляется сумма оценок отклонений

$$D(r) = \frac{1}{mn}\sum_{i=1}^{m}\sum_{j=1}^{n}(r_j - r_{ij})^2.$$

Чем ближе $D(r)$ к нулю, тем более точно совпадают мнения экспертов.

Метод парных сравнений применяется, если часть экспертов затрудняется построить ранжированный ряд, но может оценить элементы по значимости попарно. Обозначим отношение предпочтения на множестве элементов $\{e_1, e_2, ..., e_n\}$ через $\succ$, отношение эквивалентности – через $\sim$. Каждый *i*-й эксперт строит $n \times n$-матрицу предпочтений $B^i = [b^i_{kj}]$, где

$$b^i_{kj} = \begin{cases} 1, & \text{если } e_k \succ e_j, \\ 0, & \text{если } e_k \sim e_j, \\ -1, & \text{если } e_k \prec e_j. \end{cases}$$

При составлении матрицы предпочтений необходимо соблюдать выполнение правила транзитивности для отношений предпочтения и эквивалентности: если $e_k \succ (\sim) e_j$ и $e_j \succ (\sim) e_l$, то $e_k \succ (\sim) e_l$.

Далее вычисляется усредненная матрица предпочтений $B = \frac{1}{m}\sum_{i=1}^{m} B^i$, элементы которой не обязательно равны 1, 0, –1. Поэтому матрица B преобразуется в матрицу $\overline{B} = \left[\overline{b}_{kj}\right]$ явных предпочтений по следующему правилу:

$$\overline{b}_{kj} = \begin{cases} 1, & \text{если } b_{kj} \geq \delta, \\ 0, & \text{если } b_{kj} < \delta, \\ -1, & \text{если } b_{kj} \leq -\delta. \end{cases}$$

Здесь $\delta > 0$ – порог, выбираемый из условия минимальности без нарушения правила транзитивности. По матрице $\overline{B}$ строится ранжированный ряд.

Для оценки единодушия экспертов применяется сумма оценок отклонений $D(b) = \frac{1}{mn^2}\sum_{i=1}^{m}\sum_{k=1}^{n}\sum_{j=1}^{n}(\overline{b}_{kj} - b^i_{kj})^2$. Чем ближе $D(b)$ к нулю, тем более точно совпадает мнение экспертов.

Если при использовании метода непосредственного ранжирования или метода парных сравнений единодушие экспертов не достигнуто, то либо повторяют опрос, либо состав экспертов изменяется.

При построении ранжированного ряда важным является также выбор отношения предпочтения каждого элемента относительно других. Именно этот выбор устанавливает частичный порядок элементов в рассматриваемом множестве.

Проиллюстрируем проблему следующим примером. Среди десяти учеников (x_i, i = 1, 2, ..., 10), оцениваемых по биологии, истории и математике, необходимо выбрать лучшего. Оценки учеников приведены в таблице:

Дисциплина	x_1	x_2	x_3	x_4	x_5	x_6	x_7	x_8	x_9	x_{10}
Биология	7	9	8	8	7	7	9	6	8	6
История	9	9	9	10	8	9	8	9	8	8
Математика	9	8	10	7	8	8	10	7	7	7

Рассмотрим следующие отношения предпочтения элементов множества $X = \{x_i\}$, оцениваемых с точки зрения *n* критериев f_i, которые необходимо максимизировать.

***O*₁.** Элемент x_k предпочтительней, чем элемент x_l тогда и только тогда, когда существует такое $r(r \in \{1,n\})$, что

$$f_r(x_k) > f_r(x_l)$$

и для остальных $f_p(p \neq r)$

$$f_p(x_k) \geq f_p(x_l).$$

Это так называемый принцип Парето.

***O*₂.** Элемент x_k предпочтительней, чем элемент x_l тогда и только тогда, когда

$$\sum_{r=1}^{n} f_r(x_k) > \sum_{r=1}^{n} f_r(x_l).$$

Это упорядочение соответствует значениям суммы критериев (может быть, средним таких сумм).

***O*₃.** Элемент x_k предпочтительней, чем элемент x_l тогда и только тогда, когда для определенных λ_r

$$\sum_{r=1}^{n} \lambda_r f_r(x_k) > \sum_{r=1}^{n} \lambda_r f_r(x_l).$$

Это упорядочение с учетом «веса» каждого критерия. Веса λ_r устанавливаются экспертами или лицом, принимающим решение (особенно после экспериментов с моделью).

Применим вышеперечисленные правила упорядочения для примера со сравнением оценок f_1, f_2, f_3 десяти учеников. Отношение предпочтения будем изображать с помощью схемы Хассе, в которой узлы представляют учеников, а стрелки соединяют узлы x_i и x_k по направлению от x_i к x_k, в случае если x_k предпочтительней, чем x_i. В целях упрощения рисунков опустим стрелки, связанные с транзитивностью.

Схема Хассе, построенная в соответствии с ***O*₁**, представлена на рис.1.2.

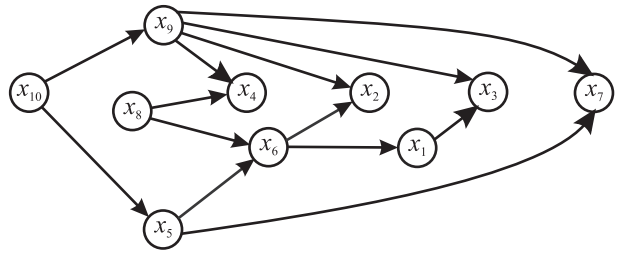

Рис. 1.2

Таким образом, ученики x_2, x_3, x_4, x_7 составляют множество лучших (это так называемое множество Парето).

Схема Хассе, построенная в соответствии с ***O*₂**, представлена на рис. 1.3.

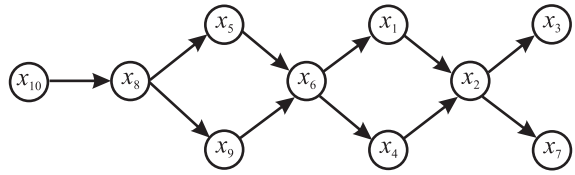

Рис. 1.3

Следовательно, делается вывод о том, что учеников x_3 и x_7 можно считать лучшими.

Установим «веса» предметов: история – 1, математика – 3, биология – 2. Схема Хассе, построенная в соответствии с $\boldsymbol{O_3}$, приведена на рис. 1.4.

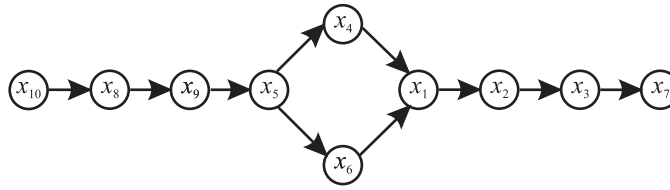

Рис. 1.4

По этому правилу лучшим будет ученик x_7.

Подобные схемы упорядочения элементов в зависимости от их «значимости» используются в самых разнообразных задачах классификации.

1.5. НЕОПРЕДЕЛЕННОСТЬ ЦЕЛЕЙ. МНОГОКРИТЕРИАЛЬНЫЕ ЗАДАЧИ

Многокритериальная задача оптимизации состоит в том, чтобы найти такие значения компонент вектора $X = (x_1, x_2, ..., x_r)$, для которых выполняются условия

$$g_j(X) \geq 0, \quad j = 1, 2, ..., m. \tag{1.3}$$

При этом целевые функции

$$f_1(X) \to \max(\min), \ f_2(X) \to \max(\min), ..., f_n(X) \to \max(\min).$$

Такое «механическое» обобщение задачи условной оптимизации (1.1), (1.2) является некорректным. Дело в том, что в случае если существует хотя бы одно решение, доставляющее требуемый экстремум одновременно всем целевым функциям, то фактически эти критерии эквивалентны между собой, т. е. неопределенности целей не существует и достаточно решать однокритериальную задачу. На практике таких случаев очень мало и возникает необходимость в уточнении самого понятия «оптимальное решение».

Пример 1.1. Конструктор самолета хотел бы спроектировать самый скоростной, самый надежный, самый дешевый и т. д. в своем классе авиалайнер. Такого в принципе добиться нельзя. Реальная конструкция – некоторый компромисс при сочетании требуемых качеств. В этом и состоит проблема оптимизации при неопределенности целей.

Существуют два основных подхода к ее решению: сведение к стандартным задачам с одним критерием и сужение неопределенности. Рассмотрим каждый из этих подходов, предполагая, что при условиях (1.3) все целевые функции требуется максимизировать.

Сведение к стандартной задаче с одним критерием. Существуют различные варианты реализации такого подхода.

Линейная свертка. Если все критерии измеряются по одной шкале, то строят обобщенный критерий вида

$$F(X) = \sum_{i=1}^{n} c_i f_i(X), \quad \sum_{i=1}^{n} c_i = 1,$$

где c_i – «веса» соответствующих критериев (положительные числа). Как правило, «веса» подбираются на основе оценок экспертов или экспериментально. Они отражают представление оперирующей стороны о важности каждого критерия.

Таким образом, проблема неопределенности целей сведена к задаче их ранжирования на основе экспертных оценок.

Использование контрольных показателей. Пусть экспертами установлены контрольные нормативные показатели f_i^*, $i = 1, ..., n,$ относительно которых критерии $f_i(X)$ должны удовлетворять условию:

$$f_i(X) \geq f_i^*, \quad i = 1, 2, ..., n. \tag{1.4}$$

Предположим, что среди функций f_i выделен основной критерий, например $f_1(X)$. Тогда снова приходим к однокритериальной задаче

$$f_1(X) \to \max$$

при дополнительных условиях (1.4) для $i = 2, ..., n$.

Введение метрики в пространство целевых функций. Предположим, решено n однокритериальных задач оптимизации соответственно с критериями

$$f_i(X) \to \max, \quad i = 1, 2, ..., n,$$

и для каждой i-й задачи определен вектор $\bar{X}_i$, доставляющий максимум критерию $f_i(X)$.

Векторы $\bar{X}_i$ в n-мерном пространстве критериев определяют точку $(\bar{f}_1, \bar{f}_2, ..., \bar{f}_n)$, где $\bar{f}_i = f_i(\bar{X}_i)$, которая называется абсолютным максимумом. Можно ввести расстояние от произвольной точки $\left(f_1(X), f_2(X), ..., f_n(X)\right)$ пространства критериев до абсолютного максимума, например, вычисляя стандартное евклидово расстояние

$$h(X) = \sqrt{\sum_{i=1}^{n} [f_i(X) - \bar{f}_i]^2}.$$

В качестве критерия теперь можно выбрать функцию

$$h(X) \to \min.$$

Полезность такого приема связана с установлением предельных возможностей для достижения точки абсолютного максимума.

Сужение неопределенности. Множества Парето

Другой подход к решению многокритериальных задач заключается в попытке сократить множество допустимых вариантов, т. е. исключить из формального анализа те варианты решений, которые являются заведомо плохими.

Предположим, что найдено допустимое решение-вектор X^* и существует некоторый другой вектор $\bar{X}$, при котором для всех критериев $f_i(X)$ выполняется условие

$$\begin{cases} f_i(\bar{X}) \leq f_i(X^*), \quad i = 1, 2, ..., n, \\ \text{причем хотя бы одно из неравенств строгое.} \end{cases} \tag{1.5}$$

Очевидно, что в этом случае вектор X^* предпочтительнее $\bar{X}$. Поэтому имеет смысл все векторы типа $\bar{X}$ исключить из рассмотрения и подвергать анализу только векторы, для которых выполняется условие (1.5).

Множество всех таких векторов X^* называют множеством Парето.

В теории принятия решений существует *принцип Парето*: в качестве решения следует выбирать вектор, который принадлежит множеству Парето. Таким образом, при использовании принципа Парето не выделяется единственное решение, а сужается множество возможных вариантов. Окончательный же выбор остается за лицом, принимающим решение.

В общем случае построение множества Парето не менее трудоемко, чем решение исходной задачи. Ниже приведем пример приближенного метода построения множества Парето.

Пусть имеется задача с двумя неизвестными и двумя критериями:

$$f_1(X) \to \max; \qquad f_2(X) \to \max, \ X \in G_x,$$

где область G_x определяется ограничениями (1.3).

Каждой допустимой точке $X \in G_x$ соответствует точка $\left(f_1(X),\ f_2(X)\right) \in G_f$ в плоскости критериев, т. е. область G_x отображается на область G_f, которая называется множеством достижимости. Сравнивая координаты точек из множества достижимости, находим те, для которых выполняются условия (1.5). Отображая найденные в области G_f точки на множество G_x, определим множество Парето. Например, пусть множество достижимости представлено графиком (рис. 1.5).

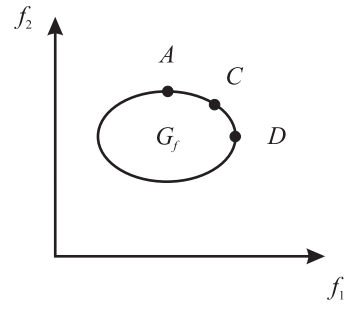

Рис. 1.5

Тогда множество Парето будет определяться лишь частью границы множества достижимости, в частности дугой ACD. Содержательно это означает, что надо ограничиваться теми решениями, для которых невозможно одновременное улучшение обоих критериев. Решения, соответствующие точкам на дуге ACD, несравнимы между собой по предпочтению. Для такого сравнения, т. е. для уменьшения неопределенности целей, необходима дополнительная информация типа: сколькими единицами выигрыша по одному критерию можно компенсировать проигрыш единицы по другому критерию?

Построение множества Парето сводится к последовательному решению задач математического программирования. Опишем одну из возможных схем.

Фиксируем некоторые желательные значения критериев f_1 и f_2:

$f_1 = C_1$ и $f_2 = C_2$ (значения C_1 и C_2 должны принадлежать множеству достижимости G_f).

После чего решаем две оптимизационные задачи:

1. $f_1(X) \to \max$, $X \in G_x$, $f_2(X) = C_2$;
2. $f_2(X) \to \max$, $X \in G_x$, $f_1(X) = C_1$.

В результате в плоскости критериев получаем точки *a* и *b* (рис. 1.6). Проведя через них прямую, строим простейшую аппроксимацию участка множества достижимости, определяющего приближение к множеству Парето.

Для уточнения полученной таким образом аппроксимации решаем задачи 3 и 4 для $C_3 > C_1$ и $C_4 > C_2$ и находим точки *c* и *d*, соответствующие элементам множества Парето (см. рис. 1.6).

3. $f_1(X) \to \max,\ X \in G_x,\ f_2(X) = C_4$;

4. $f_2(X) \to \max,\ X \in G_x,\ f_1(X) = C_3$.

Ломаная кривая *acdb* представляет следующее, более точное приближение. Часто подобной информации вполне хватает для решения практических задач.

Существует и другой способ аппроксимации множества Парето.

Пусть λ_1 и λ_2 – строго положительные числа, такие, что

$$\lambda_1 + \lambda_2 = 1. \tag{1.6}$$

Рассмотрим свертку

$$f' = \lambda_1 f_1(X) + \lambda_2 f_2(X)$$

и решим задачу математического программирования

$$f'(X) \to \max,\ X \in G_x.$$

Оказывается, что решение X^* этой задачи принадлежит множеству Парето, т. е. точка $(f_1 = f_1(X^*);\ f_2 = f_2(X^*))$ удовлетворяет условию (1.5). Поэтому аппроксимацию можно осуществить следующим образом.

Решаем задачу:

$$\lambda_1^{\alpha} f_1(X) + \lambda_2^{\alpha} f_2(X) \to \max, \quad X \in G_X, \tag{1.7}$$

где λ_1^{α} и λ_2^{α} удовлетворяют условию (1.6).

Решение задачи (1.6), (1.7) определяет некоторый вектор X_α, который в плоскости критериев определяет точку α с координатами $f_1 = f_1(X_\alpha);\ f_2 = f_2(X_\alpha)$. Выбирая новые значения $\lambda_1^{\beta},\ \lambda_2^{\beta}$, удовлетворяющие (1.6), подобным образом определим точку β (рис. 1.7) и т. д.

При использовании подобного рода построений возникает вопрос: можно ли построить любую точку Парето, задавая значения λ_1, λ_2? В общем случае ответ остается

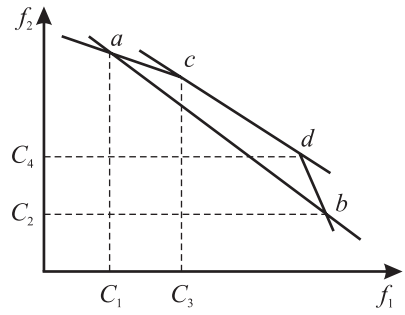

Рис. 1.6

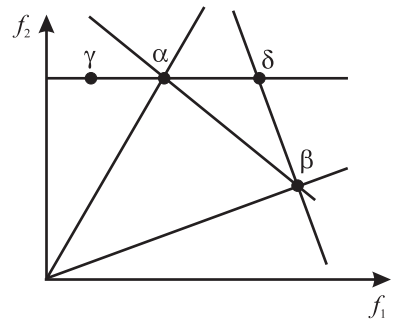

Рис. 1.7

открытым. Но он решается положительно, если G_x – выпуклый[1] многогранник, а критерии – линейные функции относительно всех переменных.

Если множество Парето выпукло, то, увеличивая количество точек по описанному выше алгоритму, можно построить многогранник, сколь угодно близко приближающий множество Парето. В иных случаях задача резко усложняется.

Теорема 1.1 (Карлина). Пусть X^0 – точка Парето для исходной многокритериальной задачи при условии, что все $f_i(X),\ i = 1, 2, ..., n,$ являются вогнутыми, а область G_x – невырожденной и выпуклой. Тогда существует такой вектор $\lambda(X^0) = (\lambda_1, ..., \lambda_n)$, что в линейной свертке

$$f = \sum_{i=1}^{n} \lambda_i f_i(X)$$

точка X^0 является точкой оптимума функции f, т. е.

$$f(X^0) \geq f(X)$$

для любых $X \in G_x$.

Существенно ограничивает число выбираемых решений из множества Парето метод *арбитражных решений*, предложенный Дж. Нэшем. В этом методе эксперты устанавливают некоторые минимально допустимые значения критериев f_i^0 $(i = 1, 2, ..., n)$, и далее решается задача максимизации

$$\prod_{i=1}^{n} \left(f_i(X) - f_i^0 \right)$$

при условиях (1.3).

1.6. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. Перечислите особенности организационного управления.
2. Охарактеризуйте объекты и методы исследования операций.
3. Охарактеризуйте типы моделей в научных исследованиях.
4. Опишите принципы моделирования в ИСО.

[1] Как известно, область какого-либо пространства называется выпуклой, если вместе с любыми двумя ее точками она содержит весь отрезок, соединяющий эти точки.

5. Что такое концептуальная модель исследуемой задачи?

6. Какая основная проблема возникает при описании системы в виде «черного ящика»?

7. Сформулируйте модель условной оптимизации.

8. Охарактеризуйте основные разделы исследования операций.

9. В чем суть проверки адекватности модели?

10. Перечислите этапы обработки экспертных оценок в методе Дельфи.

11. Опишите метод непосредственного ранжирования элементов конечного множества.

12. Опишите метод парных сравнений при ранжировании элементов конечного множества.

13. Сформулируйте принцип Парето в отношениях предпочтения для элементов множества, оцениваемых по нескольким критериям.

14. Опишите один из методов сведения многокритериальной задачи к однокритериальной.

15. Охарактеризуйте множество Парето для многокритериальных оптимизационных задач.

16. Опишите суть хотя бы одного приближенного метода построения множества Парето.

2. ЛИНЕЙНЫЕ МОДЕЛИ

2.1. УСЛОВИЯ ЛИНЕЙНОСТИ МОДЕЛИ ОПТИМИЗАЦИИ

Математическими моделями процессов управления организационно-экономическими системами очень часто являются задачи оптимизации функции многих переменных на множестве их возможных значений, т. е. задачи условной оптимизации. Исследование таких задач и методов их решения составляет содержание раздела прикладной математики, называемого математическим программированием.

Общая задача условной оптимизации может быть сформулирована следующим образом. Найти значения переменных $x_1, x_2, ..., x_n$, для которых выполняются условия

$$g_i(x_1, x_2, ..., x_n) \le (\ge) 0, \quad i = 1, 2, ..., m,$$

и для которых функция

$$f(x_1, x_2, ..., x_n)$$

достигает минимального (или максимального) значения.

С точки зрения математического анализа это задача определения условного экстремума функции многих переменных. Общего подхода, как для задачи на безусловный экстремум, в этом случае не существует. В зависимости от вида функций g_i и f, а также от свойств множества допустимых решений разработаны такие разделы математического программирования, как нелинейное программирование, выпуклое программирование, квадратичное программирование, линейное программирование и др. В каждом из таких разделов предлагаются свои методы решения.

Многие проблемы организационного управления или вообще задачи технико-экономического содержания успешно решаются с помощью линейных оптимизационных моделей, или, как их иначе называют, задач линейного программирования (ЛП). В этом словосочетании слово «линейное» характеризует вид всех формальных соотношений в математической модели, которая строится на основании содержательной постановки задачи.

Первым шагом в таком построении является установление множества так называемых управляемых переменных. Конкретные значения таких переменных могут быть вариантом управляющего решения.

В содержательной постановке задачи явно или неявно должны присутствовать два условия, приводящие к линейности модели: аддитивность и прямая пропорциональность.

Условие аддитивности. Если значение каждой управляемой переменной определено, то полное количество каждого из потребляемых ресурсов равно сумме одноименных ресурсов, затраченных на реализацию всех применяемых технологических процессов, а полная прибыль (или другая оценка) равна сумме прибылей от реализации всех процессов.

Условие прямой пропорциональности. Все показатели управляемого процесса могут быть увеличены или уменьшены при сохранении их взаимной пропорциональности. Например, себестоимость продукта должна прямо пропорционально зависеть от объема продукции. Естественно, что на практике это условие выполняется для сравнительно небольших плановых периодов. Это демонстрируют графики, представленные на рис. 2.1 и 2.2.

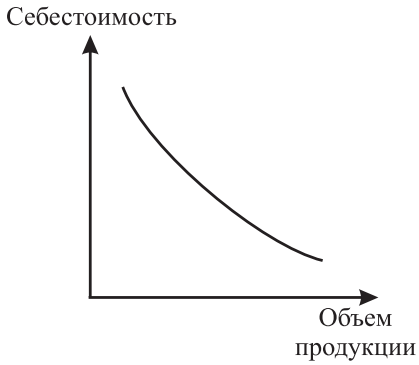

Рис. 2.1. Нелинейное изменение себестоимости на практике

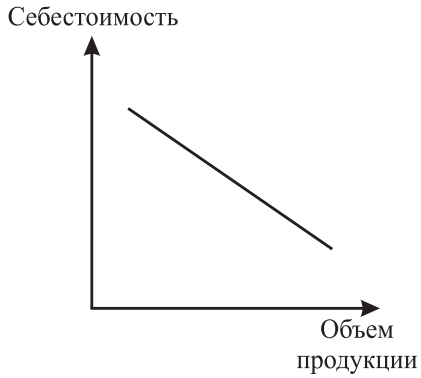

Рис. 2.2. Линейное изменение себестоимости в модели

Условия аддитивности и прямой пропорциональности обеспечивают линейность всех математических соотношений относительно каждой управляемой переменной в модели, т. е. любое приращение каждой переменной при постоянстве остальных переменных приводит к пропорциональному приращению всего соотношения.

Кроме того, в задачах линейного программирования предполагается, что каждая управляемая переменная как угодно делима.

Условие делимости. Числовое значение каждой управляемой переменной может быть любым рациональным числом.

Пример 2.1. План продукции.

В цехе производится два вида продукции A_1 и A_2. Каждый из этих видов должен пройти обработку на трех станках C_1, C_2, C_3. Известны затраты времени станков на производство единицы продукции каждого вида. Даны также общие ресурсы времени работы станков на очередной месяц. Установлено, что ожидаемая прибыль при реализации единицы продукции A_1 составляет 50 руб., а при реализации единицы продукции A_2 – 30 руб., но оговорено, что можно произвести не более чем 200 шт. продукции A_1.

Найти план продукции цеха на очередной месяц, при котором ожидаемая прибыль будет максимальной, если нормы затрат времени и ограничения на общие затраты времени представлены в следующей таблице:

Продукция	Станки		
	C_1	C_2	C_3
A_1	2	6	5
A_2	5	2	1
Временной ресурс, ч	1000	1600	2000

Построим математическую модель.

Управляемыми переменными будут значения x_1 и x_2 – количество продукции видов A_1 и A_2 соответственно на планируемый период. Будем считать, что выполняются условия аддитивности и прямой пропорциональности, хотя это явно не оговорено.

Естественно, что

$$x_1 \geq 0, \ x_2 \geq 0. \tag{2.1}$$

Общий затраченный временной ресурс для станка C_1 равен

$$2x_1 + 5x_2 \leq 1000; \tag{2.2}$$

для станка C_2:

$$6x_1 + 2x_2 \leq 1600; \tag{2.3}$$

для станка C_3:

$$5x_1 + x_2 \leq 2000. \tag{2.4}$$

Количество продукции A_1 ограничено:

$$x_1 \leq 200. \tag{2.5}$$

Других условий в содержательной постановке нет.

Вычислим значения ожидаемой прибыли при реализации всей продукции:

$$f = 50x_1 + 30x_2. \tag{2.6}$$

Таким образом, получим задачу линейного программирования: найти значения переменных $x_1 \geq 0$ и $x_2 \geq 0$, для которых выполняются условия (2.1)–(2.5) и при которых значение f в выражении (2.6) максимально.

Замечание. В задаче не выполнено условие делимости.

Пример 2.2. Общие задачи раздела ресурсов.

Понятие ресурсов часто используется в широком смысле, например, в промышленном производстве ресурсами можно считать как исходные материалы производственного процесса – сырье, энергия, станки, трудовые ресурсы и т. д., так и промежуточные продукты – детали, полуфабрикаты, узлы машин и т. д., а также конечные производимые продукты – сталь, машины и т. д.

Такой подход позволяет различать ресурсы, используемые в хозяйственной деятельности, и ресурсы производимые.

При анализе используемых ресурсов, которые обычно ограничены, главная проблема – такой их раздел, при котором они будут использованы наиболее эффективно. Критерием эффективности чаще всего будет доход, полученный при реализации производимых товаров.

В случае анализа производимых ресурсов основной проблемой является такой их раздел, при котором потребности в этих ресурсах будут удовлетворены при наиболее

экономной организации производства. Критерием эффективности в данном случае будет, как правило, стоимость производства таких ресурсов.

В итоге возникают две математические модели раздела ресурсов:

Модель раздела используемых ресурсов	Модель раздела производимых ресурсов
Расходуется m видов используемых ресурсов, известны величины их запасов $b_1, b_2, ..., b_m$. Производится n продуктов. Требуется найти такие объемы продукции $x_1 \geq 0, x_2 \geq 0, ..., x_n \geq 0$, для которых общий доход $f(x_1, x_2, ..., x_n)$ будет максимален при условиях, что общее использование каждого i-го вида ресурса $g_i(x_1, x_2, ..., x_n) \leq b_i,\ i = 1, 2, ..., m$	Известно, что требуется произвести m видов товаров в количествах, не меньших чем $b_1, b_2, ..., b_m$. В производстве можно использовать n производственных процессов. Пусть вектор $(x_1, x_2, ..., x_n)$ задает вариант производственного плана, в котором каждый элемент $x_j \geq 0$ означает интенсивность использования соответствующего j-го производственного процесса. Требуется найти такой вариант плана, для которого общая стоимость производства $f(x_1, x_2, ..., x_n)$ будет минимальна при условиях, что общее количество каждого i-го производимого товара $g_i(x_1, x_2, ..., x_n) \geq b_i,\ i = 1, 2, ..., m$

Понятно, что в любой из этих моделей должны быть описаны способы конкретизации вида функций

$$f(x_1, x_2, ..., x_n) \text{ и } g_i(x_1, x_2, ..., x_n),\ i = 1, 2, ..., m.$$

Пример 2.3. Задача о смесях (о рационе).

Общая постановка

Пусть задана дневная потребность какого-то животного в каких-то веществах (белках, жирах, углеводах, витаминах и т. д.), известно содержание этих веществ в единице имеющихся продуктов, а также цена каждого продукта.

Необходимо определить рацион, который обеспечивал бы дневную потребность в определенных веществах и вместе с тем был бы наиболее дешевым.

В состав дневного рациона питания должно входить не менее чем a_1 – первого вещества, не менее чем a_2 – второго вещества и т. д. Имеется n видов продуктов, и известно, что в единице j-го продукта содержится a_{ij} единиц i-го вещества, а также, что цена j-го продукта равна c_j. Обозначим через x_j количество единиц j-го продукта, который планируется ввести в рацион.

Понятно, что все $x_j \geq 0$ и при плане $x_1, ..., x_n$ дневное содержание i-го вещества составит $a_{i1}x_1 + ... + a_{in}x_n$ единиц, а так как оно должно удовлетворять минимальную дневную потребность, то

$$a_{i1}x_1 + ... + a_{in}x_n \geq a_i \quad i = 1, ..., m.$$

Целевая функция $f = c_1x_1 + ... + c_nx_n \to \min$.

Если предположить, что запас продуктов, из которых состоит рацион, ограничен, то на переменные накладываются ограничения

$$x_1 \leq b_1, ..., x_n \leq b_n, \text{ где } b_j - \text{величина запаса } j\text{-го продукта.}$$

В эту модель можно (и, как правило, нужно) вводить дополнительные условия, например соотношение (пропорции) между разными видами продуктов. Задача о диете с успехом используется при составлении наиболее дешевого рациона для откорма скота.

К описанной задаче сводятся так называемые задачи о смесях, т. е. задачи о составлении оптимальных в определенном смысле смесей из имеющихся веществ. К ним от-

носится, например, задача составления смесей нефтепродуктов, которые удовлетворяют соответствующим техническим требованиям и являются наиболее дешевыми.

Пример 2.4. Задача о рюкзаке при делимых (например, сыпучих) продуктах.

Собираясь в общежитие, студент хотел бы взять n продуктов, каждый продукт i массой a_i и «ценностью» (калорийностью, стоимостью) c_i. При этом известно, что в рюкзак (багажник) можно взять по массе не более чем A килограммов (при $\sum_{i=1}^{n} a_i > A$). Введем неизвестные x_i, означающие часть продукта i, которую студент может загрузить в рюкзак. Тогда задача будет состоять в определении таких значений x_i, $i = 1, 2, ..., n$, для которых выполнены условия

$$0 \le x_i \le 1, \quad i = 1, 2, ..., n,$$

$$\sum_{i=1}^{n} a_i x_i \le A,$$

для которых значение функции

$$\sum_{i=1}^{n} c_i x_i \quad \text{максимально.}$$

Легко видеть, что такая задача о рюкзаке имеет следующее решение. Найдем для всех i величины $\frac{c_i}{a_i}$ – как относительные ценности продуктов. Упорядочиваем величины $\frac{c_i}{a_i}$ по невозрастанию и загружаем рюкзак продуктами в соответствии с этим порядком до тех пор, пока оставшегося веса в рюкзаке будет недостаточно для загрузки всего очередного в установленной последовательности продукта. Определяем, какую часть этого продукта можем еще загрузить, а остальные продукты (к большому сожалению!) в рюкзак не помещаются.

Замечание. Если в рюкзак требуется сложить неделимые продукты (т. е. снимается условие делимости), то задача существенно усложняется, потому что неизвестные x_i должны вместо условия $0 \le x_i \le 1$ удовлетворять условию $x_i \in \{0,1\}$:

$x_i = 0$, если продукт не загружаем;

$x_i = 1$, если продукт загружаем в рюкзак.

В этом случае задача о рюкзаке становится задачей линейного целочисленного программирования. Интересно, что каждое допустимое решение этой задачи можно представить в виде двоичного слова длины n и общее количество допустимых решений будет равно 2^n.

2.2. ОБЩАЯ ЗАДАЧА ЛИНЕЙНОГО ПРОГРАММИРОВАНИЯ

Рассмотрим задачу линейного программирования в следующем общем виде.

Найти значения управляемых переменных $x_1, x_2, ..., x_n$, для которых выполняются ограничения

$$\sum_{j=1}^{n} a_{ij} x_j \le b_i, \quad i = 1, 2, ..., p; \tag{2.7}$$

$$\sum_{j=1}^{n} a_{ij} x_j \geq b_i, \quad i = p+1, p+2, ..., r; \tag{2.8}$$

$$\sum_{j=1}^{n} a_{ij} x_j = b_i, \quad i = r+1, r+2, ..., m; \tag{2.9}$$

$$x_j \geq 0, \quad j = 1, 2, ..., n_1, \quad n_1 \leq n, \tag{2.10}$$

и для которых функция

$$f = \sum_{j=1}^{n} c_j x_j \tag{2.11}$$

принимает максимальное или минимальное значение.

Конечно, в практических задачах ограничения типа $\leq, \geq, =$ не обязательно должны быть упорядочены так, как в этой общей модели. Все коэффициенты a_{ij}, c_j и свободные члены b_i в ограничениях (2.7)–(2.9) и в функции (2.11) являются рациональными числами. Функция (2.11) называется целевой функцией. На практике все значения b_i чаще всего неотрицательны. Каждый набор числовых значений $x_1, x_2, ..., x_n$, удовлетворяющий ограничениям (2.7)–(2.10), называется допустимым решением. Если допустимое решение доставляет максимум (или минимум) целевой функции f, то оно называется оптимальным.

Для анализа и применения какого-либо численного метода каждая конкретная задача сводится к равнозначной задаче в канонической, или стандартной, форме.

Каноническая форма содержит все ограничения только в виде равенств, причем требуется, чтобы все управляемые переменные и все свободные члены основных ограничений были неотрицательны.

Задачей ЛП в стандартной форме называется задача, в которой все ограничения являются неравенствами типа $\leq$ при максимизации целевой функции или все ограничения являются неравенствами типа $\geq$ при минимизации целевой функции и все управляемые переменные и все свободные члены основных ограничений должны быть неотрицательны.

Существуют простые приемы сведения конкретной задачи ЛП к канонической, или стандартной, форме:

а) если функция f должна принять максимальное значение, то функция

$$f_1 = (-1) f = -c_1 x_1 - c_2 x_2 - ... - c_n x_n$$

будет принимать минимальное значение;

б) если в системе основных ограничений какой-то свободный член $b_s \leq 0$, то соответствующее ограничение (неравенство или равенство) достаточно умножить на –1;

в) если неравенство типа $\leq$ среди основных ограничений требуется заменить на равенство, то в модель вводится новая, так называемая дополняющая, неотрицательная неизвестная переменная, которая прибавляется к левой части рассматриваемого неравенства, тем самым превращая его в равенство. В целевую функцию эта переменная входит с коэффициентом 0;

г) если неравенство типа $\geq$ среди основных ограничений требуется заменить на равенство, то в модель вводится новая неотрицательная неизвестная переменная, ко-

торая вычитается от левой части рассматриваемого неравенства, тем самым превращая его в равенство. В целевую функцию эта переменная входит с коэффициентом 0;

д) если в задаче ЛП имеются неизвестные с неопределенным знаком, то каждое из них можно заменить разностью двух неотрицательных переменных и ввести такую разность в модель. Например, вместо переменной x_j с неопределенным знаком необходимо во все соотношения модели ввести разность $x_j = x'_j - x''_j$ и ограничения $x'_j \geq 0,\ x''_j \geq 0$;

е) для анализа любой задачи ЛП удобно, если число основных ограничений m не больше чем число неизвестных n. Если в конкретной задаче $m > n$, то обычно рассматривают так называемую двойственную задачу.

Каноническая задача ЛП часто анализируется в векторно-матричной форме: определить вектор X, для которого выполняются ограничения

$$AX = \boldsymbol{b},$$

$$X \geq \mathbf{0}$$

и для которого

$$\boldsymbol{c}X \to \max(\min),$$

где $A = \begin{bmatrix} a_{11} & a_{12} & \ldots & a_{1n} \\ a_{21} & a_{22} & \ldots & a_{2n} \\ \ldots & \ldots & \ldots & \ldots \\ a_{m1} & a_{m2} & \ldots & a_{mn} \end{bmatrix}$ – матрица коэффициентов в основных ограничениях;

$\boldsymbol{b} = (b_1, b_2, \ldots, b_m)$ – вектор-столбец свободных членов в основных ограничениях; $X = (x_1, x_2, \ldots, x_n)$ – вектор-столбец управляемых переменных; $\boldsymbol{c} = (c_1, c_2, \ldots, c_m)$ – вектор-строка коэффициентов целевой функции; $\mathbf{0} = (0, 0, \ldots, 0)$ – вектор-столбец длиной n.

2.3. ГЕОМЕТРИЧЕСКАЯ ИНТЕРПРЕТАЦИЯ ЗАДАЧИ ЛИНЕЙНОГО ПРОГРАММИРОВАНИЯ С ДВУМЯ НЕИЗВЕСТНЫМИ

Пусть построена следующая задача ЛП.

Найти значения переменных x_1 и x_2, для которых выполняются следующие ограничения:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 \leq b_1, \\ a_{21}x_1 + a_{22}x_2 \leq b_2, \\ a_{31}x_1 + a_{32}x_2 \leq b_3, \\ \quad \ldots \quad \ldots \quad \ldots, \\ \quad \ldots \quad \ldots \quad \ldots \end{cases}$$

(любое из этих неравенств может быть вида $\geq$),

$$x_1 \geq 0,$$

$$x_2 \geq 0,$$

и для которых целевая функция

$$f = c_1x_1 + c_2x_2 \rightarrow \max(\min).$$

Такая модель имеет наглядную геометрическую интерпретацию непосредственно на плоскости. Дело в том, что каждое ограничение-неравенство на плоскости с прямоугольной евклидовой системой координат (x_1, x_2) определяет полуплоскость с границей-прямой, соответствующей равенству

$$a_{s1}x_1 + a_{s2}x_2 = b_s.$$

Когда существует пересечение всех полуплоскостей, соответствующих всем ограничениям-неравенствам (в том числе и условиям неотрицательности), то такое пересечение обязательно будет многоугольником, причем любые две точки этого многоугольника соединяются отрезком, целиком ему принадлежащим. Говорят, что получаем выпуклый многоугольник, который называется многоугольником допустимых решений (МДР). Среди бесконечного множества допустимых решений существует по крайней мере одно, доставляющее максимум (или минимум) целевой функции. Чтобы его найти, в нашей системе координат строим прямую, соответствующую уравнению

$$c_1x_1 + c_2x_2 = C,$$

где C – произвольное числовое значение.

Если построенная прямая не пересекает МДР, то передвинем ее параллельно самой себе, чтобы такое пересечение случилось в любом месте внутри МДР. Дополнительно построим так называемый вектор возрастания целевой функции, который начинается в точке (0, 0) и имеет направление на точку с координатами (c_1, c_2), где c_1 и c_2 − коэффициенты целевой функции при соответствующих неизвестных. В математике этот вектор возрастания функции называется градиентом.

Теперь можем найти решение рассматриваемой задачи ЛП.

В случае если в задаче требуется найти максимум целевой функции, то передвигаем построенную прямую в направлении градиента параллельно самой себе до последней точки касания с МДР. Координаты этой точки будут решением задачи ЛП.

Когда в задаче требуется найти минимум целевой функции, то передвигаем построенную прямую против направления градиента параллельно самой себе до последней точки касания с МДР. Координаты этой точки будут решением задачи ЛП.

Пример 2.5. Найти максимум целевой функции

$$f = 2x_1 + 3x_2$$

при ограничениях:

$$\begin{cases} x_1 - 3x_2 \le 6, & (а) \\ 2x_1 + 4x_2 \ge 8, & (б) \\ -x_1 + 3x_2 \le 6, & (в) \\ x_1 \le 8, & (г) \\ x_1 \ge 0, & (д) \\ x_2 \ge 0. & (е) \end{cases}$$

Условия (*а*)–(*е*) на плоскости соответствуют выпуклому многоугольнику *ABCDE* (рис. 2.3).

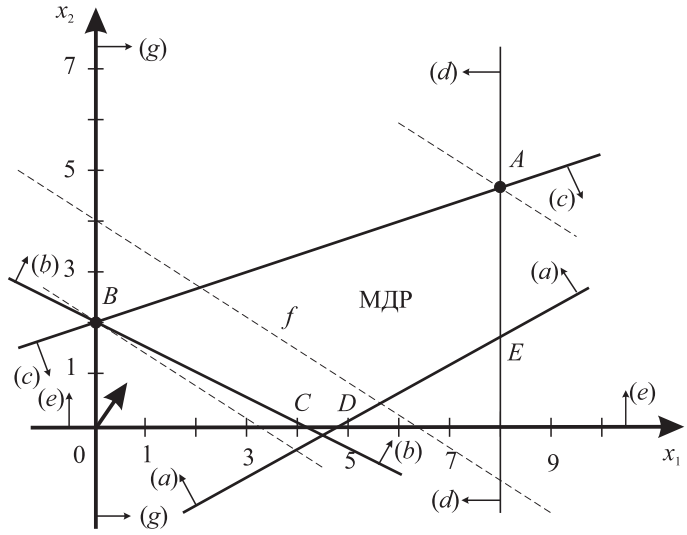

Рис. 2.3

Координаты точки A будут решением поставленной задачи $x_1^* = 8;\ x_2^* = \frac{14}{3};$ $f_{\max} = 30$.

Пример 2.6. Найти минимум целевой функции $f = 2x_1 + 3x_2$ при ограничениях из примера 2.5.

Используем рис. 2.3. Координаты точки B будут решениями поставленной задачи

$$\overline{x}_1 = 0; \quad \overline{x}_2 = 2; \quad f_{\min} = 6.$$

Проведенная геометрическая интерпретация задачи ЛП с двумя неизвестными и метод ее решения дают основание для следующих утверждений.

Следствие 2.1. Множество допустимых решений задачи ЛП выпукло.

Следствие 2.2. Решение задачи ЛП находится в вершине многоугольника допустимых решений.

Следствие 2.3. Задача ЛП может иметь бесконечное множество решений, если последним местом касания прямой, соответствующей целевой функции, будет не единственная точка, а какая-то сторона МДР.

Следствие 2.4. Задача ЛП с двумя неизвестными не имеет решения, если множество – пересечение полуплоскостей, соответствующих всем ограничениям, пусто. В этом случае система ограничений задачи несовместна.

Следствие 2.5. Если МДР не имеет границы в направлении передвижения прямой, соответствующей целевой функции, то говорят, что решение задачи ЛП не ограничено.

Все эти простые следствия могут быть перенесены на случай произвольного (большего, чем 2) числа неизвестных. Для n неизвестных каждое неравенство определяет n-мерное полупространство, ограниченное соответствующей гиперплоскостью. Пересечение таких гиперплоскостей (если оно не пусто) определяет n-мерный выпуклый многогранник. Решение задачи ЛП находится в вершине такого многогранника. Сущ-

ностью каждого метода поиска решения задачи ЛП является упорядоченный перебор вершин многогранника допустимых решений. При этом, чем меньше таких вершин анализирует выбранный метод, тем он эффективнее. Наиболее распространенный – симплексный метод (симплекс-метод), в котором с помощью известной в линейной алгебре схемы Гаусса перебираются так называемые базовые допустимые решения, соответствующие вершинам n-мерного многогранника. Именно этот метод (или его модификации) являются основой большинства пакетов компьютерных программ (в том числе коммерческих) для решения и анализа задач линейного программирования.

Замечание. Геометрическая интерпретация задач линейного программирования позволяет проиллюстрировать некоторые важные различия между задачами ЛП и линейного целочисленного программирования (ЛЦП), т. е. в моделях без условия делимости.

Во-первых, допустимым решением задачи ЛЦП может быть только точка с целочисленными координатами, т. е. узел целочисленной решетки.

Во-вторых, может быть случай, когда задача ЛП имеет решение, а задача ЛЦП не имеет (рис. 2.4).

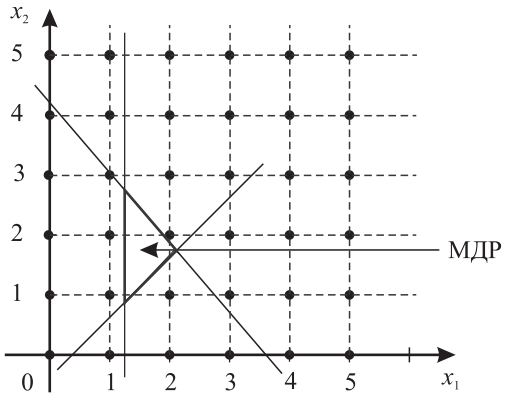

Рис. 2.4

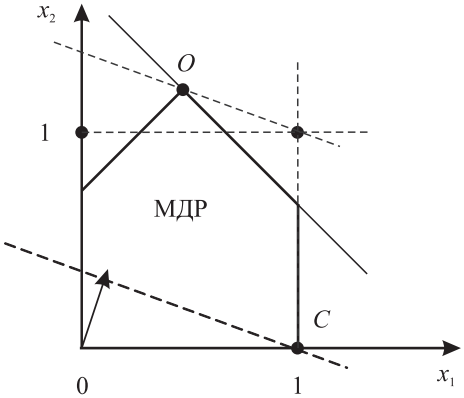

Рис. 2.5

Наконец, округление решения задачи ЛП (в любую сторону) может вообще не быть допустимым решением ЛЦП (рис. 2.5).

На этом графике точка O – решение задачи ЛП на максимум, точка C – решение соответствующей задачи ЛЦП.

2.4. ДВОЙСТВЕННЫЕ ЗАДАЧИ ЛИНЕЙНОГО ПРОГРАММИРОВАНИЯ

Для каждой конкретной задачи ЛП можно построить двойственную ей задачу. Простейшие правила построения двойственных задач без оговорок о знаках двойственных переменных формируются при переходе от одной разновидности стандартной формы ЛП к другой и состоят в следующем:

1) каждому основному ограничению прямой задачи ЛП соответствует своя двойственная неотрицательная переменная;

2) в двойственной задаче имеется столько основных ограничений, сколько переменных есть в прямой задаче;

3) коэффициенты целевой функции прямой задачи ЛП являются свободными членами соответствующих ограничений в двойственной задаче;

4) свободные члены ограничений прямой задачи становятся коэффициентами целевой функции двойственной задачи;

5) матрица коэффициентов основных ограничений двойственной задачи ЛП получается путем транспонирования матрицы ограничений прямой задачи;

6) если прямая задача ЛП состоит в максимизации целевой функции, то двойственная задача минимизирует свою целевую функцию, и наоборот.

Таким образом, задача ЛП в стандартной форме (например, при всех ограничениях $\leq$ и максимизации целевой функции) имеет двойственную задачу в иной стандартной форме (при всех $\geq$ и минимизации).

Доказаны следующие утверждения.

Теорема 2.1. Если у некоторой задачи ЛП есть оптимальное решение, то двойственная задача также имеет оптимальное решение, при этом оптимальные значения целевых функций равны.

Теорема 2.2. Задача, двойственная к двойственной задаче ЛП, совпадает с прямой задачей.

Теорема 2.3 (Джона фон Неймана). Если дана пара, состоящая из прямой и двойственных задач ЛП, то возможна в точности одна из трех ситуаций, показанных в таблице:

Прямая	Двойственная		
	Конечный оптимум	Неограниченная	Недопустимая
Конечный оптимум	1		
Неограниченная			2
Недопустимая		2	3

Теорема 2.4 (условие дополняющей нежесткости). Векторы X и Y, допустимые соответственно в прямой и двойственной задаче, оптимальны в том и только том случае, если:

$$y_i(a_i X - b_i) = 0 \text{ для } i = 1, 2, \ldots, m;$$

$$(c_i - Y^T A_j)x_i = 0 \text{ для } j = 1, 2, \ldots, n,$$

где a_i – i-я строка матрицы основных ограничений A; A_j – j-й столбец матрицы A.

Двойственная задача ЛП, двойственные переменные и утверждения 2.1–2.4 имеют важную экономическую интерпретацию. В качестве иллюстрации обобщим задачу из примера 2.1.

Пусть прямая задача ЛП является моделью проблемы максимизации дохода, достигаемого при реализации n изделий, которые изготавливаются с использованием m видов производственных средств. Известны: a_{ij} – нормы затрат i-го средства производства на изготовление j-го изделия; b_i – величина запаса i-го средства; c_j – цена j-го изделия. Задача состоит в определении плана продукции каждого изделия таким образом, чтобы не превысить имеющиеся запасы производственных средств и чтобы сум-

марный доход был максимальным. Это означает, что в математической модели требуется найти значения переменных $x_1, x_2, ..., x_n$, для которых выполняются ограничения

$$x_j \geq 0, \quad j = 1, 2, ..., n;$$

$$\sum_{j=1}^{n} a_{ij} x_j \leq b_i, \quad i = 1, 2, ..., m,$$

и для которых

$$\sum_{j=1}^{n} c_j x_j \to \max.$$

Предположим, что конкурирующая фирма оценивает, купить ли изделия, или купить средства производства этих изделий. Во втором случае необходимо решить, по какой цене y_i можно было бы выкупить такие средства, чтобы, во-первых, владеющей ими фирме была выгодна такая продажа и, во-вторых, чтобы суммарная стоимость покупки была минимальна. Это означает, что требуется найти значения переменных y_1, $y_2, ..., y_m$, для которых выполняются ограничения

$$y_i \geq 0, \quad i = 1, 2, ..., m;$$

$$\sum_{i=1}^{m} a_{ij} y_i \geq c_j, \quad j = 1, 2, ..., n,$$

и для которых

$$\sum_{i=1}^{m} b_i y_i \to \min.$$

Очевидно, что эта задача является двойственной по отношению к первой задаче.

Имеет смысл продать средства производства единицы j-го изделия по ценам y_i $(i = 1, 2, ..., m)$, если

$$\sum_{i=1}^{m} a_{ij} y_i \geq c_j \text{ для всех } j = 1, 2, ..., n.$$

Таким образом, имеем основные ограничения двойственной задачи, которую должен решить конкурент. Как следует из теоремы 2.1, оптимальное значение цены i-го средства производства, т. е. переменной y_i, определяет, насколько возрастет (уменьшится) доход, если увеличим (уменьшим) независимо от других запас i-го средства производства на единицу.

Таким образом, в соответствии с современной экономической теорией двойственная переменная y_i определяет так называемую граничную продуктивность (productiveness).

Достаточно простую экономическую интерпретацию для этой задачи имеют условия дополняющей нежесткости в теореме 2.4:

1) если использование i-го средства продукции меньше, чем его запас, то значение граничной продуктивности единицы i-го средства нулевое;

2) если стоимость средств, используемых для производства единицы j-го изделия, большая, чем его цена, то нет смысла его производить;

3) если значение конечной продуктивности *i*-го средства положительно, то необходимо полностью использовать его запасы;

4) если производится *j*-е изделие, то стоимость средств, использованных при производстве единицы *j*-го продукта, равна цене этого изделия.

Пример 2.7. Предприятие производит четыре вида продукции A_1, A_2, A_3, A_4, используя, кроме прочего, два вида ограниченных ресурсов C_1 и C_2. Затраты каждого вида ресурса на единицу продукции, запасы ресурсов и ожидаемая прибыль при реализации единицы продукции приведены в следующей таблице:

Продукция	Ресурсы		
	C_1	C_2	Прибыль, руб.
A_1	1	5	50
A_2	5	3	60
A_3	2	6	30
A_4	11	5	300
Запасы ресурсов	1100	1000	

Определить план продукции, максимизирующий суммарную прибыль.

Если план продукции задавать значениями x_1, x_2, x_3, x_4 соответственно видам продукции, то математическая модель задачи сводится к нахождению таких значений x_1, x_2, x_3, x_4, для которых выполняются ограничения

$$x_1, x_2, x_3, x_4 \geq 0;$$

$$\begin{cases} x_1 + 5x_2 + 2x_3 + 11x_4 \leq 1100, \\ 5x_1 + 3x_2 + 6x_3 + 5x_4 \leq 1000 \end{cases}$$

и для которых суммарная прибыль

$$F(x_1, x_2, x_3, x_4) = 50x_1 + 60x_2 + 30x_3 + 300x_4 \to \max.$$

Эта задача имеет стандартную форму, и для нее можно построить двойственную задачу: найти значения переменных y_1 и y_2 (по числу основных ограничений в прямой задаче), для которых выполняются ограничения

$$y_1, y_2 \geq 0;$$

$$\begin{cases} y_1 + 5y_2 \geq 50, \\ 5y_1 + 3y_2 \geq 60, \\ 2y_1 + 6y_2 \geq 30, \\ 11y_1 + 5y_2 \geq 300 \end{cases}$$

и для которых целевая функция

$$G(y_1, y_2) = 1100y_1 + 1000y_2 \to \min.$$

Полученную двойственную задачу с двумя переменными легко решить, используя геометрическую интерпретацию. В результате получим $y_1^{\text{опт}} = 25$, $y_2^{\text{опт}} = 5$, причем $G(y_1^{\text{опт}}, y_2^{\text{опт}}) = 32\,500$.

Как отмечено ранее, оптимальное значение каждой двойственной переменной определяет, насколько возрастет (или уменьшится) доход, если увеличим (уменьшим) на единицу запас соответствующего ресурса. Проверим далее, насколько выполнены неравенства основных ограничений двойственной задачи. Видно, что первое и четвертое ограничения превращаются в равенство, а второе и третье являются строгими неравенствами. По теореме 2.4 о дополняющей нежесткости это означает, что $x_2^{\text{опт}} = x_3^{\text{опт}} = 0$. Следовательно, для определения $x_1^{\text{опт}}$ и $x_4^{\text{опт}}$ достаточно решить систему уравнений

$$\begin{cases} x_1 + 11x_4 = 1100, \\ 5x_1 + 5x_4 = 1000. \end{cases}$$

Отсюда получим $x_1^{\text{опт}} = 90$, $x_4^{\text{опт}} = 90$, причем $F(x_1^{\text{опт}}, x_2^{\text{опт}}, x_3^{\text{опт}}, x_4^{\text{опт}}) = 32\,500$ руб., т. е. выполнена теорема 2.1.

2.5. СУЩНОСТЬ АНАЛИЗА ЧУВСТВИТЕЛЬНОСТИ РЕШЕНИЙ В ЗАДАЧЕ ЛИНЕЙНОГО ПРОГРАММИРОВАНИЯ

Оптимальное решение задачи ЛП дает возможность для принятия хорошего управленческого решения. Однако следует учитывать, что все числовые параметры в изучаемой математической модели известны и постоянны. Как правило, в практических задачах этого не бывает. Во-первых, эти параметры могут быть неточными, и, во-вторых, в зависимости от условий хозяйствования они могут изменяться с течением времени. Исследование изменений оптимального решения задачи в зависимости от изменения данных называется анализом чувствительности или постоптимальным анализом. Такой анализ часто решает проблему стабильности оптимального решения, в котором определяются пределы изменений параметров задачи, не приводящих к изменениям в оптимальном решении.

Пусть задача линейного программирования (ЗЛП) сформулирована в стандартном виде. Найти элементы вектора X при условиях

$$AX = \boldsymbol{b},$$

$$X \geq \mathbf{0},$$

для которого

$$\boldsymbol{c}X \to \max(\min).$$

Тогда анализ чувствительности может проводиться с учетом изменений:

а) коэффициентов целевой функции, т. е. элементов вектора $\boldsymbol{c}$;

б) элементов вектора $\boldsymbol{b}$;

в) элементов матрицы A, причем такие изменения могут касаться одного или нескольких ограничений в системе

$$AX = \boldsymbol{b}.$$

Кроме того, анализ чувствительности может касаться структурных изменений в математической модели:

г) присоединение одного или нескольких ограничений к системе $AX = \boldsymbol{b}$;

д) удаление одного или нескольких ограничений из системы $AX = \boldsymbol{b}$;

е) включение одной или нескольких управляемых переменных в математическую модель;

ж) удаление одной или нескольких управляемых переменных из математической модели.

Многие из вариантов изменений а) – ж) в исследовании операций хорошо изучены при условии, что оптимальное решение исходной задачи найдено симплексным методом. Как правило, хорошие пакеты компьютерных программ для решения ЗЛП позволяют проводить достаточно широкий анализ чувствительности оптимального решения.

2.6. ОПТИМИЗАЦИОННАЯ МОДЕЛЬ ПРОИЗВОДСТВА. АНАЛИЗ НА УСТОЙЧИВОСТЬ

Впервые такая модель была предложена Л. В. Канторовичем и ознаменовала современный этап применения математических методов в экономике.

Пусть любой (действующий или воображаемый) технологический способ производства описывается вектором

$$a^S = (a_1^S, a_2^S, ..., a_m^S, a_{m+1}^S, ..., a_{m+n}^S),$$

где a_i^S $(i = 1, 2, ..., N, \quad N = n + m, \quad S = 1, 2, ..., r)$ – объемы производства или затрат соответствующих продуктов при единичной интенсивности использования *s*-го технологического способа производства. Если $a_i^S > 0$, то *i*-й продукт производится, если $a_i^S < 0$ – затрачивается, $a_i^S = 0$ – не производится и не затрачивается.

Наличные ресурсы труда, природные ресурсы, производственные мощности, сырьевые ресурсы и часть выпускаемой продукции, которая должна быть произведена или израсходована в строго фиксированном количестве, задаются вектором ограничений

$$\gamma = (b_1, b_2, ..., b_m).$$

План организации производства определяется вектором $\pi = (x^1, x^2, ..., x^r)$ с неотрицательными компонентами и указывает на интенсивность использования соответствующих способов производства.

Пусть при фиксированном плане производства π различные продукты затрачиваются и производятся в количествах

$$\alpha_i^\pi = \sum_{S=1}^{r} a_i^S x^S, \qquad i = 1, 2, ..., N.$$

Таким образом, предполагается возможность линейного увеличения объемов производства за счет изменения интенсивностей использования технологических способов производства.

По первым *m* продуктам вводятся ограничения $\alpha_i^\pi \geq b_i$, $i = 1, 2, ..., m$, что означает: для $b_i < 0$ суммарные затраты не должны превосходить имеющиеся ресурсы, для $b_i > 0$ план производства соответствующих продуктов должен быть выполнен.

В качестве целевой функции Л. В. Канторович выбрал число ассортиментных наборов, определяемое величиной

$$\mu(\pi) = \min_{j=1,n} \frac{\alpha^{\pi}_{m+j}}{K_j}; \qquad \alpha^{\pi}_{m+j} = \sum_{S=1}^{r} a^{S}_{m+j} x^{S},$$

где K_j, $j = 1, 2, ..., n,$ – количество продукта j в одном наборе.

Итак, возникает задача оптимизации: найти величины x^S, для которых

$$x^S \geq 0, \quad S = 1, 2, ..., r,$$

$$\alpha^{\pi}_i = \sum_{S=1}^{r} a^S_i x^S \geq b_i, \quad i = 1, 2, ..., m,$$

и

$$\min_j \frac{\alpha^{\pi}_{m+j}}{K_j} \to \max,$$

т. е. максимизируется количество ассортиментных наборов.

Теорема 2.5. Для оптимизации допустимого плана $\pi = (x^1, x^2, ..., x^r)$ необходимо и достаточно, чтобы существовал вектор оценок $y = (y_1, ..., y_N),$ такой, что:

а) $y_i \geq 0,\ i = 1, 2, ..., N, \max_j y_{m+j} > 0$ – оценки продуктов неотрицательны и хотя бы один из производимых продуктов имеет положительную оценку;

б) $\sum_{i=1}^{N} a^S_i y_i \leq 0,\ S = 1, 2, ..., r$ – суммарная оценка произведенной продукции не должна превышать оценки затрат;

в) $\sum_{i=1}^{N} a^S_i y_i = 0,\ S = 1, 2, ..., r,$ если $x^S > 0,$ – в технологических способах, входящих в план, суммарная оценка продуктов равна суммарной оценке затрат;

г) $y_i = 0,$ если $a^S_i > b_i,\ i = 1, 2, ..., m,$ – ресурсы, не минимизирующие производство, получают нулевую оценку;

д) $y_{m+j} = 0,$ если $\alpha^{\pi}_{m+j} > \mu(\pi) K_j,\ j = 1, 2, ..., n,$ – продукция, производимая сверх требуемого ассортимента, получает нулевую оценку.

Компоненты вектора $y = (y_1, ..., y_N)$ Л. В. Канторович назвал объективно обусловленными оценками (о. о. о.) оптимального плана.

С математической точки зрения данное утверждение является не чем иным, как теоремой двойственности, конкретизированной для данной модели; о. о. о. – двойственные переменные.

Анализ о. о. о. дает исключительно важную информацию для модели.

Эти оценки прежде всего зависят от заданного ассортимента производимой конечной продукции, используемых технологических способов производства, наличных ресурсов и степени их ограниченности. Они, с одной стороны, показывают, какое приращение целевой функции обеспечивается единицей определенного ресурса в данных условиях и, с другой – дают количественную оценку произведенной продукции.

Замечено, что о. о. о. относительно устойчивы при незначительных изменениях исходных данных (тех изменениях, которые не приводят к изменению базисных век-

торов). Исходя из этого свойства, можно построить так называемое уравнение вариации плана, которое помогает выяснить сущность о. о. о.

Пусть при данном оптимальном плане затраты и производимая продукция характеризуется вектором

$$\alpha^{\pi} = (\alpha_1^{\pi}, ..., \alpha_N^{\pi}).$$

Встает вопрос, можно ли перейти от данного оптимального плана к некоторому другому с таким же значением целевой функции, используя отмеченные выше свойства устойчивости о. о. о.

Пусть $\alpha^{\pi} + \Delta\alpha = (\alpha_1^{\pi} + \Delta\alpha_1, ..., \alpha_N^{\pi} + \Delta\alpha_N)$ – вектор затрат и производства нового плана, где $\Delta\alpha_1$ – изменения (вариации) ресурсов и продукции.

Для того чтобы новый план был оптимальным и имел то же значение целевой функции, что и исходный, необходимо, чтобы суммарная оценка затрат этого плана была равна суммарной оценке производственной продукции, т. е. чтобы выполнялось равенство

$$y(\alpha^{\pi} + \Delta\alpha) = 0.$$

Поскольку для исходного оптимального плана равенство $y\alpha^{\pi} = 0$ выполняется (свойство в) в теореме 2.5), то для оптимальности нового плана достаточно, чтобы выполнялось равенство

$$\sum_{i=1}^{N} \Delta\alpha_i y_i = 0.$$

Это равенство называется уравнением вариации плана. Оно представляет условие эквивалентной замены одних видов продукции и производственных факторов другими и показывает, как в соответствии с о. о. о. можно осуществлять замену одних факторов производства другими, не нарушая оптимальности плана.

Например, пусть изменяются количества двух продуктов i и k. Тогда по уравнению вариации плана

$$y_i \Delta\alpha_i + y_k \Delta\alpha_k = 0.$$

Отсюда предельная норма замены α_i на α_k будет равна по абсолютной величине обратному отношению их оценок

$$\frac{\Delta\alpha_i}{\Delta\alpha_k} = \left| \frac{y_k}{y_i} \right|.$$

Экономисты показали, что свойства о. о. о. отражают свойства товарного производства. С их помощью можно оценить эффективность новых технологических способов производства.

Например, появился новый способ

$$\alpha^{0} = (\alpha_1^{0}, ..., \alpha_N^{0}).$$

С помощью о. о. о. можно определить, улучшит ли применение этого способа существующий план производства: если $\sum_{i=1}^{N} a_i^0 y_i > 0$, то план будет улучшен, если $\sum a_i^0 y_i \le 0$, то не будет.

Таким образом, о. о. о. являются оценками сравнительной экономической эффективности факторов производства, их производительностей.

2.7. ЛИНЕЙНАЯ МОДЕЛЬ МАКРОЭКОНОМИКИ (МОДЕЛЬ МЕЖОТРАСЛЕВОГО БАЛАНСА ЛЕОНТЬЕВА)

Ученый-экономист В. В. Леонтьев в 1920-х гг. предложил изучать функционирование национальной экономики в частично дезагрегированном виде. При таком подходе производственно-экономические процессы разукрупняются до уровня n отраслей (секторов) (многосекторная модель производства) и производится анализ потоков продуктов между отраслями.

Основные предпосылки анализа таковы:

а) в экономической системе производятся, покупаются, продаются, потребляются n типов продуктов $(i = 1, 2, ..., n)$;

б) каждая отрасль производит только один тип продукта, т. е. n отраслей и n продуктов находятся во взаимно-однозначном соответствии: i-й продукт выпускает i-я отрасль;

в) под производственным процессом в каждой отрасли подразумевается преобразование некоторых типов продуктов (в определенных количествах) в продукт данной отрасли.

Предполагается, что соотношение затрачиваемых и выпускаемых продуктов постоянно (во времени), причем если для производства единицы j-го продукта в j-й отрасли нужно непосредственно a_{ij} единиц i-го продукта, то для производства λ единиц необходимо λa_{ij} единиц i-го продукта. Величины a_{ij} называются коэффициентами (нормами) прямых затрат.

Обозначим через x_i количество i-го продукта, производимого в течение единицы времени (например, года), т. е. так называемый валовой выпуск.

Часть валового выпуска, а именно величина $\sum_{j=1}^{n} a_{ij} x_j$ потребляется в виде затрат, необходимых для производства. Соответственно, чистый выпуск получается вычитанием из валового выпуска полного количества продукта, потребляемого в виде производственных затрат, т. е. выражается величиной

$$x_i - \sum_{j=1}^{n} a_{ij} x_j .$$

Приравняв чистый выпуск конечному спросу b_i на i-й продукт, получим систему

$$x_i - \sum_{j=1}^{n} a_{ij} x_j = b_i , \quad i = 1, 2, ..., n , \tag{2.12}$$

или в виде

$$x - Ax = b, \tag{2.13}$$

где A – матрица коэффициентов прямых затрат, $b = b_1, b_2, ..., b_n$; b_i – величина потребления продукта i-го типа в непроизводственной сфере.

Сущность метода «затраты-выпуск» состоит в определении уровней (величин) валового выпуска по заданному конечному спросу с учетом коэффициентов прямых затрат, т. е. в определении величин $x_1, x_2, ..., x_n$.

Очевидно, что коэффициенты a_{ij} и значения x_j неотрицательны. Возникает вопрос: каково условие существования неотрицательного решения системы (2.12) при $b_i \geq 0$ и $a_{ij} \geq 0$ или, по-другому, при каких условиях модель Леонтьева является продуктивной?

Перейдем к системе

$$\sum_{j=1}^{n} d_{ij} x_j = b_i, \quad i = 1, 2, ..., n, \tag{2.14}$$

коэффициенты которой неположительны при $i \neq j$.

Теорема 2.6. Условия:

а) система (2.14) разрешима в неотрицательных переменных $x_i \geq 0$, i = 1, 2, ..., n, при некотором наборе $b_i \geq 0$;

б) система (2.14) разрешима в неотрицательных переменных $x_i \geq 0$, i = 1, 2, ..., n, при любом наборе $b_i \geq 0$;

в) в матрице коэффициентов системы (2.14) все n главных миноров положительны, т. е.

$$\begin{vmatrix} d_{11} & ... & d_{1k} \\ ... & ... & ... \\ d_{k1} & ... & d_{kk} \end{vmatrix} > 0, \quad k = 1, 2, ..., n,$$

взаимно эквивалентны.

Условие в) – это известное в линейной алгебре условие Хокинса – Саймона.

Рассмотрим теперь системы, двойственные к (2.12), (2.14):

$$p_j - \sum_{i=1}^{n} a_{ij} p_i = v_j, \quad j = 1, 2, ..., n, \tag{2.15}$$

$$\sum_{i=1}^{n} d_{ij} p_i = v_j, \quad j = 1, 2, ..., n. \tag{2.16}$$

Эти системы важны в экономических приложениях. Они характеризуют цены или стоимости в системе межотраслевых поставок.

Действительно, p_j в (2.15) можно интерпретировать как цену j продукта, тогда $\sum_{i=1}^{n} a_{ij} p_i$ – суммарные издержки на единицу выпуска, а v_j – чистый доход от единицы выпуска в j-отрасли.

Таким образом, если разрешимость системы (2.12) в неотрицательных переменных x_i означает продуктивность модели Леонтьева, то разрешимость системы (2.15) – прибыльность этой модели.

Квадратная матрица T называется неотрицательно обратимой, если T является невырожденной и ее обратная матрица T^{-1} неотрицательная.

Теорема 2.7. Матрица $D = [d_{ij}]$ системы (2.14), при $d_{ij} \le 0$ $(i \ne j)$ неотрицательно обратима тогда и только тогда, когда имеет место продуктивность модели Леонтьева.

Запишем систему (2.13) в виде

$$(E - A)x = b,$$

где A – матрица коэффициентов прямых затрат. Из теоремы 2.6 следует, что продуктивность модели Леонтьева эквивалентна неотрицательной обратимости матрицы $E - A$.

Если модель продуктивна, то вектор валового выпуска x дается выражением $(E - A)^{-1}b$. В свою очередь, матрица $(E - A)^{-1}$ дает информацию о том, каким образом вектор конечного спроса $\bar{b} > b$ пересчитывается в заведомо больший вектор валового выпуска $\bar{x}$.

Поскольку модель (2.13) линейна по x и b, то приращение Δb и, соответственно, Δx связаны между собой через матричный множитель $(E - A)^{-1}$, т. е. $\Delta x = (E - A)^{-1}\Delta b$. Поэтому матрица $(E - A)^{-1}$ дает нам информацию о величине изменений в условиях валового выпуска, вызванных в уровнях конечного спроса.

В связи с этим данная матрица называется матричным мультипликатором (по аналогии со скалярным мультипликатором $(1/1 - \alpha)$). Известно, что если $0 < \alpha < 1$, то

$$\frac{1}{1-\alpha} = 1 + \alpha + \alpha^2 + \ldots.$$

Используем аналогичное представление для матрицы A:

$$(E - A)^{-1} = E + A + A^2 + \ldots. \qquad (2.17)$$

Теорема 2.8. Пусть A – неотрицательная квадратная матрица. Тогда если матрица $(E - A)$ неотрицательно обратима, то ряд (2.17) сходится, причем сумма этого ряда равна $(E - A)^{-1}$ и обратно.

Матрица $(E - A)^{-1}$ называется матрицей коэффициентов полных затрат. На практике проверка сходимости ряда (2.17), например, с помощью условия Хокинса – Саймона является достаточно трудоемкой вычислительной проблемой. Часто вместо вычисления всех главных миноров матрицы $E - A$ вычисляют собственные значения матрицы A. Доказано: для продуктивности модели Леонтьева необходимо и достаточно, чтобы все они по модулю были меньше единицы.

Именно матрица полных затрат содержит важную информацию, необходимую для планирования экономики на макроуровне.

Из продуктивности модели Леонтьева следует, что валовой выпуск x при заданном неотрицательном конечном спросе $b \ge 0$ задается векторным рядом $b + Ab + A^2b + \ldots$.

Экономический смысл этого факта состоит в следующем.

Для получения чистого выпуска b необходимо затратить вектор продуктов Ab. Чтобы произвести этот набор продуктов Ab, дополнительно нужно затратить A^2b и т. д. Тогда сумма векторов чистого выпуска b и всех векторов промежуточных затрат Ab, A^2b, ... и будет вектором валового продукта x.

Метод «затраты-выпуск» широко применяется в практике прогнозирования и планирования экономики. Подобные модели можно разрабатывать и применять не толь-

ко на макроуровне, но и на уровне предприятий (см. пример 3.4). Хотя соответствующие математические модели не являются оптимизационными, они с полным правом могут быть отнесены к ИСО, потому что касаются вопросов количественного обоснования управленческих решений.

2.8. ТРАНСПОРТНАЯ ЗАДАЧА В ТАБЛИЧНОЙ ПОСТАНОВКЕ

2.8.1. Математическая модель транспортной задачи

Одним из важных частных случаев задачи линейного программирования является так называемая транспортная задача (ТЗ). Впервые ее формулировка и метод решения опубликованы в 1934 г. Л. В. Канторовичем. В 1941 г. Ф. Л. Хичкок (F. L. Hitchcock) опубликовал еще одну версию и алгоритм решения этой задачи.

Классическая ТЗ состоит в следующем. Имеется n поставщиков $A_1, A_2, ..., A_n$ определенного однородного товара, которые предлагают соответственно $a_1, a_2, ..., a_n$ единиц этого товара m потребителям $B_1, B_2, ..., B_m$, создающим спрос на него в количествах $b_1, b_2, ..., b_m$ единиц соответственно. Для каждой пары «i-й поставщик – j-й потребитель» известна стоимость c_{ij} $(i = 1, 2, ..., n;\ j = 1, 2, ..., m)$ перевозки единицы товара. Требуется определить такой план удовлетворения спроса потребителей, при котором общие транспортные затраты минимальны. Очень часто на практике предполагается, что такие затраты являются суммой затрат на перевозку товара для каждой пары «i-й поставщик – j-й потребитель», которые, в свою очередь, прямо пропорциональны с коэффициентом c_{ij} количеству перевозимого товара. Таким образом, выполняются свойства аддитивности и прямой пропорциональности (п. 2.1).

Многие задачи принятия решений, даже не имеющие транспортной интерпретации, можно свести к классической ТЗ. Среди них такие задачи, как производственно-транспортная (о размещении), с критерием времени, минимизации пустых пробегов, блокирования перевозок, многоэтапной транспортировки и др. Все такие задачи являются предметом изучения и применения в многочисленных логистических центрах.

Для построения математической модели классической ТЗ учтем, что проблема нахождении плана удовлетворения спроса потребителей в данной постановке равносильна определению таких значений неизвестных x_{ij}, как количества товара, перевозимого от i-го поставщика к j-му потребителю, для которых выполняются условия

$$x_{ij} \geq 0, \quad i = 1, 2, ..., n;\ j = 1, 2, ..., m; \tag{2.18}$$

$$\sum_{j=1}^{m} x_{ij} \leq a_i, \quad i = 1, 2, ..., n; \tag{2.19}$$

$$\sum_{i=1}^{n} x_{ij} \geq b_j, \quad j = 1, 2, ..., m, \tag{2.20}$$

и для которых величина суммарных затрат

$$f = \sum_{i=1}^{n} \sum_{j}^{m} c_{ij} x_{ij} \to \min. \tag{2.21}$$

Условия (2.19) означают, что от каждого поставщика можно вывезти не больше товара, чем он предлагает. Условие (2.20) означает, что спрос каждого потребителя должен быть удовлетворен.

Построенная модель называется открытой моделью ТЗ. В целях стандартизации и упрощения изложения часто принимают, что выполняются условия баланса суммарного предложения и суммарного спроса, т. е. равенство

$$\sum_{i=1}^{n} a_i = \sum_{j=1}^{m} b_j. \tag{2.22}$$

Тогда неравенства (2.19) и (2.20) превращаются в равенства

$$\sum_{j=1}^{m} x_{ij} = a_i, \quad i = 1, 2, ..., n; \tag{2.23}$$

$$\sum_{i=1}^{n} x_{ij} = b_j, \quad j = 1, 2, ..., m. \tag{2.24}$$

ТЗ в условиях (2.18), (2.23), (2.24) и целевой функции (2.21) называется замкнутой моделью. Легко найти хотя бы одно допустимое решение замкнутой модели ТЗ.

Очевидно, что построенные математические модели ТЗ являются частностью общей модели линейного программирования. В этом случае задача содержит $n \cdot m$ неизвестных и $n + m$ основных ограничений.

Для решения ТЗ можно было бы применить любой общий метод решения ЗЛП. Однако в силу специфики задачи применяются иные, существенно более эффективные методы. Важную роль в таких методах играет задача, двойственная по отношению к замкнутой модели ТЗ. Она состоит в нахождении таких значений u_i и v_j, для которых выполняются ограничения

$$u_i + v_j \le c_{ij}, \quad i = 1, 2, ..., n; \ j = 1, 2, ..., m, \tag{2.25}$$

и для которых целевая функция

$$g = \sum_{i=1}^{n} a_i u_i + \sum_{j=1}^{m} b_j v_j \to \max. \tag{2.26}$$

Можно сразу же записать допустимое решение, удовлетворяющее (2.25), для этой двойственной задачи:

$$u_i = 0, \quad i = 1, 2, ..., n;$$

$$v_j = \min_{1 \le i \le n} \{c_{ij}\}, \quad j = 1, 2, ..., m.$$

Таким образом, задача (2.25), (2.26) имеет решение. На этом основании, применяя, например, теорему 2.3 (Джона фон Неймана) о двойственности, можно получить многие теоретические результаты, касающиеся ТЗ, а также метода ее решения.

2.8.2. Сущность методов решения транспортной задачи

Для решения ТЗ используют так называемую транспортную таблицу:

Запасы продукта		Потребность в продукте					
		B_1	B_2	….	B_j	….	B_m
		b_1	b_2	….	b_j	….	b_m
A_1	a_1	c_{11} x_{11}	c_{12} x_{12}	…. ….	c_{1j} x_{1j}	…. ….	c_{1m} x_{1m}
A_2	a_2	c_{21} x_{21}	c_{22} x_{22}	…. ….	c_{2j} x_{2j}	…. ….	c_{2m} x_{2m}
….	….	….	….	….	….	….	….
A_i	a_i	c_{i1} x_{i1}	c_{i2} x_{i2}	…. ….	c_{ij} x_{ij}	…. ….	c_{im} x_{im}
….	….	….	….	….	….	….	….
A_n	a_n	c_{n1} x_{n1}	c_{n2} x_{n2}	…. ….	c_{nj} x_{nj}	…. ….	c_{nm} x_{nm}

Удобно, если в такой таблице выполняется условие баланса (2.22).

Если на практике $\sum_{i=1}^{n} a_i > \sum_{j=1}^{m} b_j$, то для получения замкнутой модели к транспортной таблице добавляют фиктивного потребителя B_{m+1}, спрос которого равен $b_{m+1} = \sum_i a_i - \sum_j b_j$ и до которого стоимость перевозки единицы товара $c_{i,m+1} = 0 \ \ (i = 1, 2, ..., n)$.

Если на практике $\sum_{i=1}^{n} a_i < \sum_{j=1}^{m} b_i$, то для получения замкнутой модели к транспортной таблице добавляют фиктивного поставщика A_{n+1}, предложение которого равно $a_{n+1} = \sum_j b_j - \sum_i a_i$ и от которого стоимость перевозки единицы товара $c_{n+1,j} = 0 \ \ (j = 1, 2, ..., m)$.

Анализируя структуру матрицы коэффициентов при неизвестных x_{ij} в основных ограничениях (2.23), (2.24), легко доказать, что ее ранг равен $n + m - 1$. Это, в частности, означает, что любому базису вектор-столбцов этой матрицы будет соответствовать допустимое решение ТЗ, содержащее не более чем $n + m - 1$ клеток транспортной таблицы с ненулевыми значениями перевозок. В остальных клетках они будут нулевыми. Такие решения называются допустимыми базисными решениями.

Теорема 2.9. Решение ТЗ находится во множестве допустимых базисных решений.

Схема любого эффективного метода решения ТЗ (например, метода потенциалов или так называемого венгерского метода) состоит в следующем.

Строится исходное допустимое базисное решение, для него оценивается значение целевой функции (2.21) и проверяется так называемый критерий оптимальности, который устанавливает, является ли полученное значение целевой функции минимальным. Если этот критерий не выполняется, то базисное решение преобразуется так, чтобы значение целевой функции по возможности уменьшилось (или, по крайней мере, не возросло). Снова проверяется критерий оптимальности, и такая итерация повторяется

до тех пор, пока критерий оптимальности не выполнится. Для ТЗ доказано, что число итераций будет конечно, т. е. что не случится так называемого зацикливания или повторения допустимых базисных решений.

Исходное допустимое базисное решение, содержащее не более чем $n + m - 1$ клеток с ненулевыми перевозками, строится следующим образом.

Общий шаг. В транспортной таблице выбирается любая клетка, например клетка (s, t), и в ней устанавливается значение перевозки

$$x_{st} = \min(a_s, b_t).$$

Для поставщика A_s и потребителя B_t обновляются соответственно значения $a'_s = a_s - x_{st}$ и $b'_t = b_t - x_{st}$. Далее в ряду (строке или столбце) транспортной таблицы, где после такого обновления получили нулевое значение a'_s или b'_t, во всех оставшихся клетках устанавливают нулевые значения перевозок. После этого общий шаг повторяют для оставшейся, еще не заполненной части транспортной таблицы.

Примечание. Если после обновления величин a'_s и b'_t получилось, что обе они равны 0, то нулевые значения перевозок устанавливаем только в одном соответствующем ряду (например, только в строке), другой (неиспользованный) нуль подчеркиваем. Это так называемый активный нуль, который будет использоваться для заполнения клеток на последующих общих шагах и тем самым войдет в допустимое базисное решение.

После построения допустимого базисного решения вычисляем значение целевой функции. Поскольку решение ТЗ состоит в минимизации суммарных транспортных затрат, то уже на этапе построения исходного допустимого базисного решения имеет смысл использовать для заполнения стратегию выбора на каждом общем шаге клетки (s, t), которая соответствует минимальному значению стоимости перевозки единицы товара. Часто (но не всегда) такая стратегия сразу приводит к оптимальному решению.

Как уже отмечалось, построенное допустимое базисное решение оценивается на оптимальность с помощью специального критерия. Например, в так называемом методе потенциалов этими потенциалами фактически будут двойственные переменные u_i и v_j, причем для всех $n + m - 1$ клеток, принадлежащих допустимому базисному решению, выполняется равенство $u_i + v_j = c_{ij}$.

Доказано, что если при этом величины $\Delta_{ij} = u_i + v_j - c_{ij} \le 0$ для всех остальных (небазисных) клеток таблицы, то имеющееся допустимое базисное решение является оптимальным. Это и есть критерий оптимальности в методе потенциалов для решения ТЗ.

После получения решения ТЗ необходима его практическая интерпретация. Если в исходной постановке уравнение (2.22) выполнено, то полученные ненулевые значения представляют собой количество единиц товара перевозимого от поставщиков соответствующим потребителям.

Если в исходной постановке был вариант $\sum_{i=1}^{n} a_i > \sum_{j=1}^{m} b_j$, то оптимальные значения перевозок фиктивному потребителю будут в оптимальном плане означать величину неиспользованного предложения для соответствующих поставщиков. Если же в исходной постановке $\sum_{i=1}^{n} a_i < \sum_{j=1}^{m} b_j$, то оптимальные значения перевозок от фиктивного поставщика будут означать величину неудовлетворенного спроса для соответствующих потребителей.

Метод построения исходного базисного решения и определения значений перевозок в клетках транспортных таблиц может быть основанием для следующего утверждения.

Теорема 2.10. Если величины a_1, a_2, ..., a_n и b_1, b_2, ..., b_m целочисленные, то и оптимальное решение ТЗ будет целочисленно.

Таким образом, для ТЗ условие делимости исходных неизвестных не существенно.

2.9. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. В чем разница между задачами линейного и нелинейного программирования?
2. Охарактеризуйте условия, приводящие к линейности модели условной оптимизации.
3. Сформулируйте общую задачу раздела используемых ресурсов.
4. Сформулируйте общую задачу раздела производимых ресурсов.
5. Постройте и решите пример задачи о рюкзаке при делимых ресурсах.
6. Покажите на примере приемы сведения конкретной задачи ЛП к канонической форме.
7. Сформулируйте общую задачу ЛП в векторно-матричной форме.
8. Сформулируйте следствия, полученные на основе геометрической интерпретации задачи ЛП с двумя неизвестными.
9. В чем сущность методов решения задач ЛП?
10. Постройте задачу, двойственную конкретной задаче ЛП.
11. Что можно сказать о решении двойственной задачи ЛП, если решение прямой задачи неограниченно?
12. Какой смысл имеют двойственные переменные в задачах планирования продукции при ограниченных средствах производства?
13. В чем сущность постоптимального анализа задач ЛП?
14. Какие структурные изменения математической модели могут быть предметом анализа чувствительности решений задач ЛП?
15. Постройте оптимизационную модель производства Канторовича.
16. Какой смысл объективно обусловленных оценок в модели Канторовича?
17. Каковы предпосылки анализа макроэкономики в модели Леонтьева?
18. Охарактеризуйте понятие продуктивности модели Леонтьева.
19. Как вычислить матрицу коэффициентов полных затрат в модели Леонтьева?
20. Сформулируйте общую модель классической транспортной задачи в табличной постановке.
21. Опишите приемы построения замкнутой модели ТЗ.
22. Опишите алгоритм построения исходного допустимого базисного решения ТЗ в табличной постановке.
23. В чем суть методов решения ТЗ в табличной постановке?

3. СЕТЕВЫЕ МОДЕЛИ

3.1. ОСНОВНЫЕ ПОНЯТИЯ ТЕОРИИ ГРАФОВ

Многочисленные задачи принятия оптимальных решений сводятся к математическим моделям в виде конечных графов или сетей.

Конечным графом G называется пара (X, U), где X – конечное множество элементов любой природы; U – некоторое подмножество множества всех пар элементов из X.

Относительно элементов множества U (при $U \neq \varnothing$) возможны два случая, когда рассматриваются:

1) упорядоченные пары;

2) неупорядоченные пары.

В первом случае граф называется *ориентированным* (*орграфом*), во втором – *неориентированным*. Если граф ориентированный, тогда U – подмножество прямого произведения множества X на себя. Ориентированные графы можно задавать в виде пары (X, Γ), где Γ – отображение множества X на себя.

Всегда, если это осуществимо, граф можно изображать на плоскости в виде произвольно разбросанных помеченных точек множества X, которые связываются линиями в соответствии с определением пар из U. Если какая-то пара $[a, b] \in U$ или $(a, b) \in U$, то точки a и точки b соединяются между собой самонепересекающейся линией. Если пара не упорядочена – линия не имеет ориентации, если упорядочена, то указывается ориентация линии в виде стрелки, направленной от первой координаты пары ко второй.

Например, пусть $X = \{a, b, c, d, f\}$, $U = \{[a, b],[b, b],[a, f],[c, a],[d, f]\}$, тогда имеем неориентированный граф (рис. 3.1).

Если же $U = \{(a, b),(b, b),(a, f),(d, f),(c, a)\}$, то имеем ориентированный граф (рис. 3.2).

В ориентированном графе пара (a, b) отличается от пары (b, a), следовательно, возможна конфигурация, представленная на рис. 3.3.

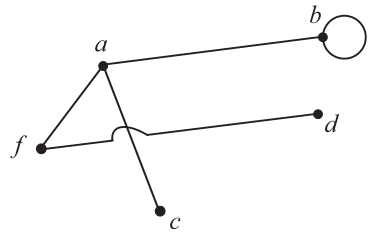

Рис. 3.1

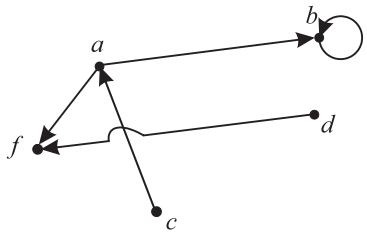

Рис. 3.2

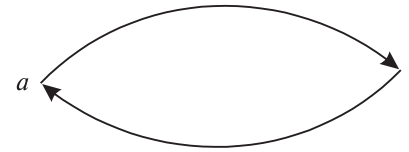

Рис. 3.3

В связи с геометрической интерпретацией в графе (X, U) элементы из X называют *вершинами*, упорядоченные пары из U – *дугами*, неупорядоченные – *ребрами*. Возможны и смешанные графы, в которых часть пар из U упорядочены, а часть нет.

Путем в орграфе называется последовательность вида $\big((x_1, x_2), (x_2, x_3), ..., (x_{n-1}, x_n)\big)$, причем конец каждой предыдущей пары в этой последовательности является началом последующей пары (рис. 3.4).

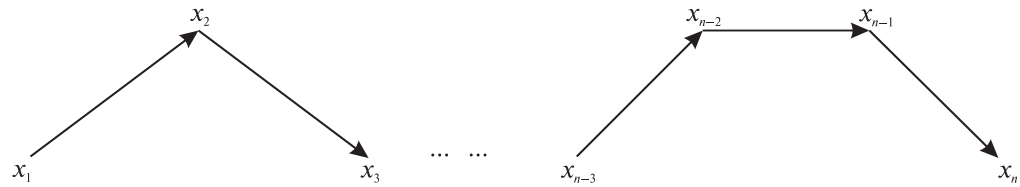

Рис. 3.4

Длиной пути обычно называется количество входящих в него дуг.

Путь называется *контуром*, если его начало совпадает с его концом, т. е. $x_n = x_1$. *Петлей* называется контур длиной 1.

Для неориентированных графов вводят понятие цепи аналогично понятию пути и понятие цикла аналогично понятию контура.

Неориентированный граф называется *связным*, если между любой парой вершин существует хотя бы одна цепь.

В орграфах существует аналогичное понятие сильной связности: орграф называется *сильно связным*, если между любой парой его вершин существует хотя бы один путь.

Если имеем любой неориентированный связный граф G, то из него можно последовательно удалять ребра так, чтобы сохранялась связность, пока не останется ровно $n - 1$ ребер, где n – число вершин графа. Полученный таким образом подграф называется деревом-остовом. Если к дереву-остову добавить одно ребро из вне остова, то в подграфе образуется ровно один цикл. Если из этого цикла удалить любое ребро, то получим новое дерево-остов.

Часто вместо обычных графов изучают более сложные объекты – мультиграфы. Мультиграф определяется в случае, если в множестве U его дуг (или ребер) одна и та же пара встречается несколько раз. Таким образом, в мультиграфах между парами вершин допускается наличие нескольких дуг (или ребер), идущих в одном направлении.

Примечание. Считается, что первую задачу на графах анализировал Л. Эйлер, который в 1736 г. опубликовал решение так называемой задачи о кенигсбергских мостах. Отдельные типы графов изучали У. Р. Гамильтон, М. Э. К. Жордан и др. Возникновение теории графов как отдельной математической дисциплины датируется 1936 г., когда вышла в свет монография Д. Кенига «Теория конечных и бесконечных графов». В последние 50 лет теория графов исключительно интенсивно развивалась, а также расширялись границы ее применения. Это объясняется тем, что по сути графы являются первичными формальными моделями систем, изучаемых в любой области знаний. В таких системах исследователь в первую очередь определяет множество составляющих ее элементов и далее выясняет попарные (бинарные) отношения между ними. В итоге получаются графы. Если вместо пар элементов выбираются другие (большие) подмножества, то возникают так называемые гиперграфы.

В ориентированных графах различают такие понятия, как полустепень захода и исхода для каждой вершины из X. *Полустепенью захода вершины* $x \in X$ называется количество входящих в эту вершину дуг, *полустепень исхода* – это количество дуг, исходящих из вершины.

Для неориентированных графов существует аналогичное понятие *степени вершины* – количество связанных с данной вершиной ребер.

Пусть задан граф $G = (X, U)$, причем множество X состоит из n элементов. *Матрицей смежности графа* G (или мультиграфа) называется квадратная матрица A порядка n, каждый элемент a_{ij} которой означает количество дуг (или ребер), связывающих вершину x_i с вершиной x_j. Естественно, что для обычных графов элементами матрицы смежности будут нули и единицы. Для мультиграфов в матрице смежности возможны и другие целочисленные элементы матрицы.

Пример 3.1. Для графа, представленного на рис. 3.5:

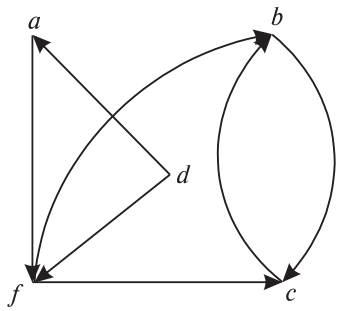

Рис. 3.5

матрица смежности имеет вид

$$A = \begin{array}{c} \\ a \\ b \\ c \\ d \\ f \end{array} \begin{array}{c} \begin{array}{ccccc} a & b & c & d & f \end{array} \\ \begin{bmatrix} 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 1 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 0 & 1 & 1 & 0 & 0 \end{bmatrix} \end{array}.$$

Теорема 3.1. Пусть $G = (X, U)$ и $H = (X, V)$ – два ориентированных мультиграфа с матрицами смежности $A = (a_{ij})_{n\times n}$ и $B = (b_{ij})_{n\times n}$. Тогда:

1) матрице $A + B$ соответствует мультиграф $G_{\oplus}$, который получается объединением множеств дуг U и V;

2) матрице $A \cdot B$ соответствует мультиграф $G_{\odot}$, который построен на множестве вершин X, и каждые две его вершины x и y соединяются таким количеством дуг, сколько существует между ними путей длины 2, причем первая дуга каждого такого пути должна принадлежать графу G, а вторая – графу H.

Пример 3.2. Пусть имеются два графа: G (рис. 3.6, *а*) и H (рис. 3.6, *б*). Результаты выполнения соответствующих операций $G_{\oplus}$ и $G_{\odot}$ представлены на рис. 3.6, *в*, *г*.

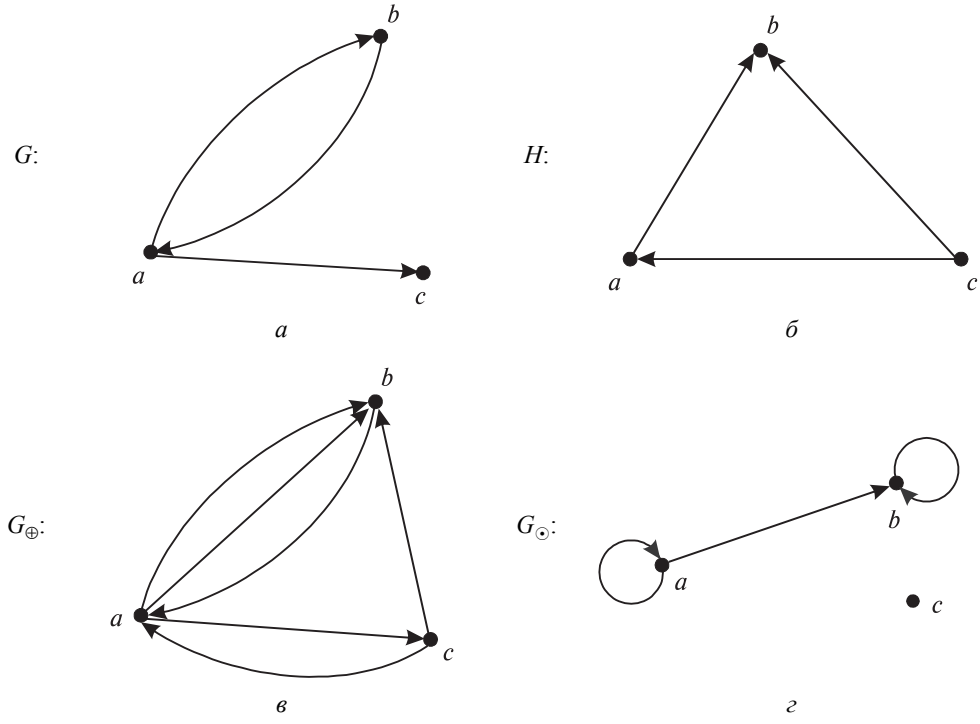

Рис. 3.6

Используя матрицы смежности, эти операции можно представить следующим образом:

$$A + B = \begin{bmatrix} 0 & 2 & 1 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix},$$

$$A \cdot B = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \cdot \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 1 & 1 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Доказательство. 1. В мультиграфе $G_{\oplus} = (X, U \cup V)$ между любой парой вершин x_i и x_j будет количество дуг, равное $a_{ij} + b_{ij}$, а это общий элемент матрицы $A + B$.

2. Посчитаем число путей вида (x_i, x_k, x_j), в которых $(x_i, x_k) \in U$, $(x_k, x_j) \in V$. Если зафиксировать вершину x_k, то число таких путей, что очевидно, равно $a_{ik} \cdot b_{kj}$. Если рассмотреть всевозможные пути при переменных x_k, то получим $\sum_{k=1}^{n} a_{ik} b_{kj}$, т. е. общий элемент матрицы $A \cdot B$.

Следствие 3.1. Если G – мультиграф и A – его матрица смежности, то каждый элемент p_{ij} матрицы A^{λ}, где λ – произвольное натуральное число, означает количество путей длины λ, связывающих вершину x_i с вершиной x_j графа G.

Доказательство. Для случая $\lambda = 1$ утверждение очевидно по определению матрицы смежности. Пусть утверждение верно для $\lambda - 1$. Учитывая, что $A^{\lambda} = A \cdot A^{\lambda-1}$, можно применить условие теоремы. Тогда длина пути будет равна сумме $1 + \lambda - 1 = \lambda$.

Пример 3.3. Если A – матрица смежности графа G, найдена матрица A^7 и ее элемент $p_{35} = 10$, то это означает, что в графе G между вершинами x_3 и x_5 существует 10 путей длины 7.

Следствие 3.2. В любом графе G существует путь длины λ (λ – любое натуральное число) тогда и только тогда, когда $A^{\lambda} \neq 0$. Не существует контуров тогда и только тогда, когда $A^{\lambda} = 0$ начиная с некоторого натурального λ.

Пример 3.4 (*задача о разузловании*). Пусть производится какое-либо сложное изделие, состоящее из различных узлов и деталей. Относительно любой пары «узел – изделие» или «деталь – узел» известно количество деталей или узлов, непосредственно используемых при изготовлении более сложных узлов или изделия. Задача разузлования состоит в том, чтобы определить, сколько всего необходимо всевозможных деталей и узлов для изготовления изделия.

Пусть, например, задача о разузловании описывается мультиграфом, приведенным на рис. 3.7, на котором V_2, V_4, V_9 – вершины графа, соответствующие изделиям; V_3, V_6 – соответствующие деталям. Остальные вершины соответствуют узлам разной степени сложности. Дуги указывают непосредственное вхождение, причем количество деталей или узлов, непосредственно используемых для более сложных, указано количеством стрелок на дугах.

Требуется определить, сколько всего деталей и узлов различной степени сложности нужно иметь, чтобы произвести по одному изделию V_2, V_4, V_9.

Для решения этой задачи можно использовать следующий способ. Построим матрицу непосредственных (прямых) затрат как матрицу A смежности данного мультиграфа. Тогда матрицу T полных затрат можно считать по формуле

$$T = E + A + A^2 + \ldots. \tag{3.1}$$

Формула (3.1) интерпретируется следующим образом: при подсчете всевозможных прямых и косвенных вхождений учитываются непосредственные вхождения (это слагаемое A), далее к ним нужно добавить всевозможные косвенные вхождения через одну промежуточную вершину, т. е. необходимо перечислить пути длины два. По следствию 3.1. такие пути задаются матрицей A^2, затем следует учитывать косвенные вхождения, проходящие через две промежуточные вершины, т. е. всевозможные пути длины три, которые задаются матрицей A^3, и т. д. Формально добавляется также еди-

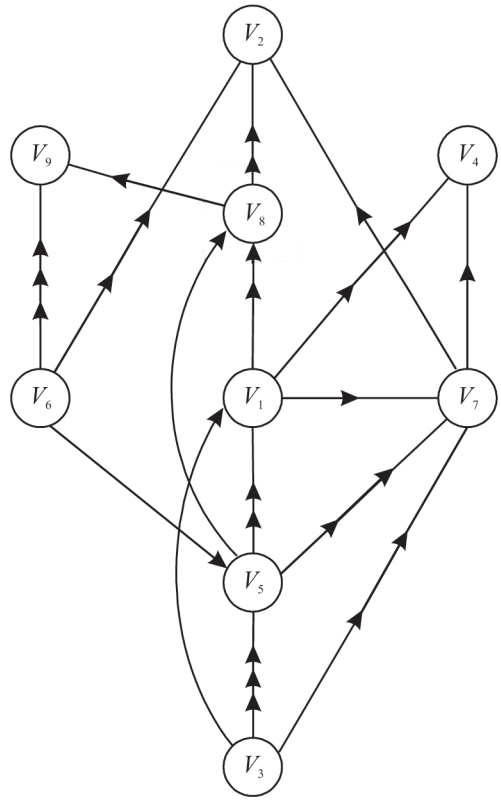

Рис. 3.7

ничная матрица E, которая отражает необходимость наличия хотя бы единицы каждой детали, узла и изделия.

Из-за содержательного смысла в графе (в соответствующих задачах о разузловании) нет контуров: деталь или узел не может использоваться для производства самого себя. В соответствии со следствием 3.2 это означает, что существует натуральное λ, начиная с которого $A^{\lambda} = 0$, т. е. (3.1) примет вид

$$T = E + A + A^2 + \ldots + A^{\lambda-1}. \tag{3.2}$$

Непосредственно из матричного исчисления получим, что

$$E + A + A^2 + \ldots + A^{\lambda-1} = (E - A)^{-1}.$$

Значение $\lambda - 1$ означает длину максимального пути в исследуемом мультиграфе. При использовании формулы (3.1) это значение может быть заранее не известно, поэтому придется выполнить лишнее умножение матриц, пока не получим $A^{\lambda} = 0$.

Матрица T полных затрат исключительно важна при планировании производства. Если план производства узлов и изделий на какой-то временной период задан в виде вектор-столбца b, то, вычисляя

$$T \cdot b = (E - A)^{-1} \cdot b,$$

определим общие потребности во всех деталях и узлах для выполнения плана.

Для нашего примера

$$\lambda - 1 = 4,\ \ A^5 = 0,\ T = E + A + A^2 + A^3 + A^4:$$

$$A = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \\ 8 \\ 9 \end{array}\!\!\begin{bmatrix} 0 & 0 & 0 & 2 & 0 & 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 3 & 0 & 2 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & 0 & 0 & 0 & 2 & 1 & 0 \\ 0 & 2 & \mathbf{0} & 0 & 1 & 0 & 0 & 0 & 3 \\ 0 & 1 & 0 & 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix},\quad T = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \\ 8 \\ 9 \end{array}\!\!\begin{bmatrix} 1 & 3 & 0 & 3 & 0 & 0 & 1 & 1 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & 0 & 0 \\ 7 & 33 & 1 & 27 & 3 & 0 & 15 & 10 & 10 \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & 0 & \mathbf{0} \\ 2 & 10 & 0 & 8 & 1 & 0 & 4 & 3 & 3 \\ 2 & 12 & 0 & 8 & 0 & 1 & 4 & 3 & 6 \\ 0 & 1 & 0 & 1 & 0 & 0 & 1 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}.$$

Каждый элемент t_{ij} матрицы T означает количество деталей или узлов i-го вида, необходимых для изготовления более сложных узлов (или изделия) j-го вида. Так, $t_{32} = 33$ означает, что для изготовления V_2 необходимо 33 детали V_3. Знание элементов матрицы полных затрат T является особо важным при планировании производства.

На практике существует другой способ решения задачи о разузловании, когда последовательно, сверху вниз, расписываются уравнения вхождения каждого узла и детали. Например, $A_9 = 3A_6 + A_8$.

Аналогичные приемы нахождения матрицы полных затрат по формуле типа (3.1) применяются и для случаев, когда мультиграф имеет контуры. Одной из таких важных задач является проблема так называемого межотраслевого баланса (см. п. 2.7). В этом случае вершины графа – это отрасли народного хозяйства. В таком графе уже могут быть контуры, потому что продукт отрасли может непосредственно использоваться для производства самого себя. Для отыскания матрицы полных затрат обычно используют формулу (3.1), но при этом необходимо доказать сходимость матричного ряда. Ряд сходится, если все собственные значения матрицы A по модулю меньше 1.

Как уже отмечалось, определение матрицы T в межотраслевом балансе является одной из основных задач при планировании народного хозяйства.

3.2. ПОТОКИ В СЕТЯХ. ОСНОВНЫЕ ПОНЯТИЯ

Сетью будем называть любой орграф без петель, у которого каждой дуге приписано фиксированное действительное число.

Пусть каждой дуге (x, y) сети $G = (X, U)$ поставлено в соответствие неотрицательное число $c(x, y)$. Это число будем называть пропускной способностью дуги. Наглядно можно представить, что значение $c(x, y)$ является максимальным количеством какого-то однородного товара, которое можно провезти по дуге (x, y).

Пусть в сети зафиксированы две вершины s, t.

Определение 3.1. Стационарным потоком величины v из вершины s в вершину t в сети $G = (X, U)$ называется функция $f(x, y)$, определенная на всех дугах $(x, y) \in U$, которая удовлетворяет следующим условиям:

$$0 \le f(x, y) \le c(x, y) \text{ для всех } (x, y) \in U; \tag{3.3}$$

$$\sum_{y \in A(x)} f(x, y) - \sum_{y \in B(x)} f(y, x) = \begin{cases} v, & \text{если } x = s, \\ 0, & \text{если } x \ne s, t, \\ -v, & \text{если } x = t, \end{cases} \tag{3.4}$$

где $A(x)$ – множество вершин сети, которые являются концами дуг, выходящих из вершины x; $B(x)$ – множество вершин сети, которые являются началами дуг, входящих в вершину x.

Вершина s в случае задания потока по формулам (3.3), (3.4) называется *источником*, вершина t – *стоком*.

Условие (3.3) означает, что поток по каждой дуге не должен превышать ее пропускную способность. Условия (3.4) показывают, что для источника s алгебраическая сумма величин выходящего и входящего потоков равна v – величине потока в сети.

Аналогично для стока t суммарное количество входящего и выходящего потоков также равно v. Для всех остальных промежуточных вершин сети выполняется равенство

$$\sum_{y} f(x, y) - \sum_{y} f(y, x) = 0,$$

т. е. должен выполняться баланс.

Пример 3.5. Предположим, что пропускные способности дуг (рис. 3.8) – некоторые достаточно большие числа. Например, все $c(x, y) = 4$. Тогда числа, проставленные на дугах, обозначают величину $f(x, y)$ на каждой дуге. Значение $f(x, y)$ удовлетворяет условиям (3.3), (3.4), значит, определен стационарный поток.

Для каждой промежуточной вершины:

$$x_1 : 4 = 2 + 1 + 1,$$
$$x_2 : 1 + 1 = 1 + 1,$$
$$x_3 : 1 + 2 = 2 + 1;$$

для источника s: $-2 + 4 + 1 = 3$;
для стока t: $4 - 1 = 3$, т. е. величина потока $v = 3$.

Определение 3.2. Разрезом сети, отделяющим источник s от стока t, будем называть множество дуг, обозначаемое через $(X_1, \bar{X}_1)$, такое, что каждая дуга начинается в множестве X_1 и оканчивается в множестве $\bar{X}_1$, и

$$s \in X_1, t \in \bar{X}_1, X_1 \cup \bar{X}_1 = X, X_1 \cap \bar{X}_1 = \varnothing,$$

т. е. $\bar{X}_1 = X \setminus X_1$.

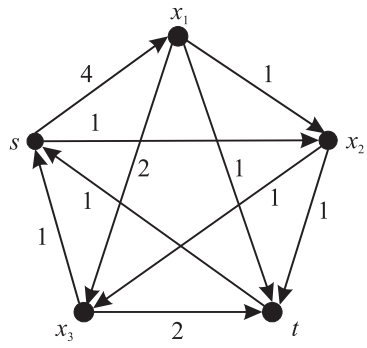

Рис. 3.8

Для построения произвольного разреза достаточно задать множество вершин X_1 как непустое подмножество X, содержащее s и не содержащее t, тогда $\overline{X}_1$ будет дополнением X_1 до множества X.

Для приведенного выше примера, если

$$X_1 = \{s, x_2\}, \quad \overline{X}_1 = \{t, x_1, x_3\}.$$

Разрез состоит из следующих дуг:

$$(X_1, \overline{X}_2) = \{(s, x_1), (x_2, x_3), (x_2, t)\}.$$

Лемма 3.1. Любой путь из s в t на заданной сети содержит, по крайней мере, одну дугу произвольного разреза, отделяющего s от t.

Доказательство. Пусть задан произвольный путь из s в t, проходящий, например, через вершины $s, x_1, x_2, \ldots, x_n, t$. При движении по этому пути с обеих сторон, от s и от t, обязательно возникает ситуация, когда две соседние вершины, лежащие на этом пути, будут принадлежать двум соседним множествам X_1 и $\overline{X}_1$, т. е. определять дугу разреза.

Следствие 3.3. Если из сети убрать дуги произвольного разреза, то не останется путей, ведущих из s в t.

Введем вспомогательные обозначения. Если на сети $G = (X, U)$ для каждой дуги $(x, y) \in U$ задана действительная функция $g(x, y)$, то будем обозначать

$$\sum_{\substack{x \in X_1 \subset X \\ y \in X_2 \subset X}} g(x, y) = g(X_1, X_2).$$

Аналогично, если на каждой вершине $x \in X$ определить функцию $h(x)$:

$$\sum_{x \in X_1 \subset X} h(x) = h(X_1).$$

Если на множестве всех дуг сети задана произвольная действительная функция $g(x, y)$, то имеют место следующие два равенства:

$$g(X_1, X_2 \cup X_3) = g(X_1, X_2) + g(X_1, X_3) - g(X_1, X_2 \cap X_3); \tag{3.5}$$

$$g(X_1 \cup X_2, X_3) = g(X_1, X_3) + g(X_2, X_3) - g(X_1 \cap X_2, X_3). \tag{3.6}$$

В этих формулах X_1, X_2, X_3 – произвольные подмножества вершин сети. Для доказательства, например, равенства (3.5) достаточно учесть схему, представленную на рис. 3.9.

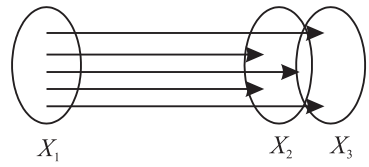

Рис. 3.9

Лемма 3.2. Пусть f – произвольный поток величины v из s в t на сети $G = (X, U)$, и пусть $(X_1, \overline{X}_1)$ – произвольный разрез, отделяющий источник s от стока t на сети. Тогда имеют место следующие соотношения:

$$v = f(X_1, \overline{X_1}) - f(\overline{X_1}, X_1) \le c(X_1, \overline{X_1}). \tag{3.7}$$

Здесь на основании введенных обозначений:

$$f(X_1, \overline{X}_1) = \sum_{(x,y)\in(X_1,\overline{X}_1)} f(x,y);$$

$$f(\overline{X}_1, X_1) = \sum_{(x,y)\in(\overline{X}_1,X_1)} f(y,x);$$

$$c(X_1, \overline{X}_1) = \sum_{(x,y)\in(X_1,\overline{X}_1)} c(x,y).$$

Величина $c(X_1, \overline{X}_1)$ называется пропускной способностью разреза $(X_1, \overline{X}_1)$.

Доказательство. Поскольку f – поток из s в t, то, следовательно, по определению в сокращенной записи он удовлетворяет следующим равенствам:

$$f(s, X) - f(X, s) = v \quad \text{для любых} \quad x \in X;$$

$$f(x, X) - f(X, x) = 0 \quad \text{для любых} \quad x \in X;$$

$$f(t, X) - f(X, t) = -v \quad \text{для любых} \quad x \in X.$$

Для заданного разреза $(X_1, \overline{X}_1)$ выберем множество вершин, принадлежащих X_1, и просуммируем все вышеописанные равенства, относящиеся к вершинам $x \in X_1$.

В итоге получим

$$v = f(X_1, X) - f(X, X_1) = f(X_1, X_1 \cup \overline{X_1}) - f(X_1 \cup \overline{X_1}, X_1) =$$

$$= f(X_1, \overline{X_1}) - f(X_1, X_1 \cap \overline{X_1}) - f(\overline{X_1}, X_1) + f(X_1 \cap \overline{X_1}, X_1) =$$

$$= f(X_1, \overline{X_1}) - f(\overline{X_1}, X_1),$$

и первая часть доказана.

Учтем, что при определении потока должно выполняться условие (3.3), что означает $f(\overline{X}_1, X_1) \ge 0$ из-за неотрицательности любого потока в сети. Кроме того, $f(X_1, \overline{X}_1) \le c(X_1, \overline{X}_1)$ из-за того, что поток по любой дуге не больше ее пропускной способности. Из этих неравенств следует, что

$$f(X_1, \overline{X}_1) - f(\overline{X}_1, X_1) \le f(X_1, \overline{X}_1) \le c(X_1, \overline{X}_1).$$

Лемма доказана.

3.3. ЗАДАЧА О МАКСИМАЛЬНОМ ПОТОКЕ. ТЕОРЕМА ФОРДА – ФАЛКЕРСОНА

На любой сети с заданными на ее дугах пропускными способностями $c(x, y)$ можно построить сколь угодно много потоков, т. е. указать как угодно много функций f, удовлетворяющих условиям (3.3)–(3.4). Задача о максимальном потоке состоит в нахождении f, удовлетворяющей (3.3)–(3.4), при котором целевая функция v принимает максимальное значение. Неизвестными в задаче о максимальном потоке являются переменные $f(x, y)$ для каждой дуги (x, y) и переменная v. Условия (3.3)–(3.4) и вид целевой функции, т. е. $f = v$, показывают, что задача о максимальном потоке представляет собой задачу линейного программирования. Специфика задачи позволяет решить ее непосредственно на сети методом более эффективным, чем методы решения задач линейного программирования. Обоснованием этого метода является следующее утверждение.

Теорема 3.2 (*Форда – Фалкерсона*). Для любой сети с источником s и стоком t максимальная величина потока из s в t равна минимальной пропускной способности разреза, отделяющего s от t.

Доказательство. Для того чтобы доказать утверждение, достаточно для какого-то потока подобрать разрез $(X_1, \overline{X}_1)$, отделяющий s от t, при котором вторая часть леммы 3.2 превращается в равенство. В самом деле, если будет выполняться равенство величины потока и пропускной способности разреза, то потока с большей величиной, т. е. $v' > c(X_1, \overline{X_1})$, быть не может из-за того, что это противоречит лемме 3.2. По этой же причине не может существовать разреза с меньшей пропускной способностью, так как снова приходим к неравенству $v > c(X_1', \overline{X_1'})$, что также противоречит лемме 3.2.

Предположим, что f – максимальный поток. Такой поток всегда существует, поскольку существует допустимый поток, например нулевой, и из-за того, что область допустимых потоков ограничена, например, неравенством (3.3): $0 \le f \le c$. По выбранному f построим разрез, используя следующее правило:

а) s будем относить к множеству X_1, т. е. $s \in X_1$;

б) если $x_1 \in X_1$ и для дуги (x_1, y) выполняется неравенство $f(x_1, y) < c(x_1, y)$, то $y \in X_1$. Аналогично, если (y_1, x) имеет ненулевой поток, т. е. $f(y, x_1) > 0$, то $y \in X_1$. В итоге многократного применения этого правила, пока есть такая возможность, будет построено множество X_1, и, для того чтобы это множество определяло разрез, отделяющий s от t, необходимо показать, что сток $t \notin X_1$.

Предположим противное: $t \notin X_1$. Это означает, что в сети существует цепь вида $(s, x_1, ..., x_n, t)$, ведущая из вершины s в вершину t, такая, что на каждой дуге вида (x_i, x_{i+1}) с ориентацией, совпадающей с направлением пути от s к t, должно выполняться неравенство $f(x_i, x_{i+1}) < c(x_i, x_{i+1})$ (на основании правила). Аналогично для каждой дуги вида (x_{i+1}, x_i) с ориентацией, противоположной направлению пути от s к t, выполняется неравенство $f(x_{i+1}, x_i) > 0$.

Вычислим ε_1 как минимум разностей $c - f$ на всех дугах с ориентацией, совпадающей с направлением пути от s к t, а также ε_2 как минимум значений f на всех дугах с ориетацией, противоположной направлению пути от s к t.

Найдем $\varepsilon = \min(\varepsilon_1, \varepsilon_2)$. Очевидно, что $\varepsilon > 0$. Изменим поток на выбранной цепи от s к t. На всех дугах, направление которых совпадает с направлением от s к t, увеличиваем значение f на ε. На всех дугах, обратных направлению от s к t, уменьшим значение f на ε.

В результате такого преобразования значений потоков на выбранной цепи новые значения будут образовывать поток и общая величина потока в сети увеличится на величину $\varepsilon > 0$. Поскольку, по предположению, поток в сети f максимальный, то получилось противоречие. Следовательно, $t \notin X_1$. Таким образом, множество X_1 определяет разрез $(X_1, \bar{X}_1)$, отделяющий s от t. Для всех $(x, y) \in (X_1, \overline{X_1})$ должно выполняться строгое равенство $f(x, y) = c(x, y)$. Если бы это равенство не выполнялось, то по правилу построения вершина y не принадлежала бы множеству $\overline{X_1}$.

Аналогично для дуг вида $(y, x) \in (\overline{X_1}, X_1)$ должно выполняться равенство $f(y, x) = 0$. В противном случае, согласно правилу, y принадлежало бы множеству X_1. На основании двух последних равенств и леммы 3.2 (вторая часть):

$$f(X_1, \bar{X}_1) - f(\bar{X}_1, X_1) = c(X_1, \bar{X}_1)$$

приходим к равенству

$$f(X_1, \bar{X}_1) = c(X_1, \bar{X}_1) = v.$$

Таким образом, мы нашли разрез, пропускная способность которого совпадает с величиной потока в сети.

Теорема доказана.

Определение 3.3. Назовем некоторую цепь из s в t *увеличивающей поток* в заданной сети, если на всех дугах, совпадающих по направлению от s к t, выполняется неравенство $f < c$ и аналогично на всех дугах, не совпадающих по направлению, $f > 0$.

Следствие 3.4. Поток f является максимальным тогда и только тогда, когда в сети не существует ни одной цепи, увеличивающей поток.

Доказательство легко проводится на основании схемы доказательства теоремы Форда – Фалкерсона.

Теорема и следствие являются основой для разработки алгоритма построения максимального потока. Необходимо систематизировать поиск цепей, увеличивающих поток.

Алгоритм расстановки пометок

Пусть имеется сеть $G = (X, U)$, на каждой дуге (x, y) которой заданы величины $c(x, y)$. Считаем, что $c(x, y)$ – рациональные числа. Не уменьшая общности (из-за возможности подбора масштаба измерений), можно рассматривать задачу при целочисленных $c(x, y)$. В практических задачах предположения о рациональности $c(x, y)$ достаточно.

Алгоритм начинается с произвольного начального потока в сети. В качестве такого начального потока можно выбирать нулевой поток, когда все $f(x, y) = 0$.

Алгоритм состоит из двух этапов:

На I этапе систематизируется поиск пути, увеличивающего поток. Это осуществляется с помощью расстановки пометок. При этом каждая вершина находится в одном из трех состояний:

а) *непомеченная*; б) *помеченная* и *непросмотренная*; в) *просмотренная*.

Этап I начинается в момент, когда все вершины не помечены. После завершения этапа I на этапе II в случае обнаружения пути, увеличивающего поток, происходит изменение (увеличение) этого потока. Шаг повторяется.

I э т а п – расстановка пометок.

Источник s получает пометку вида $(-, \infty)$. После этого он становится помеченным и непросмотренным. Пусть существует несколько помеченных и непросмотренных вершин. Выберем среди них вершину x. Перебирая всевозможные дуги (x, y), проверяем на них условие $f(x, y) < c(x, y)$. Если для какой-то дуги (x, y) это выполняется, то вершина y получает пометку $(x^+, \varepsilon(y))$, где

$$\varepsilon(y) = \min[\varepsilon(x), c(x, y) - f(x, y)]. \tag{3.8}$$

После того как будут рассмотрены все дуги вида (x, y), перебирают дуги вида (y, x), и для них проверяется условие $f(y, x) > 0$. Если на какой-то из дуг это неравенство выполняется, то вершина y получает пометку $(x^-, \varepsilon(y))$, где

$$\varepsilon(y) = \min[\varepsilon(x), f(y, x)]. \tag{3.9}$$

В обоих случаях помечаются вершины, которые раньше не были помечены. После этого вершина x становится просмотренной, выбирается очередная помеченная и непросмотренная вершина, и для нее повторяются все описанные выше действия. Расстановка пометок продолжается до тех пор, пока или не будет помечена вершина t (сток сети), или можно будет сделать вывод, что сток t пометить нельзя. В последнем случае алгоритм заканчивает свою работу, и это означает, что оптимальный поток найден на предыдущем шаге. При этом сразу определяется соответствующий ему минимальный разрез сети, который состоит из дуг, ведущих из помеченных на последнем шаге вершин в непомеченные.

В первом случае, когда сток t будет помечен, перейдем к этапу II.

II э т а п – увеличение потока.

Сток t может получить одну из двух пометок: $(x^+, \varepsilon(t))$ или $(x^-, \varepsilon(t))$.

Если t имеет пометку $(x^+, \varepsilon(t))$, поток по дуге (x, t) увеличивается на значение $\varepsilon(t)$. Если t имеет пометку $(x^-, \varepsilon(t))$, поток по дуге (t, x) уменьшается на значение $\varepsilon(t)$.

В любом из этих случаев приходят к вершине x, которая указана в первой части пометки вершины t. Эта вершина имеет пометку $(y^+, \varepsilon(x))$ или $(y^-, \varepsilon(x))$. В первом случае поток по дуге (y, x) увеличивается на $\varepsilon(t)$, во втором – поток по дуге (x, y) уменьшается на $\varepsilon(t)$. В любом из этих случаев приходят к анализу пометки вершины y. Такое изменение потока на дугах повторяется до тех пор, пока не будет достигнута вершина s. После этого удаляются все прежние пометки вершин, и этап I повторяется с новым начальным потоком.

Пример 3.6. В данной сети (рис. 3.10 и 3.11) первые числа на дугах означают пропускные способности, а вторые – величины потоков на дугах, т. е. начальный поток нулевой. Вершине s присваиваем пометку $(-, \infty)$. Тогда s становится помеченной, но непросмотренной. Нужно перебрать дуги (s, x_1), (s, x_2). На них проверяем условие $f < c$, и так как для них оно выполняется, соответственно, присваиваются пометки $x_1 : (s^+, 3)$, $x_2 : (s^+, 2)$.

Рассмотрим выходящие дуги для $x_1 : (x_1, x_2)$, но вершина x_2 уже помечена. Входящие дуги $(s, x_1), (x_2, x_1), (x_3, x_1)$, вершины x_1 и x_3 уже помечены, x_2 пометить нельзя, $f = 0$, x_1 – просмотрена, x_3 – помечена, но не просмотрена. Чтобы пометить t, рассмотрим дугу (x_3, t). Поскольку $f < c$, то t получает пометку $(x_3^+, 2)$. Вершина t достигнута, следовательно, поток по дуге (x_3, t) можно увеличить на 2 и далее поток по дуге (s, x_3) тоже увеличить на 2. Повторяем этапы I и II, пока не получим поток, представленный на рис. 3.11.

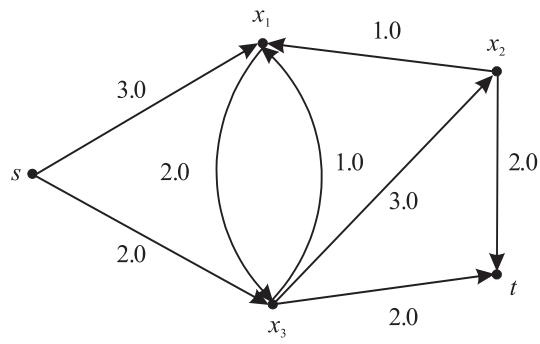

Рис. 3.10

На последнем шаге помечают s, x_1, но t не помечается, значит, поток, достигнутый на предыдущем шаге, является максимальным и при этом $X_1 = \{s, x_1\}$. Величина потока $v = 4$. Пропускная способность разреза $c(X_1, \overline{X_1}) = 4$, т. е. выполняется условие теоремы Форда – Фалкерсона.

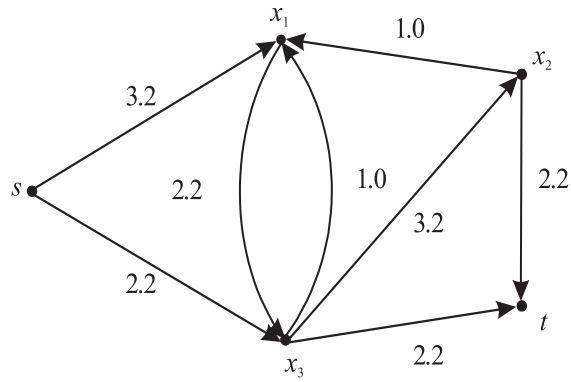

Рис. 3.11

В случае нахождения на этапе I пути, увеличивающего поток, этот поток увеличивается на величину $\varepsilon(t)$. Кроме того, $\varepsilon(t)$, по предположению о целочисленности $c(x, y)$, – целое число. Следовательно, на каждом этапе I поток увеличивается на ненулевое конечное число. Поскольку величина потока ограничена, то число шагов конечно: каждый шаг приближает на целое число величину потока к максимальному. Если пропускные способности – иррациональные числа, то можно построить такой пример, что количество шагов для метода расстановки пометок будет бесконечным.

Алгоритм расстановки пометок может служить обоснованием следующего утверждения.

Теорема 3.3 (*о целочисленности максимального потока*). Если пропускные способности сети целочисленны, то максимальный поток из s в t также целочислен.

Замечание. Задача о максимальном потоке существенно усложняется, если в сети транспортируются товары нескольких видов.

3.4. НЕКОТОРЫЕ ОБОБЩЕНИЯ ЗАДАЧИ О МАКСИМАЛЬНОМ ПОТОКЕ

Несколько источников и/или стоков. В этом случае в постановке задачи выделено несколько вершин вида $s_1, ..., s_n$ – источников и $t_1, ..., t_m$ – стоков. Требуется найти максимальный поток однородного товара, выходящий из $s_1, ..., s_n$ и входящий в $t_1, ..., t_m$. Этот случай легко сводится к классической задаче с одним источником и одним стоком путем введения общего источника s и общего стока t и добавления в сеть новых дуг вида (s, s_i), $i = 1, 2, ..., n$; (t_j, t), $j = 1, 2, ..., m$, с пропускной способностью, равной бесконечности. Любой поток (в том числе и максимальный) на исходной сети можно расширить до потока на новой сети с искусственным источником и стоком. Наоборот, максимальный поток на расширенной сети останется максимальным после удаления вершин s и t.

Нижние пропускные способности. На практике для любой дуги сети (x, y), кроме $c(x, y)$ – верхней пропускной способности дуги, могут быть заданы $l(x, y) > 0$ – нижние пропускные способности, и поток в сети определяется так, чтобы кроме общих требований выполнялось $l \le f \le c$. Для решения этой задачи применима небольшая модификация метода расстановки пометок.

Предполагается, что найден какой-то начальный поток, удовлетворяющий $l \le f \le c$ (нулевой поток уже не подходит). Если начальный поток есть, то модификация расстановки пометок состоит в том, что вычисление $\varepsilon(y)$ производится не по формуле (3.9), а по формуле $\varepsilon(y) = \min[\varepsilon(x), f(y, x) - l(y, x)]$ на каждой (y, x), для которой $f(y, x) > l(y, x)$. Остальное остается прежним. Метод построения начального потока основан на решении так называемой задачи о циркуляции потока.

Потоки в смешанных и неориентированных сетях. Пусть несколько или все дуги в сети не имеют ориентации. Предполагается, что пропускные способности заданы на каждой дуге, причем на неориентированных дугах пропускная способность принимается равной в обоих направлениях.

Требуется найти такой поток, который, кроме обычных ограничений, будет удовлетворять условию $f(x, y) \cdot f(y, x) = 0$. Для всех неориентированных дуг это означает, что ненулевой поток между двумя вершинами возможен только в одном направлении.

Алгоритм решения такой задачи состоит в следующем.

Вместо каждой неориентированной дуги вводят две ориентированные в различных направлениях. Далее решается задача о максимальном потоке в полученной расширенной ориентированной сети. Если хотя бы на одной введенной паре дуг получаются оба ненулевых потока, то поток по дуге с $\min(f_1, f_2)$ делают нулевым, а поток на другой равен разности между величиной существующего потока и значением $\min(f_1, f_2)$.

Таким образом, после того как решена задача о максимальном потоке на ориентированной сети, на дугах с противоположными направлениями происходит как бы сокращение потока и дуга, где поток становится нулевым, считается несуществующей. В результате будет найден максимальный поток и направления неориентированных дуг, при которых величина потока в сети максимальна.

Такая задача имеет практическое применение, например, при установлении знаков одностороннего движения на улицах городов: необходимо выбрать такие направления движения, чтобы общий поток был максимальным.

Задача с пропускными способностями вершин. Пусть в сети $G = (X, U)$, кроме пропускных способностей $c(x, y)$ каждой дуги, заданы также величины $k(x)$, $x \in X$, называемые пропускными способностями вершин. Число $k(x)$ означает, например, величину потока, который может выходить из вершины x. Требуется построить максимальный поток в сети из источника s в сток t, который, кроме обычных ограничений на поток, удовлетворяет ограничениям типа $f(x, X) \le k(x)$. Для сведения этой задачи к обычной задаче о максимальном потоке используется следующий прием.

Каждую вершину x, для которой задана величина $k(x)$, заменяют на две вершины вида x'' и x'. Между ними вводится дуга (x'', x') с пропускной способностью $c(x'', x') = k(x)$.

Если в сети было две вершины x и y, которые после преобразования превратятся в вершины x'', x' и y'', y', и если в старой сети была дуга (x, y), то в новой сети обязательно появится дуга вида (x', y'') с пропускной способностью $c(x, y)$.

Таким образом, после «раздвоения» вершин дуги, соответствующие дугам исходной сети, должны будут выходить из правой вершины вида x' и входить в левую вершину вида y''. На этой новой сети решается задача о максимальном потоке. Очевидно, что полученное решение легко перенести на старую сеть и при этом будут выполняться условия, налагающиеся на пропускные способности дуг и вершин.

Пример 3.7. Исходная сеть с пропускными способностями дуг (обозначены цифрами) и вершин (обозначены буквами), приведена на рис. 3.12.

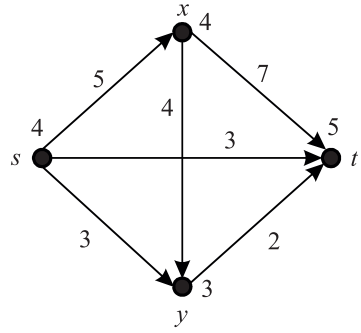

Рис. 3.12

Далее она превращается в сеть, представленную на рис. 3.13.

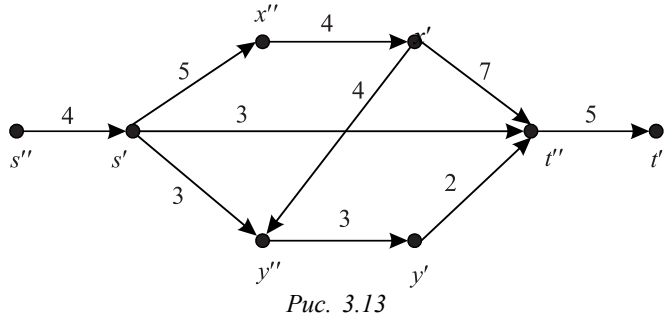

Рис. 3.13

На вновь полученной сети решается стандартная задача о максимальном потоке из s'' в t'.

3.5. ТЕОРЕМА КЕНИГА – ЭГЕРВАРИ. ПОСТРОЕНИЕ МАКСИМАЛЬНЫХ ПАРОСОЧЕТАНИЙ

Рассмотрим граф $G = (X, U)$ специального вида, а именно: у этого графа вершины разделены на подмножества S и T, причем $S \cap T = \varnothing$ и для каждой дуги $(x, y) \in U$, $x \in S$ и $y \in T$. Такие графы называются двусторонними или двудольными.

Определение. *S,T*-рассекающим множеством вершин двудольного графа будем называть любое множество вершин, исключение которого из графа G приводит к блокированию дуг, ведущих из S в T. Например, *S,T*-рассекающим множеством может быть множество S.

Во многих практических задачах на двудольных графах анализируются объекты, соответствующие множествам дуг, попарно не имеющих общих вершин. Эти объекты называются паросочетаниями. Естественно, возникают задачи о максимальных (по числу дуг) паросочетаниях.

Пример 3.8. Паросочетанием (причем максимальным) на графе (рис. 3.14) будет множество

$$\{(x_1, y_2), (x_4, y_1), (x_3, y_4), (x_5, y_3)\}.$$

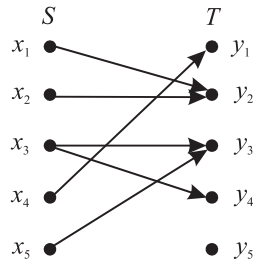

Рис. 3.14

Теорема 3.4 (*Кенига – Эгервари*). Максимальное число дуг двудольного графа G, попарно не имеющих общих вершин, равно минимальному числу вершин в некотором *S,T*-рассекающем множестве.

Доказательство. Сведем исходный двудольный граф к сети путем добавления новых вершин s и t, дуг типа (s, x) для любых $x \in S$ и дуг типа (y, t) для любых $y \in T$. Пропускные способности дуг зададим по формулам: $c(s, x) = 1$ для любых $x \in S$; $c(y, t) = 1$ для любых $y \in T$; $c(x, y) = \infty$ для любых $(x, y) \in U$.

Решим на этой сети задачу о максимальном потоке.

Пусть это будет функция f и $(X_1, \overline{X_1})$ – минимальный разрез сети, отделяющий s от t и соответствующий построенному максимальному потоку.

Построим множество $I = \{(x, y) \in U : f(x, y) = 1\}$. Не трудно убедиться, что дуги множества I попарно не имеют общих вершин. Это объясняется тем, что в каждую из вершин-начал $x \in S$ может перейти только единица потока и из-за целочисленности потока из этой вершины данная единица потока уйдет только по одной дуге.

Аналогично каждая такая дуга не будет иметь общей вершины – конца.

Построим множество $D = (S \cap \overline{X}_1) \cup (T \cap X_1)$, где $T \cap X_1$ – множество помеченных на последнем шаге стоков; $S \cap \overline{X}_1$ – множество непомеченных на последнем шаге источников.

Множество D обладает двумя свойствами:

• является S,T-рассекающим множеством, так как если из сети убрать это множество вершин, то не останется дуг, ведущих из S в T. Если бы оставалась хотя бы одна такая дуга, то это означало бы, что при построении максимального потока какая-то вершина из S была помеченной и являлась началом дуги, ведущей в непомеченную вершину из T. Однако если на последнем шаге алгоритма отыскания максимального потока будет помечена вершина из S и есть выходящая из этой вершины дуга в T, то необходимо будет пометить вершину из T;

• вершины из множества D взаимно-однозначно соответствуют дугам минимального разреза $(X_1, \overline{X_1})$, потому что в множестве D имеется либо начало каждой такой дуги, либо ее конец, а вместе они не присутствуют.

Поскольку выбранный поток f в сети максимален, то по теореме Форда – Фалкерсона будем иметь, что $|I| = |D|$, где $|D|$ – величина минимального разреза; $|I|$ – величина максимального потока. Таким образом, найден случай, когда множество дуг, попарно не имеющих общих вершин, по мощности равно количеству вершин множества D.

Следовательно, найдено максимальное множество дуг, не имеющих общих вершин, и минимальное S,T-рассекающее множество.

Теорема доказана.

Возможен другой вариант формулировки доказанной теоремы.

Дело в том, что исходную задачу можно свести к табличному варианту. Таблица, соответствующая исходному двудольному графу, строится следующим образом.

Если имеем множества $S = \{x_1, ..., x_n\}$ и $T = \{y_1, ..., y_m\}$, то таблица будет состоять из n строк, помеченных метками $x_1, ..., x_n$, и m столбцов с метками $y_1, ..., y_m$. Клетки таблицы разделяются на допустимые и недопустимые. Клетка с координатами $\{x_i, y_j\}$ будет допустимой тогда и только тогда, когда в двустороннем графе G имеется дуга $\{x_i, y_j\} \in U$. Остальные клетки считаются недопустимыми. Строки и столбцы таблицы называются рядами. Множество рядов покрывает таблицу, если каждая допустимая клетка принадлежит хотя бы одному ряду. Множество допустимых клеток называется независимым, если любая пара клеток этого множества не покрывается одним рядом. Легко видеть по построению таблицы, что множество независимых допустимых клеток на исходном двустороннем графе соответствует множеству дуг, попарно не имеющих общих вершин. Покрывающее множество рядов соответствует некоторому S,T-рассекающему множеству вершин.

В табличном варианте теорему Кенига – Эгервари можно сформулировать следующим образом.

Теорема 3.5. Максимальное число независимых допустимых клеток равно минимальному числу рядов, покрывающих все допустимые клетки таблицы.

Пример 3.9. Двудольному графу (рис. 3.15) соответствует таблица с допустимыми и недопустимыми клетками.

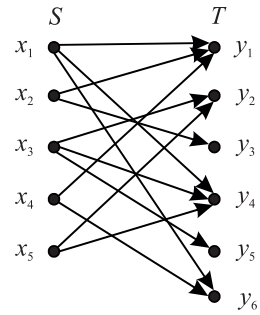

Рис. 3.15

	y_1	y_2	y_3	y_4	y_5	y_6
x_1	1					
x_2			1			
x_3		1				
x_4						1
x_5				1		

Множество клеток с единицами независимо.

Существуют различные варианты множеств независимых допустимых клеток (МНДК). Естественно, встает задача об отыскании максимального множества независимых допустимых клеток (ММНДК), или задача о максимальном паросочетании.

Алгоритм построения ММНДК

Предварительный этап. Необходимо построить произвольное множество независимых допустимых клеток (НДК). Клетки, входящие в это множество, будем отмечать в таблице, например, единицами. Для выбора такого множества применима простейшая процедура, состоящая в постановке единицы в любую допустимую клетку таблицы, и вычеркивании строки и столбца, где лежит эта клетка, и в повторении таких операций на оставшейся части таблицы до тех пор, пока это возможно. На очередных шагах алгоритма это множество клеток необходимо расширить или убедиться в том, что оно максимально.

Э т а п I. Для проверки имеющегося МНДК на максимальность используется процедура поочередных пометок строк и столбцов таблицы. Вначале, например, черточками помечают строки, в которых нет единиц. Теперь в любом порядке выбирается каждая из помеченных строк и в них ищут допустимые клетки. Столбец, где нашлась допустимая клетка, помечается номером просматриваемой строки. Если столбец уже был помечен, то его пометку не изменяют. Так просматривают все помеченные строки. После этого просматривают все помеченные столбцы. В каждом таком столбце ищут единицу. При ее наличии строку, в которой она располагается, помечают номером просматриваемого столбца. Так поступают с каждым помеченным столбцом. Если в рассматриваемом столбце не оказалось единицы, это означает, что имеющееся МНДК может быть улучшено.

Переход к этапу II. Если же все помеченные столбцы просмотрены и среди них не нашлось столбца без единицы, то переходим к просмотру вновь помеченных строк. В них отыскивают допустимые клетки и помечают соответствующие столбцы и т. д. Если на каком-то шаге возникнет ситуация, когда никаких пометок поставить больше нельзя и столбец, не содержащий единицу, не найден, то это говорит о том, что построенное на предыдущем шаге МНДК является максимальным (т. е. улучшить его нельзя). В этом случае алгоритм заканчивает работу. Кроме ММНДК (максимального паросочетания), можно сразу же найти минимальное число покрывающих рядов. Оно будет состоять из помеченных на последнем шаге столбцов и непомеченных строк.

Э т а п II. Для расширения построенного МНДК в случае, когда в каком-то столбце не нашлось единиц, ставят единицу в этом столбце в клетке, соответствующей номеру его пометки. В строке, где только что поставлена единица, необходимо убрать быв-

шую там единицу, после этого в столбце, где только что убрана единица, необходимо поставить единицу в клетке, соответствующей номеру пометки этого столбца. Стоящая в этой строке прежняя единица убирается. Этот процесс продолжается до тех пор, пока не будет достигнута строка, первоначально помеченная черточкой. Эта процедура увеличивает количество единиц на одну, т. е. МНДК расширяется, все пометки строк и столбцов стираются и алгоритм повторяет свою работу с новым МНДК.

Пример 3.10. Имеется следующая таблица с допустимыми и недопустимыми клетками:

	1	2	3	4	5	6	7	8	9
1		1							
2			1						
3									
4				1					
5						1			
6								1	
7	1								
8									
9									

Требуется найти в данной таблице ММНДК.

Пусть единицы в клетках этой таблицы соответствуют начальному МНДК. После применения алгоритма построим следующее ММНДК:

	1	2	3	4	5	6	7	8	9	
1		1								2
2			1							
3				1						4
4					1					
5						1				6
6								1		8
7							1			
8										–
9	1									
		8		8		8		1		

Оно состоит из восьми клеток: (1, 2), (2, 3), (3, 4), (4, 5), (5, 6), (6, 8), (7, 7), (9, 1). При этом на последнем шаге помечены столбцы 2, 4, 6, 8 и не помечены строки 2, 4, 7, 9. Именно эти столбцы и строки (ряды) составляют минимальное множество покрывающих рядов.

Отметим, что может быть несколько ММНДК. Каждый из них можно получить, меняя порядок просмотра помеченных строк и столбцов.

3.6. НЕКОТОРЫЕ ВАРИАНТЫ ЗАДАЧИ О НАЗНАЧЕНИЯХ

1. *Классическая задача.* Задано n работ и n исполнителей, причем каждую работу может делать любой исполнитель. «Стоимость» выполнения каждой i-й работы каждым j-м исполнителем определяется величиной c_{ij}. Требуется распределить исполнителей так, чтобы все работы были сделаны, каждый исполнитель осуществлял только одну работу, каждая работа выполнялась только одним исполнителем и суммарная стоимость производства всех работ была бы минимальной. В конкретных задачах вместо стоимостного могут быть другие, например временные, критерии.

Построим математическую модель этой задачи.

Пусть $x_{ij} = \begin{cases} 1, & \text{если } i\text{-й исполнитель назначен на } j\text{-ю работу,} \\ 0 & \text{в противном случае.} \end{cases}$

Тогда

$$\begin{cases} \sum\limits_{i=1}^{n}\sum\limits_{j=1}^{n} c_{ij}x_{ij} \to \min, \\ \sum\limits_{i=1}^{n} x_{ij} = 1, \quad j = 1, 2, ..., n, \\ \sum\limits_{j=1}^{n} x_{ij} = 1, \quad i = 1, 2, ..., n, \\ x_{ij} = 0 \vee 1. \end{cases} \tag{3.10}$$

Задача (3.10) является частным случаем транспортной задачи в табличной постановке. Однако ее можно решать более эффективными методами, чем те, которыми решаются транспортные задачи. Один из таких методов, использующих задачу о ММНДК, приведем ниже.

Рассмотрим предварительно некоторые свойства решений задачи о назначениях. Пусть u_i и v_j – произвольные рациональные числа.

Теорема 3.6. Если план X (решение) является оптимальным решением задачи (3.10), то он будет оптимальным и для задачи с целевой функцией

$$\sum_{i=1}^{n}\sum_{j=1}^{n}(c_{ij} - u_i - v_j)x_{ij} \to \min, \tag{3.11}$$

и наоборот.

Доказательство. Пусть X – оптимальный план задачи с целевой функцией

$$\sum_{i=1}^{n}\sum_{j=1}^{n}(c_{ij} - u_i - v_j)x_{ij} = \sum_{i=1}^{n}\sum_{j=1}^{n}c_{ij}x_{ij} - \sum_{i=1}^{n}\sum_{j=1}^{n}u_i x_{ij} - \sum_{i=1}^{n}\sum_{j=1}^{n}v_j x_{ij} =$$

$$= \sum_{i=1}^{n}\sum_{j=1}^{n}c_{ij}x_{ij} - \sum_{i=1}^{n}u_i\sum_{j=1}^{n}x_{ij} - \sum_{j=1}^{n}v_i\sum_{i=1}^{n}x_{ij} = \sum_{i,j=1}^{n}c_{ij}x_{ij} - \sum_{i=1}^{n}u_i - \sum_{j=1}^{n}v_j.$$

Поскольку вычитаемые члены не зависят от x_{ij}, то оптимальные планы совпадают. Теорема доказана.

Теорема 3.7. Если все $c_{ij} \geq 0$ и можно отыскать набор неизвестных x_{ij}, такой, что $\sum_i \sum_j c_{ij} x_{ij} = 0$, то это решение оптимально. (Доказательство очевидно.)

Алгоритм (венгерский). Пусть задана матрица стоимостей $C = [c_{ij}]_{n \times n}$ в задаче о назначениях.

Предварительный шаг. Находим в каждом столбце минимальный элемент v_i и вычитаем его из всех элементов этого столбца. Затем находим минимальный элемент u_i в каждой строке и также вычитаем его из элементов данной строки. По теореме 3.6 решения задачи для новой и исходной матриц совпадают. Данная процедура носит название приведения матрицы.

Общий шаг. В таблице размера $n \times n$ допустимыми считаем те и только те клетки, которые соответствуют нулям в приведенной матрице стоимостей. Решаем на этой таблице задачу о ММНДК. Если полученное ММНДК содержит ровно n допустимых клеток, то по теореме 3.7 получено оптимальное решение задачи о назначениях.

Если полученное ММНДК содержит менее n допустимых клеток, то определяем соответствующее ему минимальное множество покрывающих рядов и состоящее, как уже отмечалось, из непомеченных на последнем шаге алгоритма нахождения ММНДК строк и помеченных столбцов. Покрываем этими рядами (линиями) приведенную матрицу стоимостей и выбираем наименьший элемент, через который не проведена линия. Вычитаем это число из всех элементов приведенной матрицы, через которые не проведена ни одна линия, и прибавляем его ко всем элементам, через которые проведены две линии. Эта операция приведет к появлению в приведенной матрице стоимостей, по крайней мере, одного нового нуля, и общий шаг повторяется.

Пример 3.11. Пусть задача о назначениях задана на матрице

$$C = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \end{array} \begin{array}{c} \begin{array}{cccc} 1 & 2 & 3 & 4 \end{array} \\ \begin{bmatrix} 4 & 3 & 6 & 3 \\ 2 & 1 & 2 & 4 \\ 5 & 5 & 5 & 2 \\ 3 & 4 & 5 & 1 \end{bmatrix} \end{array}.$$

После приведения получим матрицу

$$C_1 = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \end{array} \begin{array}{c} \begin{array}{cccc} 1 & 2 & 3 & 4 \end{array} \\ \begin{bmatrix} 0 & 0 & 2 & 0 \\ 0 & 0 & 0 & 3 \\ 2 & 3 & 2 & 0 \\ 1 & 3 & 3 & 0 \end{bmatrix} \end{array}.$$

Общий шаг. На нижеследующей таблице решаем задачу о ММНДК:

	1	2	3	4	
1	1		⊠		
2		1		⊠	
3	⊠	⊠	⊠		–
4	⊠	⊠	⊠	1	4
				3	

Решением могут быть клетки с единицами. Ему соответствуют три покрывающих ряда (первая и вторая непомеченные строки и четвертый помеченный столбец), т. е. в матрице C_1 линиями покрываются первая и вторая строки и четвертый столбец. Минимальный элемент, через который не проведена линия, равен 1. Строим новую приведенную матрицу

$$C_2 = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \end{array} \begin{array}{c} \begin{array}{cccc} 1 & 2 & 3 & 4 \end{array} \\ \begin{bmatrix} 0 & 0 & 2 & 1 \\ 0 & 0 & 0 & 4 \\ 1 & 2 & 1 & 0 \\ 0 & 2 & 2 & 0 \end{bmatrix} \end{array}.$$

Снова строим таблицу с допустимыми и недопустимыми клетками и решаем на ней задачу о ММНДК:

	1	2	3	4
1		1	⊠	⊠
2			1	⊠
3	⊠	⊠	⊠	1
4	1	⊠	⊠	

Решением будут клетки с единицами. Их число равно 4. Это означает, что найдено оптимальное решение задачи о назначении: первому исполнителю поручается вторая работа, второму – третья, третьему – четвертая, четвертому – первая. Минимальная стоимость выполнения всех работ равна 10.

Возможны задачи о назначениях, в которых количество исполнителей больше числа работ. В этом случае матрицу дополняют нулями до квадратной и решают задачу обычным методом.

В некоторых случаях задачу о назначениях нужно решать на максимум. Тогда поступают следующим образом.

Матрицу стоимостей умножают на –1 и для того, чтобы оперировать неотрицательными числами, добавляют ко всем элементам любое достаточно большое положительное число M. На полученной матрице $-C + M$ решается задача минимизации.

2. *Задача о максимальной занятости.* Пусть имеется n исполнителей и m работ. Известно, что каждый i-й исполнитель умеет выполнять определенные работы (не обязательно все) из набора работ. Требуется назначить работников на работы таким образом, чтобы было занято максимальное количество рабочих. Эта задача сводится к задаче построения ММНДК. Достаточно рассмотреть таблицу размером $n \times m$ и клетку (i, j) в этой таблице назвать допустимой в том и только в том случае, если i-й исполнитель может выполнять j-ю работу. Если на этой таблице построить ММДНК, то число элементов этого множества сразу определяет максимальное число занятых рабочих. Элементы этого множества, т. е. клетки, обозначенные единицами, будут задавать искомые назначения.

3. *Задача о назначениях с максиминной функцией цели.* Предположим, что имеется n лиц и n работ, причем известно, что каждый i-й исполнитель может выполнять лю-

бую j-ю работу с эффективностью a_{ij} $(i, j = 1, 2, ..., n)$. Требуется найти такое назначение работников на работы, чтобы наименьшая эффективность при этом назначении была максимальной. Если, например, на конвейере имеется n рабочих мест и у работников на каждом рабочем месте различается эффективность труда, от которой зависит скорость движения конвейера, то требуется расставить рабочих по местам так, чтобы скорость конвейера была максимальной. Не трудно видеть, что в этой задаче, так же как и в классической задаче о назначениях, каждое назначение рабочих на работы задается отображением типа $P : i \to p(i)$, которое означает, что каждый i-й работник назначается на определенную работу $p(i)$. Если считать, что один работник не может назначаться на две работы одновременно и одна работа не может выполняться одновременно двумя работниками, то заданное отображение P представляет собой взаимно-однозначное отображение множества $\{1, 2, ..., n\}$ на себя, т. е. образует так называемую подстановку:

$$P = \begin{pmatrix} 1 & 2 & ... & n \\ p(1) & p(2) & ... & p(n) \end{pmatrix}.$$

Для произвольного назначения P вычислим $F(P) = \min\left\{a_{1p(1)}, ..., a_{np(n)}\right\}$. Требуется найти такое отображение P, при котором $F(P)$ максимально, т. е. требуется отыскать $\max\limits_{\text{для}\,\forall P} F(P)$.

Количество всевозможных назначений работников на работы, т. е. количество подстановок равно $n!$. Даже при достаточно небольших n значение $n!$ настолько велико, что перебор всех вариантов практически невозможен.

Для построения эффективного алгоритма решения этой задачи применяется метод построения ММНДК. Для этого выбирается произвольное назначение в виде подстановки

$$P_0 = \begin{pmatrix} 1 & 2 & ... & n \\ p_0(1) & p_0(2) & ... & p_0(n) \end{pmatrix}.$$

При этом назначении вычисляется значение целевой функции, т. е. величина $F(P_0) = \min\left\{a_{1p_0(1)}, ..., a_{np_0(n)}\right\}$.

Поскольку требуется найти отображение, максимизирующее $F(P)$, клетки таблицы с n строками и n столбцами можно считать допустимыми или недопустимыми путем сравнения конкретной эффективности соответствующего назначения с достигнутой величиной $F(P_0)$. Клетка (i, j) будет допустимой в том и только в том случае, когда величина $a_{ij} > F(P_0)$. На построенной таким образом таблице находим ММНДК. Для того чтобы ММНДК определяло подстановку, число выбранных клеток в этой ММНДК должно быть в точности равно n. Координаты тех клеток зададут какую-то новую подстановку P_1, причем по определению допустимых клеток таблицы $F(P_1) > F(P_0)$. Далее процесс повторяется для новой подстановки.

Если число клеток в ММНДК для некоторой очередной подстановки P_k меньше n, то предыдущее назначение оптимально и улучшить его нельзя.

Пример 3.12. Пусть задана матрица эффективностей:

$$A = \begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \end{array} \begin{array}{c} \begin{array}{cccccc} 1 & 2 & 3 & 4 & 5 & 6 \end{array} \\ \begin{pmatrix} 1 & 3 & 2 & 6 & 0 & 1 \\ 4 & 2 & 3 & 8 & 3 & 1 \\ 8 & 1 & 1 & 5 & 0 & 9 \\ 3 & 4 & 4 & 8 & 8 & 3 \\ 2 & 9 & 9 & 5 & 2 & 9 \\ 3 & 3 & 3 & 6 & 7 & 1 \end{pmatrix} \end{array}.$$

Выбираем начальное назначение

$$P_0 = \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 2 & 1 & 4 & 3 & 6 & 5 \end{pmatrix},$$

тогда

$$F(P_0) = \min(3, 4, 5, 4, 9, 7) = 3.$$

Строим таблицу допустимых и недопустимых клеток и решаем на ней задачу о ММНДК:

	1	2	3	4	5	6
1				1		
2	1					
3						1
4		1				
5			1			
6					1	

Такому решению соответствует назначение

$$P_1 = \begin{pmatrix} 1 & 2 & 3 & 4 & 5 & 6 \\ 4 & 1 & 6 & 2 & 3 & 5 \end{pmatrix},$$

для которого $F(P_1) = \min(6, 4, 9, 5, 9, 7) = 4$.

Новая таблица имеет вид

	1	2	3	4	5	6
1						
2						
3						
4						
5						
6					1	

Очевидно, что в этой таблице ММНДК содержит меньше шести допустимых клеток. Это означает, что назначение P_1 будет оптимальным.

3.7. ТРАНСПОРТНАЯ ЗАДАЧА В СЕТЕВОЙ ПОСТАНОВКЕ

3.7.1. Математическая модель сетевой транспортной задачи

Пусть $G = (X, E)$ – неориентированная сеть, у которой множество узлов $X = S \cup R \cup T$, $S \cap R = \varnothing$, $S \cap T = \varnothing$, $T \cap R = \varnothing$. Элементы множества S назовем источниками (поставщиками) однородного товара, причем для каждого $x \in S$ известна величина $a(x) > 0$ – предложение товара в источнике x. Элементы множества T назовем стоками (потребителями) товара, причем для каждого $x \in T$ известна величина $b(x) > 0$ – спрос товара в стоке x. Элементы множества R называют транзитными узлами. Для каждого ребра $(x, y) \in E$ задана величина $d(x, y)$, означающая пропускную способность ребра (x, y) в любом направлении, и $c(x, y)$ – стоимость перевозки единицы товара от узла x до узла y (или обратно).

Транспортная задача в сетевой постановке (СТЗ) состоит в следующем. Требуется найти значения $f(x, y)$, для которых выполняются условия:

$$0 \le f(x, y) \le d(x, y) \text{ для всех } (x, y) \in E; \tag{3.12}$$

$$\sum_{y \in A(x)} f(x, y) - \sum_{y \in B(x)} f(y, x) \le a(x) \text{ для всех } x \in S; \tag{3.13}$$

$$\sum_{y \in A(x)} f(x, y) - \sum_{y \in B(x)} f(y, x) = 0 \text{ для всех } x \in R; \tag{3.14}$$

$$\sum_{y \in A(x)} f(x, y) - \sum_{y \in B(x)} f(y, x) \ge b(x) \text{ для всех } x \in T \tag{3.15}$$

и для которых функция

$$F = \sum_{(x, y) \in E} c(x, y) f(x, y) \tag{3.16}$$

принимает минимальное значение.

Значения $f(x, y)$, удовлетворяющие условию (3.12)–(3.15), называются допустимым планом перевозки.

Очевидно, что условия (3.12)–(3.15) определяют поток в сети G из всех источников во все стоки. Поэтому транспортную задачу в сетевой постановке часто называют задачей о потоке минимальной стоимости.

Условия (3.12), так же как и условия (3.3), означают стандартные требования на величину потока на каждом ребре. Условия (3.13) означают, что из каждого источника x суммарно (с учетом величин ввоза-вывоза) невозможно вывезти больше, чем предложение $a(x)$. Условия (3.15) означают, что в каждый сток x должно быть суммарно привезено не менее, чем величина спроса $b(x)$ в этом узле. Условия (3.14) означает, что в каждом транзитном узле сумма величин привозимого товара должна быть равна сумме величин товара вывозимого. Смысл обозначений $A(x)$ и $B(x)$ такой же, как и для формул (3.4).

Естественно, что спрос во всех стоках будет удовлетворен, если, во-первых, сеть связная и, во-вторых, суммарные предложения не меньше, чем суммарный спрос:

$$\sum_{x \in S} a(x) = \sum_{x \in T} b(x). \tag{3.17}$$

Транспортная задача в табличной постановке является частным случаем СТЗ. Интересно, что верно и обратное: для каждой СТЗ можно построить искусственную транспортную задачу в табличной постановке. Это означает, что теоретическое обоснование метода решения одной задачи может быть использовано и для другой. В частности, получаем, что решение СТЗ также следует искать среди базовых планов.

3.7.2. Метод потенциалов для решения сетевой транспортной задачи

Для упрощения изложения метода примем, что, во-первых, все пропускные способности $d(x, y)$ достаточно велики, т. е. условия (3.12) всегда выполняются, во-вторых, выполняется равенство

$$\sum_{x \in S} a(x) = \sum_{x \in T} b(x). \tag{3.17а}$$

и, в-третьих, все значения $a(x)$ и $b(x)$ являются целыми числами. Кроме того, примем, что сеть G неориентированная, $X = \{x_1, x_2, ..., x_n\}$ и каждому ребру $(x_i, x_j) \in E$ соответствует величина $c(x_i, x_j) = c_{ij}$.

Метод потенциалов состоит из двух этапов.

Э т а п I (подготовительный).

Шаг 1. Строится произвольное дерево-остов для сети G.

Шаг 2. На построенном дереве-остове устанавливается направление ребер и величины перевозок на каждом из них так, чтобы удовлетворить спрос во всех стоках. Все эти величины (вместе с возможными нулевыми значениями) будут определять начальный допустимый базовый план.

Э т а п II (общий).

Шаг 3. Для произвольного узла x_i задается произвольное число v_i – потенциал этого узла. Далее, передвигаясь по дереву, вычисляем потенциал остальных узлов. Если узел x_i имеет потенциал v_i и к узлу x_j идем в направлении дуги дерева, то полагаем $v_j = v_i + c_{ij}$. Если же к узлу x_j идем против направления дуги дерева, то полагаем $v_j = v_i - c_{ij}$.

Шаг 4. Вычисляем так называемые возможности ребер сети вне дерева-остова от узла x_i с большим потенциалом до узла x_j с меньшим потенциалом: $m_{ij} = c_{ij} - (v_j - v_i)$.

Шаг 5 (*критерий оптимальности*). Если $m_{ij} \geq 0$ для всех ребер сети, то анализируемый допустимый базовый план является оптимальным, т. е. минимизирует суммарные транспортные издержки (3.16).

Шаг 6. Если критерий оптимальности не выполняется, т. е. имеются ребра, для которых $m_{ij} \leq 0$, то выбираем ребро с наименьшим значением m_{ij}. Это ребро вместе с некоторыми ребрами дерева-остова образуют единственный цикл. В этом цикле

устанавливаем направление нового ребра от узла с меньшим потенциалом до узла с большим потенциалом.

Двигаясь по циклу в направлении нового ребра, выбираем среди ребер с противоположным направлением ребро, имеющее наименьшее значение перевозки, например значение Δ.

Пересчитываем новые значения перевозок на ребрах цикла следующим образом. Если направление ребра цикла совпадает с направлением нового ребра, то значение перевозки на нем увеличиваем на Δ. Если направление ребра цикла не совпадает с направлением нового ребра, то значение перевозки на нем уменьшаем на Δ. После такого перераспределения перевозок из цикла удаляем одно из ребер с нулевой величиной перевозки.

Таким образом, получим новый допустимый базовый план и переходим к его анализу, т. е. к шагу 3. Доказано, что количество таких переходов (итераций) конечно.

Примечание. Если допустимый базовый план, полученный на шаге 2 или на шаге 6, содержит дуги с нулевыми величинами перевозок и при последующих итерациях от таких нулей необходимо отнимать Δ, то направление таких дуг изменяем на противоположное и осуществляем сложение.

Пример 3.13. Пусть имеется транспортная сеть, представленная на рис. 3.16.

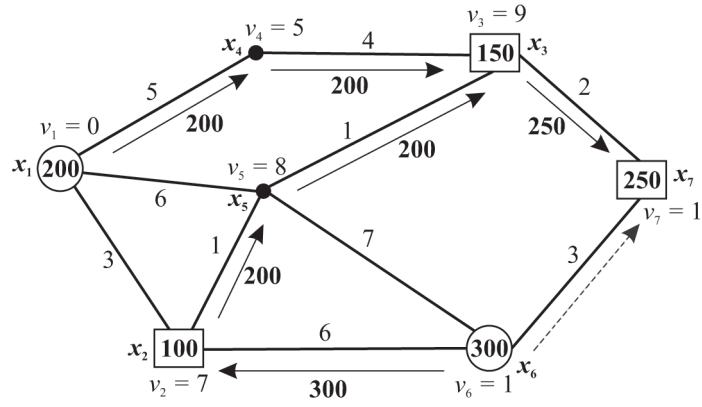

● – транзитные узлы;
ⓐ – узлы – поставщики товара, a – величина предложения;
$\boxed{b}$ – узлы – потребители товара, b – величина спроса

Рис. 3.16

На ребрах заданы стоимости перевозки товара. На сети построен в виде стрелок начальный базовый план перевозок товара, удовлетворяющий спрос всех потребителей. Суммарная стоимость перевозки для этого плана равна 4500 ед. Для этого плана вычислены потенциалы узлов, начиная от узла x_1 с потенциалом $v_1 = 0$. Вычисляем возможности ребер сети, не входящих в базовый план:

$$m_{21} = -4,\ m_{51} = -2,\ m_{56} = 0,\ m_{76} = -7.$$

Критерий оптимальности не выполняется. Добавим к базовому плану ребро $[x_6, x_7]$ с направлением от узла x_6 к узлу x_7.

Вычисляем Δ = 200, пересчитываем новые значения перевозок на ребрах цикла и удаляем из цикла, например, ребро $[x_3, x_5]$, на котором получилась нулевая величина перевозки.

Таким образом, получим новый базовый план (рис. 3.17). Суммарная стоимость перевозки равна 3100 ед.

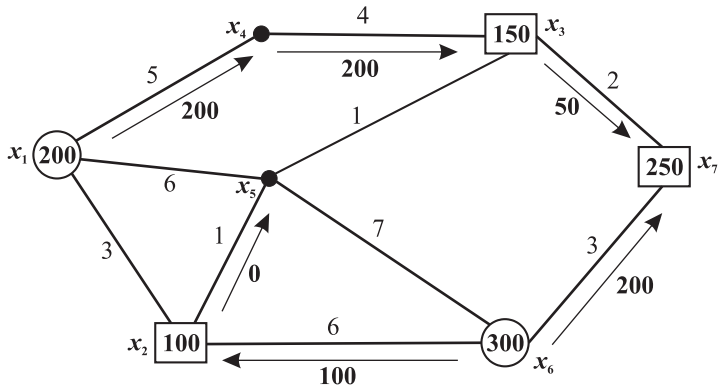

Рис. 3.17

Повторяя метод потенциалов необходимое число раз, получим базовый план (рис. 3.18), для которого выполняется критерий оптимальности.

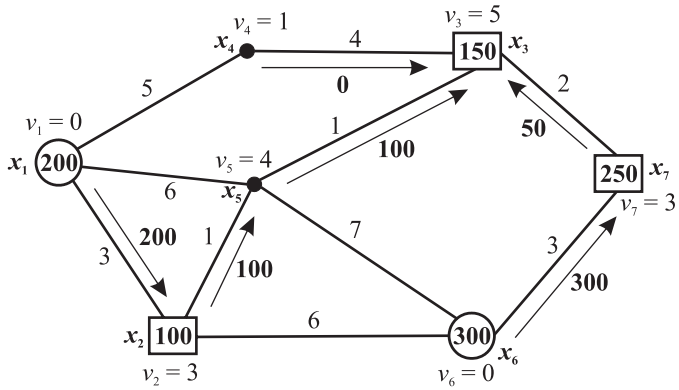

Рис. 3.18

Суммарная стоимость перевозки для этого плана равна 1800 ед. и является минимальной.

3.8. ОПТИМАЛЬНЫЕ СОЕДИНЕНИЯ В СЕТЯХ

3.8.1. Кратчайшие пути между двумя вершинами

Пусть моделью некоторой практической ситуации является ориентированная сеть $G = (V, U)$, $V = (v_1, v_2, ..., v_n)$ и каждой дуге вида $(v_i, v_j) \in U$ поставлено в соответствие определенное рациональное число d_{ij}, названное длиной (или «весом») этой дуги (пример – рис. 3.19). Длиной дуги может быть расстояние между двумя вершинами, время преодоления такого расстояния, стоимость перевозки и другие физические величи-

ны. Иногда рассматриваются модели, в которых длины дуг являются отрицательными числами. Если дуга не имеет ориентации, т. е. является ребром, то обычно принимается, что $d_{ij} = d_{ji}$.

Путем из вершины v_i до вершины v_j называется (как и ранее) последовательность дуг $((v_i, v_1), (v_1, v_2), ..., (v_k, v_j))$, в которой вершина-конец каждой предыдущей дуги является началом последующей. Длиной пути в этом случае будем называть сумму длин принадлежащих ей дуг.

Для каждой пары вершин в связной сети может существовать несколько путей различной длины. Задача о кратчайшем пути состоит в определении пути минимальной длины между двумя вершинами. Эта задача может не иметь решения (быть некорректной) только в случае, если в сети существуют контуры с суммарной отрицательной длиной. Попадая на такой контур, можно обходить его сколь угодно раз, тем самым получая путь со сколь угодно малым «весом».

Замечание. Подобно задаче о кратчайшем пути можно сформулировать задачу о наидлиннейшем пути. Очевидно, что такая постановка будет некорректной, если в сети имеются контуры с суммарной положительной длиной.

Хорошо изучены все возможные варианты задачи о кратчайшем пути:

а) найти кратчайший путь между двумя фиксированными вершинами v_i и v_j;

б) найти кратчайший путь от фиксированной вершины v_i до всех остальных вершин сети;

в) найти кратчайший путь между всеми парами вершин.

Замечание. Вариант а) задачи о кратчайшем пути – частный случай транспортной задачи в сетевой постановке. Полагаем при этом, что вершина v_i – источник товара с предложением $a(v_i) = 1$; вершина v_j – сток со спросом $b(v_j) = 1$; все остальные вершины сети – транзитные; «веса» дуг – стоимости провоза единицы товара, а значения их пропускных способностей – достаточно большие величины и не являются ограничивающими. Естественно, что любой путь из v_i до v_j в этом случае определяется потоком, который транспортирует единицу товара от v_i до v_j.

Для решения задач в вариантах а) и б) при неотрицательных дугах часто используется следующий метод.

Метод Дейкстры. Сущность метода состоит в приписывании пометок вершинам сети, начиная от вершины v_1. От нее двигаемся по направлению дуг, и тем самым помеченными могут быть только вершины, достижимые с помощью путей из вершины v_1.

Обозначим через $W \subseteq V$ множество вершин, пометки которых уже не будут изменяться на последующих шагах. Вначале $W = \{v_1\}$. Пометку u_i приписываем вершине v_i. Она означает длину кратчайшего пути от v_1 до v_i, проходящего только через вершины из множества W. Вначале $u_1 = 0$, $u_i = d_{1i}$, для всех $i = 2, ..., m$, причем если дуги (v_1, v_i) не существует, то полагаем, что d_{1i} – достаточно большое число, например ∞. На очередном шаге находим вершину $v_r \in V \backslash W$ с наименьшей пометкой. Эту вершину присоединяем к множеству W и запоминаем индекс r. Далее для остальных вершин $v_i \in V \backslash W$ проверяем неравенство $u_i > u_r + d_{ri}$.

Если оно выполняется, то вершине v_i приписываем новую пометку, равную $u_r + d_{ri}$. Если это неравенство не выполняется, то пометку вершины не изменяем.

Такой шаг повторяем до тех пор, пока не получим $W = V$. Не трудно доказать, что пометки u_i, полученные для всех вершин на последнем шаге метода, будут длинами кратчайших путей от вершины v_1 до всех остальных вершин сети.

Индексы r, которые фиксировались на каждом шаге, дают возможность восстановить дуги, принадлежащие кратчайшему пути. Например, если требуется восстановить кратчайший путь длины u_m от v_1 до v_m, находим индекс r для шага, на котором впервые получено значение u_m. Пусть этот индекс $r = k_0$, т. е. дуга (v_{k_0}, v_m), принадлежит кратчайшему пути. Далее находим индекс r, на котором впервые получено значение u_{k_0}. Пусть этот индекс $r = k_1$, значит, дуга (v_{k_1}, v_{k_0}) принадлежит кратчайшему пути. Подобным образом находим дугу (v_{k_2}, v_{k_1}) и т. д., пока не достигнем вершины v_1.

Замечание. Если при определении вершины $v_r \in V \setminus W$ с наименьшей пометкой имеется несколько вариантов, то выбираем любой из них. Выбор другого варианта приведет в конечном итоге к построению иного кратчайшего пути такой же длины.

Число шагов в методе Дейкстры будет не больше, чем число n вершин сети, при этом на шаге перебирается не более чем n пометок. Таким образом, эффективность метода Дейкстры оценивается как n^2 обобщенных операций.

Замечание. Если сеть содержит ненаправленные дуги, т. е. ребра, то ее можно превратить в ориентированную сеть путем замены каждого ребра (v_i, v_j) на две противоположно направленные дуги с одинаковым «весом» $d_{ij} = d_{ji}$. Такое преобразование не увеличит число шагов в методе Дейкстры.

Пример 3.14. Найти кратчайший путь от вершины v_1 до вершины v_6 на сети, представленной на рис. 3.19.

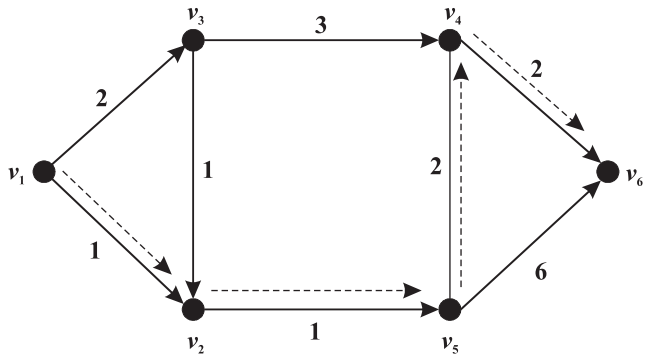

Рис. 3.19

Вычисления представим в виде следующей таблицы:

Шаг 1	Шаг 2	Шаг 3	Шаг 4	Шаг 5	Шаг 6
$r = 1$	$r = 2$	$r = 3$	$r = 5$	$r = 4$	$r = 6$
$W = \{v_1\}$	$W = \{v_1, v_2\}$	$W = \{v_1, v_2, v_3\}$	$W = \{v_1, v_2, v_3, v_5\}$	$W = \{v_1, v_2, v_4, v_5\}$	$W = V$
$u_1 = 0$	$u_1 = 0$	$u_1 = 0$	$u_1 = 0$	$u_1 = 0$	stop
$u_2 = 1$	$u_2 = 1$	$u_2 = 1$	$u_2 = 1$	$u_2 = 1$	stop
$u_3 = 2$	$u_3 = 2$	$u_3 = 2$	$u_3 = 2$	$u_3 = 2$	stop
$u_4 = \infty$	$u_4 = \infty$	$u_4 = 5$	$u_4 = 4$	$u_4 = 4$	stop
$u_5 = \infty$	$u_5 = 2$	$u_5 = 2$	$u_5 = 2$	$u_5 = 2$	stop
$u_6 = \infty$	$u_6 = \infty$	$u_6 = \infty$	$u_6 = 8$	$u_6 = 5$	stop

Кратчайший путь от v_1 до v_6 имеет длину 5 и состоит из дуг

$$((v_4, v_6), (v_5, v_4), (v_2, v_5), (v_1, v_2)).$$

Метод Флойда – Уоршелла. Этот метод применяется для решения задачи о кратчайших путях в варианте в) для графов с n вершинами, причем он может работать с отрицательными длинами дуг и позволяет установить факт наличия цикла отрицательной длины.

Метод преобразует исходную матрицу $D = [d_{ij}]_{n\times n}$, где элемент d_{ij} равен длине дуги между вершинами v_i и v_j, если она существует, или $d_{ij} = \infty$, если такой дуги нет.

Обозначим через $d_{ij}^{(k)}$ длину кратчайшего пути от вершины v_i до вершины v_j, у которой все промежуточные вершины принадлежат множеству $\{1, 2, ..., k\}$. Для $k = 0$ принимаем $d_{ij}^{(0)} = d_{ij}$.

Матрицы $D^{(k)} = \left[d_{ij}^{(k)} \right]_{n\times n}$ определяем последовательно для $k = 1, 2, ..., n$, применяя формулу

$$d_{ij}^{(k)} = \min\left\{ d_{ij}^{(k-1)}, d_{ik}^{(k-1)} + d_{kj}^{(k-1)} \right\}. \qquad (3.18)$$

Элементы матрицы $D^{(n)} = [d_{ij}^{(n)}]_{n\times n}$ являются длинами кратчайших путей между соответствующими парами вершин.

Доказательство этого проводится по индукции в соответствии с возрастанием k. Для каждого конкретного k элементы матрицы $D^{(k)}$задают кратчайшие пути, содержащие вершины из множества $\{1, 2, ..., k\}$.

Если при вычислениях для какого-то k окажется, что один из диагональных элементов матрицы $D^{(k)}$, например $d_{hh}^{(k)}$, является отрицательным, то это означает, что в графе есть цикл отрицательной длины, содержащий вершину v_h.

Для восстановления кратчайших путей между каждой парой вершин графа можно параллельно с вычислением матрицы $D^{(k)}$ вычислять так называемые матрицы предшественников $E^{(k)}$ для $k = 0, 1, 2, ..., n$. Для $k = 0$ полагаем

$$e_{ij}^{(0)} = \begin{cases} 0, & \text{если } i = j \text{ или } d_{ij} = \infty, \\ i, & \text{если } i \neq j \text{ и } d_{ij} < \infty. \end{cases}$$

Элементы $e_{ij}^{(k)}$ для $k = 1, 2, ..., n$ определяются в зависимости от того, какой из аргументов под знаком минимума в формуле (3.18) выбирается: если выбирается $d_{ij}^{(k-1)}$, то $e_{ij}^{(k)} = e_{ij}^{(k-1)}$; если выбирается аргумент $d_{ik}^{(k-1)} + d_{kj}^{(k-1)}$, то $e_{ij}^{(k)} = k$.

При восстановлении кратчайшего пути для конкретной пары вершин (i, j) в матрице $E^{(n)}$ находится элемент $e_{ij}^{(n)} = k_0$, который является вершиной – предшественником вершины j на кратчайшем пути из i до j. Далее на $E^{(n)}$ устанавливается вершина – предшественник вершины k_0 на кратчайшем пути из i до k_0 и т. д., пока не достигается вершина i.

Пример 3.15. Вычислим длины кратчайших путей в графе (рис. 3.20).

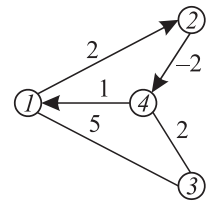

Рис. 3.20

Для этого графа $n = 4$ и $D = \begin{bmatrix} 0 & 2 & 5 & \infty \\ \infty & 0 & \infty & -2 \\ 5 & \infty & 0 & 2 \\ 1 & \infty & 2 & 0 \end{bmatrix}$.

$k = 0$: $D_0 = D$, $E_0 = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 2 \\ 3 & 0 & 0 & 3 \\ 4 & 0 & 4 & 0 \end{bmatrix}$;

$k = 1$: $D_1 = \begin{bmatrix} 0 & 2 & 5 & \infty \\ \infty & 0 & \infty & -2 \\ 5 & 7 & 0 & 2 \\ 1 & 3 & 2 & 0 \end{bmatrix}$, $E_1 = \begin{bmatrix} 0 & 1 & 1 & 0 \\ 0 & 0 & 0 & 2 \\ 3 & 1 & 0 & 3 \\ 4 & 1 & 4 & 0 \end{bmatrix}$;

$k = 2$: $D_2 = \begin{bmatrix} 0 & 2 & 5 & 0 \\ \infty & 0 & \infty & -2 \\ 5 & 7 & 0 & 2 \\ 1 & 3 & 2 & 0 \end{bmatrix}$, $E_2 = \begin{bmatrix} 0 & 1 & 1 & 2 \\ 0 & 0 & 0 & 2 \\ 3 & 1 & 0 & 3 \\ 4 & 1 & 4 & 0 \end{bmatrix}$;

$k = 3$: $D_3 = \begin{bmatrix} 0 & 2 & 5 & 0 \\ \infty & 0 & \infty & -2 \\ 5 & 7 & 0 & 2 \\ 1 & 3 & 2 & 0 \end{bmatrix}$, $E_3 = \begin{bmatrix} 0 & 1 & 1 & 2 \\ 0 & 0 & 0 & 2 \\ 3 & 1 & 0 & 3 \\ 4 & 1 & 4 & 0 \end{bmatrix}$;

$k = 4$: $D_4 = \begin{bmatrix} 0 & 2 & 2 & 0 \\ -1 & 0 & 0 & -2 \\ 3 & 5 & 0 & 2 \\ 1 & 3 & 2 & 0 \end{bmatrix}$, $E_4 = \begin{bmatrix} 0 & 1 & 4 & 2 \\ 4 & 0 & 4 & 2 \\ 4 & 4 & 0 & 3 \\ 4 & 1 & 4 & 0 \end{bmatrix}$.

Каждый элемент матрицы D_4 равняется длине кратчайшего пути между соответствующей парой вершин. Матрицы предшественников E_k позволяют восстановить каждый такой кратчайший путь. Например, $d_{13}^{(4)} = 2$ (рис. 3.20), т. е. кратчайший путь от *1* до *3* имеет длину 2. В матрице E_4 находим $e_{13}^{(4)} = 4$. Это означает, что на кратчайшем пути от *1* до *3* предшественником вершины *3* является вершина *4*. Предшественником вершины *4* на кратчайшем пути от *1* до *4* является *2* и, наконец, предшественником вершины *2* на кратчайшем пути от *1* является она сама. Таким образом, кратчайший путь от вершины *1* до вершины *3* состоит из дуг (*1*, *2*), (*2*, *4*), (*4*, *3*).

3.8.2. Минимальные остовные (или покрывающие) деревья

Если имеется неориентированный связный граф $G = (V, U)$, то, как уже отмечалось, из него можно последовательно удалять некоторые ребра так, чтобы сохранялась связность, до тех пор пока не получится дерево. Такое дерево называется остовным. Понятно, что в зависимости от выбора удаляемых ребер можно получить различные остовные деревья. Если при этом каждому ребру (v_i, v_j) исходного графа поставлено в соответствие рациональное число d_{ij} – длина этого ребра (рис. 3.21), то каждому остовному дереву будет соответствовать его длина, как сумма длин принадлежащих ему ребер. Естественно, для данного графа возникает задача о нахождении минимального (или максимального) остовного дерева. Основанием для эффективного алгоритма построения минимального остовного дерева служит следующая теорема.

Теорема 3.8. Остовное дерево T будет минимальным тогда и только тогда, когда для любого ребра (v_i, v_k) вне дерева выполняется условие

$$d_{ik} \geq \max(d_{i1}, d_{12}, ..., d_{k-1,k}), \tag{3.19}$$

где последовательность $[v_i, v_1, v_2, ..., v_{k-1}, v_k]$ является цепью (единственной) в дереве T, соединяющей вершины v_i и v_k.

Условие (3.19) говорит о том, что для минимального остовного дерева длины ребер вне этого дерева будут не меньшими, чем длины ребер в этом дереве.

Для построения минимального остовного дерева можно использовать следующий метод.

Метод Краскала. В неориентированном графе $G = (V, U)$ выбираем ребро наименьшей длины; на каждом очередном шаге среди еще не просмотренных ребер выбираем ребро наименьшей длины и, если оно не образует цикла с уже выбранными ребрами, добавляем его к множеству уже выбранных ребер. Когда это множество будет содержать ровно $n - 1$ ребер $(n = |V|)$, то тем самым оно будет минимальным остовным деревом.

Замечание. Легко модифицировать теорему – критерий минимальности и метод Краскала для построения максимальных остовных деревьев.

Пример 3.16. Построить минимальное и максимальное остовные деревья для графа, приведенного на рис. 3.21.

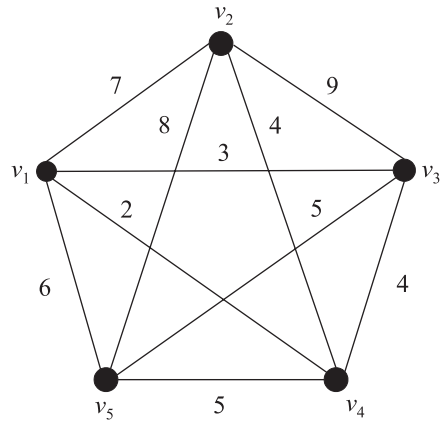

Рис. 3.21

Минимальное остовное дерево $T_{min} = \{[v_1, v_4], [v_1, v_3], [v_2, v_4], [v_3, v_5]\}$, длина $T_{min} = 2 + 3 + 4 + 5 = 14$.

Максимальное остовное дерево $T_{max} = \{[v_2, v_3], [v_2, v_5], [v_1, v_2], [v_5, v_4]\}$, длина $T_{max} = 9 + 8 + 7 + 5 = 29$.

Замечание. Минимальное остовное дерево, построенное для связного неориентированного графа, часто можно использовать для решения задачи о кратчайших путях между всеми парами вершин (вариант в) из п. 3.8.1): каждая пара вершин в этом остовном дереве соединена единственным кратчайшим путем.

Существуют различные важные для практики модификации задачи о минимальном остовном дереве, например задача Штейнера и задача о минимальном покрывающем дереве на прямоугольной (так называемой манхэтэнской) метрике.

Задача Штейнера. Имеется n точек, случайно разбросанных на плоскости с евклидовой системой координат и, соответственно, с евклидовой метрикой. Требуется соединить эти точки покрывающим деревом минимальной суммарной длины, причем допускается использование вспомогательных точек.

Такая задача эффективно решена только для случаев $n = 3$ и $n = 4$. Например, при $n = 3$ минимальное дерево Штейнера строится следующим образом. Доказано, что если исходные точки образуют остроугольный треугольник, то требуется одна вспомогательная точка и минимальное покрывающее дерево соединяет эту точку с каждой из исходных вершин так, чтобы каждая сторона треугольника была «видна» из вспомогательной точки под углом 120° (рис. 3.22).

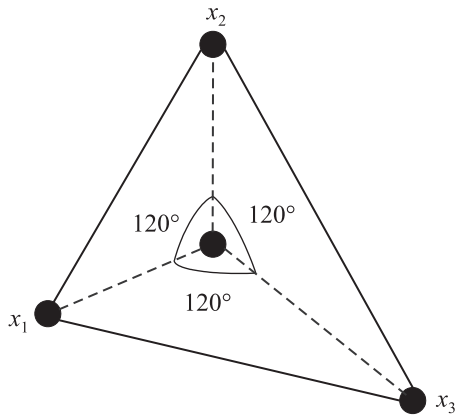

Рис. 3.22

В этом случае минимальное покрывающее дерево Штейнера будет короче длины минимального остовного дерева, найденного алгоритмом Краскала.

В случае когда исходные точки образуют треугольник с прямым или тупым углом, вспомогательная точка совпадает с вершиной такого угла и длина дерева Штейнера равна длине дерева Краскала.

При $n = 4$ в общем случае требуются две вспомогательные точки – и задача Штейнера также решена с помощью эффективного алгоритма. Для произвольного n доказано, что вспомогательных точек должно быть не более чем $n – 2$. Однако эффективного алгоритма для построения дерева Штейнера в общем случае пока не найдено.

Задача о минимальном покрывающем дереве при прямоугольной метрике. Имеется n точек, случайно разбросанных на плоскости. Эти точки являются узлами прямоугольной решетки. Расстояние между точками, например, v_1 с координатами (x_1, y_1) и v_2 с координатами (x_2, y_2) вычисляются по формуле

$$d(v_1, v_2) = |x_1 - x_2| + |y_1 - y_2|.$$

Требуется соединить эти точки покрывающим деревом так, чтобы суммарная длина всех горизонтальных и вертикальных отрезков этого дерева была минимальна. В этой задаче также допускается использование вспомогательных точек, которые также будут узлами прямоугольной решетки.

Пример 3.17. Пусть $n = 7$ (рис. 3.23) и в покрывающем (вероятно, неоптимальном) дереве использовано шесть вспомогательных точек.

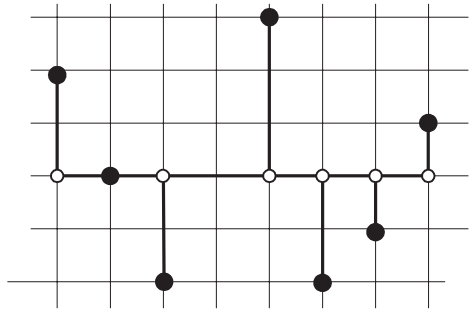

Рис. 3.23

Поставленная задача имеет практическое применение, особенно при проектировании интегральных схем. К сожалению, для общего случая пока не разработаны эффективные алгоритмы ее решения. Для различных конфигураций в расположении исходных точек можно выявить некоторые закономерности, и они помогают обосновать близость получаемых покрывающих деревьев к оптимальным.

3.9. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. Дайте определение конечного ориентированного и неориентированного графа.
2. Нарисуйте граф $G = (X, U)$, если $|X| = 5$, $U = \varnothing$.
3. Докажите, что если неориентированный граф с n вершинами связный и не имеет циклов, то он содержит $n - 1$ ребер, т. е. является деревом.
4. В каком случае матрица смежности графа симметрична?
5. Если A – матрица смежности графа G, вычислена матрица A^4 и ее элемент $p_{21} = 5$, то что это означает для графа G?
6. Постройте пример стационарного потока в сети из источника s в сток t с тремя промежуточными вершинами. Какова величина такого потока?
7. Постройте пример сети с источником s, стоком t и двумя промежуточными вершинами, определите на нем два разреза, отделяющих s от t. Как вычислить пропускные способности этих разрезов?
8. Перечислите неизвестные в задаче о максимальном потоке. Почему эта задача является задачей линейного программирования?

9. Может ли в сети существовать цепь, увеличивающая поток из s в t, которая состояла бы только из дуг, не совпадающих по направлению от s к t?

10. Как в сети определить разрез, отделяющий s от t, соответствующий максимальному потоку, построенному методом расстановки пометок? Чему равна пропускная способность этого разреза?

11. Почему метод расстановки пометок для нахождения максимального потока является обоснованием теоремы о целочисленности потока?

12. Какова схема решения задачи о максимальном потоке однородного продукта при нескольких источниках и стоках?

13. Какие трудности по сравнению со стандартной задачей о максимальном потоке появляются при ограничениях снизу на пропускные способности дуг?

14. Сколько задач о максимальном потоке можно было бы решить в смешанной сети с M неориентированными дугами?

15. Можно ли определить двусторонний неориентированный граф?

16. Сравнить формулировки теорем Форда – Фалкерсона и Кенига – Эгервари.

17. Постройте пример любого двустороннего графа и соответствующую ему таблицу.

18. Поясните задачу об отыскании максимального множества независимых допустимых клеток.

19. Сформулируйте классическую задачу о назначениях и постройте ее математическую модель.

20. Сформулируйте задачу о максимальной занятости.

21. Сформулируйте задачу о назначениях с максиминной функцией цели.

22. Опишите математическую модель транспортной задачи в сетевой постановке.

23. Покажите, что транспортная задача в табличной постановке является частным случаем транспортной задачи на сети.

24. Как построить допустимое базовое решение транспортной задачи на сети?

25. Сформулируйте задачу о кратчайших путях в сети.

26. Сформулируйте задачу о минимальном остовном дереве.

4. ЭЛЕМЕНТЫ СЕТЕВОГО ПЛАНИРОВАНИЯ

4.1. ОСНОВНЫЕ ПОНЯТИЯ И ОПРЕДЕЛЕНИЯ

При исследовании операций часто приходится решать задачи рационального планирования сложных, комплексных проектов:

- строительство больших промышленных объектов;
- развертывание систем медицинских или профилактических мероприятий;
- выполнение комплексной научно-исследовательской темы с участием ряда организаций и т. д.

Характерной особенностью таких проектов является то, что многие из составляющих их работ взаимообусловливают друг друга: одни работы не могут начаться до завершения других.

Планирование любого комплекса такого рода работ должно осуществляться с учетом следующих факторов:

- времени на выполнение всего цикла работ и его составляющих;
- стоимости комплекса и его составляющих;
- сырьевых, энергетических и людских ресурсов.

Рациональное планирование требует ответа на вопросы:

- как распределять имеющиеся ресурсы;
- в какие моменты начинать каждую из работ;
- какие могут возникнуть проблемы из-за несвоевременного выполнения отдельных работ и как их устранить и т. д.

Методы решения таких задач предлагает *сетевое планирование* – рациональное планирование (включая управление) реализации комплексных проектов на основе формализации в виде так называемых сетевых графиков (СГ). В сетевом планировании решаются как прямые задачи – оценка последствий определенного решения, так и обратные – поиск наилучших решений.

СГ – это математическая модель проекта в виде орграфа, который отображает технологические связи между работами, составляющими проект.

Для построения СГ необходимы:

- перечень работ, входящих в проект;
- сведения о непосредственном предшествовании (или следовании) работ (их упорядочении во времени);
- продолжительность каждого вида работы.

Пример 4.1. Пусть требуется реализовать проект, состоящий из 9 работ, учитывая следующие данные:

Номер работы	Каким работам непосредственно предшествует	Время выполнения работы (в определенных единицах времени)
1	2,3	2
2	8	3
3	6,7	4
4	6,7	5
5	9	4
6	8	6
7	–	4
8	–	2
9	–	7

Отношения непосредственного предшествования (или следования) задают частичный порядок, который можно представить в виде орграфа, называемого сетевым графиком. При этом часто работы, составляющие проект, изображают в виде пронумерованных дуг (рис. 4.1) с ориентацией от момента начала работы до момента ее окончания. Именно эти моменты будут соответствовать вершинам орграфа.

Вершины построенного СГ называют событиями. Каждое событие отражает тот факт, что все входящие в него работы завершены и только после этого может начинаться выполнение последующих работ.

Для нашего примера сетевой график может иметь вид, приведенный на рис. 4.1.

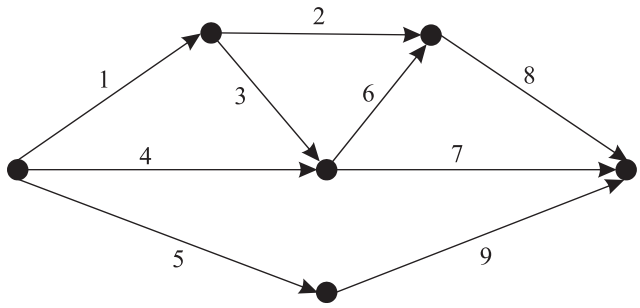

Рис. 4.1

Одно и то же событие является либо началом одних, либо концом других дуг-работ. Если у него нет входящих дуг, то это событие называют началом проекта. Событие, не имеющее выходящих дуг, – концом проекта.

Последовательными называют работы, лежащие на некотором пути (или образующие путь) в графе G. Могут быть и *параллельные* работы (как дуги в мультиграфе). Работа, формально заменяющая собой группу работ, расположенную между какими-то двумя событиями, называется *составной.* Такие работы применяются для укрупнения СГ.

Важную роль играют так называемые *фиктивные* работы нулевой продолжительности, вводимые в СГ для того, чтобы правильно отразить отношение порядка каждой

из работ и следующими за ними работами. Например, если после работы K_1 должна непосредственно следовать работа K_3, а после работ K_1 и K_2 – работа K_4, то неправильным будет орграф, представленный на рис. 4.2.

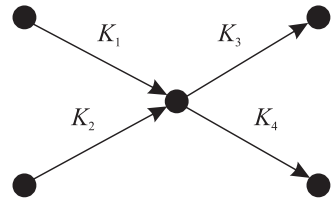

Рис. 4.2

В этом случае событие «момент окончания работ K_1 и K_2» требуется разделить на два события, соединенные между собой фиктивной работой с направлением, необходимым для правильного отображения порядка (рис. 4.3).

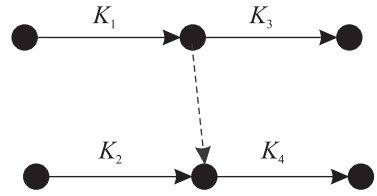

Рис. 4.3

На СГ невозможно отобразить факт начала какой-то работы после завершения части предшествующей работы. Это означает, что не может быть конструкции, приведенной на рис. 4.4.

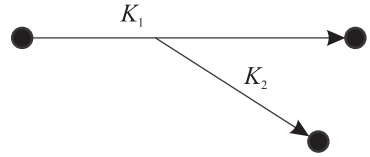

Рис. 4.4

В этом случае работу K_1 необходимо поделить на две работы K_1' и K_1'' и построить орграф, представленный на рис. 4.5.

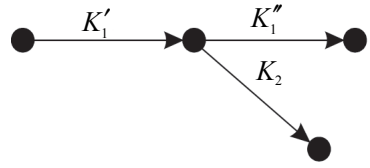

Рис. 4.5

Если СГ содержит несколько событий, не имеющих входящих дуг, то обычно вводят одно фиктивное событие – начало проекта, которое связывают фиктивными работами со всеми вышеуказанными событиями. Аналогично, если СГ содержит несколько событий, не имеющих выходящих дуг, то вводят одно фиктивное событие – конец проекта, с которым фиктивными работами связывают эти события.

Существуют и другие приемы построения СГ. Их целью является правильное и однозначное отображение отношения частичного порядка в получаемом орграфе.

Очень важным для дальнейшего анализа СГ является следующее свойство: СГ не содержит замкнутых путей-контуров.

Наличие любого контура противоречило бы отношению частичного порядка и технологическим взаимозависимостям между работами проекта.

После построения СГ его вершины-события нумеруются в произвольном порядке, например символами $P_0, P_1, ..., P_n$ (рис. 4.6). Работы после этого можно рассматривать как упорядоченные пары вида (P_i, P_j). Алгоритмы анализа СГ удобно излагать для случая, когда СГ *правильно пронумерован.*

СГ называется *правильно пронумерованным*, если для каждой работы (P_i, P_j), $i < j$.

Алгоритм правильной нумерации

Э т а п I. *Разбиение событий на классы*. К событиям класса K_0 относят все события, в которые не входит ни одной дуги. После этого удаляются дуги (на рис. 4.6 они зачеркнуты штрихами), выходящие из событий класса K_0, и к событиям класса K_1 относят все события, в которые не будет входить ни одна дуга и т. д. К очередному классу относят все события, которые не имеют входящих дуг после всех предыдущих удалений. Если на каком-то шаге окажется, что еще не все события разнесены по классам и что к очередному классу нельзя отнести ни одно событие, то это будет означать, что в сетевом графике имеется, по крайней мере, один контур, и, следовательно, СГ построен неверно, его надо исправлять.

В СГ без контуров после первого этапа все события будут разнесены по классам.

Э т а п II. *Правильная нумерация.* Событиям класса K_0 приписываем в произвольном порядке новые номера $P_0', P_1', ...$ Начиная с очередного неиспользованного номера, в произвольном порядке нумеруются события класса K_1, затем K_2 и т. д. В соответствии с правилом образования классов между событиями одного класса дуг не может быть, и они направлены только из событий класса с меньшим номером в события класса с большим номером.

Это служит основанием того, что после перенумерации для каждой работы (P_i', P_j'), $i < j$.

Примечание. Алгоритм правильной нумерации широко используется во многих других как теоретических, так и практических задачах анализа структуры орграфов. Так, например, после того как в орграфе установлен факт наличия контуров (этап I) можно применить алгоритмы построения этих контуров и выбора среди них контура с определенными свойствами. Важно также, что для правильно пронумерованного орграфа соответствующая матрица смежности имеет треугольный вид, причем все ненулевые элементы располагаются над главной диагональю.

Продолжение примера 4.1. Пусть в построенном СГ событиям были приписаны номера (рис. 4.6).

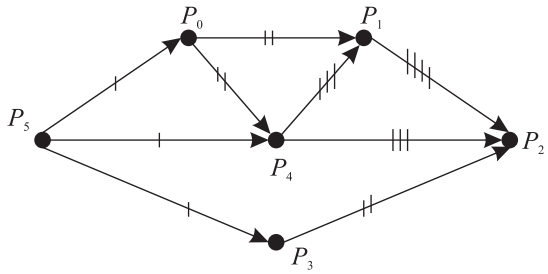

Рис. 4.6

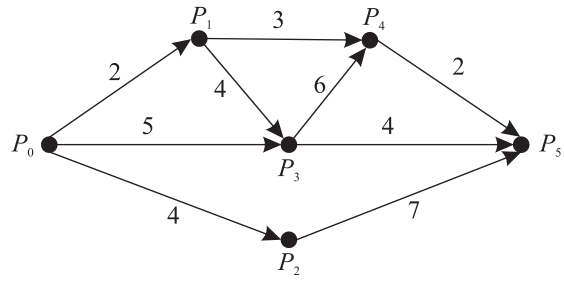

Рис. 4.7

Применим алгоритм правильной нумерации.

Э т а п I. $K_0 = \{P_5\}$, $K_1 = \{P_0, P_3\}$, $K_2 = \{P_4\}$, $K_3 = \{P_2\}$.

Э т а п II. Событию P_5 приписывают новый номер P_0', $P_0 - P_1'$, $P_3 - P_2'$, $P_4 - P_3'$, $P_1 - P_4'$, $P_2 - P_5'$.

После правильной нумерации сетевой график представляется в виде орграфа, где заданы номера вершин и на каждой дуге-работе (P_i, P_j) записывается число t_{ij}, равное продолжительности соответствующей работы из проекта (рис. 4.7).

4.2. ВРЕМЕННЫЕ ПАРАМЕТРЫ СЕТЕВОГО ГРАФИКА

Пусть построен правильно пронумерованный сетевой график G с началом P_0 и концом P_n, каждой работе (P_i, P_j) которого поставлено в соответствие время ее выполнения t_{ij}. Применение сетевых графиков при планировании реализации проекта основано в первую очередь на вычислении нескольких временных параметров. Ниже рассмотрим только четыре из них: минимальный и максимальный моменты свершения событий, свободный и полный резервы времени работ.

Определение 4.1. *Минимальным моментом* $T_j^{(0)}$ *свершения события* P_j называют самое раннее возможное время окончания всех работ, входящих в это событие.

Условимся, что для начала проекта P_0 $T_0^{(0)} = 0$.

Если длину пути в орграфе определить как сумму продолжительностей, входящих в этот путь работ, то минимальное время $T_j^{(0)}$ свершения каждого события P_j равно длине максимального пути из события P_0 в событие P_j. Все работы, выходящие из события P_j, не могут быть начаты ранее, чем будут выполнены работы, принадлежащие этому максимальному пути.

Определение 4.2. Минимальный момент свершения события-конца проекта называется *критическим временем проекта*.

По определению критическое время равно длине максимального пути из P_0 в P_n. Таким образом, все работы, входящие в проект, не могут быть выполнены за время меньшее, чем критическое время.

Алгоритм вычисления минимального момента свершения события. Из-за того, что СГ правильно пронумерован и не содержит контуров, вычисление длин максимальных путей из события P_0 во все остальные события P_j, т. е. величин $T_j^{(0)}$, можно осуществлять по формулам:

$$\begin{cases} T_0^{(0)} = 0, \\ T_j^{(0)} = \max\limits_i (T_i^{(0)} + t_{ij}), \qquad j = 1, 2, ..., n, \end{cases} \tag{4.1}$$

где i – индексы начал всех дуг, входящих в P_j.

При применении формул (4.1) можно для каждого P_j запомнить множество I_j всех тех индексов i, для которых в формуле (4.1) достигается максимум. Эти множества используются при восстановлении критического пути.

Продолжение примера 4.1. Пусть имеется правильно пронумерованный СГ (рис. 4.8), на дугах которого указаны продолжительности работ.

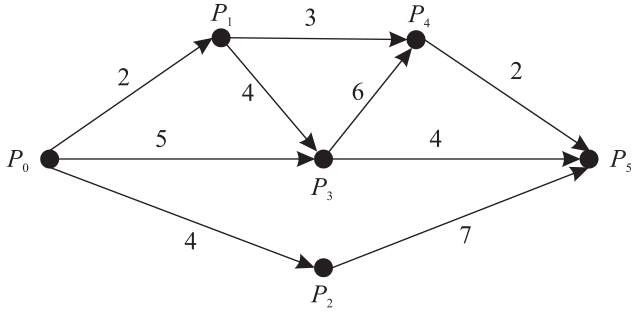

Рис. 4.8

Вычислим минимальные моменты свершения всех событий этого СГ:

$$j = 0, \quad T_0^{(0)} = 0,$$

$$j = 1, \quad T_1^{(0)} = \max_{i=0}(0 + 2) = 2, \qquad I_1 = \{0\};$$

$$j = 2, \quad T_2^{(0)} = \max_{i=0}(0 + 4) = 4, \qquad I_2 = \{0\};$$

$$j = 3, \quad T_3^{(0)} = \max_{i=0,1}(0 + 5, 2 + 4) = 6, \qquad I_3 = \{1\};$$

$$j = 4, \quad T_4^{(0)} = \max_{i=1,3}(2 + 3, 6 + 6) = 12, \qquad I_4 = \{3\};$$

$$j = 5, \quad T_5^{(0)} = \max_{i=2,3,4}(4 + 7, 6 + 4, 12 + 2) = 14, \qquad I_5 = \{4\}.$$

Таким образом, $T_5^{(0)} = 14$ – критическое время. Следовательно, весь проект при заданной продолжительности выполнения работ не может быть выполнен менее чем за 14 единиц времени. Множества I_j дают возможность восстановить критический путь (или пути). Для этого начинаем от события P_n. В множестве I_n выбираем произвольный индекс i_{n-1}. Это будет означать, что работа $(P_{i_{n-1}}, P_n)$ принадлежит критическому пути. Далее во множестве I_{n-1} выбираем произвольный индекс, например i_k. Это будет означать, что работа $(P_{i_k}, P_{i_{n-1}})$ принадлежит критическому пути. Затем подобным образом используем множество I_k и т. д., пока не достигнем события P_0, тем самым восстановим один критический путь из P_0 до P_n. Если на каком-то из таких шагов будут варианты выбора индекса, то, используя иной вариант, построим еще один кратчайший путь.

Для нашего примера множество $I_5 = \{4\}$. Это означает, что работа (P_4, P_5) принадлежит критическому пути. Далее, $I_4 = \{3\}$, т. е. работа (P_3, P_4) принадлежит критическому пути. Потом $I_3 = \{1\}$, т. е. работа (P_1, P_3) принадлежит критическому пути. Наконец, $I_1 = \{0\}$, т. е. работа (P_0, P_1) принадлежит критическому пути. Таким образом, критический путь (единственный) восстановлен.

Критический путь – важная характеристика сетевого графика. Работы, лежащие на критическом пути, являются наиболее важными и в этом смысле критическими. Их продолжительность нежелательно увеличивать, так как это приведет к увеличению времени выполнения всего проекта. Работы, не лежащие на критическом пути, – менее важные, их продолжительность можно увеличить до определенного предела, и это не приведет к увеличению времени выполнения проекта.

Определение 4.3. *Максимальным моментом* $T_j^{(1)}$ *свершения события* P_j называют наиболее позднее время окончания всех работ, входящих в P_j, которое не увеличивает критическое время проекта $T_n^{(0)}$.

Величина $T_j^{(1)}$ определяется по формуле

$$T_j^{(1)} = T_n^{(0)} - d_j, \quad j = 1, 2, ..., n, \tag{4.2}$$

где d_j – максимальная длина пути из P_j в P_n.

Алгоритм вычисления d_j

Величина d_j вычисляется по формулам:

$$\begin{cases} d_n = 0, \\ d_j = \max\limits_k (d_k + t_{jk}), \quad j = n-1, n-2, ..., 0, \end{cases} \tag{4.3}$$

где k – индексы концов всех дуг, выходящих из P_j.

После вычисления всех значений d_j, вычисляем максимальные моменты $T_j^{(1)}$ по формуле (4.2).

Продолжение примера 4.1. Для нашего СГ $T_5^{(0)} = 14$.

Вычислим максимальные моменты свершения событий

$j = 5,\ d_5 = 0;$ $\qquad$ $j = 2,\ d_2 = \max\limits_{k=5}(0 + 7) = 7;$

$j = 4,\ d_4 = \max\limits_{k=5}(0 + 2) = 2;$ $\qquad$ $j = 1,\ d_1 = \max\limits_{k=3,4}(8 + 4, 2 + 3) = 12;$

$j = 3,\ d_4 = \max\limits_{k=4,5}(2 + 6, 0 + 4) = 8;$ $\qquad$ $j = 0,\ d_0 = \max\limits_{k=1,2,3}(14, 11, 13) = 14;$

$T_0^{(1)} = 0;\ T_1^{(1)} = 2;\ T_2^{(1)} = 7;\ T_3^{(1)} = 6;\ T_4^{(1)} = 12;\ T_5^{(1)} = 0.$

Теорема 4.1. Для того чтобы событие P_j принадлежало критическому пути, необходимо и достаточно, чтобы выполнялось условие

$$T_j^{(0)} = T_j^{(1)}.$$

Доказательство

Необходимость. Пусть событие P_j принадлежит критическому пути, т. е. оно лежит на максимальном пути из P_0 в P_n, тогда

$$T_n^{(0)} = T_j^{(0)} + d_j,$$

где $T_j^{(0)}$ – длина максимального пути из P_0 в P_j; d_j – длина максимального пути из P_j в P_n.

Используем формулу (4.2) $T_j^{(1)} = T_n^{(0)} - d_j$; $T_n^{(0)} = T_j^{(1)} + d_j$, следовательно:

$$T_j^{(1)} = T_j^{(0)}.$$

Достаточность. Если $T_j^{(0)} = T_j^{(1)}$, то с учетом (4.2) приходим к тому, что $T_n^{(0)} = T_j^{(0)} + d_j$ и, следовательно, P_j принадлежит критическому пути.

Теорема 4.1 дает второй способ восстановления критического пути.

Важными временными параметрами сетевого графика являются так называемые свободный и полный резервы времени.

Определение 4.4. *Свободным резервом s_{ij} времени* работы (P_i, P_j) называется величина

$$s_{ij} = T_j^{(0)} - T_i^{(0)} - t_{ij}.$$

Величина s_{ij} для (P_i, P_j) означает отрезок времени, на который можно увеличить время выполнения работы или опоздать с ее началом так, чтобы не изменить минимальные моменты совершения событий, следующих за данной работой.

Определение 4.5. *Полным резервом p_{ij} времени* работы (P_i, P_j) называется величина

$$p_{ij} = T_j^{(1)} - T_i^{(0)} - t_{ij}.$$

Величина p_{ij} для (P_i, P_j) означает отрезок времени, на который можно увеличить время выполнения работы или опоздать с ее началом так, чтобы не увеличилось критическое время.

Теорема 4.2. Для того чтобы работа (P_i, P_j) принадлежала критическому пути, необходимо и достаточно, чтобы выполнялось условие

$$p_{ij} = 0.$$

Доказательство. Если (P_i, P_j) принадлежит критическому пути, это означает, что $T_n^{(0)} = T_i^{(0)} + t_{ij} + d_j$.

Учитывая формулу (4.2), $d_j = T_n^{(0)} - T_j^{(1)}$, и подставляя его в предыдущее выражение, получим

$$T_n^{(0)} = T_i^{(0)} + t_{ij} + T_n^{(0)} - T_j^{(1)},$$

следовательно:

$$T_j^{(1)} - T_i^{(0)} - t_{ij} = 0.$$

Проводя это же рассуждение с конца, можно показать и достаточность теоремы.

Для свободных резервов времени такое утверждение не верно, т. е. могут быть работы с нулевым свободным резервом, однако они не принадлежат критическому пути.

Эта теорема сразу позволяет находить все критические работы.

Значение p_{ij} является мерой критичности работы: чем ближе оно к 0, тем более критичной являются работа (P_i, P_j).

Особенно важно знание полного резерва времени любых работ для случая, когда указан директивный срок $T_{\text{дир}}$ выполнения проекта, причем $T_{\text{дир}} < T_{\text{крит}}$. Тогда возникает вопрос, какие из работ в первую очередь необходимо сократить по продолжительности, добавив им соответствующие ресурсы? Понятно, что это те, у которых $p_{ij} = 0$.

Продолжение примера 4.1.

Вычисления свободных и полных резервов времени работ для анализируемого СГ представим в виде следующей таблицы:

Работы	$s_{ij} = T_j^{(0)} - T_i^{(0)} - t_{ij}$	$p_{ij} = T_j^{(1)} - T_i^{(0)} - t_{ij}$
(P_0, P_1)	$s_{01} = 2 - 0 - 2 = 0$	$p_{01} = 2 - 0 - 2 = 0$
(P_0, P_2)	$s_{02} = 4 - 0 - 4 = 0$	$p_{02} = 7 - 0 - 4 = 3$
(P_0, P_3)	$s_{03} = 6 - 0 - 5 = 1$	$p_{03} = 6 - 0 - 5 = 1$
(P_1, P_3)	$s_{13} = 6 - 2 - 4 = 0$	$p_{13} = 6 - 2 - 4 = 0$
(P_1, P_4)	$s_{14} = 12 - 2 - 3 = 7$	$p_{14} = 12 - 2 - 3 = 7$
(P_2, P_5)	$s_{25} = 14 - 4 - 7 = 3$	$p_{25} = 14 - 4 - 7 = 3$
(P_3, P_4)	$s_{34} = 12 - 6 - 6 = 0$	$p_{34} = 12 - 6 - 6 = 0$
(P_3, P_5)	$s_{35} = 14 - 6 - 4 = 4$	$p_{35} = 14 - 6 - 4 = 4$
(P_4, P_5)	$s_{45} = 14 - 12 - 2 = 0$	$p_{45} = 14 - 12 - 2 = 0$

Работы (P_0, P_1), (P_1, P_3), (P_3, P_4), (P_4, P_5), как следует из таблицы, составляют критический путь. Наименее критичной является работа (P_1, P_4), для которой $p_{14} = 7$. Несмотря на то что $s_{02} = 0$, работа (P_0, P_2) не принадлежит критическому пути.

4.3. ЛИНЕЙНЫЕ ДИАГРАММЫ

Сетевые графики наглядно отражают технологические взаимосвязи между работами. Однако при их использовании трудно ответить, например, на вопрос, сколько и какие работы выполняются в каждый момент времени. Для ответа на такие вопросы используются представления СГ в виде линейных диаграмм (ЛД, диаграммы Ганнта или временные диаграммы).

Правило построения ЛД для правильно пронумерованных СГ: необходимо задать горизонтальную ось времени с нанесенной на ней градацией в выбранном масштабе. Работы изображаются в виде линий-отрезков, параллельных этой оси, причем длина каждого отрезка соответствует продолжительности работы.

Отрезки, соответствующие работам (P_{i_0}, P_j), т. е. с одинаковым началом P_{i_0}, изображаются друг над другом по возрастанию индексов j. Все работы, выходящие из P_0, начинаются от условной нулевой вертикали. Работы вида (P_i, P_j) откладываются от условной вертикали, которая проходит через самый правый конец работ вида (P_k, P_i), отложенных на диаграмме ранее.

Продолжение примера 4.1.

На ЛД (рис. 4.9) легко найти все временные параметры и, в частности, параметры, рассмотренные в предыдущем параграфе.

Минимальный момент совершения каждого события P_j будет соответствовать самой правой проекции концов работ вида (P_i, P_j). Например, $T_4^{(0)} = 12$. Таким образом, сразу же определяется критическое время проекта как самая правая проекция концов работ, входящих в проект.

Для построения критического пути на ЛД (см. рис. 4.9) достаточно выделить работу (горизонтальные линии на рис. 4.9), которая оканчивается в момент, соответствующий самой правой проекции события P_n. Далее, идя к началу этой работы и спускаясь по вертикали вниз, выделяют работу, конец которой совпадает с выделенным началом и

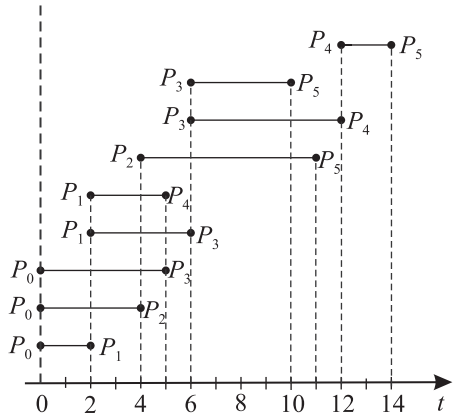

Рис. 4.9

лежит на данной вертикали. Затем вновь переходят к началу такой работы и спускаются вниз по вертикали, чтобы найти конец очередной работы и т. д., пока не дойдут до нулевой вертикали. Если на какой-то из вертикалей имеется несколько работ, концы которых совпадают с выделенным началом, то появляются варианты построения нескольких критических путей.

Свободный резерв времени каждой работы на ЛД (см. рис. 4.9) определяется как величина, на которую можно сдвинуть вправо данную работу, не сдвигая все следующие за ней работы.

Например, работу (P_1, P_4) можно сдвинуть на 7 ед. вправо, и при этом не будут сдвинуты все последующие работы.

Для определения *максимального момента* $T_j^{(1)}$ *свершения события* отрезки-работы, входящие в событие P_j и следующие после него, сдвигают вправо, насколько это возможно без увеличения критического времени. Тогда самый левый конец P_j после такого сдвига и определит на оси времени момент $T_j^{(1)}$.

Например, $T_2^{(1)}$ определяется следующим образом. Можно сдвинуть вправо отрезки (P_0, P_2) и (P_2, P_5) на три единицы, так как в этом случае критическое время не изменится. Тогда самый левый конец P_2 будет соответствовать моменту $T_2^{(1)} = 7$.

На полученной после подобных сдвигов линейной диаграмме полный резерв времени p_{ij} любой работы (P_i, P_j) определяется как величина ее сдвига, т. е. длина промежутка от старого положения P_j до нового положения P_j. Естественно, что для критических работ $p_{ij} = 0$.

Несмотря на трудоемкость построения ЛД (особенно при большом количестве работ) они часто используются из-за наглядности и простоты при ответе на вопросы, сколько и какие работы выполняются в каждый момент. Такая возможность существенна при анализе использования разных видов ресурсов, необходимых при реализации проекта.

4.4. ПРИМЕР ЗАДАЧИ ОПТИМАЛЬНОГО РАСПРЕДЕЛЕНИЯ ОГРАНИЧЕННОГО РЕСУРСА

Пусть для какого-то проекта построен СГ, на дугах-работах которого указаны продолжительности работ t_{ij}. Кроме того, для каждой работы (P_i, P_j) известно число r_{ij} – интенсивность потребления ресурса одного вида, т. е. количество того или иного ре-

сурса, необходимого для выполнения работы в единицу времени. Будем предполагать, что в течение всей работы эта интенсивность постоянна. Для всего проекта известны значения $R(t)$, задающие объем наличных ресурсов в каждый момент времени t. В целях упрощения изложения предположим, что $R(t)$ – постоянная величина, т. е. $R(t) = R$.

Такая постановка существенно упрощена, потому что на практике реализация каждого проекта требует нескольких видов ресурсов: людских, производственных, энергетических, финансовых.

Если выполнять работы в соответствии с временными параметрами СГ, то может оказаться, что в какой-то момент для выполнения работ необходим больший суммарный объем ресурса, чем заданное количество R. Следовательно, для того чтобы устранить полученное противоречие между требуемыми и имеющимися объемами ресурса, часть этих работ необходимо будет сдвинуть по оси времени вправо. Этот сдвиг приведет в общем случае к увеличению времени выполнения всего проекта.

Задача состоит в том, чтобы определить такие моменты начала работ, при которых в каждый момент времени суммарное количество используемого ресурса не превосходит R и отклонение Δ от критического времени выполнения всего проекта будет минимальным.

Продолжение примера 4.1. Дополним анализируемый СГ новой информацией, обозначенной на рис. 4.10 в кружках.

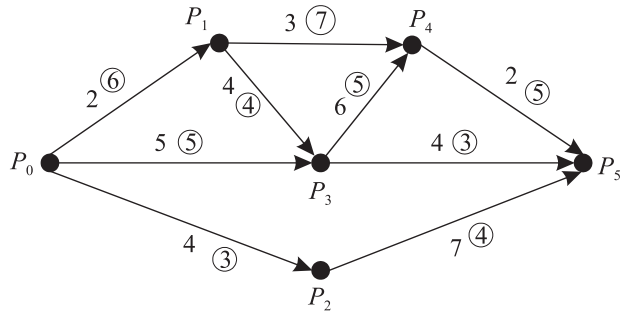

Рис. 4.10

Первое из чисел на дугах означает продолжительность каждой работы; второе – интенсивность использования одного вида ресурса, например количество требуемых рабочих. Пусть при этом $R = 14$.

Построим ЛД, на отрезках которой будут указаны потребности ресурса для соответствующей работы (рис. 4.11).

Пользуясь ЛД, можно посчитать, сколько единиц ресурса требуется в каждый момент. Например, при $t = 1$ требуется $6 + 3 + 5 = 14$ ед. ресурса. При $t = 2$ требуется $3 + 5 + 4 + 7 = 19$ ед. ресурса. Такие данные позволяют построить график использования ресурса в каждый момент времени (рис. 4.12).

Из данного графика видно, что на некоторых интервалах потребность в необходимом ресурсе превосходит его наличие. На интервале (2, 4) суммарно требуется 19 ед. ресурса, а на интервале (4, 5) − 20 ед. Это означает, что на этих интервалах некоторые из работ надо будет выполнять позже, т. е. на ЛД (см. рис. 4.12) некоторые работы придется сдвигать вправо. Такие сдвиги могут повлечь за собой, во-первых, увеличение потребности в ресурсах на последующих интервалах и, во-вторых, увеличение общего времени реализации проекта на некоторую величину Δ по сравнению с $T_{кр}$.

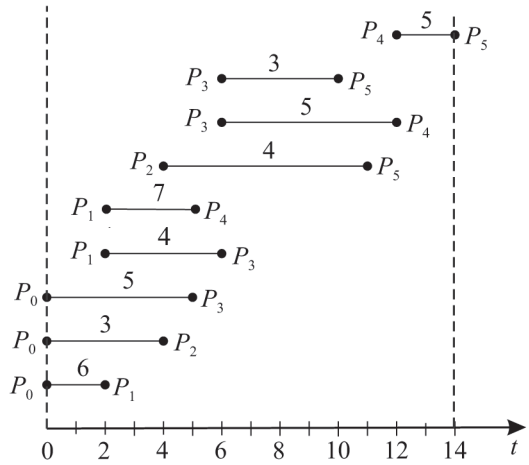

Рис. 4.11

Требуется устанавливать такую очередность сдвига работ вправо, чтобы минимизировать значение Δ и выполнить ограничение на суммарный ресурс R на всей используемой временной оси.

В общем случае для решения такой задачи даже при условии одного ограниченного ресурса пока еще не разработано эффективных методов. Имеются эвристические алгоритмы, которые часто на практике дают хорошее решение. Изложим идею одного из них, использующего временные параметры СГ и, в частности, полный резерв времени каждой работы.

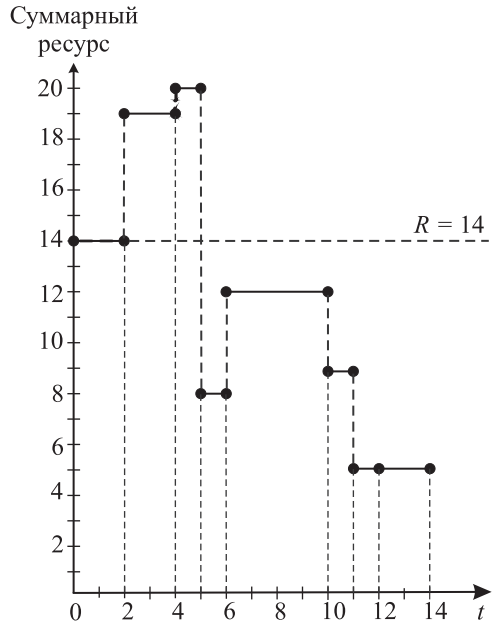

Рис. 4.12

Пример алгоритма распределения ограниченного ресурса

Общий шаг. Строятся (по возможности) ЛД и график использования ограниченного ресурса. Определяются временные параметры СГ (в том числе и полный резерв времени каждой работы).

На графике (или непосредственно после вычислений) выбирается первый слева временной интервал (τ', τ''), для которого имеется превышение величины суммарного использования ресурса над имеющимся количеством R. Такое превышение требует, чтобы начало некоторых работ над интервалом (τ', τ'') было сдвинуто направо до момента τ''. Естественно, в первую очередь сдвигать направо наименее критичные работы. Это означает, что все работы над интервалом (τ', τ'') должны быть упорядочены (пронумерованы) в порядке возрастания величины их полных резервов. Работы с одинаковыми полными резервами можно нумеровать, например, в порядке убывания интенсивности используемых ресурсов. После такого упорядочения производится постепенное накопление (суммирование) интенсивности работ в порядке возрастания их номеров. При очередном суммировании проверяем, не оказалась ли полученная сумма больше R. Если это произошло, то помечаем работу, из-за которой это случилось, исключаем ее из суммирования и продолжаем суммировать оставшиеся работы. После того как просмотрены все работы, решается вопрос о сдвиге вправо помеченных работ. В зависимости от условий задачи возможны два варианта:

A: работа не допускает перерыва;

B: работа допускает перерыв.

При *варианте A* начало помеченной работы передвигается до момента τ'' и продолжается после него.

При *варианте B* участок работы от момента τ' считается самостоятельной работой и именно его передвигаем до момента-начала τ''.

Замечание. Вариант А можно учесть уже при нумерации работ. В первую очередь номера присваиваются тем работам, которые были начаты до момента τ'. Для каждой из таких работ вычисляется разность между ее полным резервом и отрезком этой работы от ее начала до τ''. Такие работы нумеруются в порядке возрастания этих разностей.

При любом из вариантов сдвига получается новая ЛД и общий шаг повторяется.

Продолжение примера 4.1. Пусть для заданных ранее интенсивностей использования ресурса одного вида ранее построены ЛД и график использования этого ресурса (рис. 4.11 и 4.12). На графике видно, что над интервалом $(\tau', \tau'') = (2, 4)$ величина суммарного использованного ресурса равна 19 и превышает существующую величину ресурса $R = 14$. Над этим интервалом запланированы работы

$$(P_0, P_2),\ (P_0, P_3),\ (P_1, P_3),\ (P_1, P_4),$$

для которых, как вычислено ранее, $p_{02} = 3$, $p_{03} = 1$, $p_{13} = 0$, $p_{14} = 7$.

Предположим, что работы не допускают перерывов (вариант А). Тогда до момента $\tau' = 2$ были начаты работы (P_0, P_2), (P_0, P_3).

Вычислим (в соответствии с замечанием) $l_{02} = 3 - 4 = -1$ и $l_{03} = 1 - 4 = -3$. Этим самым работа

(P_0, P_3) получит номер 1,

(P_0, P_2) – номер 2,

(P_1, P_3) – номер 3,

(P_1, P_4) – номер 4.

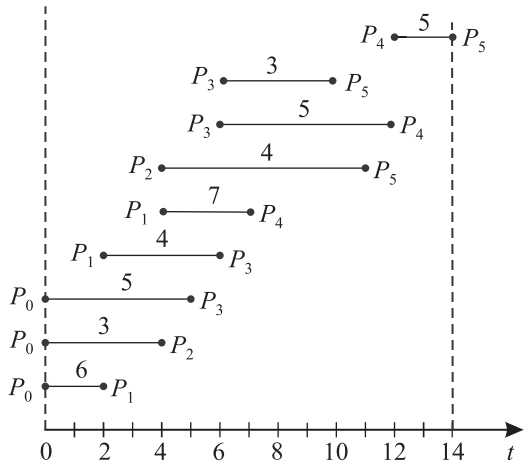

Рис. 4.13

В порядке нумерации работ суммируем интенсивности использования ресурсов, сравнивая каждую из сумм с $R = 14$:

$$3 + 5 + 4 < 14,\ 3 + 5 + 4 + 7 > 14.$$

Таким образом, работу (P_1, P_4) сдвигаем до момента-начала $\tau'' = 4$. Получаем в итоге ЛД, представленную на рис. 4.13.

Для такой ЛД получим график использования ресурса (рис. 4.14).

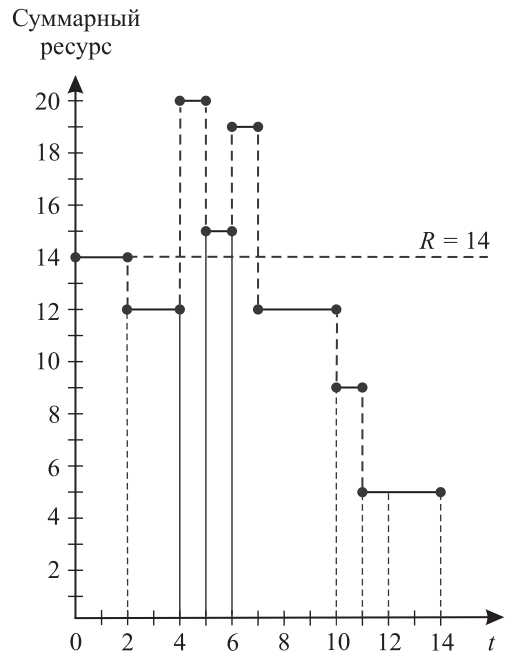

Рис. 4.14

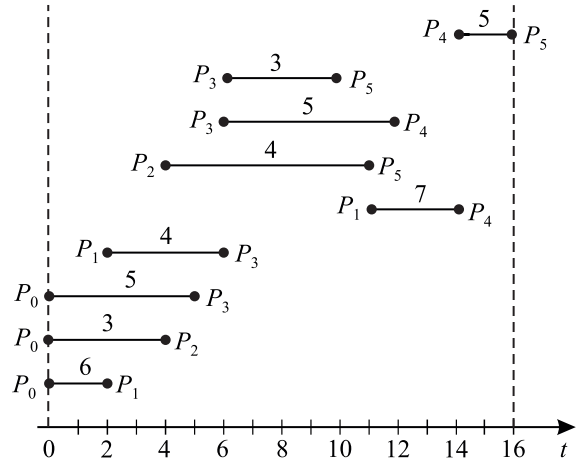

Рис. 4.15

Над интервалом $(\tau', \tau'') = (4, 5)$ имеется превышение величины необходимого ресурса над $R = 14$.

Найдем полные резервы времени работ, находящихся над временным интервалом $(\tau', \tau'') = (4, 5)$, т. е. для работ

$$(P_0, P_3), (P_1, P_3), (P_1, P_4), (P_2, P_5).$$

Они равны $p_{03} = 1$; $p_{13} = 0$; $p_{14} = 5$; $p_{25} = 3$. Работы (P_0, P_3), (P_1, P_3) начаты ранее момента $\tau' = 4$, и для них $l_{03} = 1 - 5 = -4$, $l_{13} = 0 - 3 = -3$.

Таким образом, работа (P_0, P_3) получит номер 1, (P_1, P_3) – номер 2 и далее работа (P_2, P_5) – номер 3, (P_1, P_4) – номер 4. В порядке нумерации работ суммируем интенсивности использования ресурсов, сравнивая каждую из сумм с $R = 14$:

$$5 + 4 + 4 < 14,\ 5 + 4 + 4 + 7 > 14.$$

Таким образом, работу (P_1, P_4) сдвигаем до момента-начала $\tau'' = 5$. Строим новую ЛД и график использования ресурсов и повторяем общий шаг.

Повторив несколько таких шагов, дойдем до следующей ЛД (рис. 4.15).

Этой ЛД соответствует следующий график использования ресурсов (рис. 4.16).

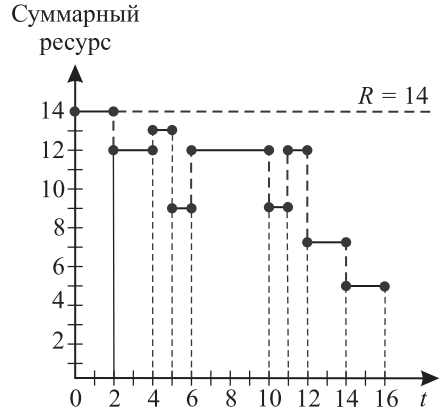

Рис. 4.16

Из этого графика видно, что последовательность выполнения работ удовлетворяет требованию ограниченности ресурса: в любой момент всего временного интервала суммарная потребность в ресурсе не превышает ограничения $R = 14$. Это достигнуто за счет прироста $\Delta = 2$ к критическому времени проекта. Формально невозможно судить, является ли построенная последовательность оптимальной (в смысле уменьшения величины $\Delta \geq 0$).

Замечание. Приведенный простейший пример задачи оптимального распределения ресурсов показывает, насколько трудоемкими являются подобные задачи. На практике число видов ограниченных ресурсов для реализации проекта – свыше одного, интенсивности использования этих ресурсов не обязательно постоянны. Кроме того, организация обычно реализует параллельно несколько проектов и требуется согласование времен их выполнения с учетом ограниченности общих ресурсов.

4.5. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. Какие задачи решает сетевое планирование?
2. На основании каких сведений строятся сетевые графики?
3. Почему сетевой график не имеет контуров?
4. Как связаны минимальные моменты свершения событий с длинами путей на сетевом графике?
5. Как связаны максимальные моменты свершения событий с длинами путей на сетевом графике?
6. Опишите хотя бы два метода восстановления критического пути.
7. В чем заключается содержательный смысл свободного резерва времени работ на сетевом графике?
8. В каких целях в сетевом планировании используют линейные диаграммы?
9. Как на линейной диаграмме найти основные временные параметры сетевого графика?
10. В чем суть задачи оптимального распределения ограниченного ресурса в сетевом планировании?
11. Как строится график использования ресурса во времени на основе линейной диаграммы?

5. ЗАДАЧИ ОПТИМАЛЬНОГО УПОРЯДОЧЕНИЯ

5.1. ЭЛЕМЕНТЫ ТЕОРИИ РАСПИСАНИЙ

5.1.1. Понятие о задачах теории расписаний

Одним из важнейших средств эффективного выполнения любого рода деятельности является планирование во времени, т. е. использование расписаний как некоторой совокупности указаний: какие именно операции какими именно исполнителями будут выполняться в каждый момент времени. Как отмечено ранее, весьма полезным средством планирования во времени являются сетевые графики и временные диаграммы. Однако эти модели применимы только в случаях, когда заранее установлена очередность выполнения всех запланированных работ. В исследовании операций изучаются также модели, когда предварительно требуется определить очередность выполнения работ с учетом возможностей исполнителей. Ограничения на возможности изменения очередности и выбор исполнителей обусловливаются различными (в том числе и экономическими) требованиями и существенно затрудняют задачу составления наилучшего (оптимального) расписания. Такого рода проблемы являются предметом изучения в специальном разделе исследования операций – теории расписаний (ТР).

В теории расписаний изучаются системы, обслуживающие некоторое множество требований для случая, когда все требования готовы к обслуживанию, и оно, как правило, состоит из нескольких последовательных операций. Общепринято модели формулировать на языке «заявки-приборы» или даже «детали-станки». Далее рассмотрим следующий, достаточно общий пример задачи теории расписаний. Пусть имеется m приборов, на которых требуется обслужить n заявок, причем считается, что все эти заявки уже поступили в систему. Для каждой i-й заявки задана последовательность $U^{(i)} = (u_1^{(i)}, ..., u_{m_i}^{(i)}), \quad i = 1, 2, ..., n,$ которая определяет технологический маршрут обслуживания этой заявки таким образом, что $u_j^{(i)}$ означает номер прибора, обслуживающего i-ю заявку на j-м шаге ее технологического маршрута. Последовательность таких номеров будет определять порядок перехода заявки при обслуживании от прибора к прибору. В каждой последовательности $U^{(i)}$, $i = 1, 2, ..., n$, в общем случае допускается повторение одинаковых номеров. Также не ограничивается значение m_i, т. е. число шагов обслуживания i-й заявки. Например, может быть маршрут $U^{(i)} = (1, 2, 3, 2, 1, 4, 1)$. В соответствии с технологическим маршрутом $U^{(i)}$ также заданы значения t_{ij} ($i = 1, 2, ..., n$; $j = 1, 2, ..., m_i$) – положительные рациональные числа, означающие продолжительность обслуживания i-й заявки на каждом j-м шаге ее технологического маршрута. Не умень-

шая общности, можно считать, что t_{ij} – целые числа. Будем рассматривать модели, в которых процесс обслуживания подчиняется следующим условиям:

1) ни одна заявка не может одновременно обслуживаться несколькими приборами;

2) если обслуживание заявки начато, то оно должно быть доведено до конца на каждом шаге без перерыва в обслуживании;

3) время перехода заявки от одного прибора к другому не учитывается;

4) ни один прибор не может одновременно обслуживать более чем одну заявку;

5) время настройки (наладки) приборов (т. е. подготовки к обслуживанию следующей в очереди заявки) не учитывается.

Задача состоит в том, чтобы при заданных маршрутах $U^{(i)}$ для $i = 1, 2, ..., n$ и, соответственно, времен обслуживания t_{ij} в условиях 1) – 5) найти такие моменты начала обслуживания каждой заявки на любом приборе, при которых общее время обслуживания всех заявок будет минимальным.

Пример 5.1. Пусть задача ТР задана в виде следующей таблицы:

Заявки	Технологические маршруты	Время обслуживания
А	(1, 2, 4, 2)	3, 2, 1, 2
Б	(1, 2, 3)	1, 3, 3
В	(2, 3, 2, 4)	2, 3, 3, 2
Г	(4, 5, 3)	4, 3, 3
Д	(3, 1, 4, 5)	3, 4, 2, 2
Е	(4, 5, 4, 1, 2)	2, 2, 2, 2, 2
Ж	(5, 1, 5, 4)	2, 1, 2, 1
З	(3, 1)	1,3
К	(5)	3

Рассмотрим два конкретных расписания на линейных диаграммах (рис. 5.1).

На приведенной линейной диаграмме полностью выполнены все требования технологического маршрута и условия обслуживания, причем уплотнить работы сдвигом их влево не возможно. Общее время обслуживания $T' = 25$ ед.

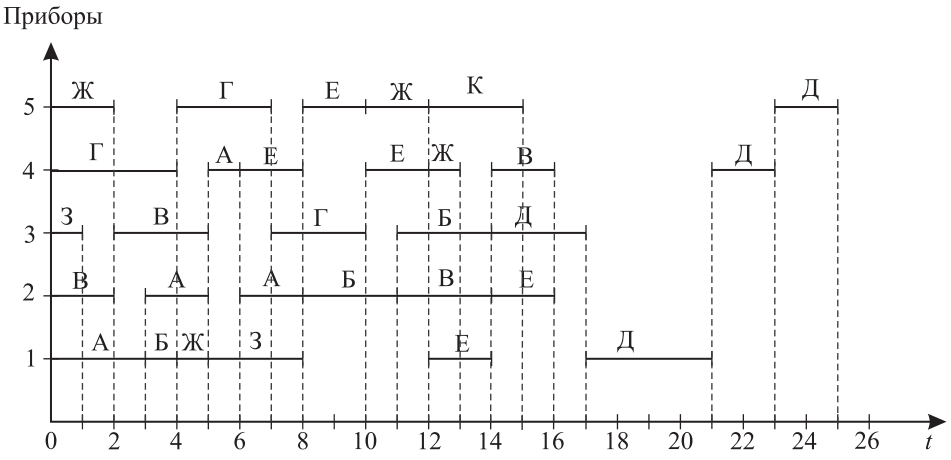

Рис. 5.1

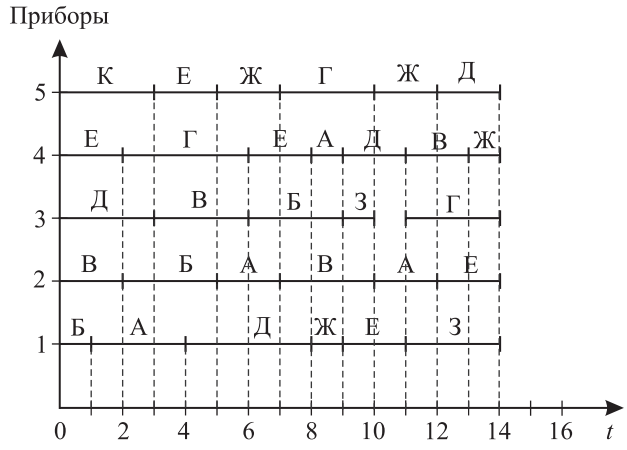

Рис. 5.2

Зададим еще один из возможных вариантов расписания обслуживания (рис. 5.2).

Вариант обслуживания заявок, который также полностью удовлетворяет всем требованиям, представлен на рис. 5.2. Общее время обслуживания $T = 14$ ед. Очевидно, что он является наилучшим с точки зрения общего времени обслуживания всех заявок, так как уменьшить время обслуживания на приборах 1, 2, 4, 5 не возможно.

Большинство задач теории расписаний не имеет строго математического решения, и, чтобы их решить, используют эвристические методы.

Замечание. Сформулированная задача может быть сведена к задаче линейного программирования с логическими условиями, которая, в свою очередь, сводится к задаче линейного целочисленного программирования. Однако даже для небольших исходных моделей соответствующая задача целочисленного программирования содержит большое число ограничений и неизвестных, что существенно затрудняет ее решение.

5.1.2. Задача Беллмана – Джонсона

Предположим, что к условиям сформулированной задачи ТР добавлены еще два условия:

6) технологический маршрут для всех заявок одинаков;

7) последовательность поступления заявок на обслуживание на всех приборах одинакова.

Как и в предыдущей модели, задача состоит в том, чтобы для заданного технологического маршрута и соответствующего времени обслуживания заявок в условиях 1) – 7) найти такие моменты начала обслуживания каждой заявки на любом приборе, при которых общее время обслуживания всех заявок будет минимальным.

Впервые эту задачу исследовали математики Р. Беллман и С. М. Джонсон (задача Б – Д), относя ее к задачам так называемого поточного типа (flow shop).

Не уменьшая общности, условие 6) можно сформулировать в виде 6′), технологический маршрут для всех заявок одинаков и имеет вид

$$U^{(i)} = (1, 2, ..., m), \quad i = 1, 2, ..., n.$$

Условие 7) по существу означает, что очередность обслуживания заявок будет установлена, если определятся моменты x_{i1}, $i = 1, 2, ..., n$, начала обслуживания каждой заявки на первом приборе при оговорке, что на остальных приборах обслуживание будет начинаться настолько рано, насколько это позволяют условия обслуживания. Более того, тогда можно утверждать, что конкретные моменты x_{i1} взаимно-однозначно определяют перестановку

$$K = (k_1, k_2, ..., k_n)$$

n чисел 1, 2, …, n, причем каждый элемент k_i в такой перестановке является номером заявки, которая будет обслуживаться в расписании i-й по порядку. Известно, что имеется $n!$ возможных перестановок чисел 1, 2, …, n. Среди такого количества перестановок в задаче Б – Д необходимо найти оптимальную. Даже для сравнительно небольших n (например, $n \geq 20$) полный перебор перестановок не осуществим в приемлемое время. Таким образом, как отмечено в п. 1.3, задачу Б – Д можно отнести к классу комбинаторных задач ИСО.

Если какая-то перестановка $K = (k_1, k_2, ..., k_n)$ задана, то анализ задачи Б – Д сводится к анализу специального сетевого графика, который имеет следующую структуру. Вершины этого сетевого графика означают операцию по обслуживанию на соответствующих приборах. Если какая-то операция выполняется для заявки k, то после нее могут быть выполнены только две из возможных операций: или будет выполняться операция по обслуживанию этой заявки на очередном приборе, или на этом же приборе будет обслуживаться очередная в расписании заявка. Эти варианты переходов будем рисовать в виде стрелок.

В итоге получим сетевой график, представленный на рис. 5.3.

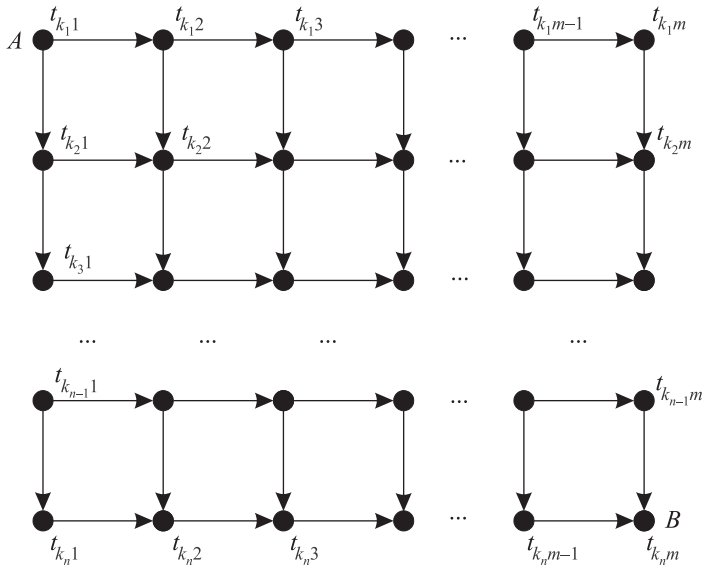

Рис. 5.3

Как известно, для того чтобы найти общее время обслуживания в комплексе работ, представленных в сетевом графике, достаточно найти длину критического пути от начальной вершины до конечной (в нашем случае это вершины A и B).

Любой путь от вершины A до B можно представить в виде вертикальных и горизонтальных отрезков от номера 1 до номера u_1 в первой колонке, от u_1 до u_2 во второй колонке и т. д. … от u_{m-1} до n в m-й колонке (рис. 5.4).

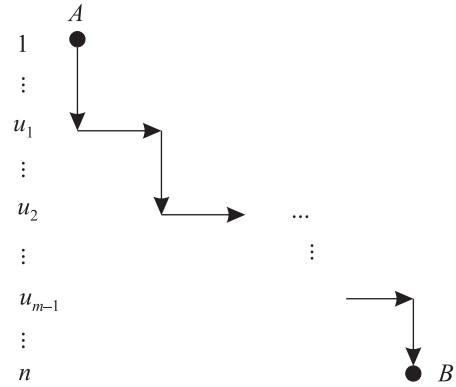

Рис. 5.4

При $1 \le u_1 \le u_2 \le ... \le u_{m-1} \le n$ длина такого пути будет равна

$$\sum_{s=1}^{u_1} t_{k_s 1} + \sum_{s=u_1}^{u_2} t_{k_s 2} + ... + \sum_{s=u_{m-1}}^{n} t_{k_s m}.$$

Тогда критическое время от A до B будет равно

$$T_{\text{крит}}(K) = \max_{\substack{1 \le u_1 \le ... u_i \le u_{m-1} \le n \\ \text{все } u_i - \text{целые числа}}} \left(\sum_{s=1}^{u_1} t_{k_s 1} + ... + \sum_{s=u_{m-1}}^{n} t_{k_s m} \right). \qquad (5.1)$$

Естественно, для практического отыскания величины $T_{\text{крит}}(K)$ не обязательно пользоваться выведенной формулой. Более эффективным является непосредственное вычисление длины критического пути от A до B как пути максимальной длины в построенном сетевом графике специального вида. Выведенная формула необходима для сравнения различных расписаний и получения на этой основе эффективных рекомендаций для нахождения оптимального расписания. Примером таких выводов может служить случай, когда $m = 2$, т. е. рассматривается задача Б – Д с двумя обслуживающими приборами. При этом формула (5.1) примет вид

$$T(K) = \max_{\substack{1 \le u_1 \le n \\ u_1 - \text{целые числа}}} \left(\sum_{s=1}^{u_1} t_{k_s 1} + \sum_{s=u_1}^{n} t_{k_s 2} \right).$$

Для построения оптимального расписания в этом случае используется следующий, так называемый перестановочный прием.

Рассматривают 2 перестановки:

$$K_{i,i+1} = (1, 2, ..., i-1, i, i+1, ..., n);$$

$$K_{i+1,i} = (1, 2, ..., i-1, i+1, i, i+2, ..., n)$$

и выясняют условия, для которых $K_{i,i+1}$ не хуже, чем перестановка $K_{i+1,i}$, т. е. условия, при которых $T(K_{i,i+1}) \le T(K_{i+1,i})$.

Для этого непосредственно записывают приведенную выше формулу для обеих перестановок и показывают, что это неравенство, в частности, выполняется, если выполняется условие

$$\min(t_{i1}, t_{i+1,2}) \le \min(t_{i2}, t_{i+1,1}). \tag{5.2}$$

Как известно, от любой заданной перестановки можно перейти к любой другой за конечное число перестановок соседних элементов. Поэтому выведенное правило легко обобщить, когда рассматриваются не две соседние заявки i и $i + 1$, а две любые i и j. Тогда, используя неравенство (5.2), можно доказать следующую теорему.

Теорема 5.1. В оптимальном расписании для задачи Б – Д с двумя приборами заявка i обслуживается ранее заявки j, если выполняется неравенство

$$\min(t_{i1},\ t_{j2}) \le \min(t_{i2},\ t_{j1}). \tag{5.3}$$

Неравенство (5.3) обладает свойством транзитивности, т. е. если оно выполняется для пар i, j и j, k, то оно будет выполняться и для пары i, k.

Это доказывается непосредственным анализом трех неравенств вида (5.3) и возможных соотношений между входящими под знак min числами t_{i1}, t_{i2}, t_{j1}, t_{j2}, t_{k1}, t_{k2}.

Свойство транзитивности позволяет строить хотя бы одно оптимальное расписание для задачи Б – Д в случае, когда $m = 2$.

Алгоритм Джонсона

Шаг 1. Составляют таблицу времен обслуживания заявок, состоящая из n строк и двух столбцов. Одновременно готовится строка из n пустых позиций.

Шаг 2. В таблице находят минимальный элемент. Если он принадлежит первому столбцу, то номер его строки записывают в первую слева свободную позицию подготовленной строки. Если этот минимум принадлежит второму столбцу, то номер его строки записывают в первую справа свободную позицию. В любом случае строка, где был минимум, вычеркивается из таблицы времен обслуживания. Шаг 2 повторяется, пока не заполнятся все пустые позиции подготовленной строки. Этим самым определится оптимальное расписание.

Если потребуется выбор из нескольких одинаковых минимумов, то можно выбирать любой из них. При выборе иного минимума может получиться иное оптимальное расписание.

Пример 5.2. Пусть $m = 2$, $n = 8$, и время обслуживания представим в следующей матрице:

$$\begin{array}{c} 1 \\ 2 \\ 3 \\ 4 \\ 5 \\ 6 \\ 7 \\ 8 \end{array} \begin{pmatrix} 5 & 4 \\ 1 & 2 \\ 6 & 1 \\ 3 & 7 \\ 1 & 10 \\ 3 & 2 \\ 4 & 3 \\ 9 & 8 \end{pmatrix}.$$

Применяя алгоритм, получим возможное оптимальное расписание $K_{\text{опт}} = (5, 2, 4, 8, 1, 7, 6, 3)$, при котором общее время обслуживания заявок будет минимально.

Данный алгоритм, разработанный в 1954 г., является эффективным по числу операций. Для задачи Б – Д при $m > 2$ в общем случае нет эффективных алгоритмов, существенно уменьшающих полный перебор всех возможных перестановок-расписаний.

5.2. ЗАДАЧА КОММИВОЯЖЕРА

5.2.1. Анализ задачи

Еще одной важной для ИСО задачей комбинаторного типа является задача коммивояжера.

Пусть имеется n пунктов, пронумерованных в некотором порядке: 1, 2, ..., n. Для каждой пары (i, j) этих пунктов известно расстояние c_{ij}. Термин «расстояние» может означать физическое расстояние между этими пунктами, время перехода из пункта i в пункт j, стоимость такого перехода или количество затраченного горючего. Значения c_{ij} образуют квадратную матрицу $C = [c_{ij}]_{n\times n}$, у которой элементы на главной диагонали не определены и, например, обозначены символом ∞. В этой матрице не обязательно $c_{ij} = c_{ji}$, т. е. она может быть несимметричной.

Коммивояжер, начиная от некоторого начального пункта, например пункта 1, должен обойти все остальные, побывав в каждом пункте по одному разу таким образом, чтобы его маршрут был оптимален по какому-либо критерию. Чаще всего оценкой маршрута является его длина как сумма расстояний непосредственных переходов в выбранном маршруте. Коммивояжеру нужно выбрать маршрут наименьшей длины.

Построим математическую модель задачи коммивояжера. Через x_{ij} обозначим переменные, такие, что $x_{ij} = 1$, если коммивояжер включил в свой маршрут переход от пункта i до пункта j, и $x_{ij} = 0$ – в противном случае. В задаче необходимо определить значения x_{ij}, при которых функция

$$f = \sum_{i=1}^{n}\sum_{j=1}^{n} c_{ij}x_{ij} \tag{5.4}$$

принимает минимальное значение и для которых выполняются условия:

$$\sum_{j=1}^{n} x_{ij} = 1, \quad i = 1, 2, ..., n; \tag{5.5}$$

$$\sum_{i=1}^{n} x_{ij} = 1, \quad j = 1, 2, ..., n; \tag{5.6}$$

$$x_{ij} \in \{0,1\}, \quad i, j = 1, 2, ..., n, \quad i \neq j; \tag{5.7}$$

множество x_{ij} *должно определять замкнутый маршрут*. (5.8)

Условие (5.5) говорит о том, что коммивояжер обязан переходить из пункта i только в один из остальных пунктов. Условие (5.6) требует, чтобы в каждый пункт j переход осуществлялся только из одного пункта.

Целевая функция (5.4) и ограничения (5.5)–(5.7) в точности совпадают с моделью классической задачи о назначениях (п. 3.6). Проанализируем детально сущность дополнительного условия (5.8).

Как уже отмечено в п. 3.6, каждый вариант назначения работников на работы соответствует подстановке, т. е. взаимно-однозначному отображению множества $N = \{1, 2, ..., n\}$ на себя. Верно и обратное, что каждая подстановка определяет один вариант назначения. Известно, что число всевозможных подстановок-назначений равно $n!$.

Условие (5.8) в задаче коммивояжера приводит к тому, что не каждая подстановка определяет замкнутый маршрут коммивояжера. Дело в том, что каждая подстановка может быть представлена в виде объединения так называемых циклов. Циклом в этом случае называется последовательность отображений пар «прообраз – образ», в которых каждый образ является прообразом в последующей паре и образ последней пары – прообразом первой. Любая подстановка − это или объединение нескольких циклов длины, меньшей n, или полный цикл длины n. Легко подсчитать, что множество полных циклов содержит $(n – 1)!$ подстановок. Условие (5.8) требует, чтобы любой маршрут коммивояжера был полным циклом. Это означает, что если на матрице расстояний $C = [c_{ij}]_{n \times n}$ в задаче коммивояжера решить задачу о назначениях с минимизацией целевой функции и если это решение будет полным циклом, то оно одновременно будет решением задачи коммивояжера. К сожалению, это сравнительно редко встречаемая ситуация. Кстати, такие задачи, где решение находится очень эффективно, могут быть тестовыми для оценки результативности других, более трудоемких методов для решения задачи коммивояжера.

Условия (5.8) можно записать в виде формальных неравенств, например, путем введения дополнительных целочисленных переменных, связанных с пунктами $1, 2, ..., n – 1$. В итоге задача коммивояжера становится задачей линейного целочисленного программирования. Однако этот факт редко используется для нахождения решения из-за больших размеров получаемой задачи.

5.2.2. Примеры задач теории расписаний, сводящихся к задаче коммивояжера

Задача коммивояжера имеет большое практическое применение не только сама по себе. К ней сводятся многие другие задачи оптимального упорядочения, в частности некоторые задачи теории расписаний.

Пример 5.3. Одностадийная задача обслуживания заявок.

Пусть n заявок необходимо обслужить на одном приборе, причем известно время t_i, $i = 1, 2, ..., n$, обслуживания каждой заявки. Кроме того, известно, что если после обслуживания заявки i будет обслуживаться заявка j, то необходима переналадка прибора, которая длится τ_{ij} единиц времени. Эти величины образуют матрицу $[\tau_{ij}]_{n\times n, i\neq j}$.

Задача состоит в том, чтобы найти такую очередность обслуживания всех заявок, при которой суммарное время обслуживания будет минимальным.

Если перестановка $K = (k_1, k_2, ..., k_n)$ определяет очередность обслуживания заявок, то общее время этого обслуживания равно

$$T(K) = \sum_{i=1}^{n} t_{k_i} + \sum_{i=1}^{n-1} \tau_{k_i k_{i+1}}.$$

Очевидно, что первое слагаемое в этой сумме не зависит от порядка обслуживания и является величиной постоянной. Второе слагаемое зависит от очередности обслуживания, и поиск оптимальной очередности заключается в нахождении такой перестановки, которая минимизирует $\sum_{i=1}^{n-1} \tau_{k_i k_{i+1}}$. Если все τ_{ij} представить на расширенной матрице

$$\begin{array}{c} \\ 0 \\ 1 \\ 2 \\ . \\ n \end{array} \begin{array}{c} \begin{array}{ccccc} 0 & 1 & 2 & ... & n \end{array} \\ \begin{bmatrix} \infty & 0 & 0 & ... & 0 \\ 0 & \infty & \tau_{12} & ... & \tau_{1n} \\ 0 & \tau_{21} & \infty & ... & \tau_{2n} \\ . & . & . & . & . \\ 0 & \tau_{n1} & \tau_{n2} & ... & \infty \end{bmatrix} \end{array},$$

то очевидно, что решение задачи коммивояжера для этой матрицы «расстояний» определит искомое оптимальное расписание для нашей одностадийной задачи обслуживания заявок. Оно получится из оптимального маршрута коммивояжера с началом в пункте 0 путем формального удаления этого пункта.

Пример 5.4. Многостадийная задача без задержек в обслуживании заявок.

Пусть, кроме условий 1) – 7), в задаче Б – Д дополнительно выполняется еще одно условие:

8) для каждой заявки момент начала ее обслуживания на очередном приборе совпадает с моментом окончания ее обслуживания на предыдущем приборе.

Требуется в условиях обслуживания 1) – 8) найти расписание-перестановку, минимизирующую общее время обслуживания всех заявок.

Покажем, что сформулированная задача сводится к специальной задаче коммивояжера. В целях упрощения выкладок примем, что $m = 3$, т. е. что в системе имеется 3 прибора.

Пусть $K = (k_1, k_2, ..., k_n)$ – произвольная очередность обслуживания заявок. Обозначим через $p_{k_i k_{i+1}}$ время ожидания прибора 3 между обслуживанием двух соседних в расписании K заявок k_i, k_{i+1} ($i = 1, 2, ..., n - 1$). Величины $p_{k_i k_{i+1}}$ вычисляются по формулам:

$$p_{k_i k_{i+1}} = t_{k_{i+1}1} + t_{k_{i+1}2} - \min(t_{k_i 2} + t_{k_i 3},\ t_{k_i 3} + t_{k_{i+1}1},\ t_{k_{i+1}1} + t_{k_{i+1}2}).$$

Введем еще значение $\sum_{i=0}^{n-1} p_{k_i k_{i+1}}$. как время ожидания третьего прибора на обслуживание заявки k_1, начиная от момента 0 – начала обслуживания всех заявок. Очевидно, что общее время обслуживания всех заявок в очередности K равно

$$T(K) = \sum_{i=1}^{n} t_{k_i} + \sum_{i=0}^{n-1} p_{k_i k_{i+1}}.$$

Следовательно, первое слагаемое в этой сумме не зависит от порядка обслуживания и является величиной постоянной. Второе слагаемое зависит от очередности обслуживания и тем самым поиск оптимальной очередности сводится к поиску перестановки, которая минимизирует $\sum_{i=0}^{n-1} p_{k_i k_{i+1}}$. Если принять, что $k_0 = 0$, и все $p_{k_i k_{i+1}}$ представить на матрице

$$\begin{array}{c} \\ 0 \\ 1 \\ 2 \\ . \\ n \end{array} \begin{array}{c} \begin{array}{ccccc} 0 & 1 & 2 & \ldots & n \end{array} \\ \begin{bmatrix} \infty & p_{01} & p_{02} & \cdots & p_{0n} \\ 0 & \infty & p_{12} & \cdots & p_{1n} \\ 0 & p_{21} & \infty & \ldots & p_{2n} \\ . & . & . & . & . \\ 0 & p_{n1} & p_{n2} & \ldots & \infty \end{bmatrix} \end{array},$$

то очевидно, что решение задачи коммивояжера для этой матрицы «расстояний» определит искомое оптимальное расписание для сформулированной задачи обслуживания. Оно получится из оптимального маршрута коммивояжера с началом в пункте 0 путем формального удаления этого пункта.

Замечание. Интересно, что при $m = 2$ (двух приборах в обслуживающей системе) в сформулированной задаче без задержек в обслуживании соответствующая задача коммивояжера решается алгоритмом, сравнимым по эффективности с алгоритмом Джонсона для решения задачи Б – Д.

5.3. МЕТОД ВЕТВЕЙ И ГРАНИЦ ДЛЯ РЕШЕНИЯ ЗАДАЧ ОПТИМАЛЬНОГО УПОРЯДОЧЕНИЯ

5.3.1. Общая схема

Пусть требуется найти минимальное значение целевой функции $f(X)$ на конечном множестве Ω допустимых решений X, т. е. найти

$$\min_{X \in \Omega} f(X).$$

Использование метода ветвей и границ при решении конкретной комбинаторной задачи состоит из нескольких основных этапов.

1. *Ветвление*. Должно существовать правило разбиения множества Ω на подмножества типа $\Omega_1^{(1)}, \ldots, \Omega_k^{(1)}$ так, чтобы $\bigcup_{i=1}^{k} \Omega_i^{(1)} = \Omega$.

Допускается пересечение множеств, получаемых в результате разбиения, после которого необходимо, чтобы правило ветвления позволило ветвить каждое из подмножеств $\Omega_i^{(1)}$, потом $\Omega_j^{(2)}$ и т. д. Таким образом, в результате ветвления должно строиться (явно или нет) дерево ветвлений, представленное на рис. 5.5, и правило разбиения должно быть применимо к каждой висячей вершине дерева, соответствующей подмножеству с более чем одним элементом.

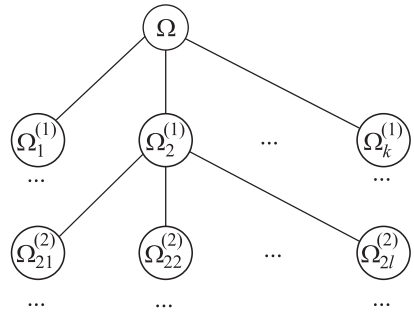

Рис. 5.5

2. *Вычисление нижней границы целевой функции*. Для каждого подмножества Ω_k, получаемого в результате ветвления, необходимо уметь вычислить нижнюю границу целевой функции на этом подмножестве, т. е. число $\xi(\Omega_k)$ такое, что

$$f(X) \geq \xi(\Omega_k) \text{ для любых } X \in \Omega_k.$$

3. *Пересчет оценок.* Если для двух множеств Ω_1 и Ω_2 выполняется включение $\Omega_1 \subset \Omega_1$, то для целевой функции будет выполняться соотношение

$$\min_{X \in \Omega_1} f(X) \geq \min_{X \in \Omega_2} f(X).$$

Можно считать, что при каждом разбиении множества Ω' на подмножества $\Omega'_1, \Omega'_2, ..., \Omega'_k$ способ вычисления нижних границ подобран так, что $\xi(\Omega'_i) \geq \xi(\Omega')$, т. е. при ветвлении нижняя граница не убывает.

4. *Построение допустимых решений.* Если на дереве ветвлений найдена вершина, которую нельзя больше разветвить, то надо уметь по единственной цепи от корня дерева до этой вершины построить соответствующее допустимое решение из Ω. Конкретный способ разрабатывается в зависимости от специфики задачи.

5. *Признак оптимальности.* Для каждой конкретной задачи должен применяться следующий принцип: если на каком-то шаге ветвления найдено решение $\bar{X}$ и при этом

$$f(\bar{X}) = \xi(\Omega_i) = \min(\Omega_k),$$

где минимум берется по всем висячим вершинам дерева ветвлений, то это решение является оптимальным: решения, для которого значение целевой функции ниже минимальной нижней границы, не может быть.

6. *Способы уменьшения возможных вариантов ветвления.* Основной прием состоит в том, что некоторым способом находится хотя бы одно решение из Ω. Значение целевой функции для него объявляют рекордом и на дереве не рассматриваются (не ветвятся) все те висячие вершины, нижняя граница которых выше значения $f(X_{\text{рек}})$.

7. *Возможность останова вычислений.* Часто либо из-за конструкции метода, либо по необходимости вычисления останавливают. В таком случае последнее достигнутое допустимое решение $\hat{X}$ со значением целевой функции $f(\hat{X})$ и наименьшей границей $\hat{\xi}$ среди всех висячих вершин дерева позволяет оценить относительную ошибку $(f(\hat{X}) - \hat{\xi})/\hat{\xi}$ недостижения оптимального решения.

В целом метод ветвей и границ – это не один специальный алгоритм, а очень широкий класс алгоритмов. Эффективность применения этого метода зависит от разработки стратегии для конкретно рассматриваемой задачи.

Замечание. Легко модифицировать общую схему метода ветвей и границ для случая максимизации целевой функции на конечном множестве допустимых решений.

5.3.2. Метод ветвей и границ для задачи о рюкзаке

Как уже отмечалось в примере 2.4, математическая модель задачи о рюкзаке (ЗР) состоит в определении таких значений $x_1, x_2, ..., x_n$, для которых выполняются условия:

$$\sum_{j=1}^{n} a_j x_j \le A; \tag{5.9}$$

$$x_j \in \{0,1\}, \quad j = 1,2,...,n, \tag{5.10}$$

и для которых целевая функция

$$z = \sum_{j=1}^{n} c_j x_j \tag{5.11}$$

достигает максимального значения.

Не уменьшая общности, можно считать, что

$$\frac{c_1}{a_1} \ge \frac{c_2}{a_2} \ge ... \ge \frac{c_n}{a_n}. \tag{5.12}$$

Используя простую структуру ЗР, можно модифицировать общую схему метода ветвей и границ и таким образом построить достаточно эффективный алгоритм.

Обозначим через $\bar{X}$ оптимальное решение вспомогательной ЗР при условии

$$0 \le x_i \le 1, \quad i = 1,2,...,n, \tag{5.13}$$

алгоритм нахождения которого описан в примере 2.4.

Каждый допустимый вариант решения ЗР определяется бинарным вектором $X = (x_1, x_2, ..., x_n)$. Легко видеть, что $z(X) \le z(\bar{X})$ для любого вектора X, т. е. значение $z(\bar{X})$ является верхней границей для целевой функции в задаче (5.9)–(5.11).

Дерево ветвлений строится следующим простейшим способом. Множество всех возможных X разбивается на два подмножества: первое с $x_1 = 0$, второе с $x_1 = 1$. На втором уровне любое из двух подмножеств можно разбить на два, в зависимости от того, $x_2 = 0$ или $x_2 = 1$ и т. д. Таким образом, после какого-то k-го разбиения в каждом векторе допустимых решений, обозначенном через $X^{(k)}$, будут определены первые k элемен-

тов. Естественно, каждое «уточнение» допустимого множества решений за счет добавления элемента $x_k = 1$ требует проверки условия $\sum_{i=1}^{k} a_k x_k \le A$ и в случае его нарушения вычеркивания как недопустимого соответствующего подмножества из дерева. Допустимость же этого подмножества приводит к необходимости решения ЗР с меньшим числом переменных и уменьшенным «объемом» рюкзака. Обозначим для $X^{(k)}$

$$A\left(X^{(k)}\right) = \sum_{i=1}^{k} a_i x_i, \qquad z\left(X^{(k)}\right) = \sum_{i=1}^{k} c_i x_i.$$

Уточненная вспомогательная ЗР в таком случае имеет следующий вид: найти $\overline{x}_i (i > k)$ такие, что $0 \le x_i \le 1$:

$$\sum_{i=k+1}^{n} a_i x_i \le A - A\left(X^{(k)}\right),$$

и при этом

$$z = \sum_{i=k+1}^{n} c_i x_i - z\left(X^{(k)}\right)$$

достигает максимума.

Значение целевой функции для оптимального решения этой вспомогательной задачи и, следовательно, верхняя граница оптимального решения ЗР не увеличатся. С ориентацией на максимизацию целевой функции в ЗР для ветвления имеет смысл выбирать вершину дерева ветвления с наибольшим значением верхней границы.

После достижения на дереве ветвлений вершины с определенным значением x_n проверяется критерий оптимальности для допустимого решения X: значение целевой функции должно совпадать с верхней границей у последней вершины, и, кроме того, эта граница должна быть не меньшей, чем верхние границы остальных висячих вершин.

Если этот критерий оптимальности не выполняется, то на дереве ветвлений выбирается иная допустимая висячая вершина с наибольшей верхней границей и от нее производятся очередные ветвления.

Замечание. Для уменьшения числа ветвлений на дереве можно использовать прием построения какого-либо допустимого решения ЗР, значение целевой функции для него объявить «рекордом» и не подвергать ветвлению все те вершины дерева, у которых верхняя граница не больше рекорда. Хорошее допустимое решение ЗР можно найти с помощью так называемого «жадного» алгоритма, следуя правилам

$$\tilde{x}_j = \begin{cases} 1, & \text{если } a_j \le A - \sum_{k=1}^{j-1} a_k x_k, \quad j = 1, 2, ..., n, \\ 0 & \text{в противном случае.} \end{cases}$$

Пример 5.5. Найти максимальное значение функции

$$z = 60x_1 + 60x_2 + 40x_3 + 10x_4 + 20x_5 + 10x_6 + 3x_7$$

при условиях

$$3x_1 + 5x_2 + 4x_3 + x_4 + 2x_5 + 3x_6 + x_7 \le 10.$$

Очевидно, что в примере $A = 10$ и переменные перенумерованы в соответствии с невозрастанием отношения $\frac{c_j}{a_j}$, $j = 1, 2, ..., 7$.

Применяя «жадный» алгоритм, получим допустимое решение $\tilde{X} = (1, 1, 0, 1, 0, 0, 1)$, для которого значение целевой функции $z(\tilde{X}) = 60 + 60 + 10 + 3 = 133$. Решение $\tilde{X}$ используем в качестве рекорда.

Решением вспомогательной задачи при условии $0 \le x_j \le 1$, $j = 1, 2, ..., 7$, будет вектор $\bar{X} = (1, 1, 1/2, 0, 0, 0, 0)$, для которого $z(\bar{X}) = 60 + 60 + 20 = 140$. Это число является верхней границей целевой функции для всех допустимых решений ЗР.

Дерево ветвлений в этом примере можно строить, начиная от подмножества допустимых решений (1, 1, ..., ..., ..., ..., ...) с верхней границей, равной 140. Эта же граница останется для вершины, соответствующей подмножеству (1, 1, 0, 0, ..., ..., ...), и уменьшится для вершины, соответствующей подмножеству (1, 1, 0, 1, ..., ..., ...). Очередные ветвления приведут в конечном итоге к вершине, соответствующей допустимому решению (1, 1, 0, 0, 1, 0, 0) с верхней границей, равной 140. Для этой вершины выполняется критерий оптимальности, т. е. найдено оптимальное решение.

5.3.3. Метод ветвей и границ для решения задачи коммивояжера

Описанный ниже метод основан на идеях, предложенных Литтлом и др. в 1963 г.

Имеется n пунктов (городов). Для каждой пары городов i и j ($i \ne j$) известно расстояние $c_{ij} \ge 0$ между ними. Коммивояжер, находясь в одном из городов, должен посетить остальные города, побывав в них по одному разу, и вернуться в начальный город так, чтобы суммарное пройденное расстояние было минимальным.

Далее будем работать с матрицей расстояний $C = [c_{ij}]_{n \times n}$, причем несуществующие или запрещенные переходы между городами будем обозначать символом ∞. Вначале все $c_{ii} = \infty$.

Ветвление каждого множества возможных маршрутов коммивояжера на два подмножества состоит во включении или не включении в эти подмножества непосредственного перехода от какого-то города i до города j. Соответствующие подмножества будем обозначать на дереве ветвлений с корнем G в виде пары (i, j) или пары $(\overline{i, j})$ в кружках – вершинах дерева (рис. 5.6). Множество G обозначает множество всех возможных маршрутов коммивояжера ($(n - 1)!$ маршрутов).

Каждому ветвлению сопутствуют оценки снизу длины маршрутов, входящих в соответствующее множество. Такие оценки чаще всего вычисляются с помощью операции приведения квадратной матрицы расстояний, соответствующей оцениваемому множеству маршрутов. Для любой матрицы расстояний эта операция состоит из двух шагов. На шаге первом из элементов каждой k-й строки вычитаем минимальный элемент h'_k этой строки. На втором шаге от элементов остатков (после первого шага) каждого j-го столбца отнимаем минимальный элемент h''_j этого столбца.

Число $H = \sum_k h'_k + \sum_j h''_j$ называется коэффициентом приведения.

Пусть L обозначает длину любого маршрута коммивояжера на матрице расстояний перед приведением, а L_1 – длина этого маршрута после приведения. Ясно, что $L = L_1 + H$.

В приведенной матрице в силу ее построения все элементы неотрицательны. Следовательно, $L_1 \geq 0$ и тем самым $L \geq H$, т. е. коэффициенты приведения являются оценкой снизу длины всех маршрутов, принадлежащих рассматриваемому множеству.

Каждой вершине дерева ветвлений, как множеству маршрутов, соответствует определенная приведенная матрица расстояний. При ветвлении такой вершины – множества маршрутов, в которых запрещается непосредственный переход от города i до города j, – в этой матрице элемент c_{ij} заменяют знаком ∞. Множеству маршрутов с разрешенным переходом от i до j будет соответствовать вышеуказанная приведенная матрица без i-й сроки и j-го столбца. В такой уменьшенной матрице, с сохранением исходных номеров строк и столбцов, необходимо запретить непосредственный переход от города j до города i, полагая $c_{ji} = \infty$. Кроме того, учитывая, что разрешение непосредственного перехода от i к j вместе с ранее разрешенными переходами на соответствующей цепочке от корня до анализируемой вершины на дереве ветвлений может образовывать определенный подмаршрут, необходимо запретить непосредственный переход от конца этого подмаршрута до его начала, снова используя символ ∞.

Для полученных в результате такого ветвления вершин и двух соответствующих матриц осуществляем операции приведения и вычисляем нижние границы длин маршрутов. При этом коэффициент приведения для каждой матрицы складываем с нижней границей ветвимой вершины и тем самым получаем нижнюю границу длин маршрутов новых вершин. Такой способ вычисления нижних границ обеспечивает их неубывание по мере дальнейшего ветвления.

При выборе очередной висячей вершины для ветвления имеет смысл выбирать ту из них, которой соответствует наименьшая нижняя оценка. Число ветвей на дереве ветвлений также, как правило, уменьшается, если в приведенной матрице путем перебора строк выбирать для запрета тот нулевой элемент, замена которого на ∞ обеспечивает наибольший коэффициент приведения.

Процесс ветвления и оценок продолжаем до тех пор, пока не получим висячую вершину, соответствующую матрице 2×2. Единственная цепь вершин дерева от его корня до этой висячей вершины вместе с возможными переходами в итоговой матрице 2×2 определит один маршрут коммивояжера. Если при этом длина полученного маршрута будет равна нижней границе висячей вершины и эта нижняя граница будет не большей, чем нижние границы остальных висячих вершин дерева, то тем самым выполняется критерий оптимальности и найдено решение задачи коммивояжера. Если же критерий оптимальности не выполняется, то ветвим какую-либо иную висячую вершину дерева с наименьшей нижней границей.

Пример 5.6.

$$C = \begin{array}{c} \\ 0 \\ 1 \\ 2 \\ 3 \\ 4 \end{array} \begin{array}{c} \begin{array}{ccccc} 0 & 1 & 2 & 3 & 4 \end{array} \\ \begin{bmatrix} \infty & 3 & 6 & 2 & 7 \\ 0 & \infty & 2 & 0 & 3 \\ 0 & 0 & \infty & 0 & 3 \\ 0 & 1 & 4 & \infty & 5 \\ 0 & 0 & 3 & 0 & \infty \end{bmatrix} \end{array}.$$

Применение метода может привести к дереву ветвлений, представленному на рис. 5.6.

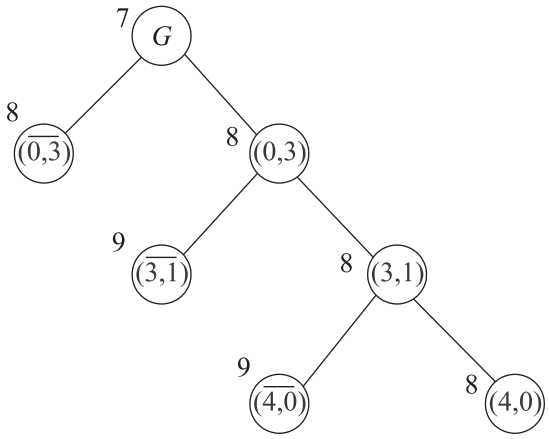

Рис. 5.6

Числа у вершин дерева ветвления являются нижними границами длин маршрутов в соответствующем их множестве. Для каждой такой вершины требуется еще запоминать соответствующие приведенные матрицы. Например, для вершины (0, 3) такая матрица будет иметь вид

$$\begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \end{array}\begin{array}{c} \begin{array}{cccc} 0 & 1 & 2 & 4 \end{array} \\ \begin{bmatrix} 0 & \infty & 0 & 0 \\ 0 & 0 & \infty & 0 \\ \infty & 0 & 1 & 1 \\ 0 & 0 & 1 & \infty \end{bmatrix} \end{array}.$$

Для вершины (3, 1) такая матрица имеет вид

$$\begin{array}{c} \\ 1 \\ 2 \\ 3 \end{array}\begin{array}{c} \begin{array}{ccc} 0 & 2 & 4 \end{array} \\ \begin{bmatrix} \infty & 0 & 0 \\ 0 & \infty & 0 \\ 0 & 1 & \infty \end{bmatrix} \end{array}.$$

Для вершины (4, 0) – вид

$$\begin{array}{c} \\ 1 \\ 2 \end{array}\begin{array}{c} \begin{array}{cc} 2 & 4 \end{array} \\ \begin{bmatrix} 0 & \infty \\ \infty & 0 \end{bmatrix} \end{array}.$$

Переходы в вершинах (0, 3), (3, 1), (4, 0), а также из последней матрицы (1, 2), (2, 4) образуют маршрут коммивояжера $0 \to 3 \to 1 \to 2 \to 4 \to 0$, длина которого равна 8, что совпадает с нижней границей вершины (4, 0). При этом данная нижняя граница является не большей, чем нижние границы всех остальных висячих вершин дерева ветвлений. Таким образом, в соответствии с критерием оптимальности найденный маршрут является маршрутом минимальной длины.

5.3.4. Метод ветвей и границ для решения задачи Беллмана – Джонсона

Метод ветвей и границ применим ко многим задачам теории расписаний. В частности, он может существенно уменьшить непосредственный перебор всех $n!$ вариантов обслуживания n заявок на m приборах в условиях задачи Б – Д.

Этап ветвления множества допустимых расписаний можно реализовать, например, в виде процесса пошагового «накопления» частичной (вначале пустой) последовательности обслуживания некоторых заявок из множества $N = \{1, 2, ..., n\}$ до полной последовательности $K = (k_1, k_2, ..., k_n)$. Такое накопление может проводиться различными способами, например путем приписывания к накопленной части справа различных заявок из N. Вершинами дерева ветвлений будут определенные множества расписаний. Корню дерева соответствует множество всевозможных расписаний. Это множество можно ветвить на n подмножеств, каждое из которых содержит расписания с фиксированной первой заявкой на обслуживание, например расписания вида (1, ...), (2, ...) и т. д. Каждая из таких вершин, в свою очередь, может ветвиться на $n - 1$ подмножеств, в которых кроме первой заявки будет фиксироваться вторая заявка. Получим, например, (1, 2, ...), (1, 3, ...) и т. д. Естественно, что в соответствии с общей схемой метода ветвлению должна подвергаться та из висячих вершин дерева, накопление частичной последовательности которой является наиболее перспективным с точки зрения целевой функции задачи и значения нижней границы для вершин дерева.

Один из методов вычисления нижней границы продемонстрируем для случая $m = 3$. Пусть приборы обозначены через A, B, C, и, соответственно, времена обслуживания заданы в следующем виде:

$$\begin{bmatrix} a_1 & b_1 & c_1 \\ a_2 & b_2 & c_2 \\ \dots & \dots & \dots \\ a_n & b_n & c_n \end{bmatrix}.$$

Если заявки из множества $\bar{N} \subset N$ обслуживаются в последовательности $K' = (k_1, k_2, ..., k_r)$, $r = |\bar{N}|$, а остальные заявки обслуживаются в последовательности $K'' = (k_{r+1}, ..., k_n)$, то на основании формулы (5.1) общее время обслуживания всех заявок равно

$$T(K', K'') = \max_{\substack{1 \le u_1 \le u_2 \le n \\ u_1, u_2 - \text{целые числа}}} \left(\sum_{i=1}^{u_1} a_{k_i} + \sum_{i=u_1}^{u_2} b_{k_i} + \sum_{i=u_2}^{n} c_{k_i} \right).$$

При этом прибор A завершит обслуживание заявок из $\bar{N}$ в момент $T_A(K') = \sum_{i=1}^{r} a_{k_i}$; прибор B – в момент $T_B(K') = \max_{1 \le u \le r} \left(\sum_{i=1}^{u} a_{k_i} + \sum_{i=u}^{r} b_{k_i} \right)$; прибор C – в момент $T_C(K') = \max_{1 \le u_1 \le u_2 \le r} \left(\sum_{i=1}^{u_1} a_{k_i} + \sum_{i=u_1}^{u_2} b_{k_i} + \sum_{i=u_2}^{r} c_{k_i} \right)$.

Определим величину $\gamma(K')$, полагая

$$\gamma(K') = \max\left[T_A(K') + \sum_{k\in N/\bar{N}} a_k + \min_{k\in N/\bar{N}}(b_k + c_k)\right],\ T_B(K') + \\ + \sum_{k\in N/\bar{N}} b_k + \min_{k\in N/\bar{N}} c_k,\ T_C(K') + \min_{k\in N/\bar{N}} c_k.$$

Из анализа соответствующих линейных диаграмм следует, что $T(K', K'') \geq \gamma(K')$ для любой фиксированной частичной последовательности K'.

Таким образом, $\gamma(K')$ может служить нижней границей общего времени обслуживания множества всевозможных расписаний, начиная с частичной последовательности K'. Добавление к последовательности K' конкретной заявки из множества $N/\bar{N}$ в любом случае не уменьшит величину γ, потому что оно может привести только к уточнению величины простоя прибора C, которое в формуле для $\gamma(K')$ не учитывалось.

Можно также определить величину $\delta(K')$, полагая:

$$\delta(K') = \max\left\{T_A(K') + \max_{k\in N/\bar{N}}\left[a_k + b_k + c_k + \sum_{j\in N/\bar{N}} \min_{j\neq k}\left(a_j, c_j\right)\right];\right. \\ \left. T_B(K') + \max_{k\in N/\bar{N}}\left[b_k + c_k + \sum_{j\in N/\bar{N}} \min_{j\neq k}\left(a_j, c_j\right)\right],\ T_C(K') + \sum_{j\in N/\bar{N}} c_k\right\}.$$

Очевидно, что $T(K', K'') \geq \delta(K')$ для любой фиксированной частичной последовательности K', т. е. величина $\delta(K')$ также может служить нижней границей целевой функции на множестве всевозможных расписаний, начинающихся с последовательности K'.

Если вычисляются обе величины – $\gamma(K')$ и $\delta(K')$, то, естественно, в качестве нижней границы выбирать большую из них.

Используя такие (или любые другие) нижние границы, постепенно строится последовательность обслуживания заявок, пока не окажется, что для некоторой последовательности-перестановки n заявок K^* значения $T(K^*)$ будет совпадать со значением нижней границы соответствующей висячей вершины дерева ветвлений и она будет не больше оценок всех остальных висячих вершин дерева, т. е. пока не выполнится критерий оптимальности.

Пример 5.7. Пусть в задаче Беллмана – Джонсона $m = 3$, $n = 5$, и таблица времен обслуживания заявок имеет вид

	A	B	C
1	5	8	1
2	4	4	9
3	7	1	4
4	2	8	4
5	3	5	1

Тогда возможно дерево ветвлений, представленное на рис. 5.7, где у вершин дерева числами обозначены нижние границы.

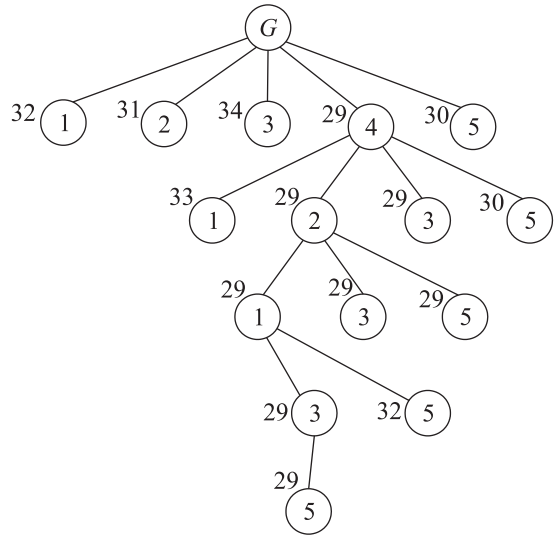

Рис. 5.7

На этом дереве ветвлений при ветвлении множества G всевозможных расписаний выбирались все варианты частичных последовательностей (1, ...), (2, ...), (3, ...), (4, ...), (5, ...). На втором шаге ветвилось множество расписаний (4, ...) путем фиксирования второй в расписании заявки (4, 1, ...), (4, 2, ...), (4, 3, ...), (4, 5, ...). Далее с учетом значения нижней границы ветвилось множество (4, 2, ...), потом множество (4, 2, 1, ...), далее множество (4, 2, 1, 3, ...) и, наконец, нашлось множество (4, 2, 1, 3, 5), для которого выполняется критерий оптимальности, т. е. оптимальным для нашей задачи является расписание $K^* = (4, 2, 1, 3, 5)$.

5.4. ДИНАМИЧЕСКОЕ ПРОГРАММИРОВАНИЕ В ЗАДАЧАХ КОМБИНАТОРНОЙ ОПТИМИЗАЦИИ

5.4.1. Общий принцип оптимальности

Идея динамического программирования, основоположником которого является Р. Беллман, состоит в том, что решение основной оптимизационной задачи заменяется процессом последовательного решения семейства вспомогательных задач с меньшим числом управляемых переменных, с той же самой целевой функцией и с той же (либо близкой) структурой множества допустимых решений, что и у основной задачи. При этом получаемые в процессе реализации процедуры оптимальные решения существенно используются в решении последующих задач и в конечном итоге для восстановления оптимального решения исходной задачи.

Обычно процедура решения вспомогательных задач трактуется как реализация шагов или этапов с результатами $D_1, D_2, ..., D_N$. Тогда, если эта последовательность оптимальна, последние $k (k < N)$ решений $D_{N-k+1}, D_{N-k+2}, ..., D_N$ должны быть опти-

мальны. Это утверждение отражает суть так называемого принципа оптимальности Беллмана в динамическом программировании.

Применение принципа оптимальности на практике сводится к тому, что на каждом этапе решение должно приниматься с учетом будущих шагов. Очевидно, что только на последнем этапе может быть принято решение, доставляющее максимум (или минимум) целевой функции без каких-либо дополнительных условий. Спланировав оптимальным образом этот последний этап, к нему можно «пристраивать» предпоследний и т. д. Поэтому процесс динамического программирования сначала разворачивается так называемым обратным ходом: от последнего этапа к первому. После этого осуществляется прямой ход: восстановление оптимального решения на основании полученных условных решений. Обычно «пристраивание» условного решения на произвольном этапе к предыдущему этапу осуществляется с помощью рекуррентного соотношения, которое связывает условное оптимальное значение целевой функции на таком предыдущем этапе с условными оптимальными значениями, полученными перед ним.

Отметим, что динамическое программирование является очень общей идеей и требует изобретательности для нахождения хороших способов разбиения исходной задачи на этапы, при которых можно найти приемлемое рекуррентное соотношение. Изначально метод разрабатывался для задач планирования во времени (отсюда и термин «динамическое программирование»). Этапы в таких задачах соответствовали определенным временным интервалам. Ниже приведем примеры задач, для решения которых этим методом необходимо искусственно определить этапы в виде вспомогательных задач более простой, чем исходная, структуры.

5.4.2. Задача о кратчайшем пути

Пусть модель транспортной сети представлена в виде ориентированного графа (рис. 5.8), на ребрах которого указаны физические расстояния между узлами сети.

Требуется методом динамического программирования найти кратчайший путь, соединяющий узлы v_1 и v_7.

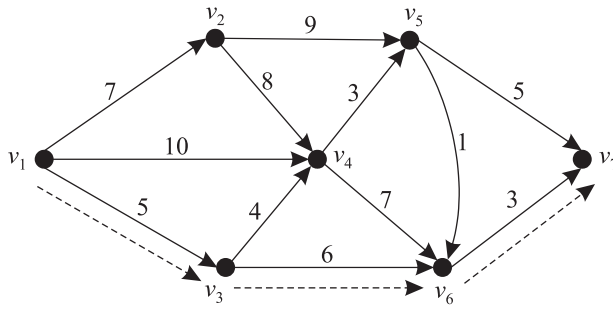

Рис. 5.8

Пусть r_{ij} означает расстояние от узла v_i до узла v_j; f_i – длина кратчайшего пути от узла v_i до конечного узла v_7. Тогда рекуррентные соотношения будут иметь вид:

$$\begin{cases} f_i = \min\limits_{r_{ij}}(r_{ij} + f_j),\ i = 6, 5, ..., 1, \\ f_7 = 0. \end{cases}$$

Далее вычислим

$$f_6 = \min(\underline{r_{67} + f_7}) = 3;$$

$$f_5 = \min\begin{pmatrix} r_{57} + f_7 \\ \underline{r_{56} + f_6} \end{pmatrix} = \min(5, 4) = 4;$$

$$f_4 = \min\begin{pmatrix} \underline{r_{45} + f_5} \\ r_{46} + f_6 \end{pmatrix} = \min(7, 10) = 7;$$

$$f_3 = \min\begin{pmatrix} r_{34} + f_4 \\ \underline{r_{36} + f_6} \end{pmatrix} = \min(11, 9) = 9;$$

$$f_2 = \min\begin{pmatrix} \underline{r_{25} + f_5} \\ r_{24} + f_4 \end{pmatrix} = \min(13, 15) = 13;$$

$$f_1 = \min\begin{pmatrix} r_{12} + f_2 \\ \underline{r_{13} + f_3} \\ r_{14} + f_4 \end{pmatrix} = \min(20, 14, 17) = 14.$$

Значение $f_i = 14$ дает длину кратчайшего пути от узла v_1 до узла v_7. Кратчайший путь легко восстановить, начиная от конца вычислений и используя подчеркнутые элементы, соответствующие минимальным значениям. Это будет путь, содержащий переходы $((v_1, v_3), (v_3, v_6), (v_6, v_7))$.

5.4.3. Задача о распределении инвестиций

Предприниматель имеет возможность расширить производство путем инвестирования капитала S в свои филиалы 1, 2, …, N. Известно, что инвестирование квоты x_i в i-м филиале принесет доход $g_i(x_i)$. На практике функции g_i нелинейны: при небольших инвестициях, в сущности, не будет дохода, а при очень большом вложении средств наступает «насыщение» и доход не увеличивается. Общий доход можно оценить, например, функцией

$$G(x_1, x_2, ..., x_N) = \sum_{i=1}^{N} g_i(x_i)$$

при условиях

$$\sum_{i=1}^{N} x_i = S, \quad x_i \geq 0, \quad i = 1, 2, ..., N.$$

Естественно, что при этих условиях требуется определить такие величины инвестиций x_i, для которых

$$\sum_{i=1}^{N} g_i(x_i) \to \max.$$

Отметим, что если x_i и S принимают целочисленные значения, то число вариантов инвестиции не больше, чем число сочетаний

$$\binom{N+S-1}{S},$$

и поэтому при малых N и S все варианты можно перебрать и выбрать наилучший.

Для применения метода динамического программирования этапом назовем факт назначения капитала одному филиалу. Обозначим через $f_N(S)$ максимальный доход, получаемый от распределения квоты S всем филиалам, т. е.

$$f_N(S) = \max_{\{x_i\}} G(x_1, x_2, ..., x_N).$$

Найдем рекуррентное соотношение, связывающее $f_N(S)$ и $f_{N-1}(S)$ для произвольных N и S. Пусть x_N $(0 \le x_N \le S)$ – квота, предназначенная для филиала N. По принципу оптимальности: каково бы не было значение x_N, оставшаяся квота $S - x_N$ должна будет использоваться так, чтобы получить максимальный доход в оставшихся филиалах, т. е. величину $f_{N-1}(S - x_N)$.

Таким образом,

$$f_N(S) = \max_{0 \le x_N \le N} [g_N(x_N) + f_{N-1}(S - x_N)]$$

$$\text{для } N = 2, 3, ...; \quad S \ge 0; \quad f_1(S) = g_1(S).$$

Это соотношение дает возможность последовательного получения величин $f_N(S)$, начиная от $f_1(S)$.

5.4.4. Задача коммивояжера

Пусть для n городов известна матрица $[c_{ij}]_{n \times n,\ i \ne j}$ попарных расстояний. В ЗК требуется найти подстановку – полный цикл $P^* = \begin{pmatrix} 1 & i_2 & ... & i_n \\ i_2 & i_3 & ... & 1 \end{pmatrix}$, которая минимизирует величину

$$c_{1i_2} + c_{i_2 i_3} + ... + c_{i_n 1}.$$

Рассмотрим множество $M = \{2, 3, ..., n\}$. Для любых $S \subseteq M$ и $l \in S$ обозначим через $C(S, l)$ минимальную стоимость пути, который начинается в городе 1, проходит через все города множества S и заканчивается в городе l. Тогда:

а) если $|S| = 1$, то $C(\{l\}, l) = c_{1l}$ для любого l;

б) если $|S| \ge 1$, то $C(S, l) = \min_{m \in S/l} [C(S/l, m) + c_{ml}]$. (5.14)

В самом деле, если на пути, проходящем через все города из S и оканчивающемся в l, город m непосредственно предшествует городу l, а все остальные города посеща-

ются в оптимальном порядке, то стоимость обхода равна $C(S/l, m) + c_{ml}$. Взяв минимум по всем m, получим соотношение б).

Обозначим через $C^{(0)}$ длину минимального пути коммивояжера. Тогда

$$C^{(0)} = \min_{l \in M}[C(M, l) + c_{l1}]. \tag{5.15}$$

Подстановка-цикл $(1, i_2, i_3, ..., i_n)$ является решением ЗК тогда и только тогда, когда

$$C^{(0)} = C(M, l) + c_{i_n 1} \tag{5.16}$$

и для $2 \le p \le n - 1$

$$C\left(\{i_2, i_3, ..., i_p, i_{p+1}\}, i_{p+1}\right) = C\left(\{i_2, i_3, ..., i_p\}, i_p\right) + c_{i_p i_{p+1}}. \tag{5.17}$$

Оптимальное решение ЗК в этом случае находят следующим образом. Сначала по формуле (5.14) рекурсивно вычисляют величины $C(S, l)$, далее, используя (5.15), вычисляют $C^{(0)}$. После этого на основании критериев (5.16), (5.17) строится оптимальный маршрут коммивояжера, причем сначала определяется i_n, затем i_{n-1} и т. д. – до i_2.

Отметим, что количество элементарных операций (сложений и сравнений) для изложенного метода оценивается числом $n^2 \cdot 2^n$, т. е. оно экспоненциально относительно размера задачи. Однако эта оценка существенно меньше, чем $(n - 1)!$ всевозможных маршрутов коммивояжера, т. е. подход с помощью динамического программирования нельзя отбрасывать.

Пример 5.8. Решим методом динамического программирования задачу коммивояжера со следующей матрицей расстояний

$$\begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{array}\begin{array}{c} \begin{array}{ccccc} 1 & 2 & 3 & 4 & 5 \end{array} \\ \begin{bmatrix} - & 10 & 11 & 15 & 13 \\ 10 & - & 17 & 19 & 22 \\ 11 & 17 & - & 12 & 16 \\ 15 & 19 & 12 & - & 9 \\ 13 & 22 & 16 & 9 & - \end{bmatrix} \end{array}.$$

В задаче $n = 5$, начало маршрута в городе 1.

$|S| = 1$: $S = \{2\}$; $S = \{3\}$; $S = \{4\}$; $S = \{5\}$.

$C(\{2\}, 2) = c_{12} = 10$;

$C(\{3\}, 3) = c_{13} = 11$;

$C(\{4\}, 4) = c_{14} = 15$;

$C(\{5\}, 5) = c_{15} = 13$.

$|S| = 2$: $S = \{2,3\}$; $S = \{2,4\}$; $S = \{2,5\}$;

$S = \{3,4\}$; $S = \{3,5\}$; $S = \{4,5\}$.

$C(\{2, 3\}, 2) = \min_{m \in S/2}[C(\{3\}, 3) + c_{32}] = 28$;

$$C(\{2, 3\}, 3) = \min_{m \in S/3} [C(\{2\}, 2) + c_{23}] = 27;$$

$$C(\{2, 4\}, 2) = \min_{m \in S/2} [C(\{4\}, 4) + c_{42}] = 34;$$

$$C(\{2, 4\}, 4) = \min_{m \in S/4} [C(\{2\}, 2) + c_{24}] = 29;$$

$$C(\{2, 5\}, 2) = \min_{m \in S/2} [C(\{5\}, 5) + c_{52}] = 35;$$

$$C(\{2, 5\}, 5) = \min_{m \in S/5} [C(\{2\}, 2) + c_{25}] = 32;$$

$$C(\{3, 4\}, 3) = \min_{m \in S/3} [C(\{4\}, 4) + c_{43}] = 27;$$

$$C(\{3, 4\}, 4) = \min_{m \in S/4} [C(\{3\}, 3) + c_{34}] = 23;$$

$$C(\{3, 5\}, 3) = \min_{m \in S/3} [C(\{5\}, 5) + c_{53}] = 29;$$

$$C(\{3, 5\}, 5) = \min_{m \in S/5} [C(\{3\}, 3) + c_{35}] = 27;$$

$$C(\{4, 5\}, 4) = \min_{m \in S/4} [C(\{5\}, 5) + c_{54}] = 22;$$

$$C(\{4, 5\}, 5) = \min_{m \in S/5} [C(\{4\}, 4) + c_{45}] = 24.$$

$|S| = 3$: $S = \{2, 3, 4\}$; $S = \{2, 3, 5\}$; $S = \{2, 4, 5\}$; $S = \{3, 4, 5\}$.

$$C(\{2, 3, 4\}, 2) = \min_{m \in \{3,4\}} [C(\{3, 4\}, 3) + c_{32}, C(\{3, 4\}, 4) + c_{42}] = 42;$$

$$C(\{2, 3, 4\}, 3) = \min_{m \in \{2,4\}} [C(\{2, 4\}, 2) + c_{23}, C(\{2, 4\}, 4) + c_{43}] = 41;$$

$$C(\{2, 3, 4\}, 4) = \min_{m \in \{2,3\}} [C(\{2, 3\}, 2) + c_{24}, C(\{2, 3\}, 3) + c_{34}] = 39;$$

$$C(\{2, 3, 5\}, 2) = \min_{m \in \{3,5\}} [C(\{3, 5\}, 3) + c_{32}, C(\{3, 5\}, 5) + c_{52}] = 46;$$

$$C(\{2, 3, 5\}, 3) = \min_{m \in \{2,5\}} [C(\{2, 5\}, 2) + c_{23}, C(\{2, 5\}, 5) + c_{53}] = 48;$$

$$C(\{2, 3, 5\}, 5) = \min_{m \in \{2,3\}} [C(\{2, 3\}, 2) + c_{25}, C(\{2, 3\}, 3) + c_{35}] = 43;$$

$$C(\{2, 4, 5\}, 2) = \min_{m \in \{4,5\}} [C(\{4, 5\}, 4) + c_{42}, C(\{4, 5\}, 5) + c_{52}] = 41;$$

$$C(\{2, 4, 5\}, 4) = \min_{m \in \{2,5\}} [C(\{2, 5\}, 2) + c_{24}, C(\{2, 5\}, 5) + c_{54}] = 44;$$

$$C(\{2, 4, 5\}, 5) = \min_{m \in \{2,4\}} [C(\{2, 4\}, 2) + c_{25}, C(\{2, 4\}, 4) + c_{45}] = 38;$$

$$C(\{3, 4, 5\}, 3) = \min_{m \in \{4,5\}} [C(\{4, 5\}, 4) + c_{43}, C(\{4, 5\}, 5) + c_{53}] = 44;$$

$$C(\{3, 4, 5\}, 4) = \min_{m \in \{3,5\}} [C(\{3, 5\}, 3) + c_{34}, C(\{3, 5\}, 5) + c_{54}] = 36;$$

$C(\{3, 4, 5\}, 5) = \min\limits_{m\in\{3,4\}} [C(\{3, 4\}, 3) + c_{35}, C(\{3, 4\}, 4) + c_{45}] = 32.$

$|S| = 4$: $S = \{2, 3, 4, 5\}$.

$C(\{2,3,4,5\},2) = \min\limits_{m\in\{3,4,5\}} [C(\{3,4,5\},3) + c_{32};$

$C(\{3,4,5\},4) + c_{42}, C(\{3,4,5\},5) + c_{52}] = 54;$

$C(\{2,3,4,5\},3) = \min\limits_{m\in\{2,4,5\}} [C(\{2,4,5\},2) + c_{23};$

$C(\{2,4,5\},4) + c_{43}, C(\{2,4,5\},5) + c_{53}] = 54;$

$C(\{2,3,4,5\},4) = \min\limits_{m\in\{2,3,5\}} [C(\{2,3,5\},2) + c_{24};$

$C(\{2,3,5\},3) + c_{34}, C(\{2,3,5\},5) + c_{54}] = 52;$

$C(\{2,3,4,5\},5) = \min\limits_{m\in\{2,3,4\}} [C(\{2,3,4\},2) + c_{25};$

$C(\{2,3,4\},3) + c_{35}, C(\{2,3,4\},4) + c_{45}] = 48.$

$M = \{2, 3, 4, 5\}.$

$C^{(0)} = \min\limits_{l\in M}[C(\{2,3,4,5\},2) + c_{21}, C(\{2,3,4,5\},3) + c_{31},$

$C(\{2,3,4,5\},4) + c_{41}, C(\{2,3,4,5\},5) + c_{51}] = 61.$

Таким образом, длина оптимального маршрута равна 61. Восстановим один из оптимальных маршрутов. Значение $C^{(0)}$ достигается для $l = 5$. Это означает, что последним является переход $5 \to 1$. Минимум $C(\{2, 3, 4, 5\}, 5)$ достигается для $m = 4$. Это означает, что в оптимальном маршруте будет переход $4 \to 5$. Значение $C(\{2, 3, 4\}, 4)$ достигается для $m = 3$. Это означает наличие перехода $3 \to 4$ в оптимальном маршруте. Значение $C(\{2, 3\}, 3)$ достигается для $m = 2$. Это означает наличие перехода $2 \to 3$ в оптимальном маршруте. Таким образом, восстановлен оптимальный маршрут коммивояжера $1 \to 2 \to 3 \to 4 \to 5 \to 1$, его длина $10 + 17 + 12 + 9 + 13 = 61$.

5.5. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. В чем состоит существенная разница между задачами сетевого планирования и задачами теории расписаний?
2. Опишите общую задачу теории расписаний.
3. Опишите условия обслуживания в общей задаче теории расписаний.
4. Сформулируйте задачу Беллмана – Джонсона.
5. Опишите множество допустимых решений в задаче Беллмана – Джонсона.
6. Как найти общее время обслуживания заявок в задаче Беллмана – Джонсона при заданной очередности обслуживания?
7. Сформулируйте теорему об оптимальном расписании в задаче Беллмана – Джонсона с двумя приборами.
8. В чем состоит задача коммивояжера?
9. Постройте математическую модель задачи коммивояжера.

10. В чем разница между моделями классической задачи о назначениях и задачи коммивояжера?

11. Сформулируйте многостадийную задачу без задержек в обслуживании заявок.

12. Как строится дерево ветвлений в общей схеме ветвей и границ?

13. Сформулируйте основное требование к способам вычисления нижних границ в методе ветвей и границ.

14. Опишите схему метода ветвей и границ при максимизации множества допустимых решений.

15. Как строить дерево ветвлений и вычислять нижние границы целевой функции для задачи о рюкзаке?

16. Как строить дерево ветвлений и вычислять нижние границы целевой функции для задачи коммивояжера?

17. Как строить дерево ветвлений и вычислять нижние границы целевой функции для задачи Беллмана – Джонсона?

18. Приведите общий принцип оптимальности в динамическом программировании.

19. Описать рекуррентные соотношения для применения метода динамического программирования к задаче о кратчайшем пути.

20. Охарактеризуйте рекуррентные соотношения для применения метода динамического программирования к задаче о распределении инвестиций.

21. Описать рекуррентные соотношения для применения метода динамического программирования к задаче коммивояжера.

6. ЭЛЕМЕНТЫ ТЕОРИИ МАССОВОГО ОБСЛУЖИВАНИЯ

6.1. ОБЩАЯ ХАРАКТЕРИСТИКА ЗАДАЧ МАССОВОГО ОБСЛУЖИВАНИЯ

Наряду с детерминированными задачами теории расписаний важным классом задач ИСО, связанных с обслуживанием заявок, являются задачи теории очередей (Queuing Theory), в русскоязычной научной литературе называемые задачами массового обслуживания (МО). Для детерминированных моделей, в частности, известно, что все заявки уже находятся в системе (или прибудут туда в конкретные моменты времени), и требуется определить оптимальную по некоторому критерию очередность их обслуживания. Задачи МО по своей сущности являются вероятностными (стохастическими) моделями, параметры которых меняются случайным образом. Например, заявки поступают в систему в случайные моменты времени, случайное время могут ожидать в очереди на обслуживание и в течение случайного времени обслуживаться. Функционирование любой системы массового обслуживания (СМО) в конечном счете можно было бы оценить, учитывая прямые и косвенные затраты из-за ожидания обслуживания, из-за последствий отказа в обслуживании и от простоя средств обслуживания. Однако трудности исследования большинства задач МО заключаются прежде всего в нахождении законов распределения всех видов случайных величин, описывающих систему. Вычисленные после этого вероятностные параметры системы являются основой необходимых управляющих решений даже без решения оптимизационной задачи. Подобный подход широко используется в ИСО, например, при анализе сетевых графиков.

Задачи МО возникают в системах, для которых заданы следующие три составляющие:

1) известны характеристики входного потока заявок на обслуживание;

2) описана дисциплина очереди;

3) задан механизм обслуживания.

Каждая СМО состоит из определенного числа обслуживающих единиц, которые будем называть приборами. Чтобы задать механизм обслуживания, необходимо указать количество приборов в системе, а также их взаимное расположение при обслуживании, например последовательно расположенные приборы, на которых будут обслуживаться все заявки, или идентичные параллельно расположенные приборы, когда каждая заявка обслуживается на одном из них. Обслуживание характеризуется определенной длительностью, которая является случайной величиной. Часто, задавая механизм обслуживания, указывают также вероятности выхода приборов из строя.

Каждая СМО предназначена для выполнения потока заявок. Заявки поступают в случайные моменты времени, и принимается, что после обслуживания каждой заявки она уходит из системы и прибор готов для обслуживания следующей заявки. Случайный характер потока заявок может привести к тому, что в какие-то моменты времени на входе системы будет скапливаться какое-то количество заявок, которые либо образуют очередь в ожидании обслуживания, либо уходят необслуженными. Может быть, что в отдельные моменты из-за отсутствия очереди приборы будут простаивать в ожидании заявок. При описании СМО также часто указывают, может ли в отдельные моменты времени появиться сразу несколько заявок. Для некоторых систем источник, генерирующий заявки, находится вне системы и считается неисчерпаемым. Изучаются также системы с ограниченным количеством возможных заявок, которые могут находиться в самой системе.

Дисциплина очереди – описание порядка выполнения заявок, например, при обслуживании могут выполняться требования типа: «первый пришел, первый обслуживается», или могут быть заранее установлены некоторые приоритеты, в соответствии с которыми классифицируются и в конечном итоге обслуживаются заявки, стоящие в очереди.

Первые задачи теории МО были изучены датским инженером А. К. Эрлангом в 1920-х гг. Он изучал организацию работы телефонных сетей как СМО. Уже Эрланг отметил, что СМО можно разделить на два класса:

1) системы с очередями;

2) системы с потерями, в этом случае заявка не становится в очередь, а сразу же уходит из системы необслуженной.

На практике каждый из этих классов может подразделяться на подклассы. Например, могут рассматриваться системы с ограниченной и с неограниченной очередью. В первом случае по какому-то условию длина очереди ограничивается. Например, если время ожидания в очереди превосходит какую-то величину, то заявка может уйти из очереди необслуженной (системы с нетерпеливыми клиентами). Во втором случае заявка остается в системе, ожидая обслуживания.

Разделение СМО на классы важно потому, что критерии функционирования могут существенно различаться. Так, например, для оценки качества обслуживания в системе с ожиданием наиболее важным является такой параметр, как среднее время ожидания начала обслуживания. Для систем с потерями – вероятность отказа в обслуживании, т. е. потери заявки. Одновременно для этой системы изучают следующие характеристики:

1) среднее число заявок, которое может обслуживать система за единицу времени, так называемая абсолютно пропускная способность системы;

2) среднее число занятых приборов;

3) среднее время суммарного простоя любого из приборов за какой-то период.

Для СМО с очередью при неограниченном ожидании важны другие характеристики:

1) среднее число заявок в очереди;

2) среднее число заявок в системе;

3) среднее время ожидания в очереди или в системе.

При изучении СМО с ограниченной очередью, как правило, находят характеристики, относящиеся к обеим из указанных групп.

После того как найдены характеристики СМО, переходят к рациональной организации системы в случае, если какая-то из характеристик превосходит заданный уровень. Например, в магазине самообслуживания можно было бы существенно уменьшить длину очередей перед кассами за счет добавления лишних аппаратов. Однако это не всегда приемлемо из-за новых дополнительных расходов. Более того, в отдельные периоды кассовые аппараты будут больше простаивать. Таким образом, возникает задача построения СМО, в которой все вероятностные характеристики доставляют минимум некоторой целевой функции или близки к нему. Отметим, что уже на начальном этапе анализа СМО имеет смысл оценить ее эффективность, вычисляя величину $\frac{\lambda}{n\mu}$, где λ – среднее число заявок, поступающих в систему в единицу времени (так называемая интенсивность входного потока); μ – среднее число заявок, обслуживаемых в единицу времени (интенсивность обслуживания); n – число идентичных приборов в системе.

Если $\frac{\lambda}{n\mu} > 1$, то изучаемая СМО заведомо неэффективна: весьма вероятно, что очередь будет бесконечно возрастать. Это означает, что условия функционирования такой СМО необходимо изначально менять, чтобы хотя бы достичь равенства $\lambda' = n\mu'$.

6.2. НЕКОТОРЫЕ ЧАСТНЫЕ СЛУЧАИ ВХОДНОГО ПОТОКА И ДЛИТЕЛЬНОСТЕЙ ОБСЛУЖИВАНИЯ

6.2.1. Простейший поток

При изучении любой СМО в первую очередь выясняют закономерности, которым подчиняются моменты поступления заявок в систему. Естественно, что наиболее простым для изучения являются такие системы, в которых заявки поступают в моменты, подчиняющиеся какому-то правилу, и их можно легко определить. Такие потоки называются регулярными. На временной оси это выглядит так, как представлено на рис. 6.1, *а*, *б*.

Достаточно хорошо изучены СМО, в которых входной поток является случайной величиной и обладает следующими тремя свойствами.

1. Поток стационарный, т. е. вероятность попадания одного и того же числа заявок на какой-то участок времени длиной t зависит только от длины этого участка и не зависит от того, в каком месте на оси времени он расположен. Стационарность потока означает его однородность во времени. В частности, в данном потоке будет постоянной такая важная характеристика, как интенсивность поступления заявок, – среднее число заявок, поступающих в единицу времени. Условие стационарности потока равносильно требованию постоянства интенсивности потока и неизменности во времени всех его вероятностных характеристик.

Для реальных СМО условие стационарности потока заявок не является достаточно жестким ограничением. Практически всегда можно выбрать интервалы времени, на которых поток заявок стационарный.

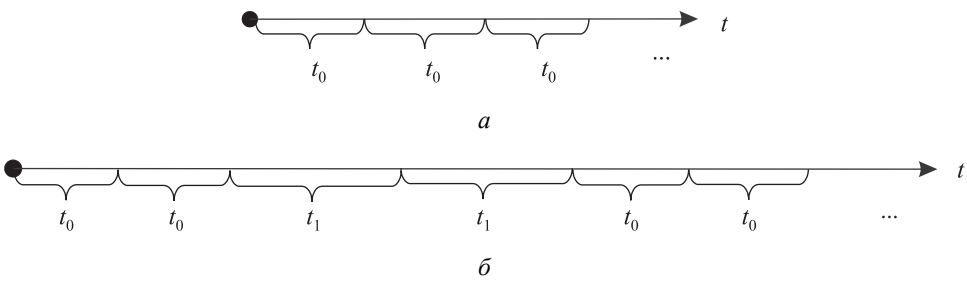

Рис. 6.1

2. Поток заявок должен быть потоком без последействия (без памяти), т. е. для каждых непересекающихся интервалов времени число заявок, попадающих на один из них, не должно зависеть от того, сколько заявок попало на другой участок. Таким образом, заявки, подчиняющиеся этому условию, должны образовывать поток независимо друг от друга. Примером тому служит поток пассажиров на станции.

3. Поток заявок является ординарным, т. е. вероятность попадания на элементарный достаточно малый участок времени более одной заявки должна быть близкой к нулю. Таким образом, это условие предполагает, что в некоторый достаточно короткий промежуток времени, близкий по длине к нулевому, одновременно не может появляться более чем одна заявка.

Существуют реальные задачи, когда это требование не выполняется. В очередь на разгрузку, например, сразу поступает несколько вагонов.

Входные потоки заявок, удовлетворяющие условиям 1) – 3), называются простейшими.

Критическое изучение перечисленных свойств простейшего потока приводит к заключению, что данные потоки не очень часто могут встречаться в практических задачах. Однако показано, что существует большой круг задач, в которых можно ограничиться изучением простейших входных потоков. Например, А. Я. Хинчин доказал, что если какой-то достаточно мощный поток состоит из большого числа стационарных и ординарных потоков и каждый из них несравним по мощности с суммарным потоком, то весь суммарный поток будет простейшим.

Простейший поток заявок связан с распределением Пуассона. Из теории вероятностей известно, что если задан временной интервал длины τ, то вероятность попадания на этот интервал ровно m случайных величин (заявок) вычисляется по формуле

$$P_m = \frac{a^m}{m!} e^{-a}, \quad m = 0,\ 1,\ 2,\ ...;\ 0! = 1,$$

где a – среднее число заявок, приходящихся на интервал.

В силу стационарности простейшего потока $a = \lambda\tau$, где λ – интенсивность потока. Значит:

$$P_m = \frac{(\lambda\tau)^m}{m!} e^{-\lambda\tau}.$$

При изучении простейшего потока важно выяснить распределения интервалов времени T между моментами поступления двух произвольных соседних заявок. Для

этого достаточно найти закон распределения случайной величины T, т. е. функцию $F(t) = P(T < t)$ для любого t.

Условие $T < t$ означает, что на интервал от какого-то начального t_0 до t попадает хотя бы одна заявка. Используя формулу для P_m, можно вычислить, когда на интервал T не попадет ни одной заявки. Эта величина будет равна

$$P(T > t) = P_0 = e^{-\lambda t} \ (t \geq 0).$$

В случае когда на интервал T попадает хотя бы одна заявка, будем иметь

$$F(t) = P(T < t) = 1 - P_0 = 1 - e^{-a} = 1 - e^{-\lambda t}.$$

Для этого закона распределения можем найти плотность распределения

$$f(t) = [F(t)]' = \lambda e^{-\lambda t}.$$

Таким образом, промежуток времени T между моментами поступления двух заявок в простейшем потоке подчиняется закону распределения $F(t)$ с плотностью $f(t)$. Закон этого вида называется показательным (экспоненциальным).

6.2.2. Показательное распределение длительности обслуживания

В СМО обычно принимается, что длительность обслуживания приборами любой заявки является случайной величиной. Рассмотрим один из самых простых законов, которому оно может подчиняться. Пусть μ – величина, равная среднему числу заявок, обслуживаемых прибором в единицу времени. Будем полагать, что μ не зависит от времени и характеризует скорость обслуживания. Простые математические модели получаются в случае, если предположить, что закон распределения длительностей обслуживания является показательным, т. е. имеет вид $F(t) = 1 - e^{-\mu t}$ с плотностью распределения $g(t) = \mu e^{-\mu t}$.

Это предположение служит некоторым ориентиром при анализе реальных длительностей обслуживания, хотя по некоторым признакам достаточно далеко от реальных задач. Например, доказано, что верна теорема 6.1.

Теорема 6.1. При показательном законе распределения длительностей обслуживания заявок вероятность завершения обслуживания заявки в последующий интервал времени не зависит от того, сколько времени уже потрачено на обслуживание заявки.

Понятно, что в реальных условиях длительность завершения обслуживания заявки на самом деле зависит от того, сколько времени до данного момента продолжалось обслуживание.

6.2.3. Еще раз о классификации СМО

В литературе СМО часто описываются в виде последовательности нескольких символов. Чаще всего используются три символа, называемых обозначениями Кендала. Символ в первой позиции характеризует входной поток заявок, символ во второй позиции – распределение длительности обслуживания, в третьей – указывает число приборов в системе. Для первого и второго приняты общие обозначения:

M – показательный закон распределения продолжительностей между поступлениями соседних заявок в систему или длительностей обслуживания на приборах;

D – регулярный (детерминированный) характер распределения интервалов поступления заявок или длительностей обслуживания;

G – произвольный характер закона распределения.

Если, например, изучаются СМО *M*|*G*|2, то это означает, что входной поток подчиняется показательному закону (простейший), распределение длительностей произвольное и в системе есть 2 идентичных прибора.

6.3. ПРОЦЕССЫ ГИБЕЛИ И РАЗМНОЖЕНИЯ

Рассмотрим специальный класс СМО, в котором в систему случайным образом может поступать заявка (процесс рождения), случайным образом она может быть обслуженной и уходить из системы (процесс гибели). В любой момент времени состояния системы могут различаться по количеству находящихся в ней заявок.

Пусть S_0 – состояние, при котором в системе нет заявок; S_1 – в системе одна заявка; S_2 – две заявки и т. д. $S_k(t)$ есть случайное событие, означающее, что в момент времени t система находится в состоянии S_k, $k = 0, 1, 2, \ldots$. Если в некоторый момент t_0 в систему прибывает новая заявка, то состояние системы изменяется на единицу в сторону увеличения, и такое изменение будем обозначать

$$S_k(t_0 - 0) \to S_{k+1}(t_0 + 0),$$

где $t_0 - 0$ и $t_0 + 1$ – один и тот же момент t_0; -0 – момент непосредственно перед t_0; $+0$ – момент, следующий непосредственно за t_0. Если из системы в момент t_0 заявка уходит, то такое изменение обозначим через

$$S_k(t_0 - 0) \to S_{k-1}(t_0 + 0).$$

Для процессов гибели и размножения существенными являются те условия, которые налагаются на вероятности перехода из одного состояния в другое за некоторый достаточно малый промежуток времени τ. Принимается, что для любого состояния S_k вероятности переходов определяются следующим образом:

$$\begin{cases} P\{S_k(t) \to S_{k+1}(t+\tau)\} = \lambda_k \tau + o(\tau), \\ P\{S_k(t) \to S_{k-1}(t+\tau)\} = \mu_k \tau + o(\tau), \\ P\{S_k(t) \to S_k(t+\tau)\} = 1 - (\lambda_k + \mu_k)\tau + o(\tau). \end{cases} \tag{6.1}$$

Здесь параметры λ_k и μ_k зависят только от того, из какого и в какое состояние переходит система, и не зависят от времени t; $o(\tau)$ означает некоторое бесконечно малое дополнение к условиям перехода.

Таким образом, принимается, что система может переходить только в соседнее состояние и вероятности перехода в любые не соседние состояния за интервал τ близки к нулю.

Формулы (6.1) – исходные данные для изучения конкретного процесса гибели и размножения. Основная задача при изучении таких процессов заключается в нахож-

дении величин $P_k(t)$, означающих вероятность пребывания системы в состоянии S_k в момент t.

Для решения описанной задачи можно вывести систему дифференциальных уравнений, которым подчиняются неизвестные $P_k(t)$ для всех $k = 0, 1, ...$ Начнем с вывода дифференциального уравнения, которому должна удовлетворять вероятность $P_0(t)$. Для этого надо рассмотреть всевозможные варианты, при которых система окажется в состоянии S_0 в момент $t + \tau$, где τ – некоторый достаточно малый интервал времени.

Таких вариантов всего два:

1) может быть, что в момент t система находилась в состоянии S_0 и за время τ ни одной заявки не поступило, т. е.

$$S_0(t) \to S_0(t+\tau);$$

2) в состояние S_0 система может перейти из состояния S_1, т. е.

$$S_1(t) \to S_0(t+\tau).$$

Учитывая эти варианты и используя формулу произведения вероятностей, можно записать, что

$$P_0(t+\tau) = P_0(t) \cdot P\{S_0(t) \to S_0(t+\tau)\} +$$

$$+ P_1(t) \cdot P\{S_1(t) \to S_0(t+\tau)\} + o(\tau).$$

Первое слагаемое – вероятность перехода из состояния S_0 в S_0 при учете вероятности P_0. Второе – вероятность перехода из S_1 в S_0 при учете вероятности P_1. На основании (6.1) имеем

$$P_0(t+\tau) = P_0(t)[1 - \lambda_0\tau + o(\tau)] + P_1(t)[\mu_1\tau + o(\tau)] + o(\tau) =$$

$$= P_0(t) - \lambda_0\tau P_0(t) + \mu_1\tau P_1(t) + o(\tau).$$

Отсюда имеем

$$\frac{P_0(t+\tau) - P_0(t)}{\tau} = -\lambda_0 P_0(t) + \mu_1 P_1(t) + o(\tau).$$

При выводе формул принято $\mu_0 = 0$ (это следует из содержательного смысла: перехода из нулевого состояния влево нет). При $\tau \to 0$ получим дифференциальное уравнение

$$P_0'(t) = -\lambda_0 P_0(t) + \mu_1 P_1(t). \tag{6.2}$$

Таким же образом можно вывести дифференциальное уравнение, которому должна подчиняться вероятность $P_k(t)$ при $k = 1, 2, ...$ Здесь уже за время τ возможны три варианта перехода системы в состояние S_k:

1) $S_k(t) \to S_k(t+\tau)$;

2) $S_{k+1}(t) \to S_k(t+\tau)$;

3) $S_{k-1}(t) \to S_k(t+\tau)$.

Как и выше, используя формулу сложения вероятностей, получим

$$P_k(t+\tau) = P_k(t)\cdot P\{S_k(t) \to S_k(t+\tau)\} + P_{k+1}(t)\cdot P\{S_{k+1}(t) \to$$

$$\to S_k(t+\tau)\} + P_{k-1}(t)\cdot P\{S_{k-1} \to S_k(t+\tau)\} + 0(\tau).$$

Используя условие (6.1) в предположении, что $\tau \to 0$, получим следующее дифференциальное уравнение:

$$P_k'(t) = -(\lambda_k + \mu_k)P_k(t) + \mu_{k+1}P_{k+1}(t) + \lambda_{k-1}P_{k-1}(t). \tag{6.3}$$

К уравнениям (6.2), (6.3), которым удовлетворяют искомые вероятности $P_k(t)$, $k = 0, 1, 2, ...$, необходимо добавить уравнение, которое означает, что в каждый момент времени система должна находиться в каком-то из состояний:

$$\sum_{k=0}^{\infty} P_k(t) = 1. \tag{6.4}$$

Система (6.2)–(6.4) – частный случай уравнений Колмогорова – Чепмена для так называемых марковских цепей.

Используя систему (6.2)–(6.4), в принципе возможно отыскание неизвестных $P_k(t)$. Далее ставится вопрос: что будет происходить с этими неизвестными при $t \to \infty$?

Важно выяснить, имеют ли последовательности $P_k(t)$ в этом случае предел. В теории марковских процессов доказана следующая теорема.

Теорема 6.2. Если число состояний системы конечно и из любого состояния можно перейти за конечное число шагов в любое другое состояние, то предельные вероятности состояний существуют и не зависят от начального состояния системы.

Предельная вероятность состояния P_k имеет четкий смысл: она показывает среднее относительное время пребывания системы в состоянии S_k. Для процессов гибели и размножения в предположении, что число состояний конечно, эта теорема также применима, и при этом сразу находятся формулы для вычисления предельных вероятностей P_k. Поскольку в установившемся режиме все вероятности состояний постоянны, то все $P_k'(t) = 0$ и получаем систему алгебраических уравнений:

$$\begin{cases} -\lambda_0 P_0 + \mu_1 P_1 = 0, \\ -(\lambda_k + \mu_k)P_k + \mu_{k+1}P_{k+1} + \lambda_{k-1}P_{k-1} = 0, \quad k = 1, 2, ..., n, \\ \sum\limits_{k=0}^{n} P_k = 1. \end{cases}$$

Отсюда последовательно можно выразить неизвестные $P_1, P_2, ..., P_n$ через P_0, а P_0 определить из последнего уравнения.

Получим

$$\begin{cases} P_1 = \dfrac{\lambda_0}{\mu_1} P_0, \\ P_2 = \dfrac{\lambda_0 \lambda_1}{\mu_2 \mu_1} P_0, \\ \ldots, \\ P_k = \dfrac{\lambda_0 \lambda_1 \cdot \ldots \cdot \lambda_{k-1}}{\mu_k \, \mu_{k-1} \cdot \ldots \cdot \mu_1} P_0, \\ \ldots, \\ P_n = \dfrac{\lambda_0 \cdot \ldots \cdot \lambda_{n-1}}{\mu_n \mu_{n-1} \cdot \ldots \cdot \mu_1} P_0, \\ P_0 = \left[1 + \dfrac{\lambda_0}{\mu_1} + \dfrac{\lambda_0 \lambda_1}{\mu_2 \mu_1} + \ldots + \dfrac{\lambda_0 \cdot \ldots \cdot \lambda_{n-1}}{\mu_n \cdot \ldots \cdot \mu_1} \right]^{-1}. \end{cases} \tag{6.5}$$

Таким образом, для процессов гибели и размножения при условиях (6.1) найдены в явном виде предельные вероятности каждого состояния, т. е. задача решена в общем случае.

6.4. СИСТЕМА МАССОВОГО ОБСЛУЖИВАНИЯ С ПОТЕРЯМИ

Пусть имеется n приборов, на которые поступает простейший поток заявок на обслуживание с интенсивностью λ. Известно, что длительности обслуживания на каждом из приборов подчинены показательному закону распределения с параметром μ, где μ – интенсивность обслуживания. Если при поступлении заявки оказывается, что все приборы заняты, она теряется, уходит из системы необслуженной. Требуется найти:

среднее число заявок, которое система может обслужить за единицу времени (так называемую абсолютную пропускную способность СМО);

отношение среднего числа заявок, обслуживаемых системой в единицу времени, к среднему числу поступающих за это время заявок (так называемую относительную пропускную способность СМО).

Состояние системы будем различать по числу занятых приборов:

S_0 – все приборы свободны;

S_1 – занят один прибор, остальные свободны;

... ...;

S_n – заняты все n приборов.

Предположим, что переходы из состояния в состояние можно представить в виде графа, приведенного на рис. 6.2.

При таком предположении видно, что допускаются переходы только в соседнее состояние из любых других, причем переход слева направо определяется входным потоком интенсивности λ. Естественно, что он не зависит от того, в каком из состояний находится система. Переход справа налево определяется интенсивностью обслуживания,

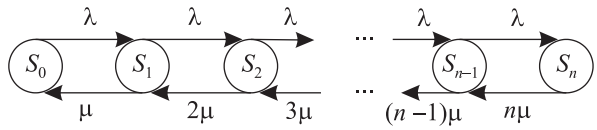

Рис. 6.2

а она зависит от того, сколько приборов занято в данный момент. Если занято k приборов, то интенсивность переходов в k раз больше интенсивности перехода из S_1 в S_0.

Не трудно видеть, что принятое предположение описывает частный случай процесса гибели и размножения, и поэтому при определении предельных вероятностей состояния системы, т. е. величин $P_0, P_1, P_2, ..., P_n$, можно непосредственно применить формулы (6.5) при

$$\lambda_0 = \lambda_1 = \lambda_2 = ... = \lambda_n = \lambda,$$

$$\mu_1 = \mu,\ \mu_2 = 2\mu, ..., \mu_n = n\mu.$$

В итоге получим, что

$$P_k = \frac{(\lambda/\mu)^k}{k!} P_0,\ k = 1, 2, ..., n,$$

$$P_0 = \left[1 + \frac{\lambda/\mu}{1!} + \frac{(\lambda/\mu)^2}{2!} + ... + \frac{(\lambda/\mu)^n}{n!} \right]^{-1}.$$

Это – формулы Эрланга.

Найдем теперь другие характеристики анализируемой СМО.

Очевидно, что $P_{\text{отк}} = P_n$, так как если система находится в состоянии S_n, то заявка не будет обслужена. Вероятность того, что заявка будет принята к обслуживанию $q = 1 - P_{\text{отк}}$, – относительная пропускная способность системы. Фактически она представляет собой отношение числа обслуженных заявок к числу всех поступивших в систему заявок.

Учитывая, что поток простейший, абсолютная пропускная способность системы, как среднее число заявок, обслуживаемых в единицу времени, равна $A = \lambda q$.

Важной характеристикой СМО с потерями является среднее число занятых приборов или среднее число заявок, занятых в системе. Поскольку один занятый прибор обслуживает в среднем за единицу времени μ заявок, A – среднее число обслуживаемых заявок в единицу времени, то среднее число занятых приборов вычисляется по формуле $\bar{k} = \dfrac{A}{\mu}$. Таким образом, формулы Эрланга дают возможность непосредственно вычислить все параметры анализируемой СМО с потерями.

Пример 6.1. СМО представляет собой одну телефонную линию, и заявка-вызов, пришедшая в момент, когда линия занята, получает отказ. Пусть $\lambda = 0{,}8$ вызова в минуту, средняя продолжительность разговора $\bar{t}_{\text{обсл}} = 1{,}5$ мин. Считается, что все потоки событий простейшие. Требуется определить параметры данной СМО и сравнить фактическую пропускную способность с той, которая получилась бы, если длительность

каждого разговора была бы в точности равна 1,5 мин и вызовы следовали друг за другом без перерыва.

Применим формулы Эрланга для случая $n = 1$. Можно посчитать, что

$$\mu = \frac{1}{\bar{t}_{\text{обсл}}} = 0,667.$$

Тогда $P_0 = \left[1 + \frac{\lambda}{\mu}\right]^{-1} \approx 0,45$; $P_1 = \frac{\lambda}{\mu} P_0 \approx 0,545$; $q \approx 0,455$, т. е. в установившемся режиме система обслуживает около 45 % поступивших вызовов:

$$A = \lambda q = 0,8 \cdot 0,455 \approx 0,364.$$

Это означает, что линия способна осуществить в среднем 0,364 разговора в минуту, $P_{\text{отк}} = 1 - P_0 = 0,545$, т. е. около 55 % заявок уходят из системы необслуженными.

Если бы длительность каждого разговора была в точности равна $t_{\text{обсл}} = 1,5$ мин, то номинальная пропускная способность СМО $A_{\text{номин}} = \frac{1}{\bar{t}_{\text{обсл}}} \approx 0,667$. Сравнение $A_{\text{номин}}$ и A показывает, что случайный характер поступления вызова и длительность обслуживания почти вдвое уменьшают абсолютную пропускную способность. Если бы поток вызовов был регулярным и разговоры одинаковы по продолжительности, то существенно увеличилась бы пропускная способность линии.

Рассмотрим этот же пример в случае, когда в системе заняты $n = 3$ одинаковые линии с теми же характеристиками, что и при исходной задаче. Тогда

$$P_0 \approx 0,312;$$

$$P_1 \approx 0,3;\ P_2 \approx 0,224;\ P_3 \approx 0,090;\ P_{\text{отк}} = P_3;\ q = 1 - P_3 \approx 0,910;\ A \approx 0,728;$$

$$\bar{k} = \frac{A}{\mu} \approx 1,09.$$

Эти параметры показывают, что система обслуживала бы около 91 % поступивших вызовов, т. е. по сравнению со случаем $n = 1$ число обслуживаемых вызовов увеличивалось бы вдвое, однако значение $\bar{k}$ говорит о том, что в среднем простаивали бы 2 линии.

6.5. СИСТЕМА МАССОВОГО ОБСЛУЖИВАНИЯ С ОЖИДАНИЕМ

6.5.1. Конечная очередь

Пусть в системе имеется n приборов и m мест для формирования очереди. Предположим, что поток заявок простейший с параметром λ и длительность обслуживания на каждом из приборов подчиняется показательному закону с параметром μ. Поступившая заявка или сразу начинает обслуживаться, или становится в очередь, если все приборы заняты, но имеются свободные места в очереди, или уходит из системы,

если в очереди нет свободных мест. Таким образом, состояния системы можно различать по числу связанных с ней заявок:

S_0 – в системе нет ни одной заявки;

S_1 – обслуживается одна заявка (остальные приборы свободны);

... ...;

S_n – все приборы заняты;

S_{n+1} – n заявок находится на обслуживании, одна – в очереди;

... ...;

S_{n+m} – n заявок находится на обслуживании, m – в очереди.

Предположим, что переход из состояния в состояние изображается в виде графа, приведенного на рис. 6.3.

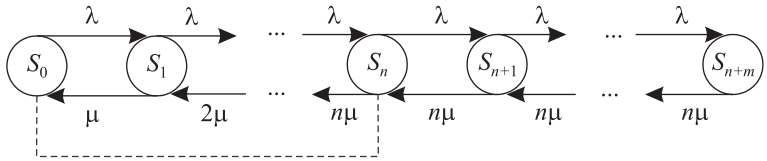

Рис. 6.3

На переходах слева направо проставлены интенсивности входного потока, которые не зависят от того, в каком из состояний находится система. На дугах справа налево проставлены интенсивности длительностей обслуживания, которые прямо пропорциональны количеству занятых приборов.

Из-за того, что по предположению система описывается таким графом, видно, что это также частный случай процесса гибели и размножения.

Общее число состояний $(n + m + 1)$, а $\lambda_0 = \lambda_1 = ... = \lambda_{n+m+1} = \lambda$ и

$$\mu_1 = \mu,\ \mu_2 = 2\mu,\ ...,\ \mu_n = n\mu,\ ...,\ \mu_{n+m} = n\mu.$$

Учитывая эти параметры и применяя формулы (6.5), найдем явные выражения для предельных вероятностей системы.

$$\begin{cases} P_0 = \left[1 + \dfrac{\lambda/\mu}{1!} + ... + \dfrac{(\lambda/\mu)^n}{n!} + \dfrac{(\lambda/\mu)^{n+1}}{n \cdot n!} + ... + \dfrac{(\lambda/\mu)^{n+m}}{n^m \cdot n!}\right]^{-1}, \\ P_1 = \dfrac{\lambda}{\mu} P_0, \\ ..., \\ P_n = \dfrac{(\lambda/\mu)^n}{n!} P_0, \\ P_{n+1} = \dfrac{(\lambda/\mu)^{n+1}}{n \cdot n!} P_0, \\ ..., \\ P_{n+m} = \dfrac{(\lambda/\mu)^{n+m}}{n^m \cdot n!} P_0. \end{cases} \tag{6.6}$$

После того как найдены P_0, …, P_n, …, сразу находятся следующие ее параметры:

$$P_{\text{отк}} = P_{n+m};\ q = 1 - P_{\text{отк}} = 1 - P_{n+m};\ A = \lambda q;\ \bar{k} = \frac{A}{\mu}.$$

Все эти параметры имеют тот же смысл, что и в п.6.4, и кроме них можно найти и другие. Например, можно посчитать среднее число заявок в очереди, определяя его как математическое ожидание дискретной случайной величины, которой является число заявок. Понятно, что одна заявка находится в очереди с вероятностью P_{n+1}, две – с вероятностью P_{n+2}, ..., $m - P_{n+m}$. Используя формулу для математического ожидания дискретной случайной величины, получим, что среднее число заявок в очереди

$$\bar{r} = 1P_{n+1} + 2P_{n+2} + \ldots + mP_{n+m}.$$

Таким же способом можно высчитать среднее время ожидания заявки в очереди. Если система находится в состоянии S_n, то ей придется ждать в среднем $\frac{1}{n\mu}$ ед. времени; если в очереди стоит одна заявка, то пришедшей второй заявке необходимо ждать $\frac{2}{n\mu}$ и т. д. Если в очереди m заявок, то пришедшая заявка не будет обслужена.

Таким образом, $\bar{t}_{\text{ожид}} = \frac{1}{n\mu}P_n + \frac{2}{n\mu}P_{n+1} + \ldots + \frac{m}{n\mu}P_{n+m-1}$.

Пример 6.2. Пусть СМО представляет собой АЗС (автомобильная заправочная станция) с двумя колонками ($n = 2$). Поток прибывающих машин имеет интенсивность $\lambda = 2$ маш/мин. Среднее время обслуживания одной машины $\bar{t}_{\text{обсл}} = 2$ мин, и у станции имеется три места для очереди ($m = 3$). Найти характеристики этой СМО.

По формуле (6.6) находим: $P_0 \approx 0{,}008$, ..., $P_5 \approx 0{,}512$. Эти данные получены на основе того, что $\mu = \frac{1}{\bar{t}_{\text{обсл}}} = 0{,}5$.

Далее

$P_{\text{отк}} \approx 0{,}512;\ q = 1 - P_{\text{отк}} \approx 0{,}488;\ A = \lambda q \approx 0{,}976;\ \bar{k} \approx 1{,}952;\ \bar{r} \approx 2{,}18;\ \bar{t}_{\text{ожид}} \approx 1{,}09.$

Значения $\bar{k}$ и $\bar{r}$ показывают, что в среднем в системе всегда работает 2 колонки и по крайней мере 2 места в очереди занято. При этом среднее время ожидания в очереди составляет 1 мин. Это позволяет обслуживать почти все прибывающие машины.

6.5.2. Системы с бесконечной длиной очереди

Предположим, что число мест в очереди не ограничено каким-то числом m, а может быть сколь угодно большим. Тогда система, описанная в п. 6.5.1, будет иметь бесконечное число состояний и граф состояний может выглядеть так, как представлено на рис. 6.4.

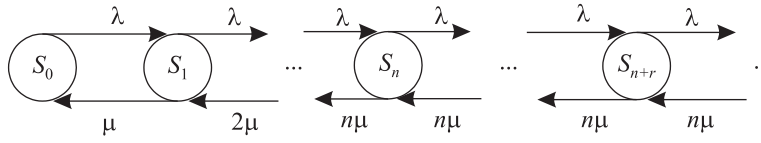

Рис. 6.4

В этом случае также имеет смысл рассматривать задачу о нахождении предельных вероятностей состояния системы. Оказывается, их не трудно получить, используя предельные переходы в формулах (6.6). Дело в том, что часть слагаемых для P_0 в этих формулах представляет собой геометрическую прогрессию со знаменателем $\frac{\lambda}{\frac{\mu}{n}}$.

Ряд сходится в случае, если $\frac{\lambda}{\frac{\mu}{n}} < 1$.

Как отмечалось в п. 6.1, если $\frac{\lambda}{\frac{\mu}{n}} > 1,$ то интенсивность входного потока настолько велика, что система не успевает за конечное время обслужить все заявки, и поэтому очередь заявок на обслуживание будет расти с течением времени.

При $\frac{\lambda}{\frac{\mu}{n}} < 1$ формулы (6.6) будут иметь вид:

$$P_0 = \left[1 + \frac{\frac{\lambda}{\mu}}{1!} + \frac{\left(\frac{\lambda}{\mu}\right)^2}{2!} + \ldots + \frac{\left(\frac{\lambda}{\mu}\right)^n}{n!} + \frac{\left(\frac{\lambda}{\mu}\right)^{n+1}}{n!\left(1 - \frac{\frac{\lambda}{\mu}}{n}\right)} \right]^{-1};$$

$$P_1 = \frac{\frac{\lambda}{\mu}}{1!} P_0, \ \ldots, P_n = \frac{\left(\frac{\lambda}{\mu}\right)^n}{n!} P_0, \ \ldots, P_{n+r} = \frac{\left(\frac{\lambda}{\mu}\right)^{n+r}}{n^r n!} P_0, \ \ldots.$$

По этим параметрам можно найти характеристики изучаемой СМО. Ясно, что для нее $P_{\text{отк}} = 0$, т. е. все заявки в конечном итоге будут обслужены: $q = 1 - P_{\text{отк}} = 1$; $A = \lambda q = \lambda$.

Другие характеристики находят с помощью предельного перехода при $m \to \infty$. Так, например, среднее число заявок в очереди:

$$\bar{r} = \frac{\left(\frac{\lambda}{\mu}\right)^{n+1}}{n \cdot n!\left(1 - \frac{\frac{\lambda}{\mu}}{n}\right)^2} P_0, \qquad \bar{t}_{\text{ожид}} = \frac{\left(\frac{\lambda}{\mu}\right)^n}{n \cdot \mu \cdot n!\left(1 - \frac{\frac{\lambda}{\mu}}{n}\right)^2} P_0.$$

Как и выше, среднее число занятых приборов $\overline{k} = \frac{A}{\mu} = \frac{\lambda}{\mu}$.

Пример 6.3. Пусть АЗС с двумя колонками ($n = 2$) обслуживает поток машин с интенсивностью $\lambda = 0{,}8$ маш/мин, среднее время обслуживания одной машины $\overline{t}_{\text{ожид}} = 2$ мин. Разрешается неограниченная по длине очередь. Найти параметры данной СМО:

$$\mu = \frac{1}{\overline{t}_{\text{обсл}}} = 0{,}5 \text{ маш/мин}; \qquad \frac{\frac{\lambda}{\mu}}{n} < 1 = 0{,}8,$$

т. е. для данной СМО можно говорить о предельных вероятностях состояний в установившемся режиме. Можем вычислить вероятности:

$$P_0 \approx 0{,}111;\ P_1 \approx 0{,}178;\ P_2 \approx 0{,}142;\ P_3 \approx 0{,}114;\ P_4 \approx 0{,}091 \text{ и т. д.}$$

Среднее число занятых колонок $\overline{k} = 1{,}6$. Вероятность обслуживания без очереди $P_0 + P_1 + P_2 = 0{,}431$. Среднее число машин в очереди $\overline{r} = 0{,}71$, $\overline{t}_{\text{ожид}} = 0{,}89$. Система работает достаточно эффективно, так как почти всегда заняты обе колонки и среднее время ожидания в очереди сравнительно невелико.

6.6. НЕКОТОРЫЕ ДРУГИЕ ТИПЫ СИСТЕМ МАССОВОГО ОБСЛУЖИВАНИЯ

Замкнутые СМО

Ранее рассматривались СМО, в которых поток заявок не был связан с системой (находился вне системы). В замкнутых СМО источник заявок находится в самой системе и, как правило, количество заявок ограничено.

Пример 6.4. Пусть m рабочих должны обслуживать n станков ($m < n$). Станки в случайные моменты времени могут выходить из строя, и тогда требуется обслуживание наладчиком.

Предположим, что интенсивность потока λ заявок-неисправностей постоянна, а сам этот поток является простейшим. Если в момент выхода станка из строя хотя бы один рабочий свободен, то он берется за наладку станка и тратит на это $\overline{t}_{\text{обсл}} = \frac{1}{\mu}$. Если все рабочие заняты, то станок ожидает своей очереди на обслуживание. Таким образом, в этой системе можно различать следующие состояния:

S_0 – все станки работают;

S_1 – один станок неисправен (1 рабочий занят);

… … …;

S_m – m станков неисправно (все m рабочих заняты);

S_{m+1} – $m + 1$ станок неисправен, 1 станок находится в очереди на обслуживание;

… … …;

S_n – n станков неисправны, $n - m$ станков находятся в очереди на обслуживание.

Граф состояний может иметь вид, приведенный на рис. 6.5.

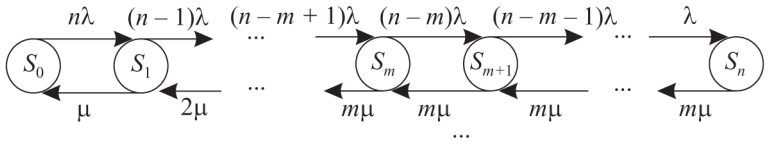

Рис. 6.5

На переходах, идущих слева направо, представлены интенсивности потока заявок на обслуживание, которые прямо пропорциональны количеству работающих станков с коэффициентом пропорциональности λ. На переходах, идущих справа налево указаны интенсивности обслуживания, которые пропорциональны количеству обслуживающих рабочих с коэффициентом пропорциональности μ.

Данная СМО – частный случай процесса гибели и размножения из п. 6.3. Тогда

$$P_1 = \frac{n}{1!}\frac{\lambda}{\mu}P_0, \quad P_2 = \frac{n(n-1)}{2!}\left(\frac{\lambda}{\mu}\right)^2 P_0, \quad ..., \quad P_m = \frac{n(n-1)\ldots(n-m+1)}{m!}\left(\frac{\lambda}{\mu}\right)^m P_0,$$

$$P_{m+1} = \frac{n(n-1)\ldots(n-m)}{m!m}\left(\frac{\lambda}{\mu}\right)^{m+1} P_0, \quad ..., \quad P_n = \frac{n!}{m!m^{n-m}}\left(\frac{\lambda}{\mu}\right)^n P_0,$$

$$P_0 = 1 - \sum_{i=1}^{n} P_i.$$

Эти вероятности позволяют определить среднее число занятых рабочих как математическое ожидание дискретной случайной величины

$$\overline{k} = 0\,P_0 + 1P_1 + \ldots + (m-1)P_{m-1} + m(P_m + \ldots + P_n).$$

Вычислим далее:

$A = \overline{k} \cdot \mu$ – среднее число станков, обслуживаемых бригадой в единицу времени;

$\overline{w} = n - \dfrac{\overline{k}\mu}{\lambda}$ – среднее число неисправных станков.

Пусть, например, в системе

$$m = 2; \quad n = 6; \quad \overline{t}_{\text{обсл}} = 10\,\text{мин}; \quad \lambda = 2\ \text{стан/ч}; \quad \mu = \frac{1}{\overline{t}_{\text{обсл}}} = 6\ \text{стан/ч}.$$

Тогда $P_0 \approx 0{,}153$; $P_1 \approx 0{,}306$; $\overline{k} \approx 1{,}235$; $\overline{A} \approx 7{,}41$; $\overline{w} \approx 2{,}295$.

Значит, система полностью загружена, двое рабочих заняты почти всегда.

СМО с ограниченным временем ожидания в очереди

В них заявки могут становиться в очередь, но, подождав некоторое время, уходят из нее необслуженными. В этом случае необходимо учитывать уже три потока событий:

1) входной поток заявок;

2) длительность обслуживания заявок;

3) поток убывания заявок из очереди.

Оказывается, если предположить, что все три потока подчиняются показательным законам распределения с параметрами λ, μ, v соответственно, то легко получить формулы для вычисления характеристик такой СМО. Граф переходов может иметь вид, представленный на рис. 6.6.

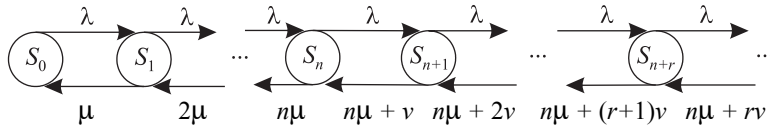

Рис. 6.6

В этом графе учтена интенсивность обслуживания и убывания заявок. Используя уже известные формулы п. 6.3 при соответствующем предельном переходе, получим необходимые характеристики СМО.

Некоторые другие модели СМО

По приведенным выше схемам можно изучить другие виды систем.

Система с приоритетом. В этом случае некоторым заявкам, поступившим в систему, отдается немедленное предпочтение по сравнению с другими, которые должны ожидать своей очереди. При изучении таких систем возможен подход, когда входной поток разделяется на два и указывается интенсивность поступления приоритетных заявок и интенсивность поступления обычных. Можно предположить, что эти потоки подчиняются показательным законам распределения, и свести задачу в этом случае к частному случаю процесса гибели и размножения.

Системы с последовательными очередями. В них выход одной очереди является входным потоком для другой. В этом случае граф переходов становится «многослойным» в зависимости от количества очередей. При обычных предположениях дело можно свести к процессам гибели и размножения. Эта схема позволяет изучить характеристики систем для случая неидентичных приборов, когда каждый прибор имеет свое среднее время обслуживания. В теории массового обслуживания показано, что если систему удается описать таким множеством состояний, что скорость перехода от одного к другому не зависит от времени пребывания системы в каком-либо из них, т. е. система представляет марковский процесс, то для нахождения предельных вероятностей состояний может быть получена система линейных алгебраических уравнений относительно этих вероятностей и она разрешима.

Последнее время в теории массового обслуживания начинают изучать новые задачи. Например, анализируются системы, в которых поток заявок характеризуется не только временными, но и пространственными параметрами. Примером служит система неотложной помощи, когда длительность обслуживания заявки зависит не только от времени поступления последней, но и от места, в котором находится неотложка.

Новыми также являются задачи, связанные с анализом устойчивости решений при сравнительно небольших изменениях законов или параметров распределения входного и выходного потоков. Построены примеры систем, в которых даже незначительное изменение (например, входного потока) может существенно сказаться на значении характеристик СМО. Поэтому в ИСО стараются описать классы систем с устойчивыми решениями.

К новым задачам относятся оптимизационные задачи теории МО, в которых по заданным ранее характеристикам оптимально функционирующей СМО требуется определить необходимые законы распределения вероятностей для входных и выходных потоков.

6.7. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. В чем состоит основное отличие задач массового обслуживания от задач теории расписаний?
2. Опишите составляющие задач массового обслуживания.
3. Как классифицировать задачи массового обслуживания?
4. Какая величина может в первую очередь характеризовать эффективность системы массового обслуживания?
5. Опишите свойства простейших потоков заявок.
6. Что означает для системы массового обслуживания символ D/M/3?
7. Как различаются состояния и переходы между ними в процессах гибели и размножения?
8. Какой смысл предельных вероятностей состояний в процессах гибели и размножения?
9. Опишите системы массового обслуживания с потерями.
10. Какой вид может иметь граф переходов между состояниями в системах массового обслуживания с потерями?
11. Опишите системы массового обслуживания с ожиданием и конечной очередью.
12. Какой вид может иметь граф переходов между состояниями в системах массового обслуживания с ожиданием и конечной очередью?
13. Какой вид может иметь граф переходов между состояниями в системах массового обслуживания с ожиданием при неограниченном числе мест в очереди?
14. Опишите граф переходов между состояниями в замкнутых системах массового обслуживания.
15. Опишите граф переходов между состояниями в системах массового обслуживания с ограниченным временем ожидания в очереди.

7. НЕКОТОРЫЕ ЗАДАЧИ УПРАВЛЕНИЯ ЗАПАСАМИ

7.1. СТРУКТУРА ЗАДАЧ УПРАВЛЕНИЯ ЗАПАСАМИ

Практически все задачи управления в сложных системах (т. е. задачи ИСО) касаются управления ресурсами. В качестве ресурсов могут выступать, например, люди, машины, энергия, информация, деньги, изделия в любой степени готовности и т. п. Как уже отмечалось ранее (п. 2.1), все виды ресурсов в конкретной задаче принятия решений можно подразделить на ресурсы используемые и ресурсы производимые. Естественным образом появляется понятие запаса (резерва) в виде годных к употреблению, но не используемых в течение определенного времени ресурсов.

Для обеспечения функционирования системы, например ритмичной работы производственного предприятия, можно создать сколь угодно большие запасы разных видов ресурсов и даже готовых изделий. В свою очередь, величина этих ресурсов влияет на затраты, связанные с их хранением. Поэтому появляются задачи управления запасами (ЗУЗ), цель которых – выработка решений по рациональному управлению объемами хранимых ресурсов.

Пусть, например, некоторое предприятие должно ежедневно поставлять одно изделие. Но для того чтобы обеспечить его производство, требуются определенные затраты на наладку оборудования. Возможны следующие варианты выполнения плана предприятия:

- каждый день предприятие производит по одному изделию и никаких запасов по этим изделиям не создается;
- предприятие производит по два изделия так, что после первого дня одно изделие остается в запасе (на второй день).

Понятно, что затраты на подготовку производства, отнесенные к одному изделию во втором варианте, уменьшаются вдвое, зато появляются затраты, необходимые для содержания запасов.

ЗУЗ возникают в условиях, когда величину запаса можно регулировать и когда существует, по крайней мере, один вид производственных затрат, убывающих при увеличении запасов. Именно за счет этого вида затрат появляется возможность ставить задачу оптимизации. Целевой является функция общих затрат, которую нужно минимизировать в зависимости от объема запасов.

Как и в других задачах ИСО, переменные в данной задаче могут быть двух видов: управляемые и неуправляемые.

Управляемыми могут быть, например, следующие переменные:

- поступающий объем ресурсов (часть из которого будет запасной). Именно определяя значение этих переменных, узнаем, сколько ресурсов разных видов надо выпустить или приобрести;

• степень готовности продукции, хранящейся в виде запасов: чем выше эта степень, тем меньше запаздывание в удовлетворении спроса. Но если в запасе хранятся изделия, близкие к готовым, этим самым повышаются затраты на хранение запасов. Если же степень готовности невелика, то затраты на хранение, как правило, уменьшаются, но необходимо больше времени на удовлетворение спроса (выполнение заказов);

• периодичность и моменты времени для поступления ресурсов в зависимости от темпа производства.

К *неуправляемым* переменным относятся:

• затраты на содержание запасов. Кроме таких естественных затрат, как учет, стоимость хранения запаса и т. п., большую роль играет стоимость капиталовложений в запасы (тот долг, которым обеспечивается запас);

• затраты, обусловленные изменением темпов производства;

• спрос, измеряемый в виде объема продукции, которая могла бы быть продана, если бы в наличии было достаточно этой продукции для удовлетворения потребностей;

• сроки выполнения заказа.

Применительно к управлению запасами оптимальное решение состоит в том, чтобы построить два следующих алгоритма:

1) алгоритм, позволяющий определить, когда и при каких условиях необходимо производить пополнение запасов;

2) алгоритм, позволяющий определить объем пополнения.

Далее рассмотрим только два типа ЗУЗ при достаточно существенных упрощающих предположениях. В реальных условиях задачи осложняются, например, взаимозаменяемостью некоторых видов ресурсов, необходимостью иметь запасы нескольких видов ресурсов в одном складском помещении и т. п. При наличии различных мест для складирования одного или нескольких видов ресурсов появляется необходимость учета транспортных затрат.

Некоторые ЗУЗ формулируются и анализируются как задачи массового обслуживания. Поступивший заказ, который выполняется путем поставки ресурса из запаса, рассматривается как заявка. Складское хозяйство можно считать средством обслуживания (одним или несколькими приборами). Очередь – это количество еще не выполненных заказов.

7.2. СТАТИЧЕСКАЯ МОДЕЛЬ С ОДНИМ ПЛАНОВЫМ ПЕРИОДОМ

Пусть u – объем запасов ресурса перед моментом принятия решения по его накоплению, x – заказываемый объем ($x \geq 0$) и $y = x + u$ – суммарный объем ресурса для выполнения будущего спроса, q – фактический уровень спроса (положим, что это неотрицательная случайная переменная).

Пусть $p(q)$ – вероятность того, что уровень спроса на какой-то момент в точности равен q. Будем предполагать, что все введенные переменные принимают целочисленные значения. Чтобы не вводить различных коэффициентов для пересчета, примем также, что вводимые переменные приведены к одной шкале измерения. При решении задачи об управлении запасами искомые переменные – x и y, и можно считать, что они являются функциями от переменной u, т. е. $x = x(u)$, $y = y(u)$.

В качестве целевой функции примем выражение общих затрат на весь плановый период. Эти затраты складываются из следующих слагаемых:

1) при пополнении запаса необходимы затраты на покупку ресурса;

2) при наличии какого-то запаса необходимы также затраты на хранение;

3) если спрос продукции не будет удовлетворен, то предприятие понесет какие-то потери в виде штрафа за неудовлетворение спроса.

Два последних вида затрат представим в виде математического ожидания их величин в зависимости от заданных вероятностей.

Распишем подробнее общий вид целевой функции. Будем считать, что затраты на приобретение ресурса в объеме x выражается формулой

$$C(x) = \begin{cases} 0, & \text{если } x = 0, \\ K + cx, & \text{если } x > 0, \end{cases} \tag{7.1}$$

где K – некоторые накладные расходы, не зависящие от объема заказанного ресурса; c – стоимость единицы ресурса. Таким образом, здесь принято, что стоимости приобретенных ресурсов близки (в силу целочисленности значений) к линейной функции от x.

Два последних вида ожидаемых потерь, при хранении ресурсов и при неудовлетворенном спросе, можно представить в виде функции

$$L(y) = \sum_{q=0}^{y} h(y-q)p(q) + \sum_{q>y} d(q-y)p(q), \tag{7.2}$$

где h – затраты на хранение единицы ресурса, остающегося в запасе до конца планового периода; d – штрафные потери на единицу ресурса из-за неудовлетворенного спроса по причине отсутствия ресурса до конца планового периода. Очевидно, что рассматриваем частный случай функции $L(y)$, когда все ожидаемые затраты также близки к линейным функциям от y. Общая целевая функция будет иметь вид

$$F = C(x) + L(y). \tag{7.3}$$

Рассмотрим стратегию пополнения запасов, подчиняющуюся следующему правилу:

$$\begin{cases} y(u) = u, \quad x(u) = 0 \quad \text{при} \quad u \geq s, \\ y(u) = S, \quad x(u) = S - u \quad \text{при} \quad u < s. \end{cases} \tag{7.4}$$

Здесь s – критический уровень запаса; S – уровень запаса, достигаемый в результате пополнения.

По этой стратегии видно, что в зависимости от значения текущего объема запасов происходит пополнение в том случае, если он становится ниже так называемого критического уровня s. Это пополнение происходит до тех пор, пока суммарный уровень запаса ресурсов не станет равным какой-то заданной величине S. Правило (7.4) в теории управления запасами (УЗ) называется (s, S)-стратегией. Для того чтобы задать (s, S)-стратегию, необходимо определить параметры s и S.

В теории управления запасами доказано, что в случае, когда целевая функция имеет вид (7.3) и ожидаемые затраты являются линейными (или более общими, выпуклыми) функциями от y, то (s, S)-стратегия – наилучшая форма пополнения запасов.

Рассмотрим способы нахождения s и S. Введем еще один параметр $R = \dfrac{d-c}{d+h}$. В рассматриваемой модели разумными предположениями являются неравенства $d - c > 0$; $d + h > 0$. Тогда $0 < R < 1$.

В теории УЗ величину R называют определяющим параметром. Именно с этим параметром связан способ нахождения значения S.

Оптимально такое значение S, при котором полный спрос на весь плановый период удовлетворяется, по крайней мере, с вероятностью R. Оказывается, что вероятность полного удовлетворения спроса можно представить в виде так называемой статистической (кумулятивной) функции распределения

$$P(S) = \sum_{q=0}^{S} p(q).$$

Поэтому для получения оптимального S требуется найти наименьшие из чисел q, при котором выполняется неравенство

$$P(S) = \sum_{q=0}^{S} p(q) \geq R. \qquad (7.5)$$

Таким образом, достаточно при $q = 0,1, ...,$ накапливать сумму $\sum p(q)$ до тех пор, пока не выполнится неравенство (7.5). Наименьшее значение q, при котором это произойдет, и даст S.

Приведем способ нахождения s.

Из (s, S)-стратегии видно, что если начальный объем запасов равен s, то заказ на дополнительную поставку не производится. Следовательно, сумма ожидаемых затрат и ожидаемых штрафных потерь при $y = s$ $(x = 0)$ не должна превышать значения целевой функции при $y = S$ $(x = S - s)$. Если бы этого не было, то имело бы смысл пополнить запас и тем самым уменьшить значение целевой функции. Из этого следует, что в качестве s можно выбирать наименьшее из чисел, при котором выполняется неравенство

$$L(s) \leq K + c(S - s) + L(S).$$

Таким образом, начиная с $y = S$ (это значение уже определено выше) необходимо перебирать последовательно все целочисленные значения, меньшие S, и сравнивать значения выражения $L(y) + cy$ со значением $K + cS + L(S)$. Наименьшее значение y, при котором $L(y) + cy \leq K + cS + L(S)$, определит величину $y = s$.

Таким образом, в предположении линейности (или выпуклости) целевой функции эффективно находятся величины s и S, и тем самым определяется оптимальная (s, S)-стратегия.

7.3. МОДЕЛИ ВЫБОРА РАЗМЕРА ЗАКАЗЫВАЕМОЙ ПАРТИИ

Предположим, что в задаче УЗ продолжительность планового периода не ограничена и, следовательно, имеет место бесконечное число отдельных моментов пополнений запасов.

Предположим сначала, что спрос можно точно установить и что в течение каждого единичного отрезка времени он равняется некоторому фиксированному числу q. Даже при таком существенном упрощении остается задача выбора моментов времени, в которые необходимо делать заказ на пополнение, а также определения величины пополняемых запасов.

Пусть, например, q = 30 ед. в неделю, а правило пополнения запасов состоит в том, что, как только уровень запаса становится равным 0, оформляется заказ на 45 ед. ресурса. Если предположить, что заказ выполняется мгновенно, то правило пополнения запасов можно представить в виде графика (рис. 7.1).

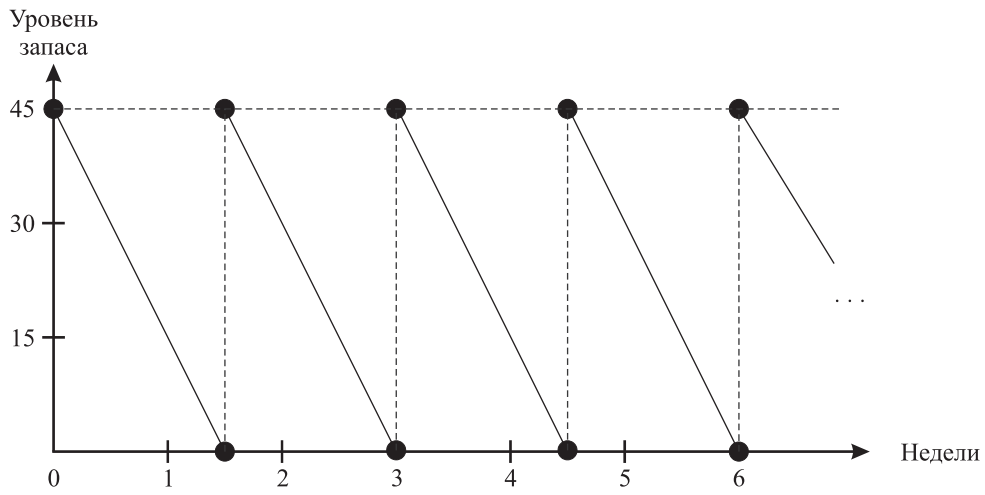

Рис. 7.1

На графике определены моменты пополнения запасов (каждые 1,5 недели). Если бы запас на пополнение не выполнялся мгновенно, а с каким-то опозданием, то при определении моментов заказа на пополнение надо было бы учитывать время выполнения заказа, т. е. моменты оформления самого заказа сдвигалось бы влево на определенный интервал.

Предположим, что q – величина спроса; x – текущий уровень запаса; s – критический уровень запаса, при котором следует производить пополнение; S – уровень запаса после пополнения; K – накладные расходы, связанные с оформлением каждого заказа на пополнение; c – стоимость единицы ресурса; h – стоимость хранения единицы ресурса в течение единичного отрезка времени; d – величина штрафа при неудовлетворении спроса из-за отсутствия сырья.

Проанализируем теперь целевую функцию, зависящую от текущего уровня запаса и представляющую собой выражение общих затрат, связанных с учетом расходов:

1) на приобретение ресурса;
2) средних затрат на хранение;
3) штрафных потерь при неудовлетворении спроса.

В итоге эта функция может иметь вид

$$H(x) = K\frac{q}{x} + cq + \frac{hS^2}{2x} + d(-s)\frac{q}{x}. \tag{7.6}$$

Первое слагаемое означает суммарные накладные расходы на одно оформление заказа с учетом того, что $\frac{q}{x}$ – среднее число оформляемых заказов в единицу времени. Второе слагаемое – средняя стоимость пополнения запасов при закупке. Третье – средние затраты, связанные с хранением ресурса, так как величина $\frac{S}{x}$ – это доля планового периода, когда уровень запасов положителен, а $\frac{S}{2}$ – средний объем запасов на интервале $\frac{S}{x}$. Четвертое слагаемое выражает штрафные потери при отсутствии ресурса из-

за того, что максимальное число единиц недостающего ресурса равно $-s$. Штраф для каждого цикла пополнения равен $d(-s)$, а средние штрафные потери в единицу времени оцениваются величиной $d(-s)\frac{q}{x}$.

В теории управления запасами доказано, что если целевая функция имеет вид (7.6), то оптимальной стратегией пополнения запасов будет (s, S)-стратегия, которая (как в п. 7.2) формулируется следующим образом: если текущий уровень запасов достигает критического уровня s, то оформляется заказ на поставку ресурса в объеме $x = S - s$.

Таким образом, в данном случае надо решить оптимизационную задачу минимизации функции $H(x)$ при определенных ограничениях, накладываемых на величины S и s. Из содержательного смысла можно вывести простейшие ограничения, которым должны подчиняться эти значения:

1) очевидно, что минимум $H(x)$ не может быть достигнут при $s > 0$, так как всегда имелись бы неизрасходованные запасы, наличие которых не приводило бы $H(x)$ к минимуму;

2) аналогично: из-за многократного пополнения запасов этот минимум не может достигаться при $S < 0$.

Таким образом, простейшими ограничениями являются

$$S \geq 0, \quad s \leq 0.$$

Поскольку в соответствии с (s, S)-стратегией $x = S - s$ или $-s = x - S$, то целевая функция будет иметь вид

$$H(x) = K\frac{q}{x} + cq + \frac{hS^2}{2x} + dq - dS\frac{q}{x}.$$

Доказано, что при некоторых предположениях, накладываемых на величину d (необходимо, чтобы $d > \sqrt{\frac{2Kh}{q}}$), оптимальное значение x должно равняться либо S, либо 0. Предположим, что $x = S$, тогда

$$H(x) = H(S) = K\frac{q}{S} + cq + \frac{hS}{2}. \tag{7.7}$$

Пользуясь необходимым условием экстремума для функции $H(S)$, можно найти $H'(S)$ и, решив уравнение $H'(S) = 0$, найти оптимальное значение S из этого уравнения. Получим

$$S_{\text{опт}} = \sqrt{2\frac{Kq}{h}}, \text{ при этом } H_{\min} = cq + \frac{1}{\sqrt{2Khq}}.$$

Выражение для $S_{\text{опт}}$, полученное в соответствии с выведенной формулой, известно в экономической теории. Оно называется экономически выгодным размером партии (ЭВРП). Из предположения, что $x = S_{\text{опт}}$ в (s, S)-стратегии, получим, что $s = 0$. Таким образом, для этого простейшего случая задача решается до конца и получена точная формула для определения $S_{\text{опт}}$. Как только критический уровень $s = 0$, происходит пополнение запаса до величины $S_{\text{опт}}$.

Рассмотрим вторую, более сложную модель, определяющую ЭВРП в предложении, что спрос носит не детерминированный, а случайный характер.

Пусть M – средняя ожидаемая величина спроса в единицу времени; l – продолжительность времени от момента появления спроса до момента удовлетворения, т. е. спрос удовлетворяется не мгновенно; M_l – средняя ожидаемая величина спроса на интервале длины l. Пусть $M_l = Ml$, т. е. математическое ожидание суммы случайных величин равно сумме математических ожиданий случайных величин; q_l – фактический объем неудовлетворенного спроса на интервале l; $P_l(q_l)$ – вероятность того, что фактический объем неудовлетворенного спроса равен q_l. Если $l = 0$, то модель фактически превращается в модель, изложенную выше. Если $l > 0$, то для исследования задачи необходимо дополнительно предположить, что:

1) распределение вероятностей $P_l(q_l)$ не зависит от того, когда уровень текущих запасов достигает критической величины;

2) пополнение запасов происходит в момент, когда $x = s$;

3) уровень запасов x можно рассматривать как непрерывную переменную;

4) для оптимальной стратегии критический уровень $s > 0$ и на любом интервале l фактический объем неудовлетворенного спроса не превышает объема заказываемой партии, т. е. $q_l \le x$.

Из условий 1), 2) следует, что закон распределения случайной величины q_l на любом временном интервале T является показательным с параметром $M \cdot T$.

Как и в первом случае, необходимо построить целевую функцию, представляющую собой суммарные затраты. Эти затраты будут слагаться из следующих составляющих:

1) затрат на пополнение ресурсов;

2) затрат, связанных с хранением запаса;

3) штрафных потерь при неудовлетворении спроса.

В целом, целевая функция может иметь следующий вид:

$$\bar{H}(x) = K\frac{M}{x} + cM + h\left(\frac{x}{2} - M_l + s\right) + \left(\frac{hM_l}{2x} + \frac{Md}{x}\right)\sum_{q_l > s}(q_l - s)P_l(q_l).$$

Если бы спрос был детерминированным, то критический объем запасов $s = M_l$ и сумма в последнем слагаемом были равны 0 (из-за нулевых вероятностей). Целевая функция превратилась бы в функцию вида (7.7).

Для определения оптимального значения x можно использовать необходимое условие экстремума функции одной переменной, т. е. найти решение уравнения $\bar{H}'(x) = 0$. Тогда решением будет

$$x_{\text{опт}} = \sqrt{\frac{2KM}{h} + \left(M_l + \frac{2Md}{h}\right)\sum_{q_l > s}(q_l - s)P_l(q_l)}. \qquad (7.8)$$

Оптимальное значение s находится как наименьшее целое число, при котором удовлетворяется неравенство

$$\sum_{q_l=0}^{s} P_l(q_l) > 1 - \frac{hx}{h\frac{M_l}{2} + Md}. \qquad (7.9)$$

Это неравенство представляет собой вероятность, при которой суммарный неудовлетворенный спрос будет больше определенного числа. Выражения (7.8) и (7.9) являются основой для определения $S = x_{\text{опт}}$ и s в (s, S)-стратегии.

Для решения этой задачи применяется следующий алгоритм.

Полагаем начальное значение $x_0 = \sqrt{\frac{2KM}{h}}$ (т. е. $S_{\text{опт}}$ – в детерминированной постановке). Подставим это значение в неравенство (7.9). После этого появляется возможность для вычисления s как наименьшего целого, при котором выполняется неравенство (7.9). Полученное значение s подставляем в (7.8) и вычисляем очередное значение x.

Если при этом значение x совпало с предыдущим, то процесс заканчивается. Если нет, то снова используем выражение (7.9), подставляем полученное x в правую часть и находим далее s. Это значение s подставляем в (7.8) и вычисляем очередное x.

Доказано, что на некотором этапе происходит совпадение предыдущего и найденного значения x, и этим самым определяется $S = x_{\text{опт}}$ и s по формуле (7.9).

Возможны и другие модели, если заданы некоторые иные законы распределения вероятностей объемов спроса $P_l(q_l)$. Когда тип распределения определен, остается рассчитать числовые значения параметров этого распределения и использовать их для определения (s, S)-стратегии.

На практике очень эффективной, например, является гипотеза о нормальном законе распределения вероятностей объемов спроса со средним значением $\bar{q}_l = M_l$ и дисперсией $D(q_l) = \sum_{q_l \geq 0} (q_l - M_l)^2 P_l(q_l)$.

7.4. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. Охарактеризуйте сущность задач управления запасами.
2. Опишите управляемые и неуправляемые переменные в задачах управления запасами.
3. Постройте математическую модель статической задачи управления запасами с одним плановым периодом.
4. Что такое (s, S)-стратегия и при каких условиях она является наилучшей формой пополнения запасов?
5. Опишите схему нахождения величин s и S в (s, S)-стратегии.
6. Постройте математическую модель выбора размера заказываемой партии при детерминированном спросе.
7. Как находится экономически выгодный размер заказываемой партии?
8. Опишите задачу выбора размера заказываемой партии, если спрос носит случайный характер.

8. ЭЛЕМЕНТЫ ТЕОРИИ ИГР

8.1. ПРИНЯТИЕ РЕШЕНИЙ ПРИ НЕОПРЕДЕЛЕННОСТИ, ВЫЗВАННОЙ НЕЗНАНИЕМ (ИГРЫ С ПРИРОДОЙ)

В модели принятия решений по управлению сложными системами весьма часто приходится включать параметры, описывающие состояние окружающей среды (например, спрос потребителей, поведение конкурентов, колебание себестоимости продукции и цены в зависимости от стоимости мировых валют, природные факторы и многое другое). Хотя такие параметры существенно влияют на качество принимаемого решения, они являются неконтролируемыми и, в общем, трудными для оценки. В таком случае в исследовании операций задачу по возможности сводят к модели, которая называется игрой с природой. В такой игре с одной стороны выступает активный участник-игрок, воздействующий на контролируемые факторы и принимающий решения, с другой стороны на систему влияет окружающая среда, называемая обобщенно природой, а ее действия – это просто возможные состояния, никоим образом не зависящие от поведения изучаемой системы.

Основная модель игры с природой – матричная модель. Пусть игрок имеет m различных решений $\alpha_1, \alpha_2, ..., \alpha_m$, а природа может оказаться в одном из n возможных состояний $\beta_1, \beta_2, ..., \beta_n$. Тогда для каждой пары (α_i, β_j) должен быть известен некоторый исход. В итоге получим матрицу исходов $[a_{ij}]_{m\times n}$. Очень часто исходы a_{ij} – не числа, а какие-то качественные оценки. В теории принятия решений есть специальное направление – количественное измерение полезности или «построение функций полезности», в котором разрабатываются методы перехода от качественных к количественным оценкам для того, чтобы естественным образом сравнивать, какой из исходов лучше других.

В случае когда величины a_{ij} являются числами, в играх с природой их называют выигрышами, а матрицу исходов – матрицей выигрышей. Используя матрицу выигрышей, игроку необходимо выбрать такое решение (строку матрицы), которое было бы в некотором смысле наилучшим. Для этого можно изобрести бесчисленное множество способов сравнения решений. На практике широко используются «классические» критерии упорядочения решений: Байеса, Лапласа, Вальда, Гурвица, Севиджа.

Критерий Байеса. Предположим, что состояния природы – случайные события, причем вероятности q_j состояний природы заранее известны и $\sum_{j=1}^{n} q_j = 1$. В этих условиях эффективность $B(\alpha_i)$ каждого решения α_i естественно оценивать как математическое ожидание выигрыша (средний выигрыш), т. е.

$$B(\alpha_i) = \sum_{j=1}^{n} q_j\, a_{ij}, \quad i = 1, 2, ..., m.$$

Критерий Байеса утверждает, что наилучшим является решение, при котором достигается $\max\limits_i B(\alpha_i)$.

Критерий Лапласа. Если ничего неизвестно о возможных вероятностях состояний природы, можно предложить, что каждое из состояний равновероятно, т. е. $q_j = \dfrac{1}{n}, \quad j = 1, 2, ..., n.$ Тогда математическое ожидание выигрыша для каждого решения α_i равно

$$L(\alpha_i) = \frac{1}{n}\sum_{j=1}^{n} a_{ij}, \quad i = 1, 2, ..., m.$$

Наилучшим считается решение, соответствующее $\max\limits_i L(\alpha_i)$.

Критерий Вальда. Для каждого решения α_i находится величина

$$W(\alpha_i) = \min_j a_{ij}, \quad i = 1, 2, ..., m.$$

Наилучшим считается решение, при котором достигается $\max\limits_i W(\alpha_i)$. Кстати, эта величина (называемая максимином) является гарантированным выигрышем при любом состоянии природы. Соответствующее управляющее решение называется гарантированным.

Критерий Гурвица. Для каждого решения α_i при заданной величине v, $0 \le v \le 1$, вычисляется значение

$$H(\alpha_i) = v \min_j a_{ij} + (1 - v)\max_j a_{ij}, \quad i = 1, 2, ..., m.$$

Наилучшим считается решение, при котором достигается $\max\limits_i H(\alpha_i)$. Коэффициент v – своеобразный показатель оптимизма игрока. Если $v = 1$, получаем максиминный критерий Вальда (критерий крайнего пессимизма). При $v = 0$ получаем критерий крайнего оптимизма.

Критерий Севиджа. Вычисляются величины r_{ij} риска потерь игрока при выборе им решения α_i и состояния природы β_j

$$r_{ij} = \max_i a_{ij} - a_{ij}.$$

На матрице $[r_{ij}]_{m\times n}$ находятся величины

$$S(\alpha_i) = \max_j r_{ij}, \quad i = 1, 2, ..., m.$$

Наилучшим является решение, при котором достигается $\min\limits_i S(\alpha_i)$.

Пример 8.1. Пусть имеем игру с природой и матрицей выигрышей

$$\begin{array}{c} \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{array} \begin{array}{c} \begin{array}{cccc} \beta_1 & \beta_2 & \beta_3 & \beta_4 \end{array} \\ \begin{bmatrix} 1 & 4 & 5 & 9 \\ 3 & 8 & 4 & 3 \\ 4 & 6 & 6 & 2 \end{bmatrix} \end{array}.$$

• Критерий Байеса при вероятностях состояний природы

$$q_1 = 0{,}1;\ q_2 = 0{,}2;\ q_3 = 0{,}5;\ q_4 = 0{,}2$$

утверждает, что решение α_1 наилучшее.

• Критерий Лапласа тоже утверждает, что решение α_1 наилучшее.

• По критерию Вальда наилучшим получается решение α_2.

• По критерию Гурвица при $\nu = 0{,}8$ (большой показатель пессимизма) наилучшим получается решение α_2.

• Для применения критерия Севиджа вычислим

$$[r_{ij}]_{3\times 4} = \begin{array}{c} \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{array} \begin{array}{c} \begin{array}{cccc} \beta_1 & \beta_2 & \beta_3 & \beta_4 \end{array} \\ \begin{bmatrix} 3 & 4 & 1 & 0 \\ 1 & 0 & 2 & 6 \\ 0 & 2 & 0 & 7 \end{bmatrix} \end{array}.$$

Тогда $S(\alpha_1) = 4;\ S(\alpha_2) = 6;\ S(\alpha_3) = 7.$ Следовательно, решение α_1 наилучшее.

При многократном применении одной и той же модели игры с природой имеет смысл расширить множество принимаемых решений путем включения так называемых рандомизированных (смешанных) решений. Любое рандомизированное решение задается вектором $(p_1, p_2, ..., p_m)$, элементами которого являются вероятности использования соответствующих решений $\alpha_1, \alpha_2, ..., \alpha_m$ при многократном использовании модели. Понятно, что $p_i > 0,\ i = 1, 2, ..., m,$ и $\sum_{i=1}^{m} p_i = 1.$ В расширенном таким образом множестве решений можно находить наилучшее по тому или иному критерию оптимальности. При этом из-за расширения множества, на котором ведется оптимизация, часто удается добиться лучших значений целевых функций. Обычно при этом задачи сводятся к специальным задачам линейного программирования.

Отметим, что нет смысла использовать рандомизированные решения при использовании критериев Байеса и Лапласа, т. е. при известных (или заданных) вероятностях состояний природы. Действительно, если игрок будет принимать какое-либо рандомизированное решение

$$(p_1,\ p_2, ...,\ p_m),\ \sum_{i=1}^{m} p_i = 1,$$

то средний ожидаемый выигрыш будет равен

$$E = p_1 B(\alpha_1) + p_2 B(\alpha_2) + ... + p_m B(\alpha_m).$$

Но поскольку любое среднее не может превосходить максимальной из осредняемых величин, то $E \le \max_i B(\alpha_i)$.

8.2. ОСНОВНЫЕ ПОНЯТИЯ И ОБЩИЕ ПОЛОЖЕНИЯ ТЕОРИИ ИГР

При решении многих практических задач управления системами приходится анализировать случаи, в которых сталкиваются интересы двух и более сторон, преследующих разные цели. При этом результат действий каждой из сторон зависит от образа действий другой. Такие ситуации называются конфликтными. Фактически каждая сторона действует в условиях неопределенности, вызванной разумным противодействием иных сторон.

Математической теорией, которая занимается анализом конфликтных ситуаций, является теория игр. В рамках этой теории вырабатываются рекомендации по рациональному образу действий участников конфликта. Отметим, что практически любую

достаточно сложную проблему принятия решений можно трактовать как теоретико-игровую. Поэтому есть книги по исследованию операций, основное содержание которых – теория игр.

Модель конфликтной ситуации называется игрой. Игра – это идеализированная математическая модель коллективного поведения нескольких сторон (игроков), влияющего на исход игры, причем их интересы (выигрыши) различны. Противопоставление интересов порождает конфликт, совпадение интересов приводит в конечном итоге к необходимой кооперации (коалиции). Игра считается заданной, если четко сформулированы требования, определяющие:

1) возможные варианты действий игроков;

2) объем информации, которую может получать каждая из сторон о действиях другой стороны;

3) результат игры, к которому приводят действия каждой стороны.

Все эти требования фактически представляют собой правила игры. Однократная реализация игры называется партией. Партия состоит из ходов, т. е. действий, предусмотренных правилами. В теории игр рассматриваются только игры, где ходы состоят в сознательном выборе одного из возможных вариантов действия, а не определяются каким-либо механизмом случайного выбора (как в азартных играх).

При выборе ходов (в партии) у игрока может быть выработана система действий, которая называется стратегией. Стратегия – это набор рекомендаций, определяющих, какие из имеющихся в распоряжении игрока ходов он должен сделать в партии при сложившейся ситуации. По числу стратегий игры бывают конечные и бесконечные.

В теории игр хорошо изучены так называемые *бескоалиционные игры*, в которых целью каждого игрока является получение по возможности большего индивидуального выигрыша. Предполагается, что игроки в одной игре действуют изолировано друг от друга, т. е. каждый игрок выбирает свою стратегию независимо от того, какие стратегии выбирают другие участники. Игроки не обмениваются информацией и на их выбор не оказывает влияния предыстория. Каждому игроку известна его собственная функция выигрыша на множестве своих стратегий и стратегий других игроков, хотя он может не знать функций выигрыша остальных игроков.

Пусть $N = \{1, 2, ..., n\}$ − множество игроков в бескоалиционной игре и для каждого i-го ($i \in N$) игрока задано множество S_i возможных его стратегий. Процесс игры состоит в выборе каждым игроком своей стратегии $s_i \in S_i$. В результате каждой партии складывается набор стратегий $s = (s_1, ..., s_n) \in S_1 \times ... \times S_n = S$, называемый ситуацией. Для каждого игрока $i \in N$ на множестве S всевозможных ситуаций должна быть определена вещественная функция $E_i(s)$, как величина выигрыша игрока i в ситуации $s \in S$.

Бескоалиционной игрой Г называется объект

$$\Gamma = < N; \{S_i\}_{i \in N}; \{E_i(s)\}_{i \in N,\ s \in S} > .$$

Если для некоторой игры Г $\sum_{i \in N} E_i(s) = \text{const} = c$, для всех $s \in S$, то она называется игрой с постоянной суммой, при $c = 0$ получаем игру с нулевой суммой.

Ситуация s в игре Г называется приемлемой для игрока i, если, изменяя в данной ситуации свою стратегию на любую другую, он не может увеличить своего выигрыша. Обозначим через $s \,\|\, s_i'$ новую ситуацию, полученную из ситуации s заменой i-й координаты на стратегию s_i'. Тогда s будет приемлемой для игрока i, если

$$E_i(s \,\|\, s_i') \le E_i(s) \quad \text{для любой стратегии } s_i'. \tag{8.1}$$

Ситуация, приемлемая для всех игроков, называется *ситуацией равновесия*. *Решение игры* состоит в том, чтобы найти *ситуацию равновесия*.

Зная только свою функцию выигрыша в бескоалиционной игре Г, каждый игрок $i \in N$ может определить для себя стратегии, более предпочтительные при стремлении к максимизации выигрыша, чем другие. Например, он может различать доминируемые и недоминируемые стратегии. Стратегия $s_i' \in S_i$ доминирует над стратегией $s_i'' \in S_i$, если независимо от стратегий других игроков стратегия s_i'' не дает для i-го игрока большего выигрыша, чем s_i', а для некоторого допустимого набора стратегий остальных игроков ему вообще выгоднее выбрать s_i', нежели s_i''. Исключение недоминируемых стратегий уменьшает размерность задачи.

Во множестве ситуаций по разным правилам также можно вводить отношение частичного порядка. Естественным в этом плане выглядит отношение доминирования, и в частности доминирование по Парето. Говорят, что ситуация $s' \in S$ в игре Г доминирует по Парето над ситуацией $s'' \in S$, если для любого $i \in N$ $E_i(s'') \le E_i(s')$ и существует, по крайней мере, один игрок $i \in N$, для которого $E_i(s'') < E_i(s')$. Любую ситуацию s^* назовем оптимальной по Парето, если она не доминируема по Парето. Оптимальные по Парето ситуации являются неулучшаемыми сразу для всех игроков.

Замечание 8.1. Очевидно, что определение ситуации, оптимальной по Парето, равносильно оптимальному по Парето решению в задачах многокритериальной оптимизации. Каждый критерий в таких задачах можно интерпретировать как цель отдельной подсистемы, т. е. отдельного игрока, в централизованной системе. Выбор оптимальной по Парето ситуации предполагает взаимодействие игроков, в частности обмен информацией между ними о принимаемых решениях. В конечном итоге «центр» принимает окончательное решение, выгодное для системы в целом.

В игре Г каждый игрок $i \in N$ может пользоваться своей осторожной стратегией, ориентируясь на самые неблагоприятные для себя стратегии остальных игроков.

Значение

$$\alpha_i = \sup_{s_i \in S_i} \inf_{\bar{s} \in S \setminus S_i} E_i(s_i, \bar{s})$$

в случае бесконечных игр или $\alpha_i = \max\limits_{s_i \in S_i} \min\limits_{\bar{s} \in S \setminus S_i} E_i(s_i, \bar{s})$ в случае конечных игр называется гарантированным выигрышем, потому что, используя осторожную стратегию, игрок i гарантирует себе выигрыш α_i при однократной реализации игры.

Обобщением статического способа принятия решения на основе доминирующих стратегий или осторожного поведения является допущение возможности общения игроков, например, при анализе результатов предыдущих партий игры или при совместном обсуждении необязательного соглашения о выборе ситуации в дальнейшей игре. Однако при принятии решения каждый игрок имеет возможность отступить от такого соглашения. Устойчивость соглашения, т. е. необходимость его выполнения каждым игроком, обеспечивает так называемое равновесие по Нэшу.

Ситуация $s^R = (s_1, s_2, \ldots, s_n)$ в игре Г называется равновесной по Нэшу, если для каждого игрока $i \in N$ и любой его стратегии, не принадлежащей s^R, выигрыш E_i может только уменьшиться при любом поведении остальных игроков.

Ситуации, равновесные по Нэшу, обладают хорошими математическими свойствами. Широко известна теорема Нэша о достаточных условиях существования таких ситуаций в конечных бескоалиционных играх. Эти условия оказались легко проверяемыми во многих прикладных моделях.

Один из важных вариантов игровых моделей – так называемые кооперативные (коалиционные) игры, в которых имеется явный обмен информацией с целью выработки такого соглашения, чтобы отклонение от него было невыгодно отклоняющимся игрокам или их коалициям. Формально при обмене информацией необходимость в коалиции появляется, когда для каждой оптимальной по Парето ситуации находится более выгодное с точки зрения какого-либо игрока отклонение. Если же выбор своих стратегий игроками производится без взаимодействий и игроки руководствуются только «личными» интересами, то они могут рассчитывать лишь на выбор ими ситуации, оптимальной по Нэшу.

8.3. АНТАГОНИСТИЧЕСКИЕ ИГРЫ

8.3.1. Предварительный анализ

Частным случаем бескоалиционной игры Г с нулевой суммой является так называемая антагонистическая игра, когда число игроков $|N| = 2$ и $E_2(s) = -E_1(s)$. Такую игру Г удобно задавать в виде $\Gamma = \langle A, B, E \rangle$, где A – множество стратегий первого игрока; B – множество стратегий второго игрока; E – функция выигрыша первого игрока (или проигрыша второго).

Если множества A и B – конечны, то в этом случае функцию E можно определить в виде так называемой матрицы выигрышей. Каждый элемент a_{ij} этой матрицы будет определять величину выигрыша первого игрока (или проигрыша второго) в случае, когда первый игрок использует стратегию $A_i \in A$ ($i = 1, 2, ..., m$), а второй – $B_j \in B$ ($j = 1, 2, ..., n$). Поэтому антагонистические игры часто просто называют матричными (точнее надо бы – одноматричными, потому что анализируются также биматричные игры и т. д.) или играми в нормальной форме.

Игрок A должен найти такую свою стратегию, при которой его выигрыш максимален. Игрок B, напротив, стремится минимизировать свой проигрыш. Считается, что каждый из игроков поступает наилучшим для себя способом. Вообще, оптимальной стратегией игрока A называется такая его стратегия, которая при многократном повторении игры обеспечивает ему максимально возможный средний выигрыш. Для игрока B оптимальной будет такая его стратегия, которая обеспечивает ему минимально возможный средний проигрыш.

Пример 8.2. *Игра «поиск»*. Пусть имеется два игрока A и B. Игрок A может прятаться в одном из двух мест (стратегии A_1 и A_2), а игрок B может вести поиск в одном из этих мест (стратегии B_1, B_2). Игрок A получает выигрыш в одну единицу, если игрок B не находит A, или проигрывает одну единицу в противном случае. Таким образом, матрица выигрышей для игрока A имеет вид

$$\begin{array}{c} \\ A_1 \\ A_2 \end{array} \begin{array}{c} \begin{array}{cc} B_1 & B_2 \end{array} \\ \begin{bmatrix} -1 & 1 \\ 1 & -1 \end{bmatrix} \end{array}.$$

Для игрока B – это матрица проигрышей. В одной партии не имеет смысла говорить о преимуществах тех или других стратегий для каждого из игроков. Очевидно, что при многократном повторении игры любой из сторон невыгодно повторять одну и ту же стратегию или чередовать стратегии в какой-то закономерности. Вторая сторона догадается об этом и всегда будет выигрывать. Напрашивается вывод: каждой стороне необходимо случайным образом выбирать свои стратегии.

Пример 8.3. *Игра «Вооружение и самолеты».* Сторона A имеет 3 вида вооружений: A_1, A_2, A_3. Сторона B имеет 3 типа самолетов: B_1, B_2, B_3. Заданы вероятности поражения каждым видом вооружения каждого типа самолета. Цель стороны A – выбрать вооружение с наибольшей вероятностью поражения. Цель стороны B – выбрать самолет, обеспечивающий наименьшую вероятность поражения. Пусть матрица выигрышей имеет вид

$$\begin{array}{c} \\ A_1 \\ A_2 \\ A_3 \end{array} \begin{array}{c} \begin{array}{ccc} B_1 & B_2 & B_3 \end{array} \\ \begin{bmatrix} 0,5 & 0,6 & 0,8 \\ 0,9 & 0,7 & 0,8 \\ 0,7 & 0,5 & 0,6 \end{bmatrix} \end{array}.$$

Перебирая стратегии стороны A, можно заметить, что в каждом случае ей выгодно повторять стратегию A_2, так как в этом случае при любой стратегии стороны B получается наибольшая вероятность поражения целей. Аналогично наиболее выгодной стратегией стороны B, которая пытается уменьшить вероятность своего поражения, оказывается стратегия B_2.

В данной игре обеим сторонам выгодно повторять одни и те же стратегии, т. е. пару (A_2, B_2). Отклонения от них ухудшает выигрыш для A или увеличивает проигрыш для B.

8.3.2. Игры с седловой точкой

Пусть $(a_{ij})_{m\times n}$ – матрица выигрышей в конечной антагонистической игре. Последовательно перебирая стратегии A_1, A_2, ..., A_m, найдем среди них наилучшую для стороны A. Игрок A должен при этом учитывать, что игрок B будет отвечать лучшей для себя стратегией. Поэтому при выборе конкретной стратегии A_i игрок A может заведомо рассчитывать на свой выигрыш $\alpha_i = \min\limits_j a_{ij}$.

Действуя осторожно, игрок A может выбрать ту из стратегий A_i, где достигается выигрыш

$$\alpha = \max_i \min_j a_{ij}.$$

Значение α – это нижняя цена игры. Стратегия, соответствующая α, называется максиминной. Если придерживаться этой стратегии, то игроку A гарантируется выигрыш, равный α. Игрок B заинтересован, чтобы обратить в минимум выигрыш игрока A. Следовательно, перебирая свои стратегии B_1, ..., B_n, он, учитывая разумное поведение игрока A, должен для каждой из стратегий выделять максимальное значение выигрыша игрока A и минимизировать этот выигрыш. Таким образом, сторона B может гарантировать себе проигрыш не более чем

$$\beta = \min_j \max_i a_{ij}.$$

Значение β – верхняя цена игры. Придерживаясь этой осторожной для себя (минимаксной) стратегии, игрок B гарантирует себе проигрыш не больший чем β.

Для примеров 8.1, 8.2 получаются различные соотношения между значениями α и β. Для примера 8.1: $\alpha = -1$, $\beta = 1$ – каждая стратегия игрока A максиминная, каждая стратегия B минимаксная. Для примера 8.2: $\alpha = \beta = 0,7$, т. е. A_2 будет максиминной

стратегией для игрока A, а B_2 – минимаксной стратегией для B. Кстати, этот пример показывает, что существуют матричные игры, у которых верхняя цена игры совпадает с нижней. Такие игры называются *играми с седловой точкой*. Проверить существование седловой точки несложно. Из общих определений понятно, что соответствующая пара максиминной и минимаксной стратегий задает ситуацию равновесия, т. е. является решением игры. При этом если один из игроков придерживается своей оптимальной стратегии, то для другого не может быть выгодным отклонение от его оптимальной стратегии.

Пример 8.1 показывает, что не все антагонистические игры являются играми с седловой точкой. Следовательно, для решения матричных игр необходим более общий подход.

8.3.3. Игры со смешанными стратегиями

Игры с седловой точкой встречаются довольно редко, и более типичны случаи, когда нижняя и верхняя цена игры различны. Как известно, игрок A, постоянно придерживаясь одной и той же максиминной стратегии, гарантирует себе выигрыш, равный α. Игрок B, придерживаясь своей минимаксной стратегии, гарантирует себе проигрыш, не больший β. Понятно, что в случае $\beta > \alpha$ встает вопрос: может ли игрок A получить выигрыш, больший α, если при многократном повторении игры использовать несколько случайным образом чередующихся стратегий? Аналогично для игрока B ставится задача уменьшить величину β за счет случайного выбора своих стратегий.

Случайный вектор, координатами которого являются вероятности применения чистых стратегий того или иного игрока при многократном повторении игры, называется его *смешанной* (рандомизированной) *стратегией.*

Таким образом, если задана антагонистическая игра Г и игрок A располагает m чистыми стратегиями, то, для того чтобы определить смешанную стратегию, необходимо задать вектор $(p_1, ..., p_m) = S_A$, где $\sum_{i=1}^{m} p_i = 1$ и величина $p_i \geq 0$ представляет собой вероятность применения i-й чистой стратегии игрока A при многократном повторении игры.

Аналогично, если игрок B располагает n чистыми стратегиями, то чтобы задать его смешанную стратегию, необходимо указать вектор $(q_1, ..., q_n) = S_B$, где $\sum_{j=1}^{n} q_j = 1$ и $q_i \geq 0$ – вероятность применения его j-й чистой стратегии при многократном повторении игры. Очевидно, что если в векторе S_A или S_B одна координата – 1, а все остальные – 0, то такая смешанная стратегия представляет собой чистую стратегию.

Ситуацией равновесия (*по Нэшу*) или *решением игры* называется пара (S_A^*, S_B^*) смешанных стратегий, обладающих тем свойством, что если один из игроков придерживается своей оптимальной стратегии, то другому невыгодно отступать от своей оптимальной стратегии. Выигрыш, соответствующий ситуации равновесия, называется ценой игры и обозначается γ.

Обозначим через $E(S_A, S_B)$ выигрыш игрока A (или проигрыш игрока B) при многократном повторении игры с использованием произвольных смешанных стратегий S_A и S_B.

Если оказывается, что для некоторых стратегий S_A^* игрока A и S_B^* игрока B выполняются неравенства $E(S_A, S_B^*) \leq E(S_A^*, S_B^*) \leq E(S_A^*, S_B)$ при любых (S_A, S_B), то пара

(S_A^*, S_B^*) называется решением игры, соответствующие стратегии S_A^* и S_B^* – оптимальными стратегиями, а величина $E(S_A^*, S_B^*) = \gamma$ – ценой игры. Встает вопрос о существовании таких оптимальных стратегий для каждого игрока.

Конкретизируем вид функции $E(S_A, S_B)$, учитывая, что игра Г задается матрицей выигрышей $(a_{ij})_{m\times n}$. Если игроки придерживаются любых своих смешанных стратегий S_A и S_B, то ожидаемый накапливаемый выигрыш при многократном повторении игры можно вычислять как математическое ожидание выигрыша для игрока A. Это будет величина

$$E(S_A, S_B) = \sum_{i=1}^{m}\sum_{j=1}^{n} a_{ij} p_i q_j. \tag{8.2}$$

Замечание 8.2. Функция (8.2) линейна относительно переменных p_i при фиксированных q_j или относительно переменных q_j при фиксированных p_i. Этот факт существенен для построения метода решения матричных игр.

Теорема 8.1 (основная теорема матричных игр). Каждая конечная матричная игра имеет, по крайней мере, одно решение, возможно, в области смешанных стратегий.

У этой теоремы есть и другая формулировка: если множество допустимых стратегий для игрока A обозначить $\boldsymbol{A}$, а множество стратегий для B через $\boldsymbol{B}$, то величины $\max\limits_{S_A\in \boldsymbol{A}} \min\limits_{S_B\in \boldsymbol{B}} E(S_A, S_B)$ и $\min\limits_{S_B\in \boldsymbol{B}} \max\limits_{S_A\in \boldsymbol{A}} E(S_A, S_B)$ существуют, причем

$$\max_{S_A\in \boldsymbol{A}} \min_{S_B\in \boldsymbol{B}} E(S_A, S_B) = \min_{S_B\in \boldsymbol{B}} \max_{S_A\in \boldsymbol{A}} E(S_A, S_B). \tag{8.3}$$

Из равенства (8.3) как раз и следует, что существует пара стратегий (S_A^*, S_B^*) такая, что

$$E(S_A^*, S_B) \ge \gamma;\ E(S_A, S_B^*) \le \gamma;\ E(S_A^*, S_B^*) = \gamma \ \text{ для любых } S_A,\ S_B.$$

Доказательство. Имеется несколько способов доказательства теоремы. Используя формулу (8.2), приведем доказательство, которое одновременно дает способ решения конечных антагонистических игр. Оно состоит из двух частей. Во-первых, задачи нахождения оптимальной смешанной стратегии для обоих игроков сводятся к задачам линейного программирования (ЛП). Во-вторых, показывается, что эти задачи имеют решение. Это свидетельствует о существовании решения любой матричной игры.

Сведем антагонистическую игру к двум задачам ЛП. Пусть требуется найти решение игры, т. е. две оптимальные стратегии $S_A^* = (p_1^*, ..., p_m^*)$, $S_B^* = (q_1^*, ..., q_n^*)$. Здесь все p_i^* и q_j^* – неизвестные величины. Найдем оптимальную стратегию S_A^*. Из определения оптимальной стратегии следует, что игрок A при применении этой стратегии и при любой стратегии игрока B будет получать выигрыш, не меньший некоторого неизвестного нам значения γ_A. Не уменьшая общности, считаем, что $\gamma_A > 0$. Это условие достигается в том случае, если все элементы a_{ij} исходной матрицы выигрышей положительны. Легко показать, что для произвольной матричной игры этого можно достичь путем добавления ко всем элементам матрицы выигрыша некоторого достаточно большого числа M. Оказывается, что в этом случае получается эквивалентная антагонистическая игра, в которой оптимальные решения останутся теми же, что и в исходной задаче. Увеличится только на величину M значение выигрыша игрока A и проигрыша игрока B.

Пусть $\gamma_A > 0$ и все $a_{ij} > 0$. Допустим, что игрок A применяет свою оптимальную стратегию S_A^*, а игрок B – некоторую чистую стратегию B_j, т. е. в его смешанной стратегии $S_B = (q_1, ..., q_n)$ координата $q_j = 1$, а остальные

$$q_1 = ... = q_{j-1} = q_{j+1} = ... = q_n = 0.$$

Используя формулу (8.2) и то, что фактически выигрыш игрока A при этом будет большим или равным γ_A, получим неравенство $\sum_{i=1}^{m} a_{ij} p_i^* \geq \gamma_A$. Преобразуем полученное неравенство, вводя замену $x_i = \frac{p_i^*}{\gamma_A}$, $i = 1, 2, ..., m$. Тогда получим, что

$$\sum_{i=1}^{m} a_{ij} x_i \geq 1, \ j = 1, 2, ..., n. \tag{8.4}$$

Учтем теперь, что $\sum_{i=1}^{m} p_i = 1$. Отсюда получим, что $\sum_{i=1}^{m} x_i = \frac{1}{\gamma_A}$.

Поскольку игрок A стремится сделать выигрыш γ_A максимальным, последнее означает, что ему необходимо найти такие значения $x_i \geq 0$, которые удовлетворяют ограничениям (8.4) и при которых

$$\sum_{i=1}^{m} x_i \to \min. \tag{8.5}$$

Таким образом, для нахождения оптимальной стратегии игрока A в виде значений $x_i \geq 0$ получается задача ЛП (8.4)–(8.5).

Аналогично можно провести рассуждения для игрока B. В этом случае предполагается, что игрок B ищет свою оптимальную стратегию $S_B^* = (q_1^*, ..., q_n^*)$, при которой он должен обеспечить себе минимальный проигрыш γ_B. Пусть игрок B применяет стратегию S_B^*, а игрок A – некую i-ю чистую стратегию, т. е. в его смешанной стратегии

$$p_i = 1, \ p_1 = ... = p_{i-1} = p_{i+1} = ... = p_m = 0.$$

Используем (8.2) и то, что игрок B стремится уменьшить проигрыш, получим неравенство $\sum_{j=1}^{n} a_{ij} q_j^* \leq \gamma_B$. Производя замену $y_j = \frac{q_j^*}{\gamma_B}$, получим систему неравенств

$$\sum_{j=1}^{n} a_{ij} y_j \leq 1, \ i = 1, 2, ..., m. \tag{8.6}$$

Учитывая, что $\sum_{j=1}^{n} y_j = \frac{1}{\gamma_B}$ и γ_B необходимо минимизировать, получим: для игрока B необходимо найти такие величины $y_j \geq 0$, которые удовлетворяют неравенствам (8.6) и при которых

$$\sum_{j=1}^{n} y_j \to \max. \tag{8.7}$$

Таким образом, для нахождения оптимальной стратегии игрока B в виде значений $y_j \geq 0$ получаем задачу ЛП (8.6)–(8.7).

Наличие решения для изучаемой игры будет доказано, если показать, что есть решение каждой из полученных задач ЛП.

Как известно, решение задачи ЛП не существует, если:

1) или условия задачи (ограничения) противоречивы;

2) или решения существуют, но среди них нет оптимальных, так как минимизирующая функция не ограничена снизу (максимизирующая функция не ограничена сверху).

Покажем, что эти условия для каждой из задач ЛП не выполняются. Рассмотрим, например, задачу (8.4), (8.5). Система (8.4) совместна, так как существует, по крайней мере, одно решение, которое может быть построено следующим образом.

Найдем величину $\mu = \min\limits_i \min\limits_j a_{ij}$ в матрице выигрышей. Положим $x_1 = \dfrac{1}{\mu}$, $x_2 = ... = x_m = 0$. Очевидно, что эти значения удовлетворяют ограничениям (8.4). Второе условие для задачи (8.4), (8.5) также выполняется, поскольку целевая функция (8.5) ограничена снизу, например, нулем (так как все x_i неотрицательны и элементы a_{ij} матрицы выигрышей положительны по предположению). Таким образом, задача (8.4), (8.5) имеет решение. Задача (8.6), (8.7) является двойственной по отношению к задаче (8.4), (8.5). Из теории двойственности известно, что если существует решение одной из задач ЛП, то существует решение двойственной задачи, и при этом

$$\min\left(\sum_{i=1}^{m} x_i\right) = \max\left(\sum_{j=1}^{n} y_j\right).$$

Следовательно, $\gamma_A = \gamma_B = \gamma$ и γ – цена игры. Теорема доказана.

Из доказательства теоремы вытекает один из способов решения антагонистической игры. Для этого, используя заданную матрицу выигрышей $(a_{ij})_{m\times n}$, необходимо выписать условия (8.4), (8.5) задачи ЛП для игрока A. После решения этой задачи, найдя $x_i^{\text{опт}}$, $i = 1, 2, ..., m$, нужно перейти к искомым вероятностям p_i^* по формуле $p_i^* = \gamma_A x_i^{\text{опт}}$, где $\gamma_A = \dfrac{1}{\sum\limits_{i=1}^{m} x_i^{\text{опт}}} = \gamma$ – цена игры. Тем самым определяется оптимальная стратегия S_A^*.

Аналогично для игрока B составляем задачу (8.6), (8.7), и после ее решения, т. е. найдя $y_j^{\text{опт}}$, находятся $q_j^* = \gamma_B y_j^{\text{опт}}$ и тем самым определяется S_B^*.

Пример 8.4. Пусть исследуется игра «Вооружение – помехи», заданная следующей матрицей:

$$\begin{array}{c} \\ A_1 \\ A_2 \\ A_3 \end{array} \begin{array}{c} \begin{array}{ccc} B_1 & B_2 & B_3 \end{array} \\ \begin{bmatrix} 0,8 & 0,2 & 0,4 \\ 0,4 & 0,5 & 0,6 \\ 0,1 & 0,7 & 0,3 \end{bmatrix} \end{array}.$$

В матрице выигрышей заданы вероятности поражения какого-то объекта при использовании вооружений A_i и помех B_j. В этой задаче нижняя цена игры $\alpha = 0,4$, верхняя цена $\beta = 0,6$.

Решим для игрока A следующую задачу ЛП:

$$x_1 + x_2 + x_3 \to \min$$
$$\begin{cases} 0,8x_1 + 0,4x_2 + 0,1x_3 \geq 1, \\ 0,2x_1 + 0,5x_2 + 0,7x_3 \geq 1, \\ 0,4x_1 + 0,6x_2 + 0,3x_3 \geq 1, \end{cases}$$
$$x_1 \geq 0,\ x_2 \geq 0,\ x_3 \geq 0.$$

Получим решение $x_1 = \frac{5}{16};\ x_2 = \frac{15}{8};\ x_1 = 0.$ При этом $\sum_{i=1}^{3} x_i = \frac{35}{16}$, т. е. $\gamma_A = \frac{16}{35}$. Тогда $p_1^* = \frac{1}{7};\ p_2^* = \frac{6}{7};\ p_3^* = 0$ – это вероятности применения чистых стратегий в оптимальной смешанной S_A^* – стратегии для игрока A. Подобным образом для игрока B найдем $q_1^* = \frac{3}{7};\ q_2^* = \frac{4}{7};\ q_3^* = 0$ как координаты оптимальной смешанной стратегии S_B^*. Отметим, что цена игры $\gamma_A = \frac{16}{35} \approx 0,46,$ т. е. достаточно близка к нижней цене игры.

Пример 8.4, в частности, показывает, что в оптимальных смешанных стратегиях вероятности некоторых чистых стратегий могут быть нулевыми.

Активные стратегии – это стратегии с ненулевыми значениями вероятности в оптимальной смешанной стратегии. Если задача решена, например, симплекс-методом, то при $m \neq n$ часть стратегий обязательно будут неактивными. Очень важно заранее найти (до решения задачи) активные стратегии. Это уменьшит размерность задачи.

Теорема 8.2 (об активных стратегиях). Если один из игроков придерживается своей оптимальной смешанной стратегии, то выигрыш остается неизменным и равным цене игры γ, независимо от того, что делает другой игрок, если только тот не выходит за пределы своих активных стратегий.

Пусть (S_A^*, S_B^*) – оптимально смешанные стратегии с ценой игры γ. Перенумеруем чистые стратегии так, чтобы активными были первые k стратегий игрока A и первые l стратегии игрока B, т. е. пусть

$$S_A^* = (p_1, ..., p_k, 0, ..., 0), \qquad p_1 + ... + p_k = 1,$$
$$S_B^* = (q_1, ..., q_l, 0, ..., 0), \qquad q_1 + ... + q_l = 1.$$

Пусть игрок A пользуется стратегией S_A^*, а игрок B – чистыми стратегиями $B_1, ..., B_l$ с соответствующими выигрышами $\gamma_1, ..., \gamma_l$. Понятно, что

$$\gamma_1 \geq \gamma, ..., \gamma_l \geq \gamma. \tag{8.8}$$

Оказывается, на самом деле ни одно из значений $\gamma_1, ..., \gamma_l$ не может быть больше γ.

Поскольку в смешанной стратегии S_B^* чистые стратегии $B_1, ..., B_l$ используются с вероятностями $q_1, ..., q_l$, то средний выигрыш равен

$$\gamma = \gamma_1 q_1 + ... + \gamma_l q_l \text{ при } q_1 + ... + q_l = 1.$$

Если в (8.8) имеется хотя бы одно строгое неравенство, например $\gamma_1 = \gamma + \varepsilon$, то получим

$$(\gamma + \varepsilon)q_1 + \gamma q_2 + ... + \gamma q_1 = \gamma \sum_{j=1}^{l} q_j + \varepsilon q_1 > \gamma.$$

Средний выигрыш будет больше γ.

Теорема доказана.

8.3.4. Графическое решение антагонистических игр $2\times n$, $m\times 2$

Когда в любой из игр $2\times n$ с матрицей выигрышей $(a_{ij})_{2\times n}$ нет седловой точки, то, как уже отмечалось, смешанная стратегия игрока A представляет собой совокупность чисел p_1 и p_2, в сумме дающих единицу. Геометрически ее можно представить точкой P на единичном отрезке (рис. 8.1).

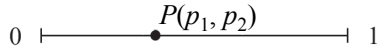

Рис. 8.1

Левая точка (точка 0) этого отрезка соответствует чистой стратегии A_2, потому что в этом случае $p_1 = 0$, $p_2 = 1$, а правая точка – стратегии A_1, потому что $p_1 = 1$, $p_2 = 0$. Восстановим на концах такого отрезка перпендикуляры-оси и зададим на них одинаковый масштаб.

Предположим, что игрок A использует свои чистые стратегии A_1 и A_2, а игрок B – свою чистую стратегию B_1, тогда на правой оси можно отметить выигрыш игрока A – значение a_{11}, а на левой – значение a_{21}. Соединим эти точки прямой (рис. 8.3) (на основании предположения (8.2) и отмеченных в замечании 8.2 свойств линейности функции выигрыша). Очевидно, что любая промежуточная точка этой прямой определит величину выигрыша игрока A в смешанной стратегии (p_1, p_2). Аналогичные прямые можно построить для остальных стратегий $B_2, B_3, ..., B_n$ и найти нижнюю границу множества n прямых над отрезком (0,1). Точка отрезка, при которой эта нижняя граница достигает максимума, определяет искомую оптимальную смешанную стратегию игрока A. Высота точки максимума равна цене игры.

Замечание 8.3. Может случиться, что максимум нижней границы достигается не в одной точке, а на бесконечном множестве, тогда любая точка этого множества является решением игры для игрока A.

Замечание 8.4. Максимум нижней границы не может оказаться на одной из осей, потому что по предположению анализируется игра без седловой точки.

Точка максимума нижней границы является пересечением двух (или более) прямых, соответствующих чистым стратегиям игрока B. На основании теоремы об активных стратегиях неактивные стратегии для игрока B можно исключить и он может искать свою оптимальную смешанную стратегию, решая для себя игру 2×2. При этом концы единичного отрезка (рис. 8.2) будут соответствовать чистым активным стратегиям, например, B_2 и B_1, а стратегия Q будет смешанной стратегией (q_1, q_2).

Опять на концах отрезка восстанавливаются перпендикуляры-оси с заданными, как для игрока A, масштабами и строятся две прямые, соответствующие чистым стратегиям

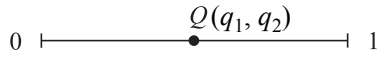

Рис. 8.2

A_1, A_2 игрока A. Теперь необходимо искать верхнюю границу этих двух прямых над отрезком (0,1). Точка отрезка, при которой эта верхняя граница достигает минимума, определяет искомую оптимальную смешанную стратегию игрока B. Высота точки минимума будет равна цене игры, которая, впрочем, уже определена игроком A.

Подобным образом решаются антагонистические игры $m\times2$. Естественно, что сначала игра рассматривается с точки зрения игрока B с построением верхней границы множества m прямых, нахождением ее минимума и соответствующего решения игры для игрока B, а также определением активных стратегий для игрока A. Далее для игрока A решается игра 2×2 путем построения нижней границы множества двух прямых и нахождения точки максимума этой нижней границы.

Пример 8.5. Пусть анализируется антагонистическая игра 2×3 с матрицей выигрыша

$$\begin{array}{c} \\ A_1 \\ A_2 \end{array}\begin{array}{c} \begin{array}{ccc} B_1 & B_2 & B_3 \end{array} \\ \begin{bmatrix} 10 & 8 & 9 \\ 5 & 11 & 6 \end{bmatrix} \end{array}.$$

Эта игра не имеет седловой точки, так как нижняя граница игры $\alpha = \max\limits_i \min\limits_j a_{ij} = 8$. Верхняя граница игры $\beta = \min\limits_j \max\limits_i a_{ij} = 9$.

Для игрока A имеем график, приведенный на рис. 8.3.

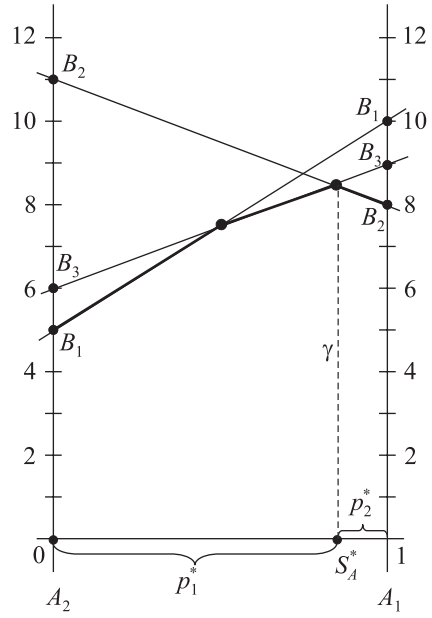

Рис. 8.3

Точка S_A^*, как следует из рис. 8.3, является точкой максимума нижней границы игры (ломаная, отмеченная жирно). Ее координаты можно найти как координаты точки пересечения двух условных прямых линий, проходящих через точки (0, a_{22}), (1, a_{12}) и (0, a_{23}), (1, a_{13}). Этим самым получим $p_1^* = \frac{5}{6}$, $\gamma = 8{,}5$. Таким образом, $S_A^* = (p_1^*, p_2^*) = \left(\frac{5}{6}, \frac{1}{6}\right)$.

Одновременно определяем, что активными стратегиями игрока *B* являются стратегии B_2 и B_3. С точки зрения игрока *B* графические построения имеют вид, представленный на рис. 8.4.

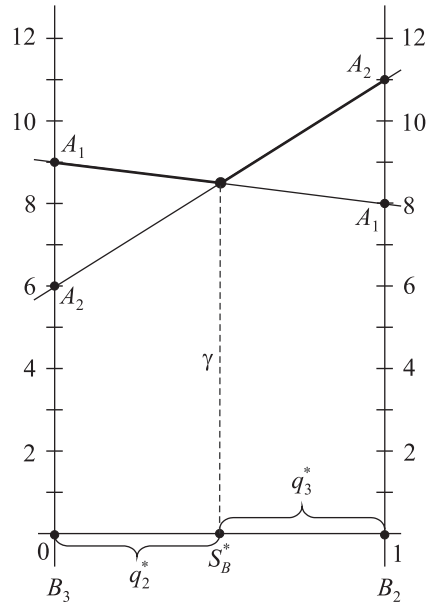

Рис. 8.4

Точка S_B^* (см. рис. 8.4) является точкой минимума верхней границы игры (ломаная, отмеченная жирно). Ее координаты $\left(\frac{1}{2}, \frac{1}{2}\right)$. Это означает, что в оптимальной стратегии $q_2^* = \frac{1}{2}$, $q_3^* = \frac{1}{2}$, $\gamma = 8{,}5$. Следовательно, $S_B^* = \left(0, \frac{1}{2}, \frac{1}{2}\right)$.

8.4. ПОЗИЦИОННЫЕ ИГРЫ

В матричных играх фактически анализируются одноходовые партии, в которых игроки одновременно выбирают свои стратегии, оценивают выигрыши и на этом партия заканчивается. Для реальных многоходовых игр, когда игроки делают ходы поочередно, более естественна развернутая или позиционная форма представления игры. При этом можно учесть, что в игре участвует более двух (конечное число) игроков, что некоторые ходы могут быть случайными, а информация о состоянии партии (позиции) в каждый момент для каждого игрока может быть различна.

Определение 8.1. Позиционной будем называть конечную игру n сторон, задаваемую следующими шестью объектами:

1) корневым ориентированным деревом T, вершины которого расположены по уровням, причем на самом нижнем уровне расположена одна вершина – корень. Дуги ориентированы в направлении от вершины меньшего уровня к вершинам большего уровня;

2) n-мерным вектором $F_1, ..., F_n$, определяемым для каждой из висячих вершин дерева T;

3) пометками из множества $\{0, 1, ..., n\}$ у всех ветвящихся вершин дерева T;

4) пометками из множества $v_j = \{1, 2, ..., m_j\}$ для каждой дуги, выходящей из вершины j;

5) сопоставлением каждой i-й дуги с вершиной дерева T с пометкой 0 i-й координаты неотрицательного вектора $(p_1, p_2, ..., p_k)$, где $\sum_{i=1}^{k} p_i = 1$;

6) разбиением ветвящихся вершин на непересекающиеся (так называемые информационные) множества со следующими свойствами:

а) все вершины, принадлежащие одному множеству, имеют одну и ту же пометку и одинаковое количество выходящих дуг;

б) каждое множество содержит не более одной вершины, принадлежащей любому пути от корня до висячей вершины;

в) множество, в котором имеется вершина с пометкой 0, состоит из одного элемента.

Таким образом, игра в позиционной форме описывается деревом T, вершины которого соответствуют состояниям игры (позициям), а дуги, выходящие из вершин, отображают варианты выбора решений в этих позициях. Каждый путь от корня до висячей вершины дерева соответствует одной партии в игре, выигрыш каждого i-го игрока в партии равен значению элемента F_i в векторе $(F_1, F_2, ..., F_n)$. Понятно, что в игре двух игроков с нулевой суммой вместо вектора $(F_1, F_2, ..., F_n)$ указывается выигрыш первого игрока, который равен проигрышу второго.

Пометка у каждой ветвящейся вершины указывает номер игрока, делающего ход. Номер 0 соответствует ходу, осуществляемому некоторым случайным механизмом. Пометки v_j для каждой дуги, выходящей из вершины j, обозначают варианты выбора решения игроком j. Дугам, исходящим из вершины с пометкой 0, кроме того, приписываются соответствующие вероятности из вектора $(p_1, p_2, ..., p_k)$. Наконец, для каждого из игроков определяется совокупность информационных множеств. Каждое информационное множество содержит необходимые сведения о сделанных выборах при определенных ходах игроков. Игрок, находящийся в любой из вершин одного информационного множества, обладает одной и той же информацией о состоянии игры, т. е. вершины одного информационного множества неразличимы для соответствующего игрока.

Имеются игры (например, шашки, шахматы и т. п.), в которых каждый из игроков достоверно знает, в каком состоянии (позиции) находится игра в каждый момент времени. Это игры с полной информацией. В таких играх каждое информационное множество содержит в точности одну вершину.

Существуют также игры (например, карточные), в которых игрок не знает точно, в какой позиции находится игра. Именно подобная неполнота информации изображается на дереве игры с помощью информационных множеств. Обычно их границы обозначают на дереве пунктиром.

Стратегией игрока j в позиционной игре называется правило, ставящее в соответствие каждому информационному множеству этого игрока определенный выбор хода в этом информационном множестве. Таким образом, стратегия однозначно определяет линию поведения игрока и указывает ему, что нужно делать при любой возможной информации.

Любую конечную позиционную игру n игроков можно свести к бескоалиционной матричной игре с n матрицами выигрышей, соответствующих игрокам. Процесс сведения позиционной игры к матричной называется *нормализацией.*

Для позиционной игры двух игроков с нулевой суммой выигрышей после нормализации получается антагонистическая матричная игра, которую можно решить известными методами.

Пример 8.6. Игра состоит из трех ходов, которые делают два игрока (на рис. 8.5 и 8.6 они обозначены в кружочках).

Первый ход делает первый игрок: он выбирает число x из множества $\{1, 2\}$.

Второй ход делает второй игрок: зная, какое число x выбрано первым игроком на первом ходе, выбирает y из $\{1, 2\}$.

Третий ход делает первый игрок: зная, что он сделал на первом ходе и что сделал второй игрок, выбирает z из $\{1, 2\}$.

Игра заканчивается, и происходит распределение выигрышей по значениям $M(x, y, z)$, указанных на висячих вершинах дерева игры (рис. 8.5).

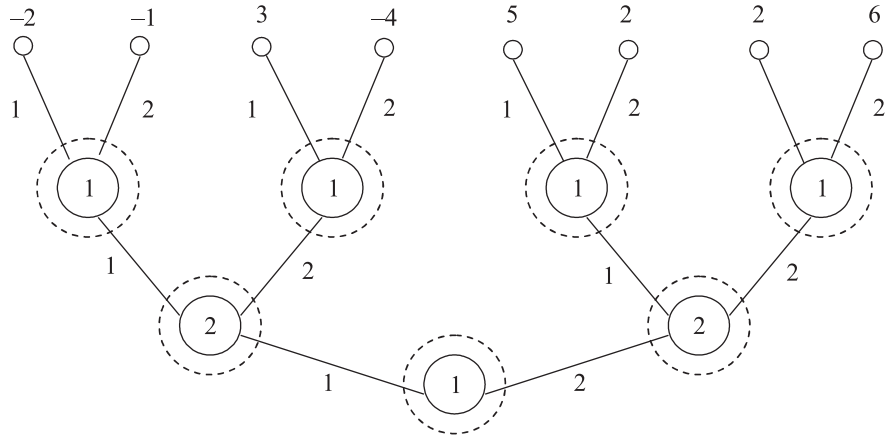

Рис. 8.5

Проведем нормализацию представленной игры.

Рассмотрим сначала все мыслимые стратегии игрока 2. У него две возможности выбора из $\{1, 2\}$, кроме того, выбирая свой ход, он может учитывать или не учитывать информации о том, какое x выбрано игроком 1 на предыдущем ходе, т. е. у него 4 стратегии:

1) выбирать $y = 1$, невзирая на значение x;

2) выбирать $y = 2$, невзирая на значение x;

3) выбирать $y = x$;

4) выбирать $y \neq x$.

Стратегия для игрока 1 должна учитывать результаты сделанных ранее ходов. При каждом выборе на первом ходе может быть два варианта, на втором ходе имеем уже че-

тыре варианта, и при каждом из этих вариантов может быть сделано два выбора, т. е. всего восемь возможных стратегий. Обозначим стратегию игрока 1 через (i, i_1, i_2), где

i – выбор первым игроком на первом ходе;

i_1 – выбор первым игроком на третьем ходе, если игрок 2 выбрал 1;

i_2 – выбор первым игроком на третьем ходе, если игрок 2 выбрал 2.

Выигрыши игрока 1 определяются следующим образом: пусть, например, игрок 1 применяет стратегию (1, 2, 1), а второй свою первую стратегию. Из (1, 2, 1) следует, что $x = 1$; игрок 2 выбирает $y = 1$ и из (1, 2, 1) игрок 1 выбирает $z = 1$. В итоге получим выигрыш $M(1, 2, 1) = -1$. В целом матрица выигрыша игрока 1 (и проигрышей игрока 2) будет иметь вид:

Стратегии игрока 1	Стратегии игрока 2			
	1	2	3	4
1, 1, 1	–2	3	–2	3
1, 1, 2	–2	–4	–2	–4
1, 2, 1	–1	3	–1	3
1, 2, 2	–1	–4	–1	–4
2, 1, 1	5	2	2	5
2, 1, 2	5*	6	6	5*
2, 2, 1	2	2	2	2
2, 2, 2	2	6	6	2

В этой антагонистической игре имеются две седловые точки (отмечены *), которые и определяют стратегии игроков в позиционной игре.

Оптимальная стратегия первого игрока (2, 1, 2) состоит в выборе $x = 2$ на первом ходе и выборе z на третьем ходе, равного числу y, выбранному вторым игроком на втором ходе. При любом выборе цена игры равна 5.

Пример 8.7. Первый ход выполняется случайно: выбираем $x = 1$ с вероятностью 0,5 или $x = 2$ с вероятностью 0,5.

Второй ход делает первый игрок. Зная, какое число x выбрано, он выбирает число y из $\{1, 2\}$.

Третий ход делает игрок 2: не зная x, но зная y, он выбирает число z из $\{1, 2\}$.

После этого игрок 2 платит игроку 1 сумму, равную $M(x, y, z)$. Дерево игры будет иметь следующий вид:

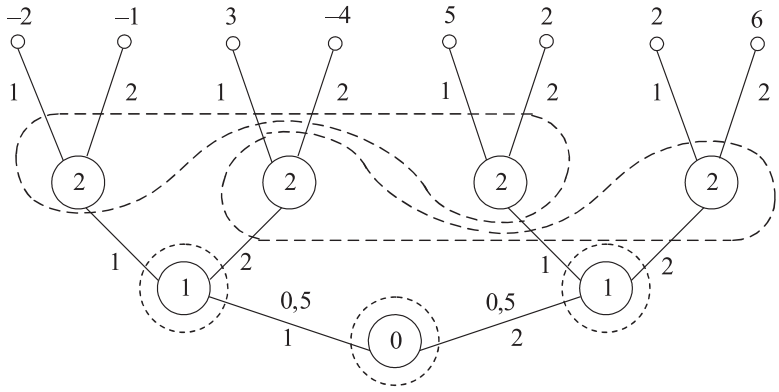

Рис. 8.6

В целях нормализации приведенной игры определим сначала стратегии первого игрока:

1) выбирать $y = 1$ независимо от выбора x;
2) выбирать $y = x$;
3) выбирать $y \neq x$;
4) выбирать $y = 2$ независимо от выбора x.

Стратегии второго игрока:

1) выбирать $z = 1$ независимо от выбора y;
2) выбирать $z = y$;
3) выбирать $z \neq y$;
4) выбирать $z = 2$ независимо от выбора y.

Построим матрицу выигрышей соответствующей антагонистической игры.

Пусть, например, игрок 1 применяет стратегию 3, а игрок 2 – стратегию 2. Надо различать тогда 2 случая: а) $x = 1$; б) $x = 2$. Если $x = 1$, игрок 1 выбирает $y = 2$ и тогда игрок 2 выбирает $z = 2$ и выигрыш $M(1, 2, 2) = -4$.

Если $x = 2$, игрок 1 выбирает $y = 1$, а второй – $z = 1$, и получаем выигрыш $M(2, 1, 1) = 5$.

Поскольку значения x выбираются случайно, то средний выигрыш будет равен $-4 \cdot 0{,}5 + 5 \cdot 0{,}5 = 0{,}5$.

Получим в итоге следующую матрицу выигрышей:

$$\begin{array}{c} \\ 1 \\ 2 \\ 3 \\ 4 \end{array} \begin{array}{c} \begin{array}{cccc} 1 & 2 & 3 & 4 \end{array} \\ \begin{pmatrix} 1{,}5 & 1{,}5 & 0{,}5 & 0{,}5 \\ 0 & 2 & 0{,}5 & 2{,}5 \\ 4 & 0{,}5 & 2{,}5 & -1 \\ 2{,}5 & 1 & 2{,}5 & 1 \end{pmatrix} \end{array}.$$

Эта антагонистическая игра не имеет седловой точки и ее оптимальные смешанные стратегии определят соответствующие вероятности выбора ходов в каждом из информационных множеств при многократном повторении игры.

Приведенные примеры показывают, в частности, что непосредственное перечисление стратегий игроков возможно для небольших по параметрам позиционных игр. Для реальных игр (например, шахмат) число возможных стратегий хоть и конечно, но необозримо велико. Доказано утверждение о том, что все позиционные игры двух игроков с полной информацией и нулевой суммой сводятся к антагонистическим играм, матрицы которых имеют седловые точки. На практике (для тех же шахмат) даже с помощью самых современных компьютеров эту седловую точку (и соответствующие оптимальные стратегии обоих игроков) невозможно найти в реальное время. Именно поэтому компьютерные шахматные программы не перебирают все возможные стратегии игроков, а в известной мере копируют рассуждения человека, играющего в шахматы, пытаясь при этом существенно увеличить «глубину» просмотра возможных вариантов ходов за счет быстродействия компьютера.

8.5. КОАЛИЦИОННЫЕ ИГРЫ

При конфликтной ситуации, в которой участвует более двух игроков, анализ игры может усложниться, если некоторые игроки договариваются о совместных действиях и правилах дележа полученного выигрыша, т. е. образуют коалицию (кооперацию). В таких моделях имеется явный обмен информацией между участниками (игроками).

Можно выделить 3 уровня взаимодействия (сотрудничества):

1) обмен информацией о ходе игры и складывающейся обстановке;

2) совместный выбор стратегии на основе общей договоренности;

3) объединение активных средств (ресурсов) с соответствующей координацией предпринимаемых действий.

Далее, в соответствии с целями настоящего учебного пособия, обсудим только некоторые результаты и подходы к решению коалиционных игр, учитывая лишь первый уровень взаимодействия игроков.

Пусть N – множество всех игроков $\{1, 2, ..., n\}$ и K – любое его непустое подмножество. Игроки из K договариваются о совместном действии и дележе получаемых выигрышей, т. е. образуют одну коалицию.

Число всевозможных коалиций равно $2^n - 1$ (по числу всевозможных непустых подмножеств).

Образовав коалицию, множество игроков K действуют как один игрок против остальных, и выигрыш этой коалиции зависит от применяемых стратегий каждым из n игроков.

Функция υ, ставящая в соответствие каждой коалиции K наибольший получаемый ею выигрыш $\upsilon(K)$, называется *характеристической функцией игры*.

Пусть x_i – выигрыш i-го игрока и $\upsilon(i)$ обозначает выигрыш $\upsilon(\{i\})$.

После реализации игры в коалициях происходит перераспределение выигрышей – *дележ*. Это перераспределение должно удовлетворять следующим условиям:

1) $x_i \geq \upsilon(i)$ для $i \in N$ – условие индивидуальной рациональности;

2) $\sum_{i \in N} x_i = \upsilon(N)$ – условие коллективной рациональности.

Вектор $x = (x_1, ..., x_n)$, удовлетворяющий этим условиям, называется дележом для характеристической функции υ.

Пара (N, υ), определяющая множество игроков, характеристическую функцию игры и дележ, называется *классической коалиционной игрой*.

Из определения дележа следует нижеприведенное утверждение.

Утверждение 8.1. Чтобы вектор $x = (x_1, ..., x_n)$ был дележом в классической коалиционной игре (N, υ), необходимо и достаточно, чтобы для всех $i \in N$:

$$x_i \geq \upsilon(i) + c_i, \text{ где } c_i \geq 0,$$

$$\sum_{i \in N} c_i = \upsilon(N) - \sum_{i \in N} \upsilon(i).$$

Важным фактором, определяющим характер кооперирования, являются так называемые побочные платежи, которыми обеспечиваются конфликтующие стороны при стремлении образовать новую коалицию, присоединиться к уже существующей коалиции, выйти из коалиции. Побочный платеж – это вступительный взнос, налог на кооперацию, штраф за выход, плата за нежелание вступить в коалицию. Побочные платежи становятся частью применяемых стратегий и влияют на исход конфликта.

Сущность коалиционной (кооперативной) игры заключается в поиске коалиций, обеспечивающих своим участникам наибольший дополнительный выигрыш.

Коалиционная игра называется *существенной*, если выполняется неравенство $\upsilon(K) + \upsilon(L) < \upsilon(K \cup L)$ для любых $K, L \subset N$ (общий выигрыш коалиции заведомо больше суммы выигрыша всех участников коалиции).

Коалиционная игра называется *несущественной*, если

$$\upsilon(K) + \upsilon(L) < \upsilon(K \cup L) \text{ для любых } K, L \subset N.$$

Справедливы следующие свойства:

1) для того чтобы коалиционная игра была несущественной, необходимо и достаточно, чтобы

$$\sum_{i \in N} \upsilon(i) = \upsilon(N);$$

2) в несущественной игре имеется только один дележ:

$$x = (\upsilon(1);\ \upsilon(2);\ ...;\ \upsilon(n));$$

3) в существенной игре множество дележей бесконечно и имеет следующий вид

$$\upsilon(1) + \alpha_1;\ \upsilon(2) + \alpha_2;\ ...;\ \upsilon(n) + \alpha_n,$$

где $\alpha_i \geq 0$ для любого $i \in N$, $\upsilon(N) - \sum_{i \in N} \upsilon(i) > 0$.

Коалиционная игра (N, υ) является стратегически эквивалентной игре (N, υ') (и обозначается $(N, \upsilon) \sim (N, \upsilon')$), если найдутся такие $k > 0$ и произвольные вещественные $c_i (i \in N)$, что для любой коалиции $K \cup N$ имеет место равенство

$$\upsilon'(K) = k\upsilon(K) + \sum_{i \in K} c_i. \tag{8.9}$$

Таким образом, в стратегически эквивалентных играх характеристические функции отличаются лишь масштабом k измерений выигрышей и начальными вложениями c_i.

Можно показать рефлективность, симметричность и транзитивность введенного отношения:

1) $(N, \upsilon) \sim (N, \upsilon)$.

Положим в (8.9) $k = 1$ и $c_i = 0$, $(i \in N)$;

2) если $(N, \upsilon) \sim (N, \upsilon')$, то $(N, \upsilon') \sim (N, \upsilon)$. Достаточно разрешить (8.9) относительно $\upsilon(K)$, $\upsilon(K) = \frac{1}{k}\upsilon'(K) - \sum_{i \in K} \frac{c_i}{k}$, и положить $\frac{1}{k} = k'$ и $-\frac{c_i}{k} = c_i'$;

3) если $(N, \upsilon) \sim (N, \upsilon')$ и $(N, \upsilon') \sim (N, \upsilon'')$, то $(N, \upsilon) \sim (N, \upsilon'')$. Применяя последовательно (8.9) к 1-му и ко 2-му отношениям, получим то же условие (8.9) для $k'' = kk'$ и $c_i'' = c_i + kc_i'$.

Из свойств рефлективности, симметричности и транзитивности вытекает, что множество всех характеристических функций существенной коалиционной игры единственным образом разбивается на попарно непересекающиеся классы, которые называются классами стратегической эквивалентности.

В каждом классе стратегической эквивалентности можно выделить одну игру, которая будет представителем этого класса (которую можно называть канонической игрой в данном классе).

Так, например, всякая несущественная коалиционная игра стратегически эквивалентна игре с нулевой характеристической функцией. Действительно, для несущественной игры справедливо

$$\upsilon(N) = \sum_{i \in N} \upsilon(i).$$

Тогда, учитывая (8.9), для любых $K \subset N$ имеем $\upsilon'(K) = k\upsilon(K) + \sum_{i \in K} c_i$. При $k = 1$ и $c_i = -\upsilon_i$ получим $\upsilon'(K) = \upsilon(K) - \sum_{i \in K} \upsilon(i) = 0$.

Игра с характеристической функцией υ имеет (0,1)-редуцированную форму, если выполняются следующие соотношения:

$$\upsilon(i) = 0 \text{ для любых } i \in N;$$

$$\upsilon(N) = 1.$$

Теорема 8.3. Каждая существенная коалиционная игра (N, υ) стратегически эквивалентна одной и только одной игре в (0,1)-редуцированной форме.

Доказательство. Подберем для характеристической функции υ такую стратегически эквивалентную функцию, что:

а) $\upsilon'(i) = k\upsilon(i) + c_i = 0$ для всех $i \in N$;

б) $\upsilon'(N) = k\upsilon(N) + \sum_{i \in N} c_i = 1$.

Из условия а) следует $k\upsilon(i) + c_i = 0$ или $c_i = -k\upsilon(i)$. По условию б) имеем $k\upsilon(N) - k\sum_{i \in N} \upsilon(i) = 1$. Поскольку игра существенная (т. е. $\upsilon(N) > \sum_{i \in N} \upsilon(i)$), то $k = \dfrac{1}{\upsilon(N) - \sum_{i \in N} \upsilon(i)} > 0$ и с учетом а)

$$c_i = -k\upsilon(i) = -\frac{\upsilon(i)}{\upsilon(N) - \sum_{i \in N} \upsilon(i)} \qquad \text{для всех } i \in N.$$

Значения k и c_i – единственные. Поэтому найдена единственная (0,1)-редуцированная игра, и теорема доказана.

Игра называется игрой с постоянной суммой, если для всех коалиций K

$$\upsilon(K) + \upsilon(N \setminus K) = \upsilon(N).$$

В игре в (0,1)-редуцированной форме дележом является любой вектор $x = (x_1, x_2, ..., x_n)$, для которого

$$x_i \geq 0 \text{ для любых } i \in N \text{ и } \sum_{i \in N} x_i = 1.$$

Таким образом, множество дележей $M(\upsilon)$ существенной игры υ в (0, 1)-редуцированной форме, как множество точек n-мерного евклидова пространства, определяет так называемый n-мерный симплекс, т. е. правильный n-вершинный многогранник, вершинами которого служат n векторов (1, 0, 0, …, 0), (0, 1, 0, …, 0), …, (0, 0, 0, …, 1). Множество $M(\upsilon)$ состоит из всех точек на границе и внутри такого симплекса.

Это полезное геометрическое представление используется при анализе коалиционных игр с небольшим количеством игроков.

Рассмотрим примеры построения стратегически эквивалентных классов.

● *Игра двух игроков с нулевой суммой.* Она является несущественной. Предположим, что имеется существенная коалиционная игра двух игроков с характеристической функцией υ. Тогда она должна быть стратегически эквивалентна некоторой игре в (0, 1)-редуцированной форме с характеристической функцией υ, удовлетворяющей

равенствам $\upsilon(1) = 0$; $\upsilon(2) = 0$; $\upsilon(N) = \upsilon(1, 2) = 1$. Но этого не может быть, потому что тогда из-за нулевой суммы выигрышей по свойству дополнительности должно было быть $\upsilon(2) = \upsilon(1, 2) - \upsilon(1) = 1$.

● *Игра трех игроков с нулевой суммой.* Во-первых, имеется класс несущественных игр, эквивалентных игре с нулевой характеристической функцией. Во-вторых, есть единственный класс существенных игр. В самом деле, пусть υ – характеристическая функция существенной игры в (0,1)-редуцированной форме, следовательно:

$$\upsilon(1) = \upsilon(2) = \upsilon(3) = 0; \qquad \upsilon(1, 2, 3) = 1.$$

Тогда по свойству дополнительности из-за нулевой суммы выигрыша:

$$\upsilon(1, 2) = \upsilon(1, 2, 3) - \upsilon(3) = 1;$$

$$\upsilon(1, 3) = \upsilon(1, 2, 3) - \upsilon(2) = 1;$$

$$\upsilon(2, 3) = \upsilon(1, 2, 3) - \upsilon(1) = 1.$$

Таким образом, характеристическая функция полностью определена.

На рис. 8.7 показано пространство дележей такой игры в (0, 1)-редуцированной форме в виде правильного треугольника на плоскости и отмечено 5 возможных точек-дележей:

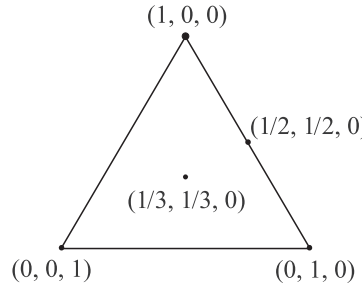

Рис. 8.7

Пусть в коалиционной игре (N, υ) имеется два дележа $x = (x_1, ..., x_n)$ и $y = (y_1, ..., y_n)$, $K \subset N$ – некоторая коалиция. Тогда дележ x доминирует по коалиции K над дележом y $(x \overset{K}{\succ} y)$, если:

1) $\sum_{i \in K} x_i \le \upsilon(K)$;

2) $x_i > y_i$ для любого $i \in K$.

Если $x \overset{K}{\succ} y$ для любой коалиции K, то дележ x эффективно доминирует над дележом y, и пишем $x \succ y$.

Отношения доминирования инвариантны относительно стратегической эквивалентности, поэтому достаточно их изучения для (0, 1)-редуцированной формы. Для отношения эффективного доминирования дележей можно построить (аналогично схемам Хассе из п. 1.4) орграф D эффективного доминирования вершин-дележей.

В отличие от антагонистических игр, где решение сводится к нахождению стратегий, обеспечивающих равновесие, в коалиционных играх стремятся определить коа-

лиции, приводящие к неулучшаемым (в определенном смысле) дележам для каждого участника коалиции. При этом коалиции должны быть устойчивыми, т. е. любое отклонение от соглашения о коалиции должно быть невыгодно отклоняющимся игрокам.

Ниже рассмотрим несколько подходов к решению коалиционных игр. Иллюстрировать такие методы будем на примерах так называемых взвешенных мажоритарных игр. В них каждый игрок i имеет k_i голосов. Коалиция «побеждает», если сумма ее голосов не меньше некоторой части Q от их общего количества. Таким образом, характеристическая функция υ определяется следующим образом:

$$\upsilon(K) = \begin{cases} 1, & \text{если } \sum\limits_{i \in K} k_i \geq Q, \\ 0 & \text{в противном случае.} \end{cases}$$

Взвешенную мажоритарную игру можно описывать строкой $(Q; k_1, k_2, ..., k_n)$, где n – число игроков.

1. *C-ядро*

Множество дележей, над которыми в любых коалициях не доминируют никакие другие дележи, называют ***C-ядром*** этой игры.

Теорема 8.4. Для того чтобы дележ принадлежал ***C-ядру*** коалиционной игры с характеристической функцией υ, необходимо и достаточно, чтобы выполнялось неравенство

$$\upsilon(K) \leq \sum_{i \in K} x_i \quad \text{для всех непустых } K \subset N.$$

Теорема 8.4 утверждает, что дележ входит в ***C-ядро*** тогда и только тогда, когда он удовлетворяет минимальным требованиям каждой коалиции. В игре с пустым ***C***-ядром всегда найдется одна неполностью удовлетворенная коалиция.

C-ядро могло бы считаться решением коалиционной игры. Смысл понятия ядра можно выяснить, анализируя ориентированный граф D эффективного доминирования дележей. Тогда ***C-ядро*** будет состоять из множества вершин-дележей, которые не имеют входящих дуг. Однако для практики такой подход мало пригоден по следующим причинам. Во-первых, орграф D может иметь бесконечное множество вершин, во-вторых, не каждый орграф имеет непустое ядро, и, в-третьих, ядро может состоять из нескольких вершин.

Вообще, одна из задач коалиционных игр состоит в доказательстве утверждений о существовании непустых ядер. Например, доказана следующая теорема.

Теорема 8.5. Всякая существенная игра с постоянной суммой не имеет ядра.

Пример 8.8. Взвешенная мажоритарная игра (2; 1, 1, 1) является существенной игрой с постоянной суммой, и поэтому ее ядро – пустое множество.

Пример 8.9. Рассмотрим следующую игру в (0, 1)-редуцированной форме:

$$\upsilon(\varnothing) = 0;$$

$$\upsilon(1) = \upsilon(2) = \upsilon(3) = 0;$$

$$\upsilon(1, 2) = \frac{1}{2}, \upsilon(1, 3) = 1, \upsilon(2, 3) = 0;$$

$$\upsilon(1, 2, 3) = 1.$$

Тогда ядро этой игры будет состоять из дележей вида $(x_1, 0, x_3)$, причем $\frac{1}{2} \le x_1 \le 1$, $x_1 + x_3 = 1$. На соответствующем правильном треугольнике-симплексе такие дележи будут принадлежать отрезку, выделенному жирно (рис. 8.8).

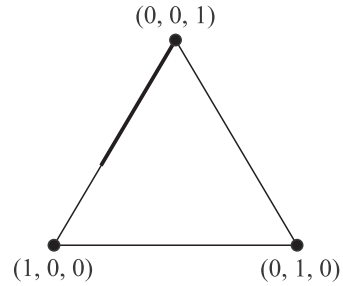

Рис. 8.8

Именно на этом отрезке $x_2 = 0,\ x_1 \ge \frac{1}{2}$.

2. *Устойчивые множества*

Еще в 1944 г. основатели теории игр Дж. фон Нейман и О. Моргенштерн предложили искать решение коалиционных игр среди вершин-дележей, входящих в так называемое устойчивое множество орграфа D эффективного доминирования дележей.

Множество вершин G' в орграфе G внутренне устойчиво, если никакие две вершины из G' не соединены дугами. Множество вершин G'' графа G является внешне устойчивым, если для каждой вершины $x \notin G''$ найдется некоторая вершина $y \in G''$, из которой в x выходит дуга.

Для орграфа D эффективного доминирования дележей в любой паре вершин-дележей, принадлежащих внутренне устойчивому множеству B, ни один из дележей эффективно не доминируется другим. Множество B будет внешне устойчивым, если для каждого $y \notin B$ найдется дележ $x \in B$, который эффективно доминирует дележ y. Внутренне и внешне устойчивое множество дележей называется устойчивым.

Продолжение примера 8.8. Для взвешенной мажоритарной игры (2; 1, 1, 1) устойчивым может быть, например, множество дележей

$$B = \left\{\left(\frac{1}{2}, \frac{1}{2}, 0\right), \left(\frac{1}{2}, 0, \frac{1}{2}\right), \left(0, \frac{1}{2}, \frac{1}{2}\right)\right\}.$$

Можно показать, что это множество внутренне и внешне устойчиво.

Дележи, принадлежащие B, равноправны: любые два игрока могут вступить в коалицию и поровну поделить выигрыш.

На соответствующем треугольнике-симплексе (рис. 8.9) множество B показано как точки – середины сторон.

Как и в случае ***C*-ядра**, подход с использованием устойчивых множеств практически малопригоден. Во-первых, не существует эффективного алгоритма нахождения устойчивых множеств для произвольных орграфов. Во-вторых, в орграфе может быть несколько устойчивых множеств или вообще их не быть. Наконец, устойчивое множество может содержать несколько дележей, среди которых будет необходим выбор.

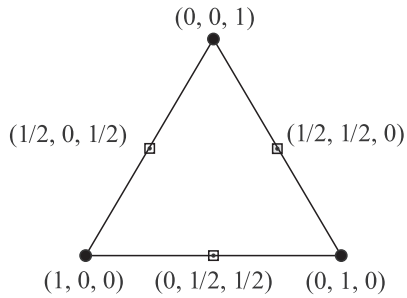

Рис. 8.9

Фактически для конкретных классов коалиционных игр нужны отдельные теоретические изыскания.

3. *Вектор цен Шепли*

Более плодотворным, чем поиск ***C-ядер*** или устойчивых множеств, является аксиоматический подход Л. С. Шепли (1953), отражающий справедливость дележей и приводящий к единственному дележу-решению.

Пусть υ – игра n игроков в форме характеристической функции.

Решением игры будем называть дележ $\varphi[\upsilon] = (\varphi_1[\upsilon], \varphi_2[\upsilon], ..., \varphi_n[\upsilon])$, по-другому – вектор цен Шепли, удовлетворяющий следующим аксиомам.

Аксиома 8.1. Если υ – характеристическая функция на множестве игроков N, π – перестановка элементов множества N такая, что для каждой коалиции $K = \{i_1, i_2, ..., i_n\}$ $\pi K = \{\pi(i_1), \pi(i_2), ..., \pi(i_k)\}$, то для всех $i \in N$

$$\varphi_i[\upsilon(\pi K)] = \varphi_{\pi(i)}[\upsilon].$$

Таким образом, утверждается независимость цены каждого игрока от его номера.

Аксиома 8.2. $\sum_{i=1}^{n} \varphi_i[\upsilon] = \upsilon(N)$.

Следовательно, вектор $\varphi[\upsilon]$ является дележом.

Аксиома 8.3. Если $\upsilon(K\backslash\{i\}) = \upsilon(K)$ для всех $K \subset N$, то $\varphi_i[\upsilon] = 0$. Значит, если игрок i ничего не добавляет к любой коалиции, то его цена равна 0.

Аксиома 8.4. Если υ' и υ'' – характеристические функции на множестве игроков N, то

$$\varphi_i[\upsilon' + \upsilon''] = \varphi_i[\upsilon'] + \varphi_i[\upsilon''] \text{ для всех } i \subset N.$$

Таким образом, если одна игра не влияет на реализацию второй, то выигрыши игроков в отдельных играх должны складываться.

Теорема 8.6 (Шепли). Для всех характеристических функций υ существует единственный дележ $\varphi[\upsilon]$, удовлетворяющий аксиомам 8.1–8.4, с координатами

$$\varphi_i[\upsilon] = \sum_K \left\{\gamma(k)\left[\upsilon(K) - \upsilon(K \setminus \{i\})\right] \text{ для } i \in K\right\},$$

где $k = |K|$ и $\gamma(k) = \dfrac{(k-1)!(n-k)!}{n!}$.

В определенном смысле величину $\varphi_i[\upsilon]$ можно рассматривать как меру «силы» i-го игрока. Особенно ярко это проявляется во взвешенных мажоритарных играх, которые возникают при различных голосованиях. Игрок i имеет k_i голосов. Коалиция

«побеждает», если сумма ее голосов не меньше некоторой доли Q от их общего количества. Тогда величина $\upsilon(K) - \upsilon(K\backslash\{i\})$ всегда равна 0 или 1, причем принимает значение 1 в том и только в том случае, если K – выигрывающая коалиция, а $K\backslash\{i\}$ – проигрывающая. Поэтому получаем, что для всех $i \subset N$

$$\varphi_i[i] = \sum_{K \subset \theta_i} \gamma(k) = \sum_{K \subset \theta_i} \frac{(k-1)!(n-k)!}{n!},$$

где $k = |K|$ и суммирование осуществляется по множеству θ_i всех выигрывающих коалиций K, содержащих i, и таких, что $K\backslash\{i\}$ – невыигрывающая коалиция.

Пример 8.10. Рассмотрим взвешенную мажоритарную игру (51; 40, 30, 20, 10), т. е. 4 игрока (например, акционеры в кооперации) имеют при голосовании соответственно 40, 30, 20, 10 голосов. Решение считается принятым, если за него будет отдано не менее чем 51 голос.

В этой игре множествами выигрывающих коалиций будут:

$\theta_1 = \{\{1, 2\}, \{1, 3\}, \{1, 2, 3\}, \{1, 2, 4\}, \{1, 3, 4\}\}$;

$\theta_2 = \{\{1, 2\}, \{1, 2, 4\}, \{2, 3, 4\}\}$;

$\theta_3 = \{\{1, 3\}, \{1, 3, 4\}, \{2, 3, 4\}\}$;

$\theta_4 = \{\{2, 3, 4\}\}$.

Тогда $\varphi_1[\upsilon] = 5/12$, $\varphi_2[\upsilon] = 1/4$, $\varphi_3[\upsilon] = 1/4$, $\varphi_4[\upsilon] = 1/12$.

В этом примере цены Шепли показывают, что игроки 2 и 3 обладают одинаковой силой, в то время как сила игрока 1 в пять раз превосходит силу игрока 4. Эти соотношения показывают, что сила игрока не обязательно пропорциональна его доле голосов.

8.6. ВОПРОСЫ ДЛЯ САМОПРОВЕРКИ

1. В каких случаях можно говорить об играх с природой?
2. Опишите математическую модель игры с природой.
3. Приведите не менее трех из пяти классических приемов решения игры с природой.
4. Что может быть математической моделью конфликтной ситуации?
5. Опишите математическую модель бескоалиционной игры. Что является решением такой игры?
6. Дать определение ситуации, оптимальной по Парето.
7. Опишите ситуации в бескоалиционной игре, равновесные по Нэшу.
8. Опишите математическую модель антагонистической игры.
9. Какие величины в матричной игре являются гарантированным выигрышем для каждого из игроков?
10. Что называется ситуацией равновесия (по Нэшу) в матричной игре без седловой точки?
11. Приведите один из возможных методов решения любой матричной игры.
12. Опишите графический метод решения матричных игр $2\times n$ (или $m\times 2$).
13. В каких случаях требуется изучать игры в развернутой (позиционной) форме?
14. Как строится дерево позиционной игры? Какие пометки имеют вершины и дуги этого дерева?

15. Опишите свойства информационных множеств в позиционной игре.

16. Дайте определение стратегий каждого игрока в позиционной игре.

17. Что такое «нормализация» позиционной игры?

18. Как можно было бы найти решение позиционной игры двух игроков с нулевой суммой?

19. Опишите коалиционную игру.

20. Дайте определение характеристической функции и дележа в коалиционной игре.

21. Дайте определение существенных и несущественных коалиционных игр и опишите их свойства.

22. Как представляется множество дележей на n-мерном симплексе?

23. Приведите примеры взвешенных мажоритарных игр.

24. Как строится орграф эффективного доминирования дележей?

25. Что такое $\boldsymbol{C}$-ядро коалиционной игры?

26. Как найти $\boldsymbol{C}$-ядро на орграфе эффективного доминирования?

27. Каковы недостатки использования $\boldsymbol{C}$-ядра как метода решения коалиционных игр?

28. Что такое устойчивое множество дележей?

29. В чем заключаются недостатки использования устойчивых множеств как метода решения коалиционных игр?

30. Дайте определение вектора цен Шепли.

31. Как построить вектор цен Шепли во взвешенных мажоритарных играх?

ЛИТЕРАТУРА

Акоф, Р. Л. Основы исследования операций / Р. Л. Акоф, М. В. Сасиени. М., 1971.

Вагнер, Г. Основы исследования операций : в 3 т. / Г. Вагнер. М., 1972–1973. 3 т.

Вентцель, Е. С. Исследование операций / Е. С. Вентцель. М., 1972.

Венцель, Е. С. Исследование операций: задачи, принципы, методология / Е. С. Вентцель. М., 1980.

Гасс, С. Линейное программирование : методы и приложения / С. Гасс. М., 1961.

Гладких, Б. А. Лекции по исследованию операций : принятие решений при неопределенности / Б. А. Гладких. Томск, 1979.

Дегтярев, Ю. И. Исследование операций / Ю. И. Дегтярев. М., 1986.

Зуховицкий, С. И. Математические методы сетевого планирования / С. И. Зуховицкий, И. А. Радчик. М., 1965.

Исаченко, А. Н. Исследование операций в задачах : в 3 ч. /А. Н. Исаченко, Л. Ф. Дробушевич. Минск, 2010–2011. Ч. 1: Математические модели. Теория игр. 2010; Ч. 2. Сетевые задачи. 2011.

Исследование операций : в 2 т. / под ред. Дж. Маудера, С. Эльмаграби. М., 1981. 2 т.

Исследование операций в экономике / под ред. Н. Ш. Крамера. М., 1997.

Краснощеков, П. С. Принципы построения моделей / П. С. Краснощеков, А. А. Петров. М., 1983.

Крушевский, А. В. Теория игр / А. В. Крушевский. Киев, 1977.

Моисеев, Н. Н. Математические задачи системного анализа / Н. Н. Моисеев. М., 1981.

Мулен, Э. Теория игр с примерами из математической экономики / Э. Мулен. М., 1985.

Пападимитру, Х. Комбинаторная оптимизация : алгоритмы и сложность / Х. Пападимитру, К. Стаглиц. М., 1985.

Розен, В. В. Цель – оптимальность – решение / В. В. Розен. М., 1982.

Робертс, Ф. С. Дискретные математические модели с приложениями к социальным, биологическим и экономическим задачам / Ф. С. Робертс. М., 1986.

Танаев, В. С. Введение в теорию расписаний / В. С. Танаев, В. В. Шкурба. М., 1975.

Таха, Х. А. Введение в исследование операций / Х. А. Таха. М., 2007.

Форд, Л. Потоки в сетях / Л. Форд, Д. Фалкерсон. М., 1966.

Badania operacyjne / pod red. E. Ignasiaka. Warszawa, 2007.

СОДЕРЖАНИЕ

ПРЕДИСЛОВИЕ 7

1. ВВЕДЕНИЕ В ИССЛЕДОВАНИЕ ОПЕРАЦИЙ

1.1. Предмет исследования операций 9
1.2. Виды моделей, приемы и принципы моделирования в ИСО 11
1.3. Типовые этапы операционных исследований 13
1.4. Экспертные оценки при принятии решений 19
1.5. Неопределенность целей. Многокритериальные задачи 24
1.6. Вопросы для самопроверки 28

2. ЛИНЕЙНЫЕ МОДЕЛИ

2.1. Условия линейности модели оптимизации 30
2.2. Общая задача линейного программирования 34
2.3. Геометрическая интерпретация задачи линейного программирования с двумя неизвестными 36
2.4. Двойственные задачи линейного программирования 39
2.5. Сущность анализа чувствительности решений в задаче линейного программирования 43
2.6. Оптимизационная модель производства. Анализ на устойчивость 44
2.7. Линейная модель макроэкономики (модель межотраслевого баланса Леонтьева) 47
2.8. Транспортная задача в табличной постановке 50
2.8.1 Математическая модель транспортной задачи 50
2.8.2. Сущность методов решения транспортной задачи 52
2.9. Вопросы для самопроверки 54

3. СЕТЕВЫЕ МОДЕЛИ

3.1. Основные понятия теории графов 55
3.2. Потоки в сетях. Основные понятия 61
3.3. Задача о максимальном потоке. Теорема Форда – Фалкерсона 65
3.4. Некоторые обобщения задачи о максимальном потоке 69
3.5. Теорема Кенига – Эгервари. Построение максимальных паросочетаний 71
3.6. Некоторые варианты задачи о назначениях 75
3.7. Транспортная задача в сетевой постановке 80
3.7.1. Математическая модель сетевой транспортной задачи 80
3.7.2. Метод потенциалов для решения сетевой транспортной задачи 81

3.8. Оптимальные соединения в сетях ... 83
3.8.1. Кратчайшие пути между двумя вершинами ... 83
3.8.2. Минимальные остовные (или покрывающие) деревья ... 88
3.9. Вопросы для самопроверки ... 90

4. ЭЛЕМЕНТЫ СЕТЕВОГО ПЛАНИРОВАНИЯ

4.1. Основные понятия и определения ... 92
4.2. Временные параметры сетевого графика ... 96
4.3. Линейные диаграммы ... 100
4.4. Пример задачи оптимального распределения ограниченного ресурса ... 101
4.5. Вопросы для самопроверки ... 107

5. ЗАДАЧИ ОПТИМАЛЬНОГО УПОРЯДОЧЕНИЯ

5.1. Элементы теории расписаний ... 108
5.1.1. Понятие о задачах теории расписаний ... 108
5.1.2. Задача Беллмана – Джонсона ... 110
5.2. Задача коммивояжера ... 114
5.2.1. Анализ задачи ... 114
5.2.2. Примеры задач теории расписаний, сводящихся к задаче коммивояжера ... 115
5.3. Метод ветвей и границ для решения задач оптимального упорядочения ... 117
5.3.1. Общая схема ... 117
5.3.2. Метод ветвей и границ для задачи о рюкзаке ... 119
5.3.3. Метод ветвей и границ для решения задачи коммивояжера ... 121
5.3.4. Метод ветвей и границ для решения задачи Беллмана – Джонсона ... 124
5.4. Динамическое программирование в задачах комбинаторной оптимизации ... 126
5.4.1. Общий принцип оптимальности ... 126
5.4.2. Задача о кратчайшем пути ... 127
5.4.3. Задача о распределении инвестиций ... 128
5.4.4. Задача коммивояжера ... 129
5.5. Вопросы для самопроверки ... 132

6. ЭЛЕМЕНТЫ ТЕОРИИ МАССОВОГО ОБСЛУЖИВАНИЯ

6.1. Общая характеристика задач массового обслуживания ... 134
6.2. Некоторые частные случаи входного потока и длительностей обслуживания ... 136
6.2.1. Простейший поток ... 136
6.2.2. Показательное распределение длительности обслуживания ... 138
6.2.3. Еще раз о классификации СМО ... 138
6.3. Процессы гибели и размножения ... 139
6.4. Система массового обслуживания с потерями ... 142
6.5. Система массового обслуживания с ожиданием ... 144
6.5.1. Конечная очередь ... 144
6.5.2. Системы с бесконечной длиной очереди ... 146
6.6. Некоторые другие типы систем массового обслуживания ... 148
6.7. Вопросы для самопроверки ... 151

7. НЕКОТОРЫЕ ЗАДАЧИ УПРАВЛЕНИЯ ЗАПАСАМИ

7.1. Структура задач управления запасами ... 152
7.2. Статическая модель с одним плановым периодом ... 153
7.3. Модели выбора размера заказываемой партии ... 155
7.4. Вопросы для самопроверки ... 159

8. ЭЛЕМЕНТЫ ТЕОРИИ ИГР

8.1. Принятие решений при неопределенности, вызванной незнанием (игры с природой) ... 160
8.2. Основные понятия и общие положения теории игр ... 162
8.3. Антагонистические игры ... 165
8.3.1. Предварительный анализ ... 165
8.3.2. Игры с седловой точкой ... 166
8.3.3. Игры со смешанными стратегиями ... 167
8.3.4. Графическое решение антагонистических игр $2\times n$, $m\times 2$ ... 172
8.4. Позиционные игры ... 174
8.5. Коалиционные игры ... 178
8.6. Вопросы для самопроверки ... 186

ЛИТЕРАТУРА ... 188

Учебное издание

Классическое университетское издание

Краснопрошин Виктор Владимирович
Лепешинский Николай Андреевич

ИССЛЕДОВАНИЕ ОПЕРАЦИЙ

Учебное пособие

Редактор *Е. В. Павлова*
Обложка художника *Т. Ю. Таран*
Технический редактор *Т. К. Раманович*
Компьютерная верстка *Л. Л. Матюшонок, Г. И. Василевской*
Корректор *М. А. Подголина*

Подписано в печать 30.04.2013. Формат 70×100/16. Бумага офсетная.
Печать офсетная. Усл. печ. л. 15,48. Уч.-изд. л. 16,50.
Тираж 150 экз. Заказ

Белорусский государственный университет.
ЛИ № 02330/0494425 от 08.04.2009.
Пр. Независимости, 4, 220030, Минск.

Республиканское унитарное предприятие
«Издательский центр Белорусского государственного университета».
ЛП № 02330/0494178 от 03.04.2009.
Ул. Красноармейская, 6, 220030, Минск.